

ANALISIS DAN PERBANDINGAN ALGORITMA SVR, XGBOOST, DAN LIGHTGBM DALAM PREDIKSI CRYPTOCURRENCY ETHEREUM

Ryan Anthony ¹⁾ Jechenthia Maria Taso ²⁾ Stephen Yohanes Christopher ³⁾ Ridhwan Ardiyansyah ⁴⁾

^{1,2,3,4)} Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara Jl. Letjen S. Parman No. 1 Jakarta Barat 11440 Indonesia

email : ¹⁾ryan.535220074@stu.untar.ac.id, ²⁾jechenthia.535220081@stu.untar.ac.id,
³⁾stephen.535220105@stu.untar.ac.id, ⁴⁾ridhwan.535220114@stu.untar.ac.id

ABSTRACT

Penelitian bertujuan untuk menganalisis dan membandingkan kinerja tiga algoritma yaitu SVR dengan kernel linear, XGBoost, dan LightGBM dalam memprediksi harga cryptocurrency Ethereum berdasarkan data historis harian. Penelitian menggunakan dataset harga Ethereum dalam satuan USD selama lima tahun terakhir yang diperoleh dari situs investing.com. Variabel yang digunakan adalah harga Close, Open, High, dan Low. Penelitian menggunakan dua skenario pembagian data yaitu 80% data latih dan 20% data uji serta 70% data latih dan 30% data uji. Penelitian ini juga menggunakan variasi time step untuk menguji pengaruh ketergantungan waktu terhadap kerja algoritma. Hasil penelitian menunjukkan bahwa algoritma LightGBM memiliki kinerja terbaik dibandingkan dua algoritma lainnya dengan nilai rata-rata MAE untuk High price yaitu 75.486, SVR memiliki nilai 115.590, dan XGBoost memiliki nilai 77.314 pada pembagian 80% data latih dan 20% data uji. Pada pembagian 70% data latih dan 30% data uji algoritma LightGBM masih mengungguli dengan nilai rata-rata MAE untuk High price yaitu 78.228, SVR sebesar 104.356, dan XGBoost sebesar 83.573. Evaluasi lainnya seperti RMSE dan R^2 juga menunjukkan keunggulan algoritma LightGBM. Untuk waktu komputasi yang diperlukan algoritma SVR mengungguli dua algoritma lainnya.

Key words

Ethereum, LightGBM, SVR, XGBoost

1. Pendahuluan

Perkembangan teknologi digital terjadi sangat cepat dan masif di seluruh dunia. Perkembangan ini mendorong berkembangnya inovasi teknologi di berbagai sektor kehidupan. Salah satu inovasi yang berkembang pada sektor keuangan yaitu cryptocurrency [1]. Cryptocurrency merupakan inovasi pada sistem perekonomian berbasis digital yang terdesentralisasi [2]. Cryptocurrency dibangun di atas teknologi blockchain

sehingga mendukung penggunaannya untuk melakukan pembayaran secara mudah dan cepat tanpa melibatkan lembaga keuangan [3].

Selama beberapa dekade terakhir cryptocurrency ramai diperbincangkan karena keefisienan dan keamanannya sebagai mata uang virtual [4]. Cryptocurrency dapat digunakan untuk berbagai tujuan seperti melakukan pembelian barang atau jasa, melakukan penambangan (mining), serta dalam investasi [5]. Salah satu cryptocurrency yang cukup populer adalah Ethereum. Ethereum merupakan salah satu dari cryptocurrency yang berkembang dan memiliki komunitas yang kuat selain Bitcoin [6]. Berbeda dengan Bitcoin yang difokuskan sebagai media pertukaran dan penyimpanan nilai, Ethereum mendukung smart contract dan platform terdesentralisasi dalam pengembangan aplikasi berbasis blockchain [3].

Dalam bursa perdagangan cryptocurrency, Ethereum menempati posisi kedua setelah Bitcoin sebagai cryptocurrency dengan kapitalisasi pasar tertinggi. Tercatat pada tahun 2025, dominasi Ethereum menunjukkan kenaikan signifikan hingga melonjak ke angka 14.65%. Angka ini merupakan kenaikan kapitalisasi pasar tertinggi yang terjadi pada tahun 2025 [7]. Hal ini semakin memperkuat posisi Ethereum dalam pasar cryptocurrency global yang membawa fungsi lebih dari sekadar alat tukar tetapi sebagai pelopor lahirnya ekosistem smart contract, aplikasi terdesentralisasi serta DeFi (Decentralized Finance) [8].

Beberapa penelitian terdahulu telah dilakukan dalam melakukan prediksi terhadap harga cryptocurrency. Penelitian menggunakan metode Long Short-Term Memory (LSTM) dengan data historis Ethereum periode Januari 2018 hingga Januari 2022 menghasilkan nilai rata-rata MSE sebesar 0.0121 [9]. Adapun penelitian yang mencoba membandingkan beberapa algoritma seperti Linear Regression, Random Forest, Support Vector Machine (SVM), dan Long Short-Term Memory (LSTM) menggunakan data dari 3 jenis cryptocurrency yang berbeda. Diperoleh hasil terbaik pada algoritma LSTM untuk Litecoin (LTC) dengan nilai MAE 6.32 dan nilai MAE 42.15 pada Ethereum [10]. Selanjutnya penelitian menggunakan metode Vector Autoregressive pada data


Ethereum memperoleh hasil evaluasi RMSE sebesar 978.37 pada harga penutupan [11]. Kemudian studi menggunakan algoritma *Gated Recurrent Unit* (GRU) dan XGBoost untuk *cryptocurrency* Ethereum memperoleh hasil GRU lebih unggul dengan nilai RMSE 101.37 dan R^2 sebesar 0.9718 [12]. Di sisi lain penelitian menggunakan metode *Support Vector Regression* (SVR) dan *Extreme Learning Machine* (ELM) dalam prediksi harga Bitcoin memperoleh hasil bahwa algoritma ELM lebih baik dengan R^2 sebesar 0.987 pada split 80/20 lalu R^2 sebesar 0.989 pada split 60/40 [13].

Berbagai penelitian menunjukkan bahwa tingkat akurasi dalam prediksi harga *cryptocurrency* sangat beragam dan dipengaruhi oleh metode yang digunakan. Oleh karena itu penelitian ini berfokus pada penggunaan algoritma *Support Vector Regression* (SVR), XGBoost, dan LightGBM. Algoritma SVR digunakan karena algoritma ini mampu memodelkan hubungan non-linear antar variabelnya menggunakan fungsi *kernel*. SVR juga tidak memerlukan banyak parameter dibanding dengan algoritma seperti *deep learning* dan bisa memberikan hasil yang stabil dan mudah dipahami. XGBoost dipilih karena algoritma ini dapat mencegah *overfitting* sehingga dapat mempelajari pola harga yang mudah berubah pada pasar *cryptocurrency*. Algoritma LightGBM dipilih karena algoritma ini cepat dan lebih efisien dalam proses pelatihan model khususnya pada data non-linear. Penelitian ini diharapkan mampu memberikan perbandingan dan analisis mendalam untuk melakukan perbandingan performa komputasi dan akurasi yang diperoleh dari setiap algoritma yang digunakan.

Pergerakan harga pasar *cryptocurrency* khususnya Ethereum sangat volatil sehingga memiliki risiko yang lebih tinggi dibanding investasi pada saham [14]. Meski demikian peluang keuntungan yang didapatkan dari *cryptocurrency* berkali-kali lipat jika dibandingkan dengan instrumen investasi lainnya. Fluktuasi harga yang tinggi tersebut disebabkan oleh faktor geopolitik dan sosioekonomi yang terjadi pada seluruh dunia [15]. Dengan mempertimbangkan sifat harga Ethereum yang berisiko tinggi dan sangat volatil, maka diperlukan eksperimen dan analisis menggunakan algoritma *machine learning* dan membandingkan algoritma mana yang paling optimal.

2. Metode Penelitian

Pada penelitian ini metode yang digunakan adalah perbandingan antara *Support Vector Regression* (SVR) dengan *kernel* linear, XGBoost, serta LightGBM yang akan digunakan untuk melakukan prediksi dari harga Ethereum. Data yang digunakan dalam penelitian ini berisi data harga Ethereum dalam Dollar Amerika Serikat (USD) yang diperoleh dari situs investing.com. Berikut ini metodologi penelitian yang digunakan yang bisa dilihat pada **Gambar 1**.



Gambar 1 Flowchart Penelitian

2.1 Dataset


Dataset yang digunakan dalam penelitian ini diperoleh dari situs investing.com, yang menyediakan data historis harga Ethereum selama 5 tahun. Harga Ethereum dinyatakan dalam dollar Amerika Serikat (USD). Data yang digunakan adalah data *time-series* harian dengan variabel seperti *Price (Close)*, *Open*, *High*, *Low*, *Vol*, dan *Change %*. Secara berurutan setiap variabel menjelaskan harga penutupan, harga pembukaan, harga tertinggi dalam satu hari, harga terendah dalam satu hari, volume transaksi perdagangan, dan persentase perubahan harga harian.

2.2 Preprocess

Dataset yang digunakan diunduh dari situs investing.com dalam format .csv, berisi 1.827 baris data historis harian harga Ethereum. Dataset tidak memiliki *missing value*. Periode data yang digunakan adalah data historis harga Ethereum selama 5 tahun (1 Juli 2020 hingga 1 Juli 2025). Variabel *Vol* dan *Change %* dihapus sedangkan variabel lain seperti *Price (Close)*, *Open*, *High*, dan *Low* digunakan untuk melakukan prediksi harga Ethereum. Berikut ini sampel dari dataset yang digunakan yang dapat dilihat pada **Tabel 1**. Untuk persebaran data yang digunakan dapat dilihat pada **Gambar 2**.

Tabel 1 Sampel 5 data pertama dari dataset

Date	Close	Open	High	Low
2020-07-01	230.95	225.61	232.47	224.33
2020-07-02	226.42	230.96	232.04	223.53
2020-07-03	225.12	226.42	228.14	224.77
2020-07-04	229.15	225.09	230.40	224.80
2020-07-05	227.98	229.09	229.80	223.79



Gambar 2 Grafik dari data Close, Open, High, dan Low

2.3 Split Data

Pada penelitian ini digunakan 2 skenario dalam pembagian data. Skenario pertama menggunakan pembagian 70% data latih dan 30% data uji. Skenario kedua menggunakan pembagian 80% data latih dan 20% data uji. Pembagian data tersebut dimaksudkan untuk melakukan analisis terhadap dua skenario pembagian yang telah ditentukan untuk melihat bagaimana performa model bekerja. Pada setiap skenario pembagian data akan menggunakan tujuh variasi *time step* (3,5,7,10,14,21,28). Variasi tersebut digunakan untuk mengatur seberapa banyak hari yang digunakan untuk melakukan prediksi untuk hari berikutnya. Pengujian dengan berbagai nilai *time step* dilakukan untuk menganalisis sejauh mana ketergantungan terhadap data historis dapat memengaruhi performa model dalam melakukan prediksi.

2.4 Support Vector Regression

Support Vector Regression (SVR) adalah algoritma supervised learning yang digunakan dalam memprediksi nilai variabel kontinu [16]. Algoritma ini menggunakan prinsip yang sama dengan *Support Vector Machine* (SVM). Tujuan dari algoritma ini adalah untuk mencari fungsi $f(x)$ yang memiliki nilai error kurang dari nilai ambang ϵ untuk seluruh data pelatihan. SVR dengan kernel linear dirumuskan sebagai berikut [13]:

$$f(x) = \omega^T x + b \quad (1)$$

$$\min \left(\frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \right) \quad (2)$$

Keterangan:

ω = vektor bobot kemiringan fungsi regresi

x = vektor fitur input prediksi

b = intersep fungsi regresi

ξ_i, ξ_i^* = variabel slack pelanggaran margin di atas/bawah batas ϵ

C = parameter regulasi yang mengatur keseimbangan kompleksitas model dan penalti error

2.5 XGBoost

Extreme Gradient Boosting (XGBoost) merupakan algoritma *ensemble learning* berbasis *gradient boosting decision tree*. Konsep utama algoritma ini adalah setiap *tree* mencoba memperbaiki kesalahan prediksi dari *tree* sebelumnya [17]. Hasil akhirnya algoritma ini bekerja dengan menggabungkan beberapa model keputusan sederhana untuk membentuk model yang lebih kuat. Fungsi prediksi XGBoost dirumuskan sebagai berikut [18]:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (3)$$

Keterangan:

$\hat{y}_i$ = hasil prediksi untuk data ke- i

$f_k(x_i)$ = pohon keputusan ke- k

K = jumlah total pohon yang dibangun

x_i = vektor fitur input

2.6 LightGBM

Algoritma *Light Gradient Boosting Machine* (LightGBM) adalah model berbasis *gradient boosting* yang dikembangkan oleh Microsoft pada tahun 2017 [19]. Algoritma ini merupakan pengembangan dari algoritma XGBoost dengan optimisasi pada kecepatan komputasi dan penggunaan memori yang lebih efisien. Kecepatan dan keefisienan tersebut diperoleh karena algoritma ini menggunakan pendekatan *histogram-based algorithm*. Berbeda dengan XGBoost yang membuat *tree* secara *level-wise*, algoritma LightGBM membuat *tree* secara *leaf-wise* (berdasarkan *loss* terbesar) [20]. Algoritma *LightGBM* untuk prediksi dapat dirumuskan sebagai berikut [21]:

$$\hat{y}_i = \sum_{t=1}^T f_t(x_i) \quad (4)$$

Keterangan:

$\hat{y}_i$ = hasil prediksi untuk data ke- i

$f_t(x_i)$ = pohon keputusan ke- t

T = jumlah total pohon yang dibangun

x_i = vektor fitur input

2.7 Evaluasi

Dalam menggunakan algoritma prediksi perlu adanya metrik evaluasi yang digunakan untuk menilai performa dari tiap algoritma yang digunakan. Dalam penelitian ini metrik evaluasi yang digunakan untuk menilai algoritma yang digunakan yaitu *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan Koefisien Determinasi (R^2). MAE menunjukkan rata-rata absolut selisih nilai hasil prediksi dengan nilai aktual. RMSE mengukur akar rata-rata kuadrat selisih nilai prediksi dan nilai aktual. Koefisien Determinasi (R^2) menunjukkan seberapa besar proporsi variansi data aktual dapat dijelaskan oleh model prediksi. Berikut ini persamaan yang digunakan untuk menghitung nilai MAE, RMSE, dan R^2 secara berurutan [22]:

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (5)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \quad (6)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (7)$$

Keterangan:

n = jumlah total data uji

y_i = nilai aktual untuk data ke- i

$\hat{y}_i$ = nilai prediksi untuk data ke- i

$\bar{y}$ = rata-rata dari nilai aktual

3. Hasil dan Pembahasan


3.1 Support Vector Regression (SVR)

Penelitian dilakukan menggunakan algoritma SVR dengan kernel linear, dengan skenario split data 80/20 untuk 7 eksperimen. Algoritma SVR menunjukkan hasil evaluasi yang menjanjikan. Nilai *Mean Absolute Error* (MAE) pada *Close price* sebesar 105.383 USD menunjukkan bahwa rata-rata perbedaan nilai prediksi harga Ethereum dan nilai aktualnya adalah sebesar 105.383 USD. Untuk *Root Mean Squared Error* (RMSE) pada seluruh eksperimen yang dilakukan untuk *Close price* adalah 133.108 USD, nilai ini menunjukkan evaluasi yang bagus dari sisi akurasi. Kemudian untuk rata-rata koefisien determinasinya sebesar 0.947, hal ini menandakan bahwa model yang terbentuk mampu melakukan prediksi yang baik sehingga mendekati nilai aktualnya. Rata-rata waktu komputasi yang diperlukan dalam algoritma SVR dalam membentuk model prediksi juga terbilang sangat cepat yaitu 0.005 detik. Rata-rata hasil evaluasi dengan pembagian 80% data latih dan 20% data uji dapat terlihat pada **Tabel 2**.

Tabel 2 Rerata Evaluasi Algoritma SVR
(80% data latih dan 20% data uji)

Price	MAE	RMSE	R^2	Runtime
Close	105.383	133.108	0.947	0.005
Open	105.832	133.458	0.947	0.004
High	115.590	140.194	0.944	0.003
Low	99.501	134.126	0.944	0.005

Selain dari *Close price*, hasil evaluasi untuk harga lainnya terlihat optimal meskipun pada *High price* model yang terbentuk memiliki nilai MAE terbesar yaitu di angka 115.590 USD dan nilai RMSE terbesar yaitu 140.194 USD. Nilai koefisien determinasi (R^2) untuk *High price* juga salah satu yang terkecil jika dibandingkan dengan *Close Price*. Hal ini menandakan bahwa model paling sulit memprediksi *High price* harian karena fluktuasi dari *High price* yang volatil dan sulit diprediksi dengan pola linear. Tingginya nilai error yang dihasilkan pada *High price* juga bisa disebabkan oleh penggunaan time step = 10, yang dimana nilai MAE, RMSE, dan R^2 berturut-turut adalah 120.144, 145.323, dan 0.94. Meskipun demikian rata-rata waktu komputasi yang diperlukan pada *High Price* adalah yang paling cepat yaitu 0.003 detik. Gambar berikut akan memperlihatkan grafik prediksi dari setiap harga dengan time step = 10.




Gambar 3 Grafik harga *Close*, *Open*, *High*, dan *Low*
(80% data latih, 20% data uji, dan time step =10)

Dengan algoritma yang sama yaitu SVR dengan data latih 70% dan data uji 30% diperoleh hasil evaluasi model menunjukkan peningkatan performa pada *Close*, *Open*, dan *High price* sedangkan pada *Low price* mengalami penurunan. Sebagai contoh pada *Close Price*, model menghasilkan nilai MAE sebesar 98.697 USD menandakan rata-rata perbedaan nilai prediksi dan nilai aktualnya sebesar 98.697 USD. Nilai tersebut menunjukkan peningkatan dibandingkan dengan pengujian pada pembagian data 80/20. Untuk nilai koefisien determinasi (R^2) pada *Close price* juga mengalami peningkatan sebesar 0.005 dibanding sebelumnya. Untuk waktu komputasi yang diperlukan secara keseluruhan tidak ada yang berubah secara signifikan. Berikut tabel rata-rata nilai evaluasi setiap harga:

Tabel 3 Rerata Evaluasi Algoritma SVR
(70% data latih dan 30% data uji)

Price	MAE	RMSE	R^2	Runtime
Close	98.697	130.621	0.952	0.005
Open	98.461	130.371	0.953	0.005
High	104.356	118.1123	0.953	0.002
Low	107.238	141.4513	0.942	0.003

Dapat terlihat pada **Tabel 3** bahwa *High price* mengalami peningkatan yang paling besar dibandingkan harga lainnya, sedangkan pada *Low price* evaluasi model mengalami penurunan. Hal ini bisa terjadi karena pada pembagian data 70/30 model memiliki variasi data yang lebih baik khususnya untuk *High price* sehingga prediksinya lebih baik jika dibandingkan dengan *Low price* yang kemungkinan lebih sensitif terhadap volatilitas harga. Sementara untuk waktu komputasi yang diperlukan untuk masing-masing harga masih sangat cepat karena algoritma SVR memiliki komputasi yang ringan. Berikut ini gambar grafik perbandingan setiap harga pada pembagian data latih 70% dan data uji 30% serta time step = 10.



Gambar 4 Grafik harga *Close*, *Open*, *High*, dan *Low*
(70% data latih, 30% data uji, dan time step =10)

3.2 XGBoost


Penelitian dengan algoritma XGBoost dilakukan tanpa melakukan tuning parameter. Hasil evaluasi yang dihasilkan dengan algoritma XGBoost menunjukkan performa yang sangat baik. Rata-rata nilai MAE yang dihasilkan oleh algoritma ini berada di bawah angka 90 USD. Untuk nilai rata-rata RMSE yang diperoleh juga sudah cukup baik dengan kisaran diantara 102-125 USD. Untuk nilai koefisien determinasinya (R^2) juga sangat memuaskan berkisar antara 0.95 – 0.97 dengan nilai tertinggi dihasilkan oleh *High price* sebesar 0.97, artinya model dengan algoritma XGBoost mampu menjelaskan lebih dari 95% variasi harga Ethereum yang fluktuatif.

Tabel 4 Rerata Evaluasi Algoritma XGBoost
(80% data latih dan 20% data uji)

Price	MAE	RMSE	R^2	Runtime
Close	87.252	117.7463	0.959	0.119
Open	88.686	119.5509	0.958	0.103
High	77.314	102.6709	0.970	0.112
Low	88.381	124.9911	0.951	0.108

Tingginya performa model karena algoritma XGBoost lebih unggul dalam menangkap pola non-linear

pada data harga historis. Waktu komputasi yang diperlukan pada algoritma XGBoost juga tergolong sangat cepat yaitu di kisaran rata-rata 0.103 – 0.119 detik, meskipun kecepatan tersebut masih lebih lambat dibanding algoritma SVR. Nilai terbaik pada evaluasi algoritma XGBoost terjadi pada *time step* = 21 pada *High price* dengan nilai MAE, RMSE, dan R^2 secara berturut – turut adalah 74.638, 99.207, dan 0.972. Hal ini menandakan bahwa model XGBoost mampu menangkap pola historis besar dan kompleks dengan stabil. Grafik perbandingan setiap harga dengan *time step* = 21 akan terlihat pada **Gambar 5**.




Gambar 5 Grafik harga *Close*, *Open*, *High*, dan *Low* (80% data latih, 20% data uji, dan *time step* =21)

Pada skenario pembagian data 70% data latih dan 30% data uji diperoleh hasil model mengalami penurunan. Penurunan performa terjadi secara jelas terlihat untuk nilai error yaitu MAE dan RMSE pada *Close*, *Open*, dan *Low price*. Sementara untuk *High price* penurunan yang terjadi tidak terlalu signifikan. Secara garis besar pembagian data 70/30 menghasilkan performa yang sedikit lebih rendah dibanding 80/20, namun model XGBoost tetap mampu mengenali pola data dengan baik dan tidak bergantung pada banyaknya jumlah data latih yang ditentukan dengan rata-rata koefisien determinasi (R^2) yang masih berada pada kisaran 0.941 – 0.967. Selain itu waktu komputasi yang diperlukan juga relatif stabil pada dua skenario pembagian data yaitu rata-rata 0.1 detik, yang berarti model XGBoost tetap efisien secara

komputasi. Contoh grafik perbandingan setiap harga prediksi dan aktualnya dapat dilihat pada **Gambar 6**.

Tabel 5 Rerata Evaluasi Algoritma XGBoost (70% data latih dan 30% data uji)

Price	MAE	RMSE	R^2	Runtime
Close	98.086	130.8543	0.952	0.103
Open	97.711	130.6773	0.953	0.098
High	83.573	110.2787	0.967	0.097
Low	101.373	141.9163	0.941	0.100



Gambar 6 Grafik harga *Close*, *Open*, *High*, dan *Low* (70% data latih, 30% data uji, dan *time step* =7)

3.3 LightGBM


Penelitian dengan algoritma LightGBM dilakukan tanpa melakukan tuning parameter tertentu untuk menjaga objektivitas perbandingan dengan model lainnya. Pada skenario pembagian data 80% data latih dan 20% data uji, algoritma ini memiliki performa yang paling unggul yang dibandingkan algoritma SVR dan XGBoost. Nilai MAE yang diperoleh berada di bawah 90 USD, lalu untuk nilai RMSE yang dihasilkan oleh model berada di bawah 120 USD. Hal ini berarti algoritma ini mampu melakukan generalisasi dengan sangat baik dan kemampuan dalam mengenali pola kompleks antar variabel juga efisien. Dengan nilai koefisien determinasi

(R^2) berada pada kisaran 0.959 – 0.972, model ini mampu menjelaskan variasi harga Ethereum dengan baik dan menunjukkan kecocokan prediksi yang tinggi terhadap data sebenarnya.

Tabel 6 Rerata Evaluasi Algoritma LightGBM
(80% data latih dan 20% data uji)

Price	MAE	RMSE	R^2	Runtime
Close	85.553	116.306	0.959	0.088
Open	86.966	117.263	0.959	0.055
High	75.486	99.601	0.972	0.054
Low	82.525	114.160	0.959	0.052

Pada **Tabel 6** dapat dilihat bahwa variabel *High price* menunjukkan hasil evaluasi model terbaik jika dibandingkan dengan variabel lainnya. Ini menandakan bahwa model memiliki kemampuan yang kuat dalam mengenali pola pergerakan harga maksimum harian Ethereum. Nilai koefisien determinasi (R^2) yang tertinggi pada angka 0.972 ini menandakan bahwa algoritma LightGBM menjadi algoritma yang cocok untuk digunakan pada prediksi harga Ethereum berdasarkan data historisnya. Selain itu, kinerja komputasi algoritma LightGBM memiliki waktu eksekusi yang berada pada kisaran 0.05 - 0.09 detik, menjadikan algoritma ini cepat sekaligus akurat. Contoh grafik perbandingan harga prediksi dan aktual untuk setiap variabel dapat dilihat pada **Gambar 7**.




Gambar 7 Grafik harga *Close*, *Open*, *High*, dan *Low*
(80% data latih, 20% data uji, dan *time step* =3)

Pada pembagian data 70% data latih dan 30% data uji model mengalami penurunan yang sangat kecil. Nilai error yaitu MAE dan RMSE mengalami kenaikan tipis pada seluruh variabel. Sementara nilai koefisien determinasi (R^2) masih tetap tinggi yaitu diatas 0.95 pada semua variabel. Hal ini menunjukkan bahwa algoritma LightGBM tetap dapat bekerja secara stabil dan konsisten meskipun proporsi data latih berkurang secara signifikan. Selain itu waktu komputasi yang diperlukan juga relatif stabil dan bahkan pada beberapa skenario mengalami penurunan.

Tabel 7 Rerata Evaluasi Algoritma LightGBM
(70% data latih dan 30% data uji)

Price	MAE	RMSE	R^2	Runtime
Close	93.987	125.562	0.956	0.076
Open	92.869	124.381	0.957	0.059
High	78.228	103.487	0.971	0.053
Low	91.438	124.741	0.955	0.053

Terlihat pada **Tabel 7**, variabel *High price* masih menjadi variabel yang paling akurat dan stabil. Nilai MAE meningkat hanya sekitar 2.7 USD dan untuk nilai koefisien determinasinya (R^2) hampir tidak menunjukkan perubahan. Ini menunjukkan bahwa fluktuasi harga tertinggi harian Ethereum masih dapat diprediksi dengan baik oleh model ini bahkan ketika proporsi data latih dikurangi. Berikut in grafik perbandingan harga prediksi dan aktualnya:



Gambar 8 Grafik harga *Close*, *Open*, *High*, dan *Low*
(70% data latih, 30% data uji, dan *time step* =28)

3.4 Perbandingan SVR, XGBoost, dan LightGBM

Pada eksperimen yang telah dilakukan untuk masing-masing algoritma diperoleh hasil evaluasi pada pembagian data 80% data latih dan 20% uji bahwa secara keseluruhan ketiga algoritma yang digunakan menunjukkan kemampuan prediksi yang baik terhadap data harga Ethereum, namun dengan tingkat performa yang berbeda. Algoritma SVR memberikan hasil yang paling rendah dibanding dua algoritma lainnya, namun kecepatan eksekusi algoritma SVR adalah yang tercepat. Di sisi lain algoritma XGBoost memiliki hasil yang lebih baik dibanding algoritma SVR meskipun kecepatan eksekusinya lebih lambat. Secara keseluruhan algoritma LightGBM memiliki hasil yang paling menjanjikan, hal ini dibuktikan dari hasil yang diberikan paling tinggi diantara algoritma lainnya. Untuk performanya algoritma LightGBM memiliki kecepatan eksekusi yang sangat cepat meskipun lebih lambat beberapa milidetik dari SVR, tapi hasil evaluasinya jauh lebih baik. Pada skenario pembagian data 70% data latih dan 30% data uji, masing-masing algoritma menunjukkan penurunan performa, namun algoritma LightGBM masih menunjukkan keunggulannya. Meskipun proporsi data latih dikurangi algoritma LightGBM masih dapat memprediksi harga Ethereum dengan sangat baik.

4. Kesimpulan

Cryptocurrency merupakan instrumen investasi yang beresiko sangat tinggi. Fluktuasi harga *cryptocurrency* khususnya Ethereum bisa disebabkan oleh beberapa faktor seperti faktor sosioekonomi dan geopolitik. Volatilitas harga *cryptocurrency* tersebut membuat penelitian untuk melakukan prediksi harga dengan metode *machine learning* diperlukan. Evaluasi yang dilakukan menggunakan beberapa algoritma dalam penelitian ini dilakukan untuk melihat algoritma mana yang lebih optimal dalam melakukan prediksi harga Ethereum yang fluktuatif. Hasil yang didapat pada penelitian ini bahwa algoritma LightGBM memiliki performa yang paling optimal dibanding dua algoritma lainnya yaitu SVR dan XGBoost. Performa tersebut dinilai berdasarkan dua skenario pembagian data yang berbeda yaitu 80% data latih dan 20% data uji serta 70% data latih dan 30% data uji. Sebagai contoh pada pembagian data 80% data latih dan 20% data uji rata-rata nilai MAE pada variabel *High price* dengan algoritma SVR adalah 115.590, pada algoritma XGBoost nilainya adalah 77.314, sedangkan pada LightGBM nilainya adalah 75.486. Hal ini terjadi juga pada pembagian data 70% data latih dan 30% data uji, LightGBM masih menunjukkan superioritasnya dengan nilai rata-rata MAE untuk SVR, XGBoost, dan LightGBM adalah 104.356, 83.573, dan 78.228. Berdasarkan hasil tersebut diperoleh bahwa algoritma LightGBM bisa dipertimbangkan digunakan untuk prediksi harga Ethereum. Untuk penelitian selanjutnya, saran yang bisa diberikan adalah

melakukan optimisasi parameter khususnya pada algoritma XGBoost dan LightGBM.

REFERENSI

- [1] D. Shin and J. Rice, "Cryptocurrency: A panacea for economic growth and sustainability? A critical review of crypto innovation," *Telemat. Informatics*, vol. 71, p. 101830, Jul. 2022, doi: 10.1016/J.TELE.2022.101830.
- [2] G. De Marzo, F. Pandolfelli, and V. D. P. Servedio, "Modeling innovation in the cryptocurrency ecosystem," *Sci. Rep.*, vol. 12, no. 1, pp. 1–12, Dec. 2022, doi: 10.1038/S41598-022-16924-7; SUBJMETA.
- [3] C. da S. Robusti, A. B. A. Avelar, M. C. Farina, and C. A. Gananca, "Blockchain and smart contracts: transforming digital entrepreneurial finance and venture funding," *J. Small Bus. Enterp. Dev.*, vol. 32, no. 3, pp. 739–761, Aug. 2025, doi: 10.1108/JSBED-12-2023-0584.
- [4] P. R. Cunha, P. Melo, and H. Sebastião, "From bitcoin to central bank digital currencies: Making sense of the digital money revolution," *Futur. Internet*, vol. 13, no. 7, Jul. 2021, doi: 10.3390/FI13070165.
- [5] I. D. Astuti, S. Rajab, and D. Setiyouji, "Cryptocurrency Blockchain Technology in the Digital Revolution Era," *Aptisi Trans. Technopreneursh.*, vol. 4, no. 1, pp. 9–15, Jan. 2022, doi: 10.34306/ATT.V4I1.216.
- [6] A. De Vries, "Cryptocurrencies on the road to sustainability: Ethereum paving the way for Bitcoin," *Patterns*, vol. 4, no. 1, p. 100633, Jan. 2023, doi: 10.1016/j.patter.2022.100633.
- [7] UMAIR, "\$ETH Market Dominance Reaches 14.65%, Highest Point In 2025." Accessed: Oct. 04, 2025. [Online]. Available: <https://blockchainreporter.net/eth-market-dominance-reaches-14-65-highest-point-in-2025>
- [8] B. Sriman and S. G. Kumar, "Decentralized finance (DeFi): The Future of Finance and Defi Application for Ethereum blockchain based Finance Market," *Proc. - IEEE Int. Conf. Adv. Comput. Commun. Appl. Informatics, ACCAI 2022*, 2022, doi: 10.1109/ACCAI53970.2022.9752657.
- [9] T. B. Sianturi, I. Cholissodin, and N. Yudistira, "Penerapan Algoritma Long Short-Term Memory (LSTM) berbasis Multi Fungsi Aktivasi Terbobot dalam Prediksi Harga Ethereum," *J. Pengemb. Teknol. Inf. dan Ilmu Komput.*, vol. 7, no. 3, pp. 1101–1107, Mar. 2023.
- [10] S. A. Khoiri, A. Wahid, and P. Koresponden, "Analisis Kinerja Algoritma Machine Learning dalam Prediksi Harga Cryptocurrency," *JUSTINDO (Jurnal Sist. dan Teknol. Inf. Indones.)*, vol. 9, no. 2, pp. 133–141, Aug. 2024, doi: 10.32528/JUSTINDO.V9I2.1965.
- [11] P. Pradana Ananda Raharja, "Prediksi Harga Ethereum Menggunakan Metode Vector Autoregressive," *J. Informatics Inf. Syst. Softw. Eng. Appl.*, vol. 3, no. 2, pp. 71–79, Jul. 2021, doi: 10.20895/INISTA.V3I2.285.
- [12] M. F. Reza and Ghufro, "IMPLEMENTATION OF THE GATED RECURRENT UNIT (GRU) OR EXTREME GREED BOOSTING (XGBOOST) MODEL FOR ETHEREUM CRYPTOCURRENCY PRICE PREDICTION," *J. Rekayasa Sist. Inf. dan Teknol.*, vol. 3, no. 1, pp. 209–222, Aug. 2025, doi: 10.70248/JRSIT.V3I1.3031.
- [13] F. Ferdinand, R. Anthony, T. J. Winata, J. Sutanto, R. Souwiko, and C. Fernando, "Comparison of Support Vector Regression and Extreme Learning Machine Methods for Predicting Bitcoin Prices," *J. Appl. Informatics Comput.*, vol. 9, no. 5, pp. 2121–2130, Oct.

- 2025, doi: 10.30871/JAIC.V9I5.10983.
- [14] S. Zhang and G. Mani, "Popular cryptoassets (Bitcoin, Ethereum, and Dogecoin), Gold, and their relationships: volatility and correlation modeling," *Data Sci. Manag.*, vol. 4, pp. 30–39, Dec. 2021, doi: 10.1016/J.DSM.2021.11.001.
 - [15] S. Theiri, R. Nekhili, and J. Sultan, "Cryptocurrency liquidity during the Russia–Ukraine war: the case of Bitcoin and Ethereum," *J. Risk Financ.*, vol. 24, no. 1, pp. 59–71, Feb. 2023, doi: 10.1108/JRF-05-2022-0103.
 - [16] I. M. Gananta, I. N. Purnama, and K. Q. Fredlina, "OPTIMASI PREDIKSI HARGA EMAS DENGAN METODE SUPPORT VECTOR REGRESSION (SVR) MENGGUNAKAN ALGORITMA GRID SEARCH," *JATI (Jurnal Mhs. Tek. Inform.)*, vol. 7, no. 6, pp. 3160–3165, Jan. 2023, doi: 10.36040/JATI.V7I6.8000.
 - [17] M. F. Asnawi, H. H. Bisono, M. A. Megantara, and K. Kusri, "Aplikasi Prediksi Banjir Menggunakan Algoritma XGBoost Berbasis Website," *J. Econ. Manag. Account. Technol.*, vol. 7, no. 2, pp. 379–389, Aug. 2024, doi: 10.32500/JEMATECH.V7I2.7644.
 - [18] T. Astutiningsih, D. R. S. Saputro, and Sutanto, "Optimasi Algoritme Xtreme Gradient Boosting (XGBoost) pada Harga Saham PT. United Tractors Tbk.," *SPECTA J. Technol.*, vol. 7, no. 3, pp. 632–641, 2023, doi: 10.35718/specta.v7i3.1031.
 - [19] P. Septiana Rizky, R. Haiban Hirzi, U. Hidayaturrohmah, U. Hamzanwadi Selong Jl TGKH Muhammad Zainuddin Abdul Madjid Pancor, and L. Timur, "Perbandingan Metode LightGBM dan XGBoost dalam Menangani Data dengan Kelas Tidak Seimbang," *J Stat. J. Ilm. Teor. dan Apl. Stat.*, vol. 15, no. 2, pp. 228–236, Dec. 2022, doi: 10.36456/JSTAT.VOL15.NO2.A5548.
 - [20] U. A. Syam, I. Irdyanti, I. Magfirah, B. Sartono, and A. R. Firdawanti, "Evaluasi Kinerja Model Random Forest dan LightGBM untuk Klasifikasi Status Imunisasi Hepatitis B (HB-0) pada Balita," *Euler J. Ilm. Mat. Sains dan Teknol.*, vol. 13, no. 1, pp. 1–8, Apr. 2025, doi: 10.37905/EULER.V13I1.29762.
 - [21] J. P. Immanuel and T. Handhayani, "PREDIKSI HARGA PANGAN JAYAPURA MENGGUNAKAN ELM, LSTM, LIGHTGBM, DAN GB," *J. Ilmu Komput. dan Sist. Inf.*, vol. 13, no. 2, Sep. 2025, doi: 10.24912/JIKSI.V13I2.35122.
 - [22] A. V. Tatachar, "Comparative Assessment of Regression Models Based On Model Evaluation Metrics," *Int. Res. J. Eng. Technol.*, vol. 8, no. 9, pp. 853–860, 2021.