

**ANALISIS KOMPARATIF ALGORITMA *MACHINE LEARNING*
BERBASIS *TREE* DAN VEKTOR UNTUK PREDIKSI INHIBISI
ISOENZIM SITOKROM P450 DENGAN INTERPRETASI SHAP**

TUGAS AKHIR



Disusun Oleh :
PANJI ARIF JAFARUDIN
123220091

**PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
YOGYAKARTA
2026**

**ANALISIS KOMPARATIF ALGORITMA *MACHINE LEARNING*
BERBASIS *TREE* DAN VEKTOR UNTUK PREDIKSI INHIBISI
ISOENZIM SITOKROM P450 DENGAN INTERPRETASI SHAP**

TUGAS AKHIR

Tugas Akhir ini sebagai salah satu syarat untuk memperoleh gelar sarjana Informatika
Universitas Pembangunan Nasional “Veteran” Yogyakarta



Disusun Oleh :
PANJI ARIF JAFARUDIN
123220091

**PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL “VETERAN”
YOGYAKARTA
2026**


HALAMAN PENGESAHAN PEMBIMBING

ANALISIS KOMPARATIF ALGORITMA *MACHINE LEARNING* BERBASIS *TREE* DAN VEKTOR UNTUK PREDIKSI INHIBISI ISOENZIM SITOKROM P450 DENGAN INTERPRETASI SHAP


Disusun Oleh:
Panji Arif Jafarudin
123220091

Telah diuji dan dinyatakan lulus oleh pembimbing
pada tanggal: ...8 Juni 2026.....

Menyetujui,
Pembimbing


Dr. Heru Cahya Rustamaji, S.Si., M.T.
NIDN. 0514067101

Mengetahui,
Koordinator Program Studi


Dessyanto Boedi Prasetyo, S.T., M.T.
NIDN. 0505127501

HALAMAN PENGESAHAN PENGUJI

ANALISIS KOMPARATIF ALGORITMA *MACHINE LEARNING* BERBASIS *TREE* DAN VEKTOR UNTUK PREDIKSI INHIBISI ISOENZIM SITOKROM P450 DENGAN INTERPRETASI SHAP


Disusun Oleh:
Panji Arif Jafarudin
123220091

Telah diuji dan dinyatakan lulus oleh penguji
pada tanggal: 8 Juni 2026

Menyetujui,

Penguji 1

Penguji 2


Dr. Heru Cahya Rustamaji, S.Si., M.T.
NIDN. 0514067101


Bambang Yuwono, S.T., M.T.
NIDN. 0512027401

Penguji 3

Penguji 4


Dhimas Arief Dharmawan, S.T., Ph.D.
NIDN. 0004079305


Andrey Ferriyan, S.T., M.Cs., Ph.D.
NUPTK. 1255761662130193

SURAT PERNYATAAN KARYA ASLI TUGAS AKHIR

Sebagai mahasiswa Program Studi Informatikai Fakultas Teknik Industri Universitas Pembangunan Nasional “Veteran” Yogyakarta, yang bertanda tangan di bawah ini, saya:

Nama : Panji Arif Jafarudin
NIM : 123220091

Menyatakan bahwa karya ilmiah saya yang berjudul:

Analisis Komparatif Algoritma *Machine Learning* Berbasis *Tree* dan Vektor untuk Prediksi Inhibisi Isoenzim Sitokrom P450 dengan Interpretasi SHAP

Merupakan karya asli saya dan belum pernah dipublikasikan dimanapun. Apabila di kemudian hari, karya saya disinyalir bukan merupakan karya asli saya, maka saya bersedia menerima konsekuensi apa pun yang diberikan Program Studi Informatika Fakultas Teknik Industri Universitas Pembangunan Nasional “Veteran” Yogyakarta kepada saya.

Demikian surat pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Yogyakarta
Pada Tanggal : 11 Juni 2026

Yang Menyatakan



Panji Arif Jafarudin
NIM. 123220091

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini:

Nama : Panji Arif Jafarudin
NIM : 123220091
Prodi : Informatika

Dengan ini saya menyatakan bahwa judul Tugas Akhir
**Analisis Komparatif Algoritma *Machine Learning* Berbasis *Tree* dan Vektor untuk
Prediksi Inhibisi Isoenzim Sitokrom P450 dengan Interpretasi SHAP**

adalah hasil kerja saya dan benar bebas dari plagiasi kecuali cuplikan serta ringkasan yang terdapat di dalamnya telah saya jelaskan sumbernya (Sitasi) dengan jelas. Apabila pernyataan ini terbukti tidak benar maka saya bersedia menerima sanksi sesuai peraturan Mendiknas RI No 17 Tahun 2010 dan Peraturan Perundang-undangan yang berlaku.

Demikian surat pernyataan ini saya buat dengan penuh tanggung jawab.

Dibuat di : Yogyakarta
Pada Tanggal : 11 Juni 2026

Yang Menyatakan


Panji Arif Jafarudin
NIM. 123220091

ABSTRAK

Inhibisi enzim Sitokrom P450 (CYP450) pada isoenzim CYP2C9, CYP2D6, dan CYP3A4 merupakan faktor risiko utama terjadinya interaksi obat-obat (*drug-drug interaction*) yang berpotensi memicu toksisitas serius. Pengujian laboratorium konvensional memerlukan biaya tinggi dan waktu yang lama, sehingga pendekatan komputasional berbasis *in silico* menjadi solusi yang mendesak. Namun, pemodelan *machine learning* menghadapi tantangan *class imbalance* pada *dataset* bioaktivitas publik. Selain itu, penggunaan *threshold* standar (0,5) sering menghasilkan nilai sensitivitas yang rendah, yang secara klinis berisiko karena gagal mendeteksi inhibitor berbahaya. Masalah ini diperumit oleh sifat kompleks algoritma *ensemble* dan vektor yang memiliki tingkat transparansi rendah (*black box*), sehingga menyulitkan identifikasi alasan di balik sebuah prediksi medis.

Penelitian ini menerapkan pendekatan kuantitatif dengan desain eksperimental yang bersifat komparatif. Sebanyak 54.364 data bioaktivitas diakuisisi dari database ChEMBL dan PubChem melalui proses *preprocessing* yang ketat, mencakup penghapusan fragmen garam, audit struktur, dan resolusi konflik aktivitas. Representasi molekul dikodekan menggunakan fitur hibrida dari *Morgan fingerprint* dan *MACCS keys* menjadi vektor 2215-bit, dengan penerapan teknik SMOTE untuk menangani ketidakseimbangan data. Sebagai bentuk perlakuan eksperimental, strategi optimasi mencakup pencarian *hyperparameter* melalui *framework* Optuna dan *decision threshold optimization* menggunakan Indeks Youden. Tiga algoritma disandingkan secara komparatif, yaitu *Random Forest*, *Support Vector Machine* (SVM), dan *Extreme Gradient Boosting* (XGBoost), guna menentukan arsitektur terbaik untuk data *sparse* berdimensi tinggi. Hasil penelitian kemudian direalisasikan melalui proses serialisasi model menjadi format biner terkompresi (.pkl) menggunakan pustaka joblib, diikuti dengan validasi fungsionalitas inferensi menggunakan kode Python pada Jupyter Notebook.

Hasil eksperimen menunjukkan keunggulan signifikan algoritma XGBoost dengan nilai *Matthews Correlation Coefficient* (MCC) tertinggi secara konsisten pada angka 0,5387 (CYP2C9), 0,5836 (CYP2D6), dan 0,6540 (CYP3A4). Implementasi Indeks Youden terbukti berhasil meningkatkan sensitivitas deteksi secara dramatis, seperti pada target CYP2C9 yang melonjak dari 0,6139 ke 0,7914, sehingga meminimalkan risiko *false negative* pada prediksi inhibitor. Melalui analisis transparansi model dengan metode SHAP (*SHapley Additive exPlanations*), fitur aromatik (Bit_MacCS_125) teridentifikasi sebagai kontributor utama aktivitas inhibisi. Validasi lokal pada studi kasus Amlodipine mengonfirmasi kemampuan model dalam menangkap fragmen struktural yang relevan secara farmakologi. Penelitian ini memberikan kontribusi pada pengembangan instrumen *virtual screening* yang akurat, sensitif, dan transparan dalam menjamin keamanan metabolisme obat.

Kata Kunci: Sitokrom P450, Interaksi Obat, *Machine Learning*, *Threshold Optimization*, *Explainable AI*

ABSTRACT

Cytochrome P450 (CYP450) enzyme inhibition, specifically in CYP2C9, CYP2D6, and CYP3A4 isoenzymes, is a primary risk factor for Drug-Drug Interactions (DDI) that can trigger serious toxicity. Conventional laboratory testing is costly and time-consuming, making *in silico* computational approaches an urgent necessity. However, Machine Learning modeling faces challenges with class imbalance in public bioactivity datasets. Furthermore, the use of standard decision thresholds (0.5) often results in low sensitivity, which is clinically risky as it fails to detect dangerous inhibitors. This issue is complicated by the inherent complexity of ensemble and vector algorithms, often characterized as "black box" models, which make it difficult to understand the logic behind a prediction, thereby hindering transparency in medical decision support systems.

This study applies a quantitative approach with an experimental and comparative design. A total of 54,364 bioactivity data points were acquired from the ChEMBL and PubChem databases through rigorous preprocessing, including salt stripping, structural auditing, and activity conflict resolution. Molecular representations were encoded using hybrid features of Morgan Fingerprints and MACCS Keys into 2215-bit vectors, with the application of the SMOTE technique to handle data imbalance. As a form of experimental treatment, optimization strategies included hyperparameter search via the Optuna framework and Decision Threshold Optimization using Youden's Index. Three algorithms were compared: Random Forest, Support Vector Machine (SVM), and Extreme Gradient Boosting (XGBoost), to determine the best architecture for high-dimensional sparse data. The research findings were then realized through model serialization into a compressed binary format (.pkl) using the joblib library, followed by inference functionality validation using a Python script within a Jupyter Notebook environment.

Experimental results demonstrate the significant superiority of the XGBoost algorithm, consistently achieving the highest Matthews Correlation Coefficient (MCC) scores at 0.5387 (CYP2C9), 0.5836 (CYP2D6), and 0.6540 (CYP3A4). The implementation of Youden's Index successfully increased detection sensitivity dramatically; for instance, the CYP2C9 target jumped from 0.6139 to 0.7914, thereby minimizing false-negative risks in inhibitor prediction. Through model transparency analysis using the SHAP (Shapley Additive Explanations) method, aromatic features (Bit_MACCS_125) were identified as the primary contributors to inhibitory activity. Local validation on an Amlodipine case study confirmed the model's ability to capture pharmacologically relevant structural fragments. This research contributes to the development of accurate and transparent virtual screening instruments to ensure drug metabolic safety.

Keywords: Cytochrome P450, Drug Interactions, Machine Learning, Threshold Optimization, Explainable AI

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas segala rahmat, hidayah, dan karunia-Nya, sehingga penulis dapat menyelesaikan skripsi yang berjudul "**Analisis Komparatif Algoritma *Machine Learning* Berbasis *Tree* dan Vektor untuk Prediksi Inhibisi Isoenzim Sitokrom P450 dengan Interpretasi SHAP**". Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Informatika, Universitas Pembangunan Nasional "Veteran" Yogyakarta.

Dalam penyusunan karya ilmiah ini, penulis banyak mendapatkan bantuan, bimbingan, serta motivasi dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan terima kasih yang sebesar-besarnya kepada:

1. Bapak Dr. Heru Cahya R., S.Si., M.T., selaku Dosen Pembimbing yang telah memberikan arahan, ilmu, serta waktu dan kesabarannya yang luar biasa dalam membimbing penulis sehingga penelitian ini dapat terselesaikan dengan baik.
2. Bapak Bambang Yuwono, S.T., M.T., Bapak Dhimas Arief Dharmawan, S.T., Ph.D, dan Bapak Andrey Ferriyan, S.T., M.Cs., Ph.D, selaku Dosen Penguji yang telah memberikan kritik, saran, dan masukan konstruktif demi kesempurnaan naskah skripsi ini.
3. Ibu Wilis Kaswidjanti, S.Si., MKom., selaku Dosen Wali yang telah membimbing penulis selama masa perkuliahan, serta seluruh Bapak dan Ibu Dosen Program Studi Informatika yang telah membekali penulis dengan ilmu pengetahuan yang bermanfaat.
4. Teristimewa kepada kedua orang tua tercinta, Bapak Heri Priyatno dan Ibu Ratna Dian Maharani, serta adik-adik tersayang, yang senantiasa memberikan doa tulus, dukungan material, serta kasih sayang yang tidak terhingga sebagai motivasi terbesar penulis dalam setiap langkah.
5. Tarisa Puspita Sari, terima kasih atas segala dukungan emosional, kesabaran, dan semangat yang selalu diberikan sebagai pendamping setia yang menemani penulis di masa-masa sulit pengerjaan tugas akhir ini.
6. Mbak Tari, Pak Sugeng, rekan-rekan Asisten dan Admin di lingkungan Laboratorium Jurusan Informatika yang telah banyak berbagi ilmu akademis yang sangat bermanfaat di dalam maupun di luar perkuliahan.
7. Rekan-rekan seperjuangan, Wijdan, Kanang, Andre, Rafiq, Rayan, Albarry, Arya, Fikri, Ferbrian, dan teman-teman lainnya yang tidak dapat disebutkan satu per satu, terima kasih atas setiap diskusi cerdas, bantuan teknis, serta tawa yang membuat perjalanan ini menjadi lebih bermakna.
8. Anggota Kelompok KKN AD.83.280 dan Tim Magang UPN di Balai Pelaksana Penyediaan Perumahan dan Kawasan Pemukiman Jawa III yang memberikan berbagai pengalaman berharga untuk penulis selama masa KKN dan Magang.
9. Teman-teman angkatan 2022, kakak tingkat, serta adik tingkat Informatika, yang telah menjadi bagian dari keluarga besar yang saling mendukung selama masa perkuliahan.
10. Teman-teman PKS SMKN2YK, Berkah Dalem Farm, grup Kacaw dan KF yang menjadi tempat tertawa dan berkeluh kesah penulis selama ini.

Penulis menyadari bahwa skripsi ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan. Akhir kata, semoga skripsi ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang informatika medis.

Yogyakarta, 4 Juni 2026

Penulis

DAFTAR ISI

HALAMAN PENGESAHAN PEMBIMBING	ii
HALAMAN PENGESAHAN PENGUJI	iii
SURAT PERNYATAAN KARYA ASLI TUGAS AKHIR	iv
PERNYATAAN BEBAS PLAGIASI	v
ABSTRAK	vi
<i>ABSTRACT</i>	vii
KATA PENGANTAR	viii
DAFTAR ISI	x
DAFTAR TABEL	xiii
DAFTAR GAMBAR	xiv
DAFTAR LAMPIRAN	xv
BAB I PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	2
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Tahapan Penelitian	4
1.7 Sistematika Penulisan	5
BAB II TINJAUAN LITERATUR	6
2.1 Penyakit Kardiovaskular dan Polifarmasi	6
2.2 Enzim Sitokrom P450 (CYP450)	6
2.3 Kriteria Aktivitas Biologis dan Pelabelan Data	8
2.4 Kemoinformatika dan Representasi Molekul	9
2.5 Algoritma Machine Learning	11
2.5.1 <i>Random Forest</i>	11
2.5.2 <i>Extreme Gradient Boosting</i> (XGBoost)	12
2.5.3 <i>Support Vector Machine</i> (SVM)	13
2.6 Teknik Penyeimbangan dan Optimasi Model	14
2.7 Metrik Evaluasi Performa	17
2.8 Interpretasi Model dengan SHAP	18
2.8.1 Konsep Dasar Shapley Value	18
2.8.2 Teknik Visualisasi dan Analisis SHAP	19
2.9 Penelitian Terdahulu	20

BAB III METODOLOGI PENELITIAN	23
3.1 <i>Business Understanding</i>	24
3.2 <i>Data Understanding</i>	25
3.2.1 Sumber Data	25
3.2.2 Karakteristik Atribut <i>Dataset</i>	25
3.2.3 Audit Kualitas dan Penyusutan Data	26
3.2.4 Distribusi Kelas dan Analisis Ketidakseimbangan.....	27
3.3 <i>Data Preparation</i>	27
3.3.1 <i>Data Cleaning & Labeling</i>	28
3.3.2 Integrasi dan Deduplikasi Data	28
3.3.3 Ekstraksi Fitur	29
3.3.4 <i>Data Splitting</i>	30
3.3.5 Ilustrasi Penelusuran Data	30
3.4 <i>Modeling</i>	31
3.4.1 Representasi dan Dimensi Fitur.....	31
3.4.2 Algoritma <i>Random Forest</i>	31
3.4.3 Algoritma <i>Extreme Gradient Boosting</i> (XGBoost)	31
3.4.4 Algoritma <i>Support Vector Machine</i> (SVM).....	32
3.4.5 Strategi Penanganan Ketidakseimbangan Data	32
3.4.6 <i>Stratified K-Fold Cross Validation</i>	33
3.4.7 Implementasi <i>Pipeline</i> SMOTE, dan <i>Cross Validation</i>	33
3.4.8 Optimasi <i>Hyperparameter</i> dengan Optuna.....	34
3.5 <i>Evaluation</i>	35
3.5.1 Skenario Pengujian.....	35
3.5.2 Metrik Kinerja Model.....	36
3.5.3 <i>Decision Threshold Optimization</i>	36
3.6 <i>Interpretation</i> (SHAP Analysis)	37
3.6.1 Pendekatan <i>TreeExplainer</i> untuk Interpretasi Global.....	37
3.6.2 Mekanisme Pemetaan Fitur dan Visualisasi Substruktural.....	37
3.6.3 Validasi Relevansi Biologis.....	37
3.7 <i>Deployment</i>	38

BAB IV HASIL PENGUJIAN DAN PEMBAHASAN	39
4.1 Implementasi.....	39
4.1.1 Deskripsi Alat dan Lingkungan Eksekusi.....	39
4.1.2 Tahapan Implementasi.....	40
4.2 Hasil	46
4.2.1 <i>Data Preparation</i>	47
4.2.2 <i>Modeling</i>	48
4.2.3 <i>Evaluation</i>	50
4.2.4 <i>Interpretation</i>	54
4.2.5 <i>Deployment</i>	60
4.3 Pembahasan.....	61
4.3.1 Analisis Komparatif Algoritma dalam Ruang Fitur Dimensi Tinggi	61
4.3.2 Efektivitas <i>Decision Threshold Optimization</i>	62
4.3.3 Analisis Transparansi Logika Model Melalui Global SHAP	63
4.3.4 Analisis Kesalahan dan Batasan Domain Aplikasi.....	64
BAB V PENUTUP	65
5.1 Kesimpulan	65
5.2 Saran	65
DAFTAR PUSTAKA	67
LAMPIRAN	69

DAFTAR TABEL

Tabel 2.1 <i>State of the art</i>	21
Tabel 2.2 <i>State of the art</i> (lanjutan)	22
Tabel 3.1 Pernetaan atribut <i>dataset</i> integrasi.....	26
Tabel 3.2 Laporan penyusutan data	26
Tabel 3.3 Distribusi kelas final per target isoenzim	27
Tabel 3.4 Contoh penelusuran transformasi data pada molekul Levo Propranolol.....	30
Tabel 3.5 Alur <i>input-process-output</i> (IPO) <i>Random Forest</i>	31
Tabel 3.6 Alur <i>input-process-output</i> (IPO) <i>XGBoost</i>	32
Tabel 3.7 Alur <i>input-process-output</i> (IPO) <i>Support Vector Machine</i>	32
Tabel 3.8 Ruang pencarian <i>hyperparameter</i> dalam proses optimasi.....	35
Tabel 3.9 Skenario dan alur kerja pengujian model	35
Tabel 3.10 Prosedur teknik interpretasi SHAP	38
Tabel 4.1 Deskripsi perangkat keras.....	39
Tabel 4.2 Deskripsi pustaka utama	40
Tabel 4.3 Ringkasan hasil akuisisi data mentah (<i>raw data</i>)	47
Tabel 4.4 Komposisi <i>dataset</i> final	48
Tabel 4.5 Durasi eksekusi optimasi <i>hyperparameter</i> (50 trials)	49
Tabel 4.6 Ringkasan skor AUC validasi terbaik hasil optimasi Optuna.....	50
Tabel 4.7 Perbandingan performa algoritma pada data uji (sebelum optimasi ambang batas)	51
Tabel 4.8 Perbandingan performa algoritma pada data uji (setelah optimasi ambang batas)	51
Tabel 4.9 Contoh senyawa dengan kesalahan prediksi (<i>false negative</i>).....	54
Tabel 4.10 Ringkasan fitur teratas setiap target.....	54

DAFTAR GAMBAR

Gambar 2.1 Peran enzim sitokrom P450 (CYPs) dalam alur metabolisme obat fase I dan jalur detoksifikasi tubuh	7
Gambar 2.2 Struktur molekuler isoenzim CYP3A4 (PDB: 1TQN) dengan identifikasi sisi katalitik dan gugus heme	7
Gambar 2.3 Mekanisme pembentukan <i>molecular fingerprint</i> melalui metode MACCS (A) dan strategi ECFP/Morgan (B).....	10
Gambar 2.4 Arsitektur <i>random forest</i> dengan mekanisme <i>bagging</i> dan <i>majority voting</i>	11
Gambar 2.5 Mekanisme <i>sequential learning</i> dan reduksi residu pada <i>XGBoost</i>	12
Gambar 2.6 Prinsip pemisahan <i>hyperplane</i> dan maksimalisasi margin pada SVM.....	13
Gambar 2.7 Transformasi data non-linear ke dalam ruang fitur 3D menggunakan <i>kernel trick</i>	14
Gambar 2.8 Perbandingan mekanisme <i>random over-sampling</i> dan SMOTE dalam penanganan <i>imbalanced data</i>	15
Gambar 2.9 Diagram alur proses optimasi <i>hyperparameter</i> menggunakan Optuna.....	16
Gambar 3.1 Alur metodologi penelitian	23
Gambar 3.2 <i>Flowchart data preparation</i>	27
Gambar 3.3 <i>Flowchart</i> ekstraksi fitur.....	29
Gambar 3.4 <i>Flowchart pipeline</i> pemodelan dengan integrasi SMOTE dan <i>cross validation</i>	34
Gambar 4.1 Distribusi kelas inhibitor vs non-inhibitor setelah integrasi.....	48
Gambar 4.2 Riwayat optimasi AUC (representasi XGBoost pada CYP3A4)	49
Gambar 4.3 Kurva ROC komparatif target CYP2C9	52
Gambar 4.4 Kurva ROC komparatif target CYP2D6.....	52
Gambar 4.5 Kurva ROC komparatif target CYP3A4.....	53
Gambar 4.6 Plot SHAP <i>beeswarm</i> target CYP2C9	55
Gambar 4.7 Plot SHAP <i>beeswarm</i> target CYP2D6.....	56
Gambar 4.8 Plot SHAP <i>beeswarm</i> target CYP3A4	57
Gambar 4.9 Struktur 2D senyawa amlodipine.....	58
Gambar 4.10 Pemetaan fitur dominan (top SHAP) pada struktur amlodipine.....	59
Gambar 4.11 Tampilan keluaran kode prediksi senyawa Amlodipine pada Jupyter Notebook	60

DAFTAR LAMPIRAN

Lampiran A. Tabel Penjelasan MACCS <i>Keys</i> (Sumber: www.mayachemtools.org)	69
Lampiran B. Riwayat Optimasi Optuna	73
Lampiran C. Grafik <i>Beeswarm Plot</i> Hasil SHAP.....	76

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Penyakit kardiovaskular merupakan penyebab utama kematian di Indonesia yang memberikan beban ekonomi signifikan, dengan biaya pelayanan kesehatan katastrofik mencapai Rp8,2 triliun per tahun (Handayani, 2025). Berdasarkan data Riset Kesehatan Dasar, prevalensi penyakit jantung koroner sebagai salah satu subtype penyakit kardiovaskular utama di Indonesia mencapai 1,5% atau diperkirakan menyerang 883.447 jiwa, dengan prevalensi di wilayah Kalimantan Timur mencapai 1,9% (Saputri & Dewi, 2023). Kompleksitas klinis pasien sering kali disertai berbagai penyakit penyerta yang mengharuskan manajemen polifarmasi, dengan rata-rata konsumsi mencapai 10,21 jenis obat per pasien (Akbar *et al.*, 2021). Hal ini secara drastis meningkatkan risiko interaksi obat, bahkan, dalam sebuah studi observasional mencatat hingga 100% pasien kardiovaskular mengalami potensi interaksi obat (Akbar *et al.*, 2021). Dampak dari interaksi ini sangat serius, dimana data farmakovigilans global menempatkan obat-obatan kardiovaskular sebagai salah satu penyebab tersering kematian akibat reaksi obat yang tidak diinginkan (Montastruc *et al.*, 2021). Oleh karena itu, pengembangan metode yang akurat untuk memprediksi dan mencegah interaksi obat menjadi prioritas mendesak demi meningkatkan keselamatan pasien dan efektivitas terapi.

Secara mekanisme biologis, mayoritas interaksi obat yang berbahaya terjadi akibat gangguan pada proses biotransformasi di hati, terutama pada reaksi fase I yang dikatalisis oleh superfamili enzim Sitokrom P450 (CYP450) (Zhao *et al.*, 2021). Enzim ini memegang peranan vital dalam farmakologi karena bertanggung jawab atas metabolisme oksidatif sekitar 80% obat klinis yang digunakan saat ini, dengan kontribusi terbesar berasal dari famili CYP1, CYP2, dan CYP3 (Zhao *et al.*, 2021). Di antara 57 gen CYP fungsional pada manusia, delapan isoenzim utama termasuk CYP2C9, CYP2D6, dan CYP3A4 merupakan varian yang paling signifikan secara klinis karena memetabolisme mayoritas obat-obatan (Guengerich, 2022; Zhou & Lauschke, 2022). Namun, aktivitas enzim ini sangat rentan terhadap inhibisi oleh obat lain (*perpetrator*), baik melalui mekanisme kompetitif maupun ireversibel. Inhibisi tersebut mengakibatkan terhambatnya metabolisme obat substrat (*victim*), yang memicu lonjakan kadar obat dalam plasma hingga mencapai level toksik. Kondisi inilah yang menjadi pemicu utama terjadinya efek samping fatal pada pasien (Guengerich, 2022).

Meningkatnya kompleksitas risiko tersebut membuat evaluasi menggunakan metode konvensional *in vitro* sering kali terkendala oleh tingginya biaya dan waktu yang lama (N.-N. Wang *et al.*, 2022). Sebagai solusi, pendekatan *in silico* berbasis *Machine Learning* (ML) berkembang pesat sebagai alternatif yang efisien pada tahap awal (Litsa *et al.*, 2021). Studi referensi oleh Zahid *et al.* (2024) telah menerapkan algoritma *Support Vector Machine* (SVM) untuk prediksi inhibisi CYP450, namun melaporkan bahwa algoritma berbasis pohon seperti *Random Forest* memberikan hasil yang kurang memuaskan pada *dataset* mereka. Di sisi lain, algoritma *boosting* modern seperti XGBoost telah terbukti unggul dalam berbagai domain data tabular, namun perbandingannya secara *head-to-head* dengan SVM dan

Random Forest dalam konteks keamanan obat kardiovaskular masih terbatas. Selain itu, ketergantungan pada nilai *threshold* standar 0,5 sering kali kurang sensitif dalam mendeteksi potensi inhibisi pada kelas minoritas. Padahal dalam konteks metabolisme obat, kegagalan mendeteksi satu saja senyawa inhibitor dapat berisiko buruk pada homeostasis metabolisme pasien. Sifat *black box* dari model *Machine Learning* juga sering kali menjadi hambatan bagi peneliti farmasi untuk memahami alasan ilmiah di balik sebuah keputusan prediksi.

Berdasarkan permasalahan tersebut, penelitian ini melakukan analisis komparatif algoritma *Machine Learning* berbasis *tree* (*Random Forest* dan *XGBoost*) serta berbasis vektor (SVM) untuk memprediksi potensi inhibisi isoenzim CYP2C9, CYP2D6, dan CYP3A4. Penelitian ini mengintegrasikan teknik *Bayesian Optimization* melalui Optuna untuk pencarian parameter optimal dan SMOTE untuk menangani ketidakseimbangan data. Fokus utama dalam penelitian ini terletak pada penerapan optimasi *decision threshold* menggunakan Indeks Youden untuk meningkatkan sensitivitas deteksi terhadap potensi bahaya interaksi obat, serta penggunaan SHAP (*SHapley Additive exPlanations*) untuk memberikan transparansi terhadap kontribusi gugus fungsi kimia yang bertanggung jawab atas aktivitas inhibisi. Melalui evaluasi model pada domain senyawa kardiovaskular, penelitian ini diharapkan dapat menghasilkan model prediktif teroptimasi yang tidak hanya mengedepankan performa statistik, tetapi juga mempertimbangkan aspek keamanan metabolisme guna memberikan informasi awal dalam memitigasi risiko interaksi obat pada penderita penyakit jantung dan pembuluh darah.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan utama penelitian ini berkaitan dengan strategi optimasi dan analisis komparatif metode komputasi guna menyeimbangkan performa prediksi dengan aspek keamanan metabolisme dan transparansi interpretasi fitur. Oleh karena itu, rumusan masalah penelitian ini adalah:

1. Belum diketahuinya efektivitas komparatif antara algoritma berbasis *tree* (*Random Forest* dan *XGBoost*) serta vektor (SVM) dalam menangani data bioaktivitas ligan Sitokrom P450 yang memiliki karakteristik ketidakseimbangan kelas (*class imbalance*).
2. Adanya potensi risiko pengabaian keamanan metabolisme akibat rendahnya sensitivitas deteksi inhibitor pada penggunaan *threshold* standar, sehingga diperlukan strategi optimasi melalui pengaturan *hyperparameter* menggunakan Optuna dan optimasi *decision threshold* menggunakan Indeks Youden.
3. Adanya keterbatasan transparansi klinis akibat sifat *black box* pada algoritma *ensemble* dan vektor yang menyebabkan sulitnya mengidentifikasi kontribusi fitur molekuler (*hybrid fingerprint*) terhadap keputusan prediksi model tanpa bantuan metode interpretasi seperti SHAP.

1.3 Batasan Masalah

Agar penelitian ini lebih terarah dan fokus pada tujuan yang ingin dicapai, penulis menetapkan batasan-batasan masalah sebagai berikut:

1. Objek Penelitian adalah enzim target yang dibatasi pada tiga isoenzim utama Sitokrom P450, yaitu CYP2C9, CYP2D6, dan CYP3A4, yang memiliki kontribusi terbesar dalam metabolisme obat klinis terutama pada obat kardiovaskular.
2. *Dataset* yang digunakan merupakan integrasi data bioaktivitas senyawa dari dua basis data publik berskala besar, yaitu ChEMBL dan PubChem (AID 883, 891, dan 884). Fokus validasi hasil dikhususkan pada senyawa obat golongan kardiovaskular.
3. Fitur yang digunakan adalah representasi struktur kimia obat menggunakan format SMILES yang dikonversi menjadi *hybrid molecular fingerprint*, yang terdiri dari gabungan *Morgan fingerprint* (radius 2, 2048 bit) dan *MACCS keys* (167 bit).
4. Algoritma yang dibandingkan mencakup *Random Forest*, *XGBoost*, dan *Support Vector Machine* (SVM).
5. Fokus utama penelitian mencakup penanganan data tidak seimbang menggunakan SMOTE, optimasi *hyperparameter* menggunakan *Bayesian Optimization* melalui Optuna, dan optimasi *decision threshold* menggunakan Indeks Youden untuk meningkatkan metrik Sensitivitas deteksi.
6. Analisis transparansi keputusan model dilakukan menggunakan metode SHAP (*SHapley Additive exPlanations*) untuk mengidentifikasi kontribusi fitur molekuler terhadap hasil prediksi.
7. Luaran penelitian ini berupa file biner hasil *model serialization* teroptimasi beserta kode inferensi pada Jupyter Notebook.
8. Penelitian ini merupakan studi *in silico* (komputasi) yang ditujukan sebagai referensi akademis atau riset dan tidak mencakup pengujian laboratorium *in vitro* maupun *in vivo*.

1.4 Tujuan Penelitian

Tujuan penelitian ini dirumuskan untuk menjawab pertanyaan masalah di atas, yaitu:

1. Menganalisis efektivitas komparatif antara algoritma berbasis *tree* (*Random Forest* dan *XGBoost*) serta berbasis vektor (SVM) dalam mengklasifikasikan data bioaktivitas ligan yang mengalami *class imbalance*.
2. Menerapkan strategi optimasi melalui pengaturan *hyperparameter* menggunakan Optuna dan optimasi *decision threshold* menggunakan Indeks Youden untuk meningkatkan Sensitivitas model dalam memitigasi risiko keamanan metabolisme.
3. Mengidentifikasi kontribusi fitur molekuler (*hybrid fingerprint*) yang bertanggung jawab atas aktivitas inhibisi menggunakan metode SHAP guna memberikan interpretasi pada model yang bersifat *black box*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat membantu memprediksi risiko inhibisi isoenzim Sitokrom P450 pada senyawa obat kardiovaskular guna memitigasi potensi interaksi obat yang berbahaya, serta mendukung optimalisasi alur skrining awal berbasis komputasi.

1. Bagi Peneliti dan Akademisi

Memberikan referensi mengenai performa algoritma berbasis *tree* dan vektor dalam menangani data bioaktivitas farmasi yang tidak seimbang.

2. Bagi Praktisi Kesehatan dan Farmasi
Menyediakan informasi mengenai fragmen kimia penting yang berkontribusi pada inhibisi enzim melalui analisis SHAP sebagai bahan pertimbangan dalam analisis interaksi obat.
3. Bagi Pengembangan Ilmu Komputasi
Menunjukkan implementasi optimasi *decision threshold* menggunakan Indeks Youden sebagai pendekatan untuk meningkatkan keandalan model *machine learning* pada domain yang sensitif terhadap risiko keamanan medis.

1.6 Tahapan Penelitian

Penelitian ini dilakukan melalui serangkaian tahapan sistematis yang mengadopsi kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*) yang telah disesuaikan dengan domain bioinformatika:

1. Fase *Business Understanding*
Memahami urgensi klinis interaksi obat pada terapi kardiovaskular serta mekanisme biokimia inhibisi isoenzim Sitokrom P450 sebagai penyebab utama kegagalan metabolisme obat.
2. Fase *Data Understanding & Preparation*
Mengumpulkan dan mengintegrasikan *dataset* bioaktivitas dari dua pangkalan data utama, yaitu ChEMBL dan PubChem. Tahap ini mencakup kurasi data tingkat lanjut, penanganan data ganda melalui *deduplication* antar-sumber, pembersihan *missing values*, serta transformasi struktur kimia SMILES menjadi *hybrid molecular fingerprint* melalui teknik ekstraksi fitur numerik.
3. Fase *Modeling*
Membangun model komparatif menggunakan tiga algoritma dengan arsitektur berbeda: *Random Forest (Bagging)*, *XGBoost (Boosting)*, dan *SVM (Vector-based)*. Proses ini mencakup penanganan data tidak seimbang menggunakan teknik SMOTE dan pencarian koordinat *hyperparameter* optimal menggunakan *Bayesian Optimization* melalui Optuna.
4. Fase *Evaluation*
Melakukan uji tanding performa ketiga model menggunakan metrik statistik (*AUC*, *MCC*, *Sensitivity*, dan *Specificity*). Pada fase ini juga diterapkan optimasi *decision threshold* menggunakan Indeks Youden untuk menyesuaikan sensitivitas model terhadap risiko keamanan obat kardiovaskular.
5. Fase *Interpretation (Explainable AI)*
Mengintegrasikan metode SHAP (*SHapley Additive exPlanations*) untuk membedah pengaruh fitur molekuler terhadap keputusan model, guna memberikan transparansi terhadap mekanisme inhibisi yang diprediksi.
6. Fase *Deployment*
Melakukan *model serialization* untuk mengeksport arsitektur dan parameter optimal model final terbaik ke dalam format file biner *.pkl* menggunakan *joblib*, serta memvalidasi fungsionalitas inferensinya menggunakan kode program pada Jupyter Notebook.

1.7 Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini disusun sebagai berikut:

1. BAB I PENDAHULUAN

Bab ini menjelaskan urgensi penelitian terkait risiko interaksi obat kardiovaskular, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, serta tahapan dan sistematika penulisan.

2. BAB II TINJAUAN LITERATUR

Bab ini memuat landasan teori mengenai isoenzim Sitokrom P450, mekanisme inhibisi obat, konsep *molecular fingerprint*, serta teori dasar algoritma yang dibandingkan (*Random Forest*, *XGBoost*, dan *SVM*). Bab ini juga membahas metodologi optimasi menggunakan *Optuna* dan *SMOTE* serta prinsip *Explainable AI* melalui metode *SHAP*.

3. BAB III METODOLOGI PENELITIAN

Bab ini menguraikan secara mendalam desain eksperimen, mulai dari alur integrasi *dataset* ChEMBL dan PubChem, teknik pra-pemrosesan data kimia, skema pembagian data, prosedur *hyperparameter tuning*, hingga langkah-langkah optimasi *decision threshold* dan prosedur analisis *SHAP*.

4. BAB IV HASIL PENGUJIAN DAN PEMBAHASAN

Bab ini menyajikan hasil analisis komparatif performa ketiga algoritma, visualisasi proses optimasi *Optuna*, tabel perbandingan antara metrik standar dan metrik teroptimasi, serta visualisasi interpretasi *SHAP* yang membedah determinan kimiawi inhibitor. Bab ini juga mencakup pembahasan hasil validasi model pada domain senyawa obat kardiovaskular.

5. BAB V PENUTUP

Bab ini berisi kesimpulan akhir yang menjawab seluruh rumusan masalah penelitian berdasarkan hasil pengujian, serta saran-saran strategis untuk pengembangan penelitian di masa mendatang.

BAB II

TINJAUAN LITERATUR

2.1 Penyakit Kardiovaskular dan Polifarmasi


Penyakit kardiovaskular merupakan kelompok gangguan kesehatan yang mencakup patologi pada organ jantung maupun sistem pembuluh darah, seperti penyakit jantung koroner (PJK), stroke, penyakit arteri perifer, serta penyakit jantung hipertensi. Secara global maupun nasional, kondisi ini menjadi tantangan serius bagi sistem kesehatan karena angka mortalitasnya yang sangat tinggi. Di Indonesia, estimasi kematian akibat penyakit kardiovaskular mencapai 651.481 jiwa per tahun, yang didominasi oleh kasus stroke dan PJK (Handayani, 2025). Secara spesifik, prevalensi PJK di Indonesia mencapai 1,5% atau sekitar 883.447 jiwa, di mana wilayah Kalimantan Timur memiliki angka prevalensi sebesar 1,9% (Saputri & Dewi, 2023). Dampak yang dihasilkan tidak hanya terbatas pada beban kesehatan, tetapi juga pada stabilitas ekonomi, di mana biaya pelayanan kesehatan katastrofik untuk penyakit ini mencapai Rp8,2 triliun per tahun (Handayani, 2025).

Kompleksitas klinis pada pasien kardiovaskular sering kali disertai dengan berbagai penyakit penyerta (*comorbidities*), seperti diabetes melitus atau hipertensi kronis, yang mengharuskan penerapan manajemen terapi polifarmasi guna mengontrol berbagai parameter fisiologis secara simultan (Saputri & Dewi, 2023). Pada pasien kardiologi rawat inap, rata-rata jumlah obat yang diterima mencapai 10,21 jenis per pasien, dengan rentang penggunaan antara 6 hingga 21 jenis obat (Akbar *et al.*, 2021). Tingginya intensitas konsumsi obat ini berbanding lurus dengan peningkatan risiko Interaksi Obat (*Drug-Drug Interaction*).

Prevalensi interaksi obat pada terapi kardiovaskular berada pada tingkatan yang mengkhawatirkan. Studi observasional menunjukkan bahwa 100% pasien kardiovaskular berpotensi mengalami setidaknya satu kejadian interaksi obat selama masa perawatan (Akbar *et al.*, 2021). Risiko ini diperburuk oleh sifat farmakologis obat-obatan kardiovaskular, seperti statin atau *beta-blocker*, yang mayoritas memiliki jalur metabolisme kompleks melalui sistem enzim di hati (Zahid *et al.*, 2024). Tanpa pengawasan yang presisi, inhibisi pada jalur metabolisme ini dapat memicu Reaksi Obat yang Tidak Diinginkan (*Adverse Drug Reactions*) yang fatal bagi keselamatan pasien (Montastruc *et al.*, 2021). Oleh karena itu, pemahaman mendalam mengenai profil inhibisi isoenzim sitokrom P450 menjadi krusial dalam mitigasi risiko interaksi obat sejak tahap skrining awal.

2.2 Enzim Sitokrom P450 (CYP450)


Sitokrom P450 (CYP) merupakan superfamili enzim yang memegang peranan paling krusial dalam metabolisme obat pada manusia, dengan tanggung jawab mencakup sekitar 75% dari total metabolisme obat klinis dan 80% dari seluruh reaksi oksidatif fase I (Zhao *et al.*, 2021). Secara fisiologis, enzim ini mengatalisis konversi senyawa lipofilik menjadi metabolit yang lebih polar agar dapat diekskresikan oleh tubuh melalui jalur metabolisme Fase I dan Fase II, sebagaimana diilustrasikan pada Gambar 2.1.



Gambar 2.1 Peran enzim sitokrom P450 (CYPs) dalam alur metabolisme obat fase I dan jalur detoksifikasi tubuh

Sumber: Zhao *et al.* (2021)

Gangguan pada aktivitas enzim ini, terutama melalui mekanisme inhibisi, menjadi penyebab utama terjadinya interaksi obat (*Drug-Drug Interaction*). Inhibisi tersebut secara umum dikategorikan menjadi dua jenis, yaitu inhibisi reversibel yang bersifat tidak permanen (seperti inhibisi kompetitif), serta inhibisi ireversibel atau *Mechanism-Based Inhibition* (MBI) di mana inhibitor berikatan secara kovalen dan merusak fungsi enzim secara permanen (Guengerich, 2022; Zhao *et al.*, 2021). Secara struktural, efisiensi katalitik enzim ini sangat ditentukan oleh arsitektur proteinnya yang kompleks. Sebagai contoh, isoenzim CYP3A4 memiliki elemen struktur sekunder yang terdiri dari α -helices, β -sheets, dan *loops* yang fleksibel. Bagian paling vital dari enzim ini adalah sisi katalitik (*catalytic site*) yang mengandung gugus Heme sebagai pusat reaksi oksidasi, seperti yang ditunjukkan pada Gambar 2.2.



Gambar 2.2 Struktur molekuler isoenzim CYP3A4 (PDB: 1TQN) dengan identifikasi sisi katalitik dan gugus heme

Sumber: Nair *et al.* (2016)

Kemampuan model *Machine Learning* untuk mengenali perbedaan struktur molekul yang memicu mekanisme inhibisi tersebut sangat bergantung pada representasi fitur kimia yang digunakan. Molekul inhibitor sering kali memiliki pola struktural tertentu yang menyerupai substrat alami enzim sehingga dapat menempati sisi aktif secara kompetitif. Oleh karena itu, penggunaan *molecular fingerprint* menjadi sangat vital dalam riset ini guna menangkap gugus fungsi spesifik yang bertanggung jawab atas terjadinya ikatan antara ligan obat dengan protein enzim Sitokrom P450.

Penelitian ini memfokuskan analisis pada tiga isoenzim utama yang memiliki dampak klinis paling signifikan terhadap metabolisme obat kardiovaskular. Isoenzim pertama adalah CYP3A4, yang merupakan enzim paling melimpah di tubuh manusia dan bertanggung jawab memetabolisme 30% hingga 50% obat klinis saat ini (Zhao *et al.*, 2021). CYP3A4 memiliki sisi aktif yang fleksibel sehingga mampu mengakomodasi struktur molekul yang sangat beragam. Isoenzim kedua, CYP2D6, memetabolisme sekitar 25% obat klinis termasuk golongan *beta-blocker* (seperti metoprolol) yang umum digunakan pada pasien jantung. CYP2D6 dikenal memiliki variasi genetik (polimorfisme) yang tinggi, yang membagi populasi menjadi fenotipe metabolizer yang berbeda-beda (Guengerich, 2022).

Isoenzim ketiga adalah CYP2C9, yang memiliki peran vital dalam metabolisme obat dengan indeks terapi sempit seperti warfarin. Inhibisi pada CYP2C9 dapat secara drastis meningkatkan konsentrasi obat dalam darah, yang berisiko memicu efek samping fatal seperti pendarahan (Guengerich, 2022). Perlu dicatat bahwa dalam terapi kardiovaskular, penggunaan obat seperti Amiodarone sering kali menjadi tantangan klinis karena sifatnya sebagai inhibitor universal yang mampu menghambat berbagai isoenzim utama sekaligus. Pemahaman mendalam terhadap karakteristik unik dari ketiga isoenzim ini menjadi dasar bagi model komputasi untuk melakukan prediksi inhibisi yang lebih presisi dan spesifik pada masing-masing target.

2.3 Kriteria Aktivitas Biologis dan Pelabelan Data

Penentuan status aktivitas sebuah ligan sebagai inhibitor atau non-inhibitor merupakan tahapan krusial dalam membangun model klasifikasi yang andal. Parameter utama yang digunakan untuk mengukur kekuatan inhibisi secara *in vitro* adalah nilai IC_{50} (*Half Maximal Inhibitory Concentration*), yang merepresentasikan konsentrasi senyawa yang diperlukan untuk menghambat 50% aktivitas katalitik enzim target (Zahid *et al.*, 2024). Namun, penggabungan data bioaktivitas dari berbagai pangkalan data publik (seperti ChEMBL dan PubChem) sering kali menghadapi tantangan berupa tingkat kebisingan (*noise*) yang signifikan akibat perbedaan protokol eksperimen (Landrum & Riniker, 2024).

Dalam pengembangan model komputasi, ambang batas (threshold) sebesar **10.000 nM (10 μ M)** ditetapkan sebagai standar binerisasi untuk memisahkan senyawa aktif (inhibitor) dari senyawa tidak aktif (non-inhibitor). Angka ini merupakan kriteria umum dalam *High Throughput Screening* (HTS) untuk mengidentifikasi senyawa yang memiliki potensi inhibisi signifikan yang dapat mengganggu homeostasis metabolisme enzim (N.-N. Wang *et al.*, 2022).

Untuk menjamin kepastian aktivitas, diterapkan logika *Smart Labeling* guna mentransformasi data kontinu menjadi label biner dengan mempertimbangkan simbol relasi

matematis ($<$, $>$, $=$) Fungsi pelabelan tersebut didefinisikan secara matematis dalam Persamaan 2.1.

$$y_i = \begin{cases} 1 & \text{jika } (rel \in \{=, \approx, <, \leq\} \text{ dan } val \leq 10.000) \\ 0 & \text{jika } (rel \in \{=, \approx, >, \geq\} \text{ dan } val \geq 10.000) \\ Drop & \text{kondisi lainnya (ambigu)} \end{cases} \dots\dots\dots (2.1)$$


Keterangan:

- y_i : Label target biner (1 untuk Inhibitor, 0 untuk Non-inhibitor)
- val : Nilai aktivitas enzim dalam satuan nM (*standard_value*)
- rel : Simbol relasi matematis dari hasil pengujian (*standard_relation*)
- 1 : Kelas positif (Senyawa bersifat Inhibitor)
- 0 : Kelas negatif (Senyawa bersifat Non-inhibitor)
- Drop : Data yang dikeluarkan karena memiliki ambiguitas nilai aktivitas

2.4 Kemoinformatika dan Representasi Molekul

Kemoinformatika merupakan disiplin ilmu yang mengintegrasikan prinsip kimia dengan teknik informatika untuk menyimpan, mengelola, serta menganalisis informasi molekuler dalam skala besar (Ding *et al.*, 2021). Menurut An *et al.* (2022), representasi molekul menjadi elemen krusial bagi keberhasilan prediksi respons obat. Standar utama yang digunakan dalam representasi ini adalah *Simplified Molecular-Input Line-Entry System* (SMILES). Notasi tersebut mendeskripsikan topologi molekul melalui algoritma penelusuran graf berbasis *depth-first search* yang mengeksplorasi cabang hingga ke atom ujung. Terakhir, proses transformasi data dilanjutkan dengan konversi SMILES menggunakan pustaka RDKit untuk ekstraksi fitur *Molecular Fingerprint* (Ding *et al.*, 2021).

Molecular Fingerprint (MF) adalah metode pengkodean fitur struktural ke dalam bentuk vektor biner berisi angka 0 dan 1 dengan panjang yang tetap (Ding *et al.*, 2021). Dalam vektor tersebut, angka 1 merepresentasikan kehadiran substruktur kimia tertentu, sementara angka 0 menunjukkan ketiadaannya. Meskipun MF umumnya berbentuk bit string, metode ini dihasilkan melalui algoritma pemetaan gugus fungsi atau tetangga sirkular yang bersifat 2D (An *et al.*, 2022). Penelitian ini menerapkan strategi Hybrid Fingerprint dengan menggabungkan dua jenis fingerprint utama, yaitu MACCS Keys dan Morgan Fingerprint, untuk mensinergikan daya deskripsi topologi mendetail dengan kejelasan fragmen struktural, sebagaimana diilustrasikan pada Gambar 2.3.



Gambar 2.3 Mekanisme pembentukan *molecular fingerprint* melalui metode MACCS (A) dan strategi ECFP/Morgan (B)

Sumber: An *et al.* (2022)

Berdasarkan ilustrasi pada Gambar 2.3, proses representasi molekul dalam penelitian ini dilakukan melalui dua pendekatan utama. Pendekatan pertama adalah MACCS Keys (Gambar 2.3a), sebuah *structural keys* berbasis kamus fragmen struktural baku yang menandai kehadiran gugus fungsi spesifik secara eksplisit pada *bit string*. Menurut An *et al.* (2022), pendekatan kedua adalah Morgan Fingerprint atau *Extended Connectivity Fingerprint* (ECFP) (Gambar 2.3b), yang merepresentasikan lingkungan sekitar setiap atom melalui fungsi *hash mapping*. Identitas atom tersebut diperbarui secara iteratif dengan menggabungkan informasi dari atom tetangga dalam radius sirkular r yang meningkat secara bertahap.


Dalam implementasinya, Morgan Fingerprint digunakan dengan parameter radius $r = 2$ (setara dengan ECFP4) yang dipetakan menjadi vektor 2048-bit untuk menangkap kompleksitas topologi molekul secara mendetail. Sebagai pelengkap, MACCS Keys diintegrasikan untuk memberikan dimensi interpretasi yang lebih eksplisit melalui 167 fragmen struktural baku, seperti keberadaan cincin aromatik atau gugus fungsi tertentu (Zahid *et al.*, 2024). Penggabungan kedua metode ini menghasilkan dimensi fitur total sebesar 2215-bit yang mencakup informasi topologi sirkular dan kunci struktural eksplisit.

Strategi hibridasi ini krusial untuk membangun model yang dapat dipercaya. Ding *et al.* (2021) menekankan bahwa penggunaan *hybrid fingerprint* memungkinkan interpretasi menggunakan metode SHAP untuk memvalidasi apakah prediksi inhibisi isoenzim CYP3A4, CYP2D6, dan CYP2C9 didasarkan pada pemahaman farmakologi yang masuk akal. Dengan membedah kontribusi fragmen kimia spesifik secara transparan, sistem ini mampu menghubungkan luaran algoritma komputasi dengan domain ilmu kimia secara terukur dan objektif.

2.5 Algoritma Machine Learning

2.5.1 *Random Forest*

Random forest merupakan metode *ensemble learning* berbasis pohon keputusan yang menerapkan prinsip *Bagging* (*Bootstrap Aggregating*). Algoritma ini membangun sekumpulan pohon keputusan secara independen dengan mengambil sampel data secara acak dari dataset latih. Prediksi akhir dari model *Random Forest* diperoleh melalui mekanisme *majority voting* untuk tugas klasifikasi, di mana setiap pohon memberikan suara untuk satu kelas dan kelas dengan suara terbanyak ditetapkan sebagai hasil akhir (Fadzryan & Laksana, 2025). Proses pengambilan sampel fitur secara acak dan mekanisme pemungutan suara ini diilustrasikan secara mendetail pada Gambar 2.4.



Gambar 2.4 Arsitektur *random forest* dengan mekanisme *bagging* dan *majority voting*


Sumber: Abdulla *et al.* (2023)

Keunggulan utama RF terletak pada kemampuannya dalam mengurangi risiko *overfitting* dan meningkatkan stabilitas prediksi melalui keragaman pohon yang dibangun. Dalam tugas klasifikasi biner pada penelitian ini, hasil akhir ditentukan sepenuhnya oleh suara terbanyak dari seluruh pohon dalam *ensemble*, sehingga model mampu memberikan

keputusan yang lebih robust dibandingkan penggunaan pohon keputusan tunggal. (Fadzryan & Laksana, 2025).

2.5.2 *Extreme Gradient Boosting (XGBoost)*

Berbeda dengan *Random Forest* yang membangun pohon secara paralel, *Extreme Gradient Boosting (XGBoost)* merupakan algoritma *ensemble* berbasis *Gradient Boosting* yang bekerja secara sekuensial. *XGBoost* membangun pohon keputusan baru untuk memperbaiki kesalahan atau residu prediksi yang dihasilkan oleh pohon sebelumnya. Secara visual, mekanisme pembelajaran bertahap yang memanfaatkan residu ini diilustrasikan pada Gambar 2.5.



Gambar 2.5 Mekanisme *sequential learning* dan reduksi residu pada *XGBoost*

Sumber: Uddin *et al.* (2024)

Secara matematis, XGBoost merupakan model aditif yang memprediksi luaran melalui penjumlahan fungsi dari sekumpulan pohon keputusan, yang dirumuskan pada Persamaan 2.2 (Uddin *et al.*, 2024).

$$y_i = \sum_{k=1}^K f_k(x_i), f_k \in F \dots \dots \dots (2.2)$$


Keterangan:

- y_i : Hasil prediksi akhir untuk sampel ke- i .
- K : Jumlah total pohon keputusan dalam model.
- f_k : Fungsi dari pohon keputusan independen pada langkah ke- k .
- F : Ruang fungsional yang mencakup seluruh struktur pohon yang mungkin dibentuk.

Karakteristik utama yang membedakan *XGBoost* adalah adanya komponen regularisasi yang berfungsi untuk mengontrol kompleksitas model dan mencegah *overfitting*. *XGBoost* sangat efektif dalam menangani data kimia yang bersifat *sparse* (banyak nilai nol) seperti *molecular fingerprint* karena kemampuannya dalam mempelajari struktur data secara efisien melalui algoritma *sparsity-aware split finding*.

2.5.3 Support Vector Machine (SVM)


Support Vector Machine (SVM) merupakan algoritma pembelajaran mesin berbasis vektor yang bekerja dengan prinsip *Structural Risk Minimization*. Tujuan utama dari SVM adalah menemukan *hyperplane* (bidang pemisah) optimal dalam ruang fitur berdimensi tinggi yang mampu memisahkan kelas inhibitor dan non-inhibitor dengan jarak (*margin*) maksimal. Vektor-vektor data yang berada paling dekat dengan *hyperplane* disebut sebagai *support vectors*, yang menjadi penentu utama posisi bidang pemisah tersebut, sebagaimana diilustrasikan pada Gambar 2.6.



Gambar 2.6 Prinsip pemisahan *hyperplane* dan maksimalisasi margin pada SVM

Sumber: Zahid *et al.* (2024)

Mengingat data *molecular fingerprint* bersifat non-linear dan memiliki kompleksitas tinggi, pemisahan secara linear pada ruang dimensi asli seringkali tidak mungkin dilakukan. Oleh karena itu, SVM menggunakan *Kernel Trick* untuk memetakan data asli ke dalam ruang fitur baru yang memiliki dimensi lebih tinggi (*feature space*) sehingga pemisahan secara linear dapat dilakukan menggunakan *hyperplane*. Visualisasi transformasi dimensi ini ditunjukkan pada Gambar 2.7.



Gambar 2.7 Transformasi data non-linear ke dalam ruang fitur 3D menggunakan *kernel trick*
 Sumber: Zahid *et al.* (2024)

Dalam penelitian ini, digunakan kernel *Radial Basis Function* (RBF) yang didefinisikan pada Persamaan 2.3 (Zahid *et al.*, 2024).

$$K(x, x') = \exp(-\gamma \|x - x'\|^2) \dots \dots \dots (2.3)$$

Keterangan:

- $K(x, x')$: Nilai kernel (fungsi kesamaan) antara dua vektor fitur x dan x' .
- $\exp$: Fungsi eksponensial.
- γ (gama) : Parameter yang menentukan seberapa jauh pengaruh sebuah sampel pelatihan tunggal (jangkauan kernel).
- $\|x - x'\|$: Kuadrat dari jarak *Euclidean* antara dua vektor fitur.

Keputusan klasifikasi final pada SVM ditentukan oleh fungsi keputusan pada Persamaan 2.4 (Zahid *et al.*, 2024).

$$f(x) = \text{sgn}(\sum_{i=1}^n \alpha_i y_i K(x_i, x) + b) \dots \dots \dots (2.4)$$

- $f(x)$: Fungsi keputusan klasifikasi (hasil prediksi).
- sgn : Fungsi *signum* (menghasilkan +1 untuk inhibitor dan -1 untuk non-inhibitor).
- α_i : Pengali *Lagrange* yang merepresentasikan bobot kontribusi setiap *support vector*.
- y_i : Label target dari sampel ke- i .
- b : Nilai bias (*intercept*) dari *hyperplane*.

2.6 Teknik Penyeimbangan dan Optimasi Model

Efektivitas algoritma *machine learning* dalam mengklasifikasikan senyawa bioaktif sangat dipengaruhi oleh distribusi kelas pada dataset dan pemilihan kombinasi *hyperparameter* yang tepat. Dataset medis, khususnya dalam prediksi inhibisi CYP450, sering kali mengalami masalah ketidakseimbangan kelas (*class imbalance*), di mana jumlah senyawa non-inhibitor (mayoritas) jauh lebih besar dibandingkan senyawa inhibitor


(minoritas). Kondisi ini dapat menyebabkan model cenderung mengalami bias terhadap kelas mayoritas, yang berakibat pada rendahnya nilai sensitivitas dalam mendeteksi senyawa aktif (Erlin *et al.*, 2022). Untuk mengatasi hal tersebut, penelitian ini menerapkan teknik *Synthetic Minority Over-sampling Technique* (SMOTE).

Untuk mengatasi hal tersebut, penelitian ini menerapkan teknik *Synthetic Minority Over-sampling Technique* (SMOTE). Berbeda dengan *Random Over-sampling* yang hanya menduplikasi data minoritas secara identik, SMOTE bekerja dengan cara menciptakan instans baru di ruang fitur melalui interpolasi linear antara sampel minoritas dan tetangga terdekatnya (*k-nearest neighbors*). Secara matematis, pembentukan sampel sintetis baru dalam SMOTE dirumuskan pada Persamaan 2.5.

$$x_{new} = x_i + (x_j - x_i) \times \delta \dots \dots \dots (2.5)$$

- x_{new} : Sampel sintetis baru yang dihasilkan.
- x_i : Sampel dari kelas minoritas yang sedang diproses.
- x_j : Salah satu sampel dari k tetangga terdekat (*k-nearest neighbors*) dari x_i
- δ : Angka acak (*random number*) dalam rentang $[0, 1]$.

Ilustrasi perbedaan mekanisme antara penggandaan data sederhana dan sintesis data terinterpolasi ditunjukkan pada Gambar 2.8.




Gambar 2.8 Perbandingan mekanisme *random over-sampling* dan SMOTE dalam penanganan *imbalanced data*

Sumber: Li *et al.* (2024)

Penggunaan SMOTE memungkinkan model untuk mempelajari batas keputusan (*decision boundary*) yang lebih luas dan representatif bagi kelas inhibitor, tanpa memicu terjadinya *overfitting* yang ekstrem akibat replikasi data identik (Erlin *et al.*, 2022). Menurut Erlin *et al.* (2022), penerapan teknik ini secara signifikan mampu meningkatkan kinerja

algoritma seperti *Random Forest* dalam menangani data tidak seimbang, sehingga menghasilkan model yang lebih valid (*fit*) yang ditandai dengan peningkatan nilai sensitivitas dan *Youden's Index*.

Setelah dataset diseimbangkan, tahap selanjutnya adalah melakukan optimasi *hyperparameter* guna menemukan konfigurasi model yang paling sesuai dengan karakteristik data hybrid fingerprint. Penelitian ini menerapkan *Optuna*, sebuah kerangka kerja optimasi *hyperparameter* berbasis Bayesian yang dirancang untuk efisiensi tinggi. Berbeda dengan metode *Grid Search* yang mengeksplorasi seluruh ruang parameter secara lengkap namun memakan waktu lama, *Optuna* menggunakan algoritma *Tree-structured Parzen Estimator* (TPE) yang bekerja dengan memodelkan distribusi probabilitas berdasarkan hasil percobaan sebelumnya untuk mengarahkan pencarian ke wilayah parameter yang menjanjikan (Fadzryan & Laksana, 2025). Alur kerja optimasi *Optuna* diilustrasikan pada Gambar 2.9.



Gambar 2.9 Diagram alur proses optimasi *hyperparameter* menggunakan *Optuna*

Sumber: diadaptasi dari Z. Wang *et al.* (2025)

TPE membagi pengamatan menjadi dua kelompok berdasarkan nilai ambang batas skor (*threshold score*) y^* sesuai pada Persamaan 2.6.

$$p(x|y) = \begin{cases} l(x) & \text{jika } y < y^* \\ g(x) & \text{jika } y \geq y^* \end{cases} \dots\dots\dots(2.6)$$

Keterangan:

$l(x)$: Distribusi *hyperparameter* yang menghasilkan nilai fungsi objektif yang baik (error kecil).

$g(x)$: Distribusi *hyperparameter* yang menghasilkan nilai fungsi objektif yang kurang optimal (error besar).

y^* : Nilai kuantil tertentu (misalnya persentil ke-15) dari hasil observasi yang sudah ada.

Optuna secara efisien mengeksplorasi ruang parameter untuk memaksimalkan rasio antara kedua distribusi tersebut, sehingga menghasilkan model yang lebih akurat dalam waktu yang lebih singkat dibandingkan metode *Grid Search* (Fadzryan & Laksana, 2025).

2.7 Metrik Evaluasi Performa

Evaluasi kualitas model dilakukan untuk mengukur sejauh mana algoritma mampu mengklasifikasikan senyawa bioaktif secara tepat berdasarkan data yang belum pernah dilihat sebelumnya. Dasar dari seluruh perhitungan metrik evaluasi dalam klasifikasi biner adalah *Confusion Matrix*, sebuah tabel kontingensi yang memetakan hasil prediksi model terhadap label aktual yang terdiri dari *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN). Berdasarkan komponen tersebut, metrik dasar seperti Akurasi dapat dihitung untuk mengukur rasio prediksi benar terhadap keseluruhan data. Namun, pada dataset dengan ketidakseimbangan kelas seperti bioaktivitas CYP450, Akurasi sering kali memberikan hasil yang menyesatkan karena cenderung mencerminkan performa kelas mayoritas saja (Zahid *et al.*, 2024). Persamaan untuk metrik Akurasi didefinisikan pada Persamaan 2.7.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \dots\dots\dots(2.7)$$

Untuk mengatasi keterbatasan Akurasi, digunakan metrik yang lebih spesifik yaitu Presisi (*Precision*) dan Sensitivitas (*Recall*). Presisi mengukur tingkat keakuratan model dalam memprediksi kelas positif, yang dalam konteks ini sangat krusial untuk memastikan bahwa senyawa yang diprediksi sebagai inhibitor benar-benar memiliki aktivitas biologis guna meminimalkan kesalahan identifikasi (*false positive*). Sebaliknya, Sensitivitas mengukur kemampuan model dalam menjaring seluruh senyawa inhibitor yang ada dalam dataset untuk meminimalkan *false negative*, yang sangat vital bagi keselamatan pasien. Selain itu, metrik Spesifisitas digunakan untuk mengukur kemampuan model dalam mengenali senyawa non-inhibitor secara benar (N.-N. Wang *et al.*, 2022). Persamaan untuk ketiga metrik tersebut pada Persamaan 2.8, 2.9 dan 2.10.

$$Precision = \frac{TP}{TP+FP} \dots\dots\dots(2.8)$$

$$Sensitivity = \frac{TP}{TP+FN} \dots\dots\dots(2.9)$$

$$Specificity = \frac{TN}{TN+FP} \dots\dots\dots(2.10)$$

Mengingat dataset bioaktivitas sering kali tidak seimbang, penelitian ini mengandalkan *Matthews Correlation Coefficient* (MCC) sebagai indikator kualitas utama. Metrik ini dianggap sebagai parameter klasifikasi biner yang paling andal karena memperhitungkan seluruh kuadran dalam *Confusion Matrix* secara proporsional, sehingga memberikan gambaran korelasi yang lebih jujur antara nilai prediksi dan nilai aktual (Zahid *et al.*, 2024). Nilai MCC berkisar antara -1 hingga $+1$, di mana nilai $+1$ menunjukkan prediksi sempurna. Selain itu, kualitas diskriminasi model diukur menggunakan *Area Under the Receiver Operating Characteristic Curve* (AUC-ROC) yang memplot hubungan antara sensitivitas terhadap *false positive Rate* pada berbagai ambang batas keputusan. Secara matematis, MCC dirumuskan pada Persamaan 2.11.

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \dots\dots\dots(2.11)$$

Sebagai tahap akhir evaluasi, penelitian ini menerapkan Indeks Youden (*Youden's J Index*) untuk menentukan ambang batas keputusan (*decision threshold*) yang paling optimal. Indeks Youden berfungsi untuk memaksimalkan selisih antara Sensitivitas dan Spesifisitas, sehingga model dapat menetapkan titik potong yang memberikan keseimbangan performa terbaik dalam mendeteksi kelas inhibitor dan non-inhibitor. Rumus untuk Indeks Youden didefinisikan pada Persamaan 2.12 (Erlin *et al.*, 2022).

$$J = Sensitivity - (1 - Spesificity) \dots\dots\dots(2.12)$$

2.8 Interpretasi Model dengan SHAP

Implementasi algoritma kompleks seperti *Random Forest*, XGBoost, dan SVM sering kali menghadapi kendala interpretasi karena sifatnya yang sulit dijelaskan (*black box*). Meskipun mampu memberikan akurasi prediksi yang tinggi, model-model tersebut secara inheren tidak mampu menjelaskan alasan di balik penetapan suatu keputusan klasifikasi. Dalam domain farmakologi, transparansi model menjadi aspek krusial guna memastikan bahwa prediksi inhibisi enzim CYP450 didasarkan pada fitur molekuler yang valid secara biologis (Ding *et al.*, 2021). *Explainable AI* (XAI) hadir sebagai solusi untuk menjembatani kesenjangan antara performa model yang tinggi dengan kebutuhan akan interpretabilitas manusia. Salah satu metode XAI yang dianggap paling stabil dan memiliki landasan teoretis kuat saat ini adalah SHAP (*SHAPley Additive Explanations*).

2.8.1 Konsep Dasar Shapley Value

SHAP merupakan kerangka kerja interpretasi model yang didasarkan pada teori permainan kooperatif (*coalitional game theory*) yang diperkenalkan oleh Lloyd Shapley. Metode ini bekerja dengan menghitung kontribusi rata-rata marginal dari setiap fitur terhadap hasil prediksi akhir model. Dalam konteks penelitian ini, fitur tersebut merupakan bit-bit dari hybrid fingerprint (2215 bit). Nilai SHAP (ϕ_i) menentukan seberapa besar pengaruh keberadaan atau ketiadaan suatu fragmen kimia tertentu dalam mendorong model untuk memprediksi suatu ligan sebagai inhibitor atau non-inhibitor dibandingkan dengan nilai rata-rata prediksi dasar (*base value*).

Secara matematis, nilai SHAP untuk fitur i dihitung dengan mempertimbangkan seluruh kemungkinan kombinasi subset fitur yang ada, sebagaimana dirumuskan dalam Persamaan 2.13 (Uddin *et al.*, 2024).

$$\phi_i = \sum_{S \subseteq F \setminus i} \frac{|S|!(|F|-|S|-1)!}{|F|!} [f_x(S \cup \{i\}) - f_x(S)] \dots \dots \dots (2.13)$$

Keterangan:

- ϕ_i : Nilai SHAP untuk fitur i pada sampel x
- F : Himpunan seluruh fitur (2048-bit *fingerprint*)
- S : Subset fitur yang tidak mengandung fitur i
- $f_x(S)$: Fungsi prediksi model menggunakan subset fitur S

Melalui perhitungan ini, SHAP menjamin sifat konsistensi dan akurasi lokal, di mana jumlah total kontribusi dari setiap fitur akan sama dengan selisih antara prediksi model untuk sampel tersebut dengan prediksi rata-rata seluruh dataset.

2.8.2 Teknik Visualisasi dan Analisis SHAP

Hasil perhitungan nilai SHAP diolah melalui berbagai teknik visualisasi untuk membedah pola pengambilan keputusan model, baik secara global untuk seluruh dataset maupun secara lokal pada sampel individu. Salah satu teknik visualisasi utama yang digunakan dalam penelitian ini adalah *SHAP Summary Plot*. Visualisasi ini memberikan gambaran menyeluruh mengenai fitur-fitur yang paling dominan dalam memengaruhi luaran model dengan mengurutkan fitur berdasarkan besarnya rata-rata nilai absolut SHAP. Dalam plot ini, distribusi pengaruh setiap fitur direpresentasikan melalui sebaran titik-titik yang memiliki kode warna tertentu. Warna merah mengindikasikan nilai fitur yang tinggi, yang dalam konteks *fingerprint* berarti kehadiran suatu bit atau substruktur (nilai 1), sedangkan warna biru mengindikasikan nilai fitur yang rendah atau ketiadaan substruktur (nilai 0). Posisi titik pada sumbu horizontal menunjukkan arah kontribusinya; titik yang berada di sebelah kanan angka nol menunjukkan bahwa fitur tersebut mendorong model untuk memberikan prediksi "Inhibitor", sementara posisi di sebelah kiri menunjukkan kontribusi terhadap prediksi "Non-Inhibitor" (Ding *et al.*, 2021).

Selain *summary plot*, teknik visualisasi lain yang diterapkan adalah *SHAP Bar Plot*. Visualisasi ini menyederhanakan informasi dengan menampilkan peringkat kepentingan fitur berdasarkan rata-rata besaran kontribusi absolut di seluruh sampel. *Bar plot* sangat efektif untuk mengidentifikasi bit *fingerprint* mana yang secara konsisten memberikan dampak paling signifikan terhadap keputusan model bagi ketiga isoenzim CYP450 yang diteliti. Dengan memfokuskan analisis pada fitur-fitur dengan nilai SHAP tertinggi, peneliti dapat melakukan pemetaan kembali dari bit biner menuju struktur kimia asli melalui notasi SMILES.

Integrasi kedua teknik visualisasi ini memungkinkan dilakukannya analisis kontribusi molekuler yang mendalam. Sebagai contoh, melalui interpretasi visual SHAP, keberadaan gugus fungsi spesifik seperti cincin aromatik atau substituen halogen dapat diidentifikasi perannya dalam meningkatkan atau menurunkan potensi inhibisi suatu senyawa kardiovaskular. Dengan demikian, SHAP tidak hanya berperan sebagai alat validasi

performa, tetapi juga sebagai instrumen penemuan pengetahuan (*knowledge discovery*) yang menghubungkan luaran algoritma komputasi dengan domain ilmu farmakologi secara transparan dan terukur (Ding *et al.*, 2021; Zahid *et al.*, 2024).

2.9 Penelitian Terdahulu

Penelitian mengenai prediksi bioaktivitas molekul terhadap enzim Sitokrom P450 (CYP450) telah berkembang pesat dengan fokus pada peningkatan akurasi, penanganan data tidak seimbang, dan interpretabilitas model. Berbagai pendekatan *machine learning* telah diterapkan untuk mengatasi kompleksitas data kimia yang berdimensi tinggi. Penelitian yang dilakukan oleh Zahid *et al.* (2024) mengevaluasi performa SVM menggunakan berbagai deskriptor seperti Morgan dan MACCS *Fingerprint* pada lima isoenzim CYP450 utama. Hasilnya menunjukkan bahwa SVM memberikan performa stabil dengan nilai AUC mencapai 0,89. Namun, penelitian tersebut melaporkan bahwa algoritma *Random Forest* standar memberikan hasil yang tidak memuaskan pada *dataset* tersebut, sehingga SVM dipilih sebagai model final. Temuan ini menjadi celah bagi penelitian ini untuk menerapkan teknik optimasi pada algoritma berbasis pohon guna membuktikan ketangguhannya jika dipadukan dengan penanganan data yang tepat.

N.-N. Wang *et al.* (2022) mengembangkan *Consensus Model* menggunakan algoritma RF dan XGBoost yang berhasil mencapai akurasi sebesar 0,86 pada dataset skala besar. Meskipun memberikan performa yang kuat, penggunaan model konsensus meningkatkan kompleksitas komputasi dan sulit untuk diinterpretasikan secara langsung oleh praktisi klinis karena transparansi model yang rendah (*black box*). Masalah transparansi ini dijawab oleh Ding *et al.* (2021) yang menekankan bahwa interpretasi model menggunakan metode SHAP (*Shapley Additive Explanations*) sangat krusial untuk mengungkap pengaruh struktur atom terhadap prediksi sifat molekul secara konsisten dengan fakta eksperimental. Sejalan dengan itu, Uddin *et al.* (2024) mengimplementasikan kerangka kerja XGBoost yang dipadukan dengan analisis fitur melalui SHAP pada data bioinformatika kompleks dan berhasil mencapai nilai MCC sebesar 0,821 serta AUC 0,938. Keberhasilan tersebut menunjukkan potensi besar algoritma *boosting* dalam menangani data biologis jika didukung oleh metode interpretasi yang memadai.

Tantangan utama berupa ketidakseimbangan data yang sering memicu *overfitting* dibahas secara mendalam oleh Erlin *et al.* (2022). Dengan menerapkan teknik SMOTE, penelitian tersebut berhasil mentransformasi model *Random Forest* dari kondisi *overfitting* menjadi model yang FIT dengan perolehan Youden's Index sebesar 0,85. Penggunaan Youden's Index ini menjadi parameter kritis untuk menjamin keseimbangan antara sensitivitas dan spesifisitas, khususnya pada domain yang memerlukan keamanan medis tinggi. Hal ini diperkuat oleh temuan Fadzyan dan Laksana (2025) yang menunjukkan bahwa penggunaan kerangka kerja *Optuna* dengan algoritma *Tree-structured Parzen Estimator* (TPE) mampu meningkatkan efisiensi pencarian *hyperparameter* dibandingkan metode standar. Integrasi dari berbagai teknik optimasi data, parameter, dan interpretasi tersebut menjadi landasan bagi penelitian ini untuk melakukan analisis komparatif guna menghasilkan model prediksi inhibisi CYP450 yang tidak hanya akurat secara statistik,

tetapi juga aman secara klinis dan transparan secara fungsional. Ringkasan perbandingan penelitian terdahulu disajikan pada Tabel 2.1 sebagai *state of the art*.

Tabel 2.1 *State of the art*

No	Pemulis	Metode	Masalah	Dataset	Evaluasi	Kekurangan
1.	Zahid <i>et al.</i> (2024)	SVM (<i>Support Vector Machine</i>) dengan deskriptor Morgan, MACCS, dan RDKit <i>fingerprints</i> .	Inhibisi isozim CYP menyebabkan interaksi obat-obat (DDI) dengan efek farmakologis dan toksikologis tinggi.	PubChem (AID 1851, 410, 883, 884, 899, 891) dan ChEMBL	MCC (0.61-0.70), BA (0.81-0.85), Sn (0.72-0.83), Sp, dan Presisi.	Tidak memiliki akses ke database ADME (non-publik), sehingga data lebih sedikit dan lebih tidak seimbang.
2.	N.-N. Wang <i>et al.</i> (2022)	<i>Consensus Model</i> yang menggabungkan <i>Random Forest</i> dan XGBoost dengan 4 jenis deskriptor (MOE_2D, CATS, ECFP4, MACCS).	Evaluasi DDI secara eksperimental memakan waktu dan biaya besar. Kurangnya diskusi mekanisme spesifik dan validasi eksternal yang memadai pada studi sebelumnya.	Substrat dan inhibitor dari 5 isozim CYP450 (1A2, 2C9, 2C19, 2D6, 3A4). Data bersumber dari DrugBank, SuperCYP, dan PubChem (AID 1851).	ACC (~0.8), AUC (~0.9), SE, SP, dan F-value.	Pendekatan <i>consensus model</i> meningkatkan kompleksitas komputasi. Kurangnya transparansi model <i>black box</i> yang menyulitkan interpretasi langsung oleh praktisi klinis.
3.	Ding <i>et al.</i> (2021)	XGBoost berbasis <i>Molecular Fingerprint</i> (Morgan dan <i>atom-pair</i>) dikombinasikan dengan metode SHAP untuk interpretasi model.	Skrining eksperimental properti cairan ionik (ionic liquids) tidak realistis karena jumlahnya mencapai 10^{18} . Metode tradisional (GCM dan MD) memakan waktu lama dan biaya tinggi.	Empat dataset indeks bias dan viskositas cairan ionik (Refractive index 1 & 2, Viscosity 1 & 2) yang bersumber dari literatur sebelumnya.	RMSE (0.0091 – 0.053) dan R^2 (0.782 – 0.989) pada dataset uji.	Fokus utama penelitian adalah pada prediksi properti fisikokimia (viskositas dan indeks bias), bukan pada bioaktivitas atau inhibisi enzim klinis.
4.	Uddin <i>et al.</i> (2024)	Kerangka kerja XGBoost dengan strategi pengkodean hibrida dan interpretasi fitur menggunakan SHAP.	Sulitnya mengidentifikasi situs modifikasi RNA secara akurat karena kompleksitas data molekuler.	Dataset sekuens RNA manusia (<i>Homo sapiens</i>).	Akurasi 86.43%, Sensitivitas 82.35%, MCC 0.821, dan AUC 0.938.	Berfokus pada data sekuens RNA; belum diuji pada data ligan obat kecil atau inhibisi enzim sitokrom P450.

Tabel 2.2 *State of the art* (lanjutan)


No	Pemulis	Metode	Masalah	Dataset	Evaluasi	Kekurangan
5.	Erlin <i>et al.</i> (2022)	<i>Random Forest</i> dipadukan dengan teknik penyeimbangan data SMOTE	Ketidakeimbangan kelas (<i>class imbalance</i>) yang menyebabkan model cenderung bias pada kelas mayoritas.	Dataset Kredit (<i>Credit Card Fraud</i>) dari Kaggle.	Akurasi 0.90, Sensitivitas 0.91, F1-Score 0.88, Youden's Index 0.85.	Fokus pada dataset finansial tabular, belum diuji pada data bioinformatika/kimiawi yang memiliki dimensi fitur sangat tinggi.
6.	Fadzrya n & Laksana (2025)	<i>Random Forest</i> dipadukan dengan <i>Optuna</i> (<i>Hyperparameter Tuning</i>).	Ketidakefisienan dan rendahnya akurasi akibat pencarian parameter secara manual (<i>Trial and Error</i>)	Dataset Harga Rumah (Real Estate) dari Kaggle.	Akurasi mencapai 91.75%.	Implementasi masih terbatas pada data tabular umum; belum diuji pada data kimiawi berdimensi tinggi (<i>sparse</i>) seperti molecular fingerprint.

Berdasarkan tinjauan terhadap penelitian-penelitian terdahulu, dapat disimpulkan bahwa meskipun terdapat berbagai kemajuan signifikan dalam penggunaan *machine learning* untuk prediksi molekuler, masih terdapat beberapa celah kritis yang belum teratasi secara komprehensif. Penelitian terdahulu umumnya memiliki keterbatasan pada pemilihan algoritma tunggal tanpa melakukan analisis komparatif yang mendalam antara arsitektur berbasis pohon dan vektor pada karakteristik data kimia yang sangat renggang (*sparse*), atau menerapkan pendekatan model konsensus yang meningkatkan akurasi namun mengorbankan efisiensi komputasi serta transparansi model (*black box*). Selain itu, strategi optimasi penyeimbangan data menggunakan SMOTE dan pencarian parameter otomatis melalui Optuna, serta metode interpretasi model menggunakan SHAP, sebagian besar diuji secara terpisah atau pada ranah data yang berbeda seperti data finansial dan sekuens RNA. Hal ini menyebabkan efektivitas integrasi teknik-teknik tersebut dalam satu kerangka kerja skrining enzim Sitokrom P450 belum teruji secara memadai. Oleh karena itu, kebaruan riset ini terletak pada pengembangan analisis komparatif yang mengintegrasikan teknik *resampling* SMOTE, optimasi *hyperparameter* berbasis *Bayesian*, dan strategi *Explainable AI* (XAI) melalui SHAP guna menghasilkan model prediksi yang tidak hanya akurat secara statistik, tetapi juga memiliki reliabilitas klinis dan kejelasan fungsional yang dapat dipertanggungjawabkan.

BAB III

METODOLOGI PENELITIAN

Penelitian ini menerapkan pendekatan kuantitatif dengan metode eksperimental yang bersifat Komparatif. Sejalan dengan definisi Sugiyono (2013), metode eksperimental digunakan untuk mencari pengaruh perlakuan terhadap variabel lain dalam kondisi terkendali. Dalam penelitian ini, eksperimen dilakukan secara *in silico* (komputasi) dengan memberikan perlakuan berupa variasi penggunaan algoritma, optimasi *hyperparameter* dengan Optuna, dan optimasi ambang batas dengan Indeks Youden untuk mengukur pengaruhnya terhadap kinerja prediksi inhibisi isoenzim Sitokrom P450. Berdasarkan paradigma positivisme, penelitian ini mengandalkan data atribut molekuler yang terukur (Sugiyono, 2013) guna mendapatkan kesimpulan objektif melalui kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*). Alur penelitian digambarkan pada Gambar 3.1.



Gambar 3.1 Alur metodologi penelitian

Berdasarkan alur penelitian pada Gambar 3.1, operasionalisasi variabel dalam eksperimen ini disusun secara sistematis untuk menjamin objektivitas hasil komputasi (Sugiyono, 2013). Penelitian ini memfokuskan analisis pada dua kategori variabel utama, yaitu variabel independen dan variabel dependen. Arsitektur algoritma (*Random Forest*, *SVM*, dan *XGBoost*) serta nilai *decision threshold* berkedudukan sebagai variabel independen (variabel bebas) yang dimanipulasi secara sengaja di dalam *pipeline* pemodelan. Manipulasi ini dilakukan untuk mengukur pengaruh langsungnya terhadap variabel dependen (variabel terikat), yaitu performa prediktif model yang diukur secara kuantitatif melalui metrik statistika MCC, AUC, dan Sensitivitas. Sementara itu, komponen pra-

pemrosesan seperti teknik penyeimbangan data dengan SMOTE dan optimasi parameter dengan Optuna diintegrasikan secara konstan sebagai satu kesatuan prosedur eksperimen guna menjamin keandalan hasil evaluasi.

3.1 *Business Understanding*

Tahap awal penelitian ini difokuskan pada pemahaman mendalam mengenai risiko interaksi obat yang dimediasi oleh inhibisi isoenzim Sitokrom P450 (CYP450), khususnya isoform CYP2C9, CYP2D6, dan CYP3A4. Ketiga isoenzim ini diibaratkan sebagai "gerbang utama" metabolisme yang bertanggung jawab mengolah sebagian besar obat klinis dalam tubuh manusia. Kegagalan deteksi dini potensi inhibisi atau hambatan kerja enzim pada pasien penyakit kardiovaskular sangat berisiko memicu efek samping fatal, seperti lonjakan toksisitas sistemik akibat obat yang tidak terurai atau kegagalan efikasi terapi di mana obat tidak bekerja sebagaimana mestinya.

Dalam spektrum toksikologi komputasi, identifikasi dini melalui pendekatan *insilico* (metode simulasi komputer) menjadi instrumen krusial. Metode ini bertindak sebagai "penyaring awal" yang efisien untuk memitigasi risiko keselamatan pasien sebelum sebuah kandidat obat memasuki fase uji laboratorium (*in vitro*) yang memakan waktu lama dan biaya sangat besar. Dari perspektif komputasi, penelitian ini mengedepankan analisis komparatif antara algoritma berbasis pohon (*Random Forest* dan *XGBoost*) serta berbasis vektor (*Support Vector Machine*) guna menemukan arsitektur model yang paling tangguh dalam menangani data kimia yang bersifat *high-dimensional* (memiliki ribuan fitur) dan *non-linear*.

Untuk memperluas cakupan ruang kimia senyawa, penelitian ini mengintegrasikan data bioaktivitas heterogen dari dua pangkalan data utama, yaitu ChEMBL dan PubChem BioAssay. Dalam tahap ini, diterapkan strategi standarisasi SMILES yaitu representasi struktur kimia dalam bentuk baris teks kode ASCII agar dapat dikenali oleh computer guna menjamin integritas dataset. Implementasi teknis didukung oleh bahasa pemrograman Python dengan integrasi pustaka RDKit untuk ekstraksi *hybrid molecular fingerprints*. *Fingerprint* ini berfungsi sebagai "sidik jari digital" molekul yang merangkum ciri khas struktur kimia ke dalam deretan angka biner agar bisa dihitung oleh algoritma. Selanjutnya, kerangka kerja *Optuna* digunakan untuk optimasi *hyperparameter* guna mencari konfigurasi model yang paling optimal, serta penerapan Indeks Youden untuk menyesuaikan ambang batas (*threshold*) probabilitas model terhadap standar keamanan medis.

Sebagai tahap akhir, metode SHapley Additive Explanations (SHAP) diintegrasikan untuk mentransformasi keluaran model yang bersifat *black box* (sulit dipahami proses internalnya) menjadi informasi kontribusi fitur molekuler yang dapat diinterpretasikan secara kimiawi. Melalui SHAP, model tidak hanya sekadar memberikan prediksi, tetapi juga mampu memberikan alasan kimiawi di balik keputusan tersebut guna membangun kepercayaan terhadap hasil pemodelan. Performa model dievaluasi secara komprehensif menggunakan berbagai metrik statistik, dengan *Matthews Correlation Coefficient* (MCC) ditetapkan sebagai indikator utama karena ketangguhannya dalam menilai kualitas prediksi pada dataset bioaktivitas yang sangat tidak seimbang (*imbalanced*). Model dianggap berhasil secara substansial apabila mampu mencapai target performa statistik yang stabil sekaligus

mengidentifikasi fragmen struktural kimiawi yang konsisten dengan literatur farmakologi melalui analisis nilai SHAP.

3.2 Data Understanding

Tahap *Data Understanding* dalam penelitian ini berfungsi sebagai proses eksplorasi teknis untuk mengenali karakteristik, kualitas, dan distribusi data bioaktivitas yang menjadi fondasi utama model *machine learning*. Fokus utama tahap ini adalah melakukan integrasi data heterogen (*data fusion*) guna memperluas cakupan ruang kimia (*chemical space*) ligan yang diteliti. Dengan menggabungkan data dari pangkalan data kurasi literatur (ChEMBL) dan hasil skrining massal (PubChem), model diharapkan mampu mengenali pola interaksi molekuler yang lebih bervariasi pada isoenzim CYP2C9, CYP2D6, dan CYP3A4.

3.2.1 Sumber Data

Penelitian ini mengintegrasikan data dari dua pangkalan data publik dengan karakteristik kurasi yang berbeda guna mendapatkan representasi ligan yang komprehensif terhadap target CYP2C9, CYP2D6, dan CYP3A4. Sumber data pertama berasal dari ChEMBL versi 36, yang merupakan basis data bioaktivitas hasil kurasi manual dari berbagai literatur ilmiah global. Data ini diekstraksi menggunakan sistem manajemen basis data MySQL lokal dengan memfokuskan pencarian pada metrik IC_{50} (nanomolar), yaitu nilai yang menunjukkan konsentrasi senyawa yang diperlukan untuk menghambat 50% aktivitas enzim target. Guna menjamin reliabilitas hasil eksperimen, penelitian ini menerapkan kriteria ketat dengan hanya menyertakan data yang memiliki nilai tingkat kepercayaan (confidence score) ≥ 7 . Dataset mentah dari ChEMBL berjumlah 19.566 baris.

Sebagai pelengkap, sumber data kedua diperoleh dari PubChem BioAssay yang merupakan hasil uji skrining massal (*High-Throughput Screening*). Data ini diekstraksi melalui nomor identitas asai (AID) spesifik, yaitu 883 untuk CYP2C9, 891 untuk CYP2D6, dan 884 untuk CYP3A4. Penggunaan data PubChem berfungsi sebagai mitigasi terhadap bias publikasi (*publication bias*) yang umum ditemukan pada pangkalan data berbasis literatur, di mana peneliti cenderung lebih banyak melaporkan senyawa aktif. Dengan menyertakan data skrining sistematis dari PubChem, algoritma dapat mempelajari batasan antara senyawa inhibitor dan non-inhibitor secara lebih objektif di luar lingkup analog senyawa yang sudah populer di literatur. Dataset mentah dari PubChem berjumlah 34.798 baris.

3.2.2 Karakteristik Atribut Dataset

Proses integrasi melibatkan tahapan penyelarasan skema (*schema mapping*) guna menyatukan atribut dari kedua sumber ke dalam satu standar format yang seragam. Penjelasan mengenai pemetaan atribut mentah dari kedua sumber menjadi atribut final dirangkum dalam Tabel 3.1.

Tabel 3.1 Penetaan atribut *dataset* integrasi

No	Atribut Final	Atribut ChEMBL	Atribut PubChem	Deskripsi & Transformasi
1.	clean_smiles	canonical_smiles	PUBCHEM_EXT_DATASOURCE_SMILES	Struktur kimia ligan dalam notasi SMILES 1D yang telah distandarisasi.
2.	status	standard_value	PUBCHEM_ACTIVITY_OUTCOME	Target klasifikasi (1: <i>Active</i> , 0: <i>Inactive</i>). ChEMBL dilabeli berdasarkan ambang batas $IC_{50} \geq 10.000$ nM.
3.	target_name	target_name	(Ditetapkan manual)	Identitas isoenzim target spesifik (CYP2C9, CYP2D6, atau CYP3A4).
4.	source	(Ditetapkan: ChEMBL)	(Ditetapkan: PubChem)	Identitas asal sumber data untuk keperluan audit kualitas.

3.2.3 Audit Kualitas dan Penyusutan Data

Sebelum memasuki tahap pemodelan, dilakukan audit kualitas untuk menyaring data yang tidak memenuhi kriteria teknis. Proses penyusutan data ini menunjukkan transparansi dalam memilih sampel yang benar-benar valid secara saintifik. Rincian penyusutan data dari kondisi mentah hingga siap diintegrasikan ditunjukkan pada Tabel 3.2.

Tabel 3.2 Laporan penyusutan data

Tahapan Audit Kualitas	ChEMBL (Baris)	Pub Chem (Baris)	Keterangan
Data Mentah Awal	19.566	34.798	Data awal sebelum proses filtering
Filter Standarisasi	16.910	34.798	Pembersihan struktur dan tipe data
Audit Label Ambigu	16.407	28.740	Eliminasi data relasi matematis tidak pasti
Filtering Molekuler Lanjutan	16.353	25.914	Filter molekuler dan deduplikasi kembali setelah filter
<i>Dataset</i> Bersih (Input Integrasi)	16.353	25.914	Total data siap digabung: 42.267 sampel
Integrasi & Resolusi Konflik	-	-	Total final setelah integrasi: 42.106 sampel

Penyusutan yang signifikan pada data PubChem (sebesar 25,5%) utamanya disebabkan oleh eliminasi data berstatus '*Inconclusive*' yang tidak memiliki kepastian aktivitas, serta penghapusan duplikat tersembunyi guna mencegah *data leakage*. Sementara pada ChEMBL, audit difokuskan pada eliminasi relasi matematis ambigu yang dapat mengaburkan ambang batas binerisasi.

3.2.4 Distribusi Kelas dan Analisis Ketidakseimbangan

Hasil integrasi final menghasilkan *dataset* dengan distribusi kelas yang bervariasi untuk setiap target enzim. Analisis distribusi ini memberikan justifikasi teknis mengenai perlunya strategi penanganan data tidak seimbang (*class imbalance*) pada tahap metodologi selanjutnya. Sebaran data final ditunjukkan pada Tabel 3.3.


Tabel 3.3 Distribusi kelas final per target isoenzim

Target Isoenzim	Total Data	Inhibitor (1)	Non-Inhibitor (0)	Rasio (1:0)
CYP2C9	12.409	2.681	9.728	1 : 3,6
CYP2D6	12.334	2.842	9.492	1 : 3,3
CYP3A4	17.363	6.211	11.152	1 : 1,8

Berdasarkan Tabel 3.3, terlihat bahwa CYP2C9 memiliki tingkat ketidakseimbangan kelas yang paling tinggi dibandingkan target lainnya. Hal ini memberikan dasar bagi penelitian untuk menerapkan teknik *Synthetic Minority Over-sampling Technique* (SMOTE) guna mencegah bias model terhadap kelas mayoritas (Non-Inhibitor) dan meningkatkan sensitivitas deteksi pada kelas minoritas (Inhibitor) demi memenuhi aspek keamanan metabolisme obat.

3.3 Data Preparation

Tahap *Data Preparation* merupakan fase krusial untuk mentransformasi data mentah (*raw data*) menjadi *dataset* terstandar yang siap diproses oleh algoritma pemodelan. Tujuan utama dari tahap ini adalah menjamin integritas data kimiawi dan meminimalkan risiko *noise* melalui serangkaian prosedur otomatis menggunakan bahasa pemrograman Python. Hal ini didasarkan pada prinsip bahwa kualitas luaran model sangat bergantung pada kualitas data masukan. Keseluruhan alur persiapan data diringkas dalam diagram alir pada Gambar 3.2.



Gambar 3.2 Flowchart data preparation

3.3.1 Data Cleaning & Labeling

Proses pembersihan dan pelabelan merupakan tahapan awal yang krusial untuk menjamin setiap ligan memiliki informasi struktur serta nilai aktivitas yang valid. Tahapan ini diawali dengan standardisasi unit ke dalam satuan nanomolar (nM) guna memastikan konsistensi skala numerik. Untuk data yang bersumber dari ChEMBL, diterapkan prosedur pengurutan potensi (*sorting by potency*) secara menaik berdasarkan nilai IC_{50} guna memprioritaskan aktivitas penghambatan paling kuat dan menjaga sensitivitas model terhadap potensi inhibisi ligan. Transformasi nilai bioaktivitas kontinu tersebut menjadi label biner dilakukan melalui metode smart labeling yang merujuk pada fungsi matematis pada Persamaan (2.1). Sementara itu, untuk data dari PubChem, pelabelan dilakukan dengan mengekstraksi status aktivitas langsung dari kolom Activity Outcome dengan mengeliminasi data berstatus ambigu (Inconclusive). Integrasi ini memastikan status inhibitor hanya diberikan pada senyawa yang secara numerik maupun relasional memenuhi ambang batas 10.000 nM.

Setelah pelabelan, dilakukan filtrasi struktur molekuler secara mendalam mengikuti protokol standarisasi yang telah divalidasi dalam literatur (Zahid *et al.*, 2024). Prosedur ini diimplementasikan secara otomatis melalui fungsi `clean_and_canonicalize` yang mencakup empat tahapan audit struktur. Pertama, dilakukan parsing notasi SMILES menjadi objek molekul digital menggunakan pustaka RDKit untuk memvalidasi sintaksis kimia. Kedua, diterapkan prosedur penghapusan fragmen garam dengan mengekstraksi fragmen molekul terbesar (*parent molecule*) guna memastikan fokus analisis hanya pada entitas kimia utama. Ketiga, dilakukan pengecekan validitas valensi (*sanitization*) dan penghapusan atom hidrogen eksplisit untuk menyederhanakan representasi molekul tanpa menghilangkan informasi fitur kunci.

Sebagai filter akhir dalam protokol ini, dilakukan pembatasan berat molekul (BM) dalam rentang 100 Da hingga 1000 Da. Pembatasan ini bertujuan untuk mengeliminasi molekul yang terlalu sederhana (di bawah 100 Da) atau makromolekul raksasa (di atas 1000 Da) yang secara farmakologis tidak relevan dengan profil metabolisme enzim CYP450. Selain itu, kriteria inklusi atom dibatasi pada elemen organik standar yaitu C, N, O, P, S, F, Cl, Br, I, dan Se. Seluruh ligan yang lolos filtrasi kemudian ditransformasi menjadi notasi *Canonical SMILES* guna menjamin setiap struktur memiliki identitas unik yang konsisten. Integrasi antara filter bioaktivitas dan audit struktur molekuler ini bertujuan untuk meminimalisasi *noise* data serta menjamin bahwa fitur kimia yang dipelajari dalam model *machine learning* ini memiliki relevansi biologis yang dapat dipertanggungjawabkan.

3.3.2 Integrasi dan Deduplikasi Data


Setelah melalui pembersihan awal, data dari ChEMBL dan PubChem disatukan melalui proses integrasi (*data fusion*). Tantangan utama dalam tahap ini adalah adanya redundansi data, di mana senyawa yang sama muncul di kedua pangkalan data namun dengan format penulisan struktur yang berbeda. Untuk mengatasinya, dilakukan penghapusan redundansi (*deduplication*) menggunakan notasi *Canonical SMILES* melalui pustaka RDKit. Proses kanonikalisasi ini menjamin hubungan satu-ke-satu (*one-to-one*

mapping) antara entitas kimia dan representasi *string*-nya, sehingga molekul yang sama memiliki identitas unik yang konsisten.

Deduplikasi dilakukan dengan membandingkan nilai *Canonical SMILES* pada seluruh baris data. Apabila ditemukan senyawa duplikat dengan label aktivitas yang berbeda (*conflicting labels*) antara ChEMBL dan PubChem, diterapkan prosedur resolusi konflik dengan mengeliminasi senyawa tersebut sepenuhnya. Langkah ini merupakan bentuk audit kualitas guna memastikan model hanya mempelajari data dengan konsensus aktivitas yang pasti, sehingga meminimalisasi *noise* akibat kontradiksi hasil eksperimen antar-laboratorium. Selanjutnya, setiap notasi SMILES divalidasi ulang untuk memastikan konversi menjadi objek molekul digital yang bebas dari kesalahan struktur (*error-free*). Tahap ini krusial karena kualitas representasi molekul akan menentukan akurasi ekstraksi fitur pada tahap berikutnya.

3.3.3 Ekstraksi Fitur

Representasi molekul dalam penelitian ini ditransformasikan dari notasi SMILES menjadi vektor numerik melalui metode *molecular fingerprint* yang menyeimbangkan efisiensi komputasi dengan daya deskripsi fitur. Strategi hibrida diterapkan dengan mensinergikan dua kategori deskriptor utama menggunakan pustaka RDKit, yaitu Morgan Fingerprint dan MACCS Keys. Alur transformasi struktur kimia menjadi vektor hibrida ini diilustrasikan pada Gambar 3.3.



Gambar 3.3 Flowchart ekstraksi fitur

Morgan Fingerprint digunakan untuk menangkap informasi topologi molekul melalui analisis lingkungan atom secara sirkular dengan radius 2 (setara ECFP4) dan panjang vektor 2048 bit (An *et al.*, 2022). Secara simultan, MACCS Keys diintegrasikan sebagai deskriptor berbasis kunci struktural guna mengidentifikasi keberadaan 167 fragmen struktural spesifik yang telah didefinisikan sebelumnya, seperti gugus fungsi kunci atau heteroatom (Zahid *et al.*, 2024). Penggabungan kedua vektor tersebut menghasilkan dimensi fitur total sebesar 2215 bit. Integrasi ini memungkinkan model untuk mempelajari hubungan struktur-aktivitas secara lebih luas dengan menggabungkan keunggulan ekstraksi fitur otomatis dan kamus struktur kimia yang baku (An *et al.*, 2022; Zahid *et al.*, 2024).

3.3.4 Data Splitting

Dataset final dibagi menjadi dua himpunan independen menggunakan teknik *stratified random sampling* dengan proporsi 80% untuk data latih (*training set*) dan 20% untuk data uji (*test set*). Penggunaan metode *stratified* sangat krusial untuk menjaga konsistensi distribusi kelas yang tidak seimbang (*imbalanced*) antara kedua himpunan, sehingga rasio inhibitor dan non-inhibitor tetap representatif terhadap karakteristik *dataset* asli.

Penting untuk dicatat bahwa teknik penanganan ketidakseimbangan kelas menggunakan SMOTE (*Synthetic Minority Over-sampling Technique*) tidak dilakukan pada tahap pra-pemrosesan awal, melainkan diintegrasikan ke dalam *modeling pipeline*. Hal ini bertujuan agar *oversampling* hanya diterapkan pada lipatan pelatihan (*training folds*) dalam skema *5-fold cross validation*, sehingga mencegah terjadinya *data leakage* pada data validasi dan data uji.

3.3.5 Ilustrasi Penelusuran Data

Guna memberikan gambaran konkret mengenai mekanisme transformasi data dalam penelitian ini, berikut adalah ilustrasi penelusuran data menggunakan senyawa *Levo Propranolol* sebagai molekul contoh pada Table 3.3.

Tabel 3.4 Contoh penelusuran transformasi data pada molekul *Levo Propranolol*

Tahap Pemrosesan	Representasi Data	Deskripsi Kontekstual
Identitas Senyawa	CHEMBL452861 (<i>Levo Propranolol</i>)	Obat kardiovaskular golongan <i>beta-blocker</i> .
<i>Input</i> (SMILES)	<chem>CC(C)NC[C@H](O)COc1cccc2ccccc12</chem>	Struktur kimia dalam format teks (SMILES).
Pembersihan	<i>Salt Removed</i> , Berat Molekul: 259.3 Da	Molekul induk valid (rentang 100-1000 Da).
Pelabelan Data	Label: 1 (Inhibitor)	Nilai IC_{50} (1.400 nM) < 10.000 nM.
Ekstraksi Fitur	Vector: [0, 0, 0, ..., 1, 0] (2215-bit) [Morgan_0,1,2, ..., MACCS_165,166]	Transformasi menjadi <i>Hybrid Fingerprint</i> .

3.4 Modeling

Tahap pemodelan merupakan fase pembangunan mesin inferensi untuk mengklasifikasikan ligan menjadi inhibitor atau non-inhibitor pada target enzim CYP450. Penelitian ini menerapkan pendekatan analisis komparatif dengan menguji tiga algoritma yang memiliki paradigma pembelajaran berbeda: *Bagging* (*Random Forest*), *Boosting* (XGBoost), dan *Kernel-based* (SVM). Ketiga model ini dilatih, dioptimasi, dan dievaluasi secara independen untuk setiap target isoenzim (CYP2C9, CYP2D6, dan CYP3A4) guna memastikan model mampu menangkap karakteristik interaksi molekuler yang spesifik pada masing-masing situs aktif enzim.

3.4.1 Representasi dan Dimensi Fitur

Berdasarkan hasil ekstraksi fitur hibrida, penelitian ini menetapkan penggunaan seluruh dimensi fitur sebesar 2215 bit sebagai masukan bagi model. Penggunaan fitur penuh dipilih sebagai strategi metodologis untuk meminimalkan risiko kehilangan informasi mengenai fragmen struktural langka yang mungkin memiliki kontribusi biologis signifikan dalam mekanisme inhibisi enzim. Meskipun dimensi fitur yang tinggi dapat meningkatkan kompleksitas komputasi, risiko *overfitting* akan dimitigasi melalui optimasi parameter regularisasi dan mekanisme internal pemilihan fitur pada algoritma berbasis pohon.

3.4.2 Algoritma *Random Forest*

Random Forest diimplementasikan sebagai metode *ensemble* berbasis *Bagging* (*Bootstrap Aggregating*) yang membangun sekumpulan pohon keputusan secara independen. Mekanisme kerja algoritma ini diawali dengan pembuatan beberapa sub-*dataset* melalui teknik *bootstrap sampling* dari data latih asli. Pada setiap simpul pohon yang dibangun, algoritma hanya mempertimbangkan subset fitur acak untuk menentukan percabangan optimal menggunakan kriteria *Gini Impurity*. Pendekatan ini sangat efektif untuk data sidik jari molekuler karena mampu mencegah dominasi fitur tertentu dan menghasilkan model yang lebih stabil melalui mekanisme *majority voting* dari seluruh pohon yang terbentuk.

Tabel 3.5 Alur *input-process-output* (IPO) *Random Forest*

Komponen	Deskripsi Teknis
Input	Vektor <i>Hybrid Fingerprint</i> (2215 bit) dalam format NumPy array.
Process	1. <i>Bootstrap sampling</i> 2. Konstruksi $n_{estimators}$ pohon 3. Pemilihan fitur acak ($\sqrt{d}$) per <i>split</i> , dan perhitungan <i>Gini Impurity</i> .
Output	Probabilitas kelas $[0, 1]$ dan label klasifikasi final (Inhibitor/Non-Inhibitor).

3.4.3 Algoritma *Extreme Gradient Boosting* (XGBoost)

Algoritma XGBoost diterapkan dengan paradigma *Gradient Boosting* yang bekerja secara sekuensial untuk memperbaiki kesalahan prediksi (*residual error*) dari pohon-pohon sebelumnya. Proses ini melibatkan optimasi fungsi *loss* yang mencakup komponen regularisasi L1 dan L2 guna mencegah kompleksitas model yang berlebihan. XGBoost memiliki keunggulan pada kemampuan menangani data kimia yang bersifat *sparse* melalui

teknik *sparsity-aware split finding*, di mana algoritma secara efisien menentukan arah percabangan untuk nilai bit nol tanpa menambah beban komputasi secara signifikan.

Tabel 3.6 Alur *input-process-output* (IPO) XGBoost

Komponen	Deskripsi Teknis
Input	Vektor hibrida 2215 bit yang dikonversi ke format internal DMatrix.
Process	1. Perhitungan <i>gradient</i> dan <i>hessian</i> 2. Penambahan pohon sekuensial 3. <i>loss minimization</i> dengan regularisasi, dan <i>tree pruning</i>
Output	Skor prediksi mentah yang dikonversi melalui fungsi sigmoid menjadi probabilitas kelas.

3.4.4 Algoritma *Support Vector Machine* (SVM)

Support Vector Machine dengan kernel *Radial Basis Function* (RBF) digunakan sebagai pembanding berbasis vektor yang bekerja dengan prinsip pencarian *hyperplane* optimal. SVM melakukan pemetaan ligan ke dalam ruang fitur berdimensi tinggi secara non-linear untuk menemukan batas keputusan dengan margin maksimal yang memisahkan kelas inhibitor dan non-inhibitor. Parameter C digunakan untuk mengontrol keseimbangan antara lebar margin dan kesalahan klasifikasi, sementara parameter γ mengatur jangkauan pengaruh dari satu sampel pelatihan terhadap pembentukan batas keputusan.

Tabel 3.7 Alur *input-process-output* (IPO) *Support Vector Machine*

Komponen	Deskripsi Teknis
Input	Vektor fitur 2215 bit yang telah melalui standarisasi skala.
Process	1. Pemetaan non-linear menggunakan kernel RBF 2. Optimasi parameter C dan γ untuk menyeimbangkan margin. 3. Identifikasi <i>support vectors</i> sebagai batas keputusan.
Output	Jarak ligan terhadap <i>hyperplane</i> yang dikonversi menjadi probabilitas melalui <i>Platt Scaling</i> .

3.4.5 Strategi Penanganan Ketidakseimbangan Data

Mengingat karakteristik *dataset* yang memiliki rasio ketidakseimbangan kelas cukup signifikan terutama pada isoenzim CYP2C9 dengan rasio mencapai 1:3,6 penelitian ini menerapkan teknik *Synthetic Minority Over-sampling Technique* (SMOTE). Berbeda dengan metode *oversampling* konvensional yang melakukan replikasi data mentah, SMOTE bekerja dengan cara menyintesis sampel baru pada kelas minoritas (inhibitor) melalui interpolasi linier di antara sampel yang ada dengan tetangga terdekatnya (*k-nearest neighbors*).

Mekanisme sintesis data ini dilakukan dengan merujuk pada logika matematis yang telah dijabarkan pada Persamaan (2.5). Dalam implementasinya, penelitian ini menetapkan parameter tetangga terdekat sebesar $k = 5$ untuk memastikan sampel sintesis yang dihasilkan tetap berada dalam distribusi ruang kimia yang realistis. Penggunaan SMOTE bertujuan untuk memperluas batas keputusan (*decision boundary*) model agar tidak hanya terfokus pada kelas mayoritas (non-inhibitor), sehingga meningkatkan sensitivitas model dalam mendeteksi potensi inhibisi senyawa yang krusial bagi analisis keamanan metabolisme obat.

3.4.6 *Stratified K-Fold Cross Validation*


Untuk menjamin stabilitas dan kemampuan generalisasi model, diterapkan skema *5-Fold Stratified Cross-Validation*. Penggunaan metode *stratified* (berstrata) menjamin bahwa setiap lipatan (*fold*) mempertahankan rasio kelas inhibitor dan non-inhibitor yang identik dengan *dataset* asli. Hal ini sangat penting pada *dataset imbalanced* untuk mencegah adanya lipatan yang tidak memiliki sampel kelas minoritas sama sekali, yang dapat menyebabkan kegagalan pelatihan model.

Dalam skema *5-fold*, *dataset* dibagi menjadi lima bagian. Pada setiap iterasi, empat bagian digunakan sebagai data latih dan satu bagian sebagai data validasi. Proses ini diulang sebanyak lima kali sehingga setiap sampel pernah menjadi bagian dari data validasi satu kali. Skor performa akhir dihitung berdasarkan rata-rata statistik dari kelima iterasi tersebut, yang memberikan estimasi performa yang lebih reliabel dibandingkan pembagian data tunggal.

3.4.7 Implementasi *Pipeline* SMOTE, dan *Cross Validation*

Untuk menjamin stabilitas dan objektivitas model, penelitian ini mengintegrasikan seluruh komponen pemodelan ke dalam sebuah *pipeline* otomatis. Skema evaluasi yang dirancang adalah *5-Fold Stratified Cross-Validation* yang dikombinasikan dengan teknik penyeimbangan data *Synthetic Minority Over-sampling Technique* (SMOTE). Alur kerja sistematis mulai dari pemrosesan lipatan data hingga pelatihan model final diringkas dalam diagram alir pada Gambar 3.4.

Mekanisme perulangan pada Gambar 3.4 menunjukkan bahwa SMOTE hanya diaplikasikan pada porsi *training fold* di setiap iterasi validasi silang. Hal ini dilakukan untuk menghindari fenomena *data leakage* (kebocoran data), sehingga model dievaluasi pada data validasi yang tetap murni. Setelah 50 iterasi optimasi selesai dan parameter terbaik ditemukan, dilakukan proses Final Training (Fit). Pada tahap ini, model dilatih ulang menggunakan seluruh 80% data latih yang telah diseimbangkan dengan SMOTE tanpa melalui proses validasi silang lagi, guna menghasilkan model final yang memiliki kemampuan generalisasi maksimal untuk disimpan dalam format .pkl.



Gambar 3.4 *Flowchart pipeline pemodelan dengan integrasi SMOTE dan cross validation*

3.4.8 Optimasi Hyperparameter dengan Optuna

Prosedur pencarian konfigurasi parameter paling optimal dilakukan menggunakan kerangka kerja Optuna dengan algoritma *Tree-structured Parzen Estimator* (TPE) berbasis optimasi Bayesian. Optimasi dijalankan sebanyak 50 iterasi (*trials*) untuk setiap algoritma dan target isoenzim. Metrik evaluasi yang ditetapkan sebagai fungsi objektif dalam seluruh proses optimasi adalah ROC-AUC. Pemilihan ROC-AUC didasarkan pada stabilitas metrik ini dalam mengukur kemampuan diskriminasi model antara kelas inhibitor dan non-inhibitor, terutama pada *dataset* yang memiliki ketidakseimbangan kelas (*imbalanced*).

TPE bekerja secara iteratif dengan memodelkan distribusi *hyperparameter* yang memberikan hasil performa tinggi dan rendah secara probabilistik. Berdasarkan hasil evaluasi pada setiap *trial*, Optuna akan memperbarui pemahaman terhadap ruang pencarian guna memprediksi kombinasi parameter yang memiliki *Expected Improvement* tertinggi.

Strategi ini jauh lebih efisien dibandingkan *Grid Search* konvensional dalam menjelajahi ruang pencarian yang luas. Rincian *hyperparameter* yang dieksplorasi disajikan pada Tabel 3.8.

Tabel 3.8 Ruang pencarian *hyperparameter* dalam proses optimasi

Algoritma	Hyperparameter	Rentang Pencarian	Metrik Optimasi
Random Forest	n_estimators, max_depth, max_features	[100, 300], [10, 50], [0.05, 0.3]	ROC-AUC
XGBoost	n_estimators, learning_rate, max_depth	[100, 500], [0.01, 0.3], [3, 15]	ROC-AUC
SVM	C, gamma, kernel	[0.1, 100], [10^{-4} , 10^{-1}], [rbf]	ROC-AUC

3.5 Evaluation

Evaluasi kinerja model dilakukan menggunakan himpunan data uji (*test set*) yang bersifat independen untuk mengukur kemampuan generalisasi model terhadap senyawa yang belum pernah dilihat sebelumnya. Mengingat adanya ketidakseimbangan kelas pada *dataset* bioaktivitas, penelitian ini mengadopsi prosedur evaluasi dua tahap yang mencakup perhitungan metrik performa berbasis *Confusion Matrix* dan optimasi ambang batas keputusan guna memastikan model tidak hanya akurat secara global, tetapi juga sensitif terhadap kelas minoritas.

3.5.1 Skenario Pengujian

Skenario pengujian dirancang secara sistematis untuk mengevaluasi kemampuan generalisasi dari sembilan model final yang telah dihasilkan pada tahap pemodelan. Prosedur pengujian difokuskan pada penggunaan himpunan data uji (*test set*) yang sepenuhnya independen dan belum pernah terlibat dalam proses penyeimbangan data maupun optimasi parameter. Langkah ini krusial untuk memastikan bahwa performa yang dilaporkan mencerminkan reliabilitas model dalam menghadapi data senyawa baru di masa depan. Alur operasional dari skenario pengujian ini diringkas dalam Tabel 3.9.

Tabel 3.9 Skenario dan alur kerja pengujian model

Tahapan	Input	Proses Teknis	Output
Pemuatan & Inferensi	Model .pkl & Data Uji (20%)	Pemuatan arsitektur model tersimpan dan prediksi probabilitas terhadap data uji.	Nilai probabilitas kontinu [0, 1]
Optimasi Ambang Batas	Nilai Probabilitas & Label Aktual	Pencarian titik potong optimal melalui pemindaian indeks Youden (<i>J</i>) pada kurva ROC.	Ambang batas (<i>threshold</i>) optimal
Evaluasi Performa	<i>Threshold</i> & Nilai Probabilitas	Konversi probabilitas ke label biner dan kalkulasi metrik kinerja (MCC, ROC-AUC, dsb).	Matriks Kebingungan & Tabel Evaluasi

3.5.2 Metrik Kinerja Model

Kinerja klasifikasi diukur menggunakan beberapa metrik fundamental untuk memberikan gambaran performa yang menyeluruh. Pertama, Akurasi digunakan untuk mengukur rasio prediksi benar terhadap keseluruhan data uji (Latief *et al.*, 2024). Namun, karena akurasi dapat menyesatkan pada data tidak seimbang, digunakan pula Sensitivitas (Recall) untuk mengukur kemampuan model dalam mengidentifikasi senyawa inhibitor secara tepat hal ini sangat krusial dalam studi farmakologi untuk meminimalkan *false negative*. Presisi digunakan untuk mengukur keakuratan prediksi positif model guna meminimalkan *false positive*, sedangkan Spesifisitas digunakan untuk menjamin model dapat mengenali senyawa non-inhibitor secara benar guna menghindari kesalahan identifikasi senyawa aktif (*false positive*) (Zahid *et al.*, 2024).

Sebagai indikator kualitas utama, penelitian ini mengandalkan *Matthews Correlation Coefficient* (MCC). Metrik ini dianggap sebagai parameter klasifikasi biner yang paling andal untuk *dataset* tidak seimbang karena mempertimbangkan keempat parameter matriks kebingungan secara seimbang, sehingga memberikan gambaran korelasi yang lebih jujur antara prediksi dan data aktual. Selain itu, *Area Under the ROC Curve* (ROC-AUC) digunakan untuk mengukur kemampuan model dalam membedakan kedua kelas pada berbagai ambang batas keputusan. Dasar matematis dan rumusan untuk masing-masing metrik tersebut telah dijabarkan secara rinci pada Bab II (Tinjauan Literatur). Penting untuk dicatat bahwa nilai Akurasi, Sensitivitas, Presisi, Spesifisitas, dan MCC yang dilaporkan adalah hasil perhitungan berdasarkan ambang batas optimal yang diperoleh melalui Indeks Youden, bukan sekadar nilai *default* algoritma.

3.5.3 Decision Threshold Optimization

Secara *default*, algoritma klasifikasi menggunakan ambang batas 0,5 sebagai titik potong penentuan kelas. Namun, pada *dataset* dengan ketidakseimbangan kelas, ambang batas tersebut sering kali menghasilkan prediksi yang bias terhadap kelas mayoritas. Oleh karena itu, penelitian ini menerapkan optimasi ambang batas keputusan menggunakan metode Youden's J Index guna mencari titik potong optimal pada kurva ROC.

Secara geometris, Indeks Youden mewakili titik pada kurva ROC yang memiliki jarak vertikal terjauh dari garis diagonal, sehingga memaksimalkan efektivitas deteksi tanpa meningkatkan risiko salah klasifikasi. (Erlin *et al.*, 2022). Dalam implementasi penelitian ini, prosedur pencarian titik potong (*cutoff*) dilakukan dengan memindai seluruh probabilitas luaran model pada data uji untuk menemukan nilai yang menghasilkan kombinasi Sensitivitas dan Spesifisitas tertinggi. Hal ini memastikan bahwa model akhir memiliki keseimbangan performa yang optimal dalam mendeteksi ligan inhibitor tanpa mengorbankan akurasi pada ligan non-inhibitor. Perumusan Indeks Youden (*J*) yang digunakan dalam tahap optimasi ini mengacu pada Persamaan (2.12). Ambang batas yang menghasilkan nilai *J* tertinggi ditetapkan sebagai parameter final guna meningkatkan kemampuan model dalam menghindari kesalahan klasifikasi pada kelas minoritas (Erlin *et al.*, 2022).

3.6 Interpretation (SHAP Analysis)

Guna membedah sifat *black box* dari algoritma *ensemble* (Random Forest dan XGBoost) serta memahami signifikansi setiap fitur molekuler secara transparan, penelitian ini menerapkan metode SHAP (*SHapley Additive exPlanations*). Analisis ini bertujuan untuk memberikan landasan teoretis mengenai fitur-fitur yang paling berkontribusi dalam klasifikasi inhibitor CYP450 berdasarkan kontribusi bit-bit pada *hybrid fingerprint*. (Zahid *et al.*, 2024).

3.6.1 Pendekatan *TreeExplainer* untuk Interpretasi Global

Analisis interpretasi difokuskan pada algoritma berbasis pohon (*tree-based models*) menggunakan varian *TreeExplainer*. Varian ini dipilih karena mampu menghitung nilai kontribusi fitur secara eksak dan efisien untuk model *ensemble*. Fokus utama tahap ini adalah melakukan Interpretasi Global (*Feature Importance*) guna mengidentifikasi fitur (bit) mana yang memiliki pengaruh paling dominan secara konsisten di seluruh *dataset*. Hasil analisis ini divisualisasikan melalui *SHAP Summary Plot*, yang merangkum distribusi nilai SHAP untuk fitur-fitur utama yang menentukan aktivitas inhibisi ligan.

3.6.2 Mekanisme Pemetaan Fitur dan Visualisasi Substruktural

Prosedur pemetaan fitur dilakukan untuk memberikan interpretasi kimiawi terhadap bit-bit yang telah diidentifikasi sebagai fitur paling berpengaruh melalui analisis SHAP global. Mengingat *hybrid fingerprint* terdiri dari dua jenis deskriptor yang berbeda, maka mekanisme pemetaan dibagi menjadi dua skema yang saling melengkapi. Untuk deskriptor berbasis *MACCS Keys*, pemetaan dilakukan dengan mencocokkan indeks bit yang memiliki nilai SHAP tertinggi terhadap kamus standar 166 kunci fungsional (*MACCS structural keys*). Langkah ini memungkinkan peneliti untuk mengidentifikasi keberadaan gugus fungsi makroskopis, seperti cincin aromatik atau keberadaan atom heterosiklik tertentu, yang secara konsisten menjadi penanda bagi model dalam mengenali sifat inhibisi suatu ligan.

Sementara itu, untuk fitur yang berasal dari *Morgan fingerprint*, digunakan pendekatan visualisasi substruktural yang bersifat dinamis. Karena setiap bit pada *Morgan fingerprint* merepresentasikan lingkungan atom lokal dengan radius tertentu, pemetaan dilakukan menggunakan fungsi *DrawMorganBits* dengan memanfaatkan modul *bitInfo* pada pustaka RDKit. Proses ini mengekstraksi informasi mengenai pusat atom dan ikatan di sekitarnya yang membentuk fitur tersebut, kemudian merendernya menjadi gambar fragmen molekuler dua dimensi (2D). Melalui visualisasi ini, kontribusi fitur yang bersifat abstrak dapat diterjemahkan menjadi unit-unit struktural molekul yang nyata, sehingga memudahkan proses validasi silang dengan literatur farmakologi mengenai mekanisme interaksi senyawa pada situs aktif enzim CYP450.

3.6.3 Validasi Relevansi Biologis

Tahap akhir dari interpretasi model adalah melakukan validasi terhadap fragmen molekuler dan gugus fungsi yang telah diidentifikasi. Temuan substruktural dari hasil pemetaan SHAP dan RDKit dibandingkan dengan studi literatur farmakologi yang berkaitan dengan mekanisme interaksi ligan pada situs aktif enzim CYP450. Langkah ini bertujuan

untuk mengonfirmasi apakah fitur yang dianggap penting secara komputasi memiliki dasar biologis yang sah, sehingga model yang dikembangkan memiliki kegunaan dalam proses penemuan atau pengembangan obat (*drug discovery*). Detail operasional dari proses interpretasi ini dirangkum dalam Tabel 3.10.

Tabel 3.10 Prosedur teknik interpretasi SHAP

Komponen	Deskripsi Operasional
Alat Interpretasi	<i>SHAP Library</i> dengan implementasi <i>TreeExplainer</i> .
Data Masukan	Model .pk1 terbaik dan sampel data uji (<i>X_{test}</i>).
Metode Visualisasi	<i>SHAP Summary Plot</i> (Global) dan <i>RDKit Fragment Grid</i> (Struktural).
Teknik Pemetaan	<i>Dictionary lookup</i> (MACCS) dan <i>bitInfo mapping</i> (Morgan).
Target Output	Identifikasi gugus fungsi dan fragmen kimia pemicu inhibisi.

3.7 Deployment

Fase *Deployment* dalam penelitian eksperimen *in silico* ini disederhanakan murni sebagai tahapan *model serialization* untuk menyimpan objek model hasil eksperimen. Model final terbaik yang dihasilkan dari algoritma *Random Forest*, SVM, dan XGBoost diekspor ke dalam format biner terkompresi dengan ekstensi .pk1 melalui proses serialisasi. Proses ini bertujuan untuk menyimpan seluruh konfigurasi arsitektur, parameter optimal, dan bobot matematis model secara permanen agar bersifat *reusable*.

Untuk memvalidasi bahwa file biner tersebut berhasil disimpan dan dapat beroperasi secara konsisten tanpa mengalami kebocoran data (*data leakage*), dilakukan uji fungsionalitas inferensi menggunakan skrip demonstrasi sederhana berbasis Jupyter Notebook. Uji fungsionalitas ini dilakukan secara langsung menggunakan studi kasus ligan nyata (senyawa Amlodipine) untuk memastikan model biner mampu melakukan ekstraksi *hybrid fingerprint* 2215-bit dan mengeluarkan prediksi status inhibisi secara instan tanpa memerlukan proses pelatihan ulang (*retraining*). Tahap ini menjadi penutup siklus CRISP-DM guna menjamin kesiapan model untuk diintegrasikan ke dalam alur *virtual screening* skala besar di masa mendatang.

BAB IV

HASIL PENGUJIAN DAN PEMBAHASAN

4.1 Implementasi

Bagian ini menjelaskan secara komprehensif mengenai tahap realisasi dari rancangan penelitian yang telah disusun pada bab metodologi menjadi sebuah produk akhir berupa file model prediktif terklasifikasi. Implementasi ini mencakup seluruh alur kerja eksperimental, mulai dari akuisisi data senyawa ligan, *preprocessing* molekul dengan representasi *hybrid fingerprint*, penyeimbangan data menggunakan metode SMOTE, hingga proses optimasi serta pelatihan model *machine learning* (*Random Forest*, *XGBoost*, dan *SVM*). Selain itu, dipaparkan pula teknis implementasi interpretabilitas menggunakan SHAP untuk membedah kontribusi fitur kimia serta *model serialization* ke dalam file biner sebagai sarana validasi fungsional. Seluruh tahapan ini disertai dengan penjelasan teknis serta cuplikan kode sumber yang relevan untuk menggambarkan proses transformasi dari kerangka teoretis menuju implementasi konkret.

4.1.1 Deskripsi Alat dan Lingkungan Eksekusi

Pelaksanaan implementasi dan pengujian model dalam penelitian ini dilakukan pada sebuah perangkat komputer portabel dengan spesifikasi yang memadai untuk menangani komputasi data berdimensi tinggi. Deskripsi mengenai perangkat keras yang digunakan disajikan pada Tabel 4.1.

Tabel 4.1 Deskripsi perangkat keras

Komponen	Spesifikasi	Keterangan
Processor	AMD Ryzen 7 6800H (8-Core, up to 4.7 GHz)	Unit pemrosesan utama.
RAM	16 GB DDR5	Memori utama untuk pengolahan <i>dataset</i> .
GPU	AMD Radeon 680M (iGPU)	Pemrosesan grafis terintegrasi.
Storage	SSD 512 GB	Media penyimpanan data dan model.

Selain perangkat keras, lingkungan pengembangan perangkat lunak juga dikonfigurasi untuk mendukung eksekusi algoritma *machine learning* dan manipulasi data kimia (*cheminformatics*). Sistem operasi yang digunakan adalah Windows 11 dengan bahasa pemrograman Python versi 3.11.13. Seluruh skrip program dikembangkan menggunakan IDE Visual Studio Code dengan ekstensi Jupyter Notebook untuk memudahkan proses *debugging* dan analisis data secara interaktif. Daftar pustaka (*library*) utama yang diimplementasikan dalam penelitian ini dirangkum dalam Tabel 4.2.

Tabel 4.2 Deskripsi pustaka utama

Kategori	Nama Library	Versi	Fungsi Utama
<i>Data Manipulation</i>	pandas, numpy	2.3.3 / 2.3.4	Pengolahan struktur data dan matriks.
<i>Machine Learning</i>	scikit-learn, xgboost	- / 3.1.1	Implementasi algoritma RF, SVM, dan XGB.
<i>Data Balancing</i>	imbalanced-learn	-	Eksekusi teknik SMOTE.
<i>Hyperparameter Tuning</i>	optuna	-	Optimasi model secara otomatis.
<i>Model Explainability</i>	shap	0.49.1	Interpretasi kontribusi fitur (XAI).
Visualisasi	matplotlib, seaborn	3.10.6 / -	Pembuatan grafik dan plot hasil.

4.1.2 Tahapan Implementasi

Tahapan implementasi dilaksanakan secara sistematis dengan merujuk pada siklus hidup pengembangan model prediktif berbasis CRISP-DM. Alur ini dimulai dari realisasi kebutuhan bisnis menjadi proses akuisisi data, persiapan *dataset*, hingga pembangunan model final.

1. *Data Collection*

Langkah awal ini merupakan implementasi dari strategi pengumpulan data untuk mendapatkan *dataset* bioaktivitas terhadap isoenzim CYP2C9, CYP2D6, dan CYP3A4. Hasil akhir dari tahap ini adalah empat berkas data mentah (*raw data*) yang belum mengalami proses filtrasi kimiawi maupun pelabelan.

Implementasi pengumpulan data ChEMBL dilakukan dengan mengunduh *database dump* ChEMBL_36 dalam format MySQL. Berkas tersebut kemudian diimpor ke dalam lingkungan basis data lokal menggunakan MySQL *server*. Pengambilan data dari database lokal ke lingkungan Python dilakukan menggunakan kueri SQL melalui *driver* `mysql.connector`. Fokus utama pada tahap ini adalah menarik data mentah berupa struktur SMILES dan nilai IC_{50} numerik. Proses interaksi antara lingkungan Python dan basis data lokal untuk menarik data tersebut direalisasikan melalui Kode Program 1.

Kode Program 1: Akuisisi Data Mentah dari Database Lokal ChEMBL

```
# Menghubungkan ke database lokal hasil import dump ChEMBL_36
conn = mysql.connector.connect(**DB_CONFIG)
# Eksekusi kueri untuk menarik data mentah (raw)
query = """
    SELECT md.chembl_id, cs.canonical_smiles,
           act.standard_value, act.standard_type, act.standard_relation,
           td.chembl_id AS target_id
    FROM molecule_dictionary md
    JOIN compound_structures cs ON md.molregno = cs.molregno
    JOIN activities act ON md.molregno = act.molregno
    ...
    """
df_chembl_raw = pd.read_sql(query, conn)
```

Sementara itu, Pengumpulan data PubChem dilakukan secara manual dengan mengunduh berkas bioesei dalam format .csv langsung dari repositori resmi PubChem BioAssay untuk masing-masing ID (AID 883, 884, dan 891). Berkas-berkas tersebut disimpan secara lokal untuk kemudian dimuat ke dalam *DataFrame* Python menggunakan pustaka *pandas*.

2. Data Cleaning & Labeling

Tahap ini bertujuan untuk menstandarisasi unit bioaktivitas dan menetapkan label klasifikasi pada masing-masing sumber data mentah. Pada *dataset* ChEMBL, dilakukan prosedur Prioritas Potensi (*Sorting by Potency*) dengan mengurutkan data berdasarkan nilai IC_{50} terkecil guna mengutamakan ligan dengan daya hambat terkuat jika ditemukan duplikasi struktur. Transformasi nilai kontinu ChEMBL menjadi label biner kemudian direalisasikan melalui metode Smart Labeling untuk menangani operator relasi kimia ($<$, $>$, $=$, $\leq$, $\geq$) sesuai dengan ambang batas 10.000 nM.

Sementara itu, pada *dataset* PubChem, pelabelan dilakukan secara langsung dengan memetakan nilai string pada kolom *Activity Outcome* menjadi nilai biner. Senyawa berstatus "Active" dikonversi menjadi label 1, sedangkan "Inactive" menjadi label 0, dengan mengeliminasi data yang bersifat ambigu (*Inconclusive*). Prosedur pengurutan potensi senyawa untuk menjamin integritas data serta implementasi logika pelabelan cerdas (*smart labeling*) bagi kedua pangkalan data direalisasikan melalui Kode Program 2.

Kode Program 2: Implementasi Prioritas Potensi dan Pelabelan

```
# 1. ChEMBL: Sorting by Potency dan Smart Labeling
df_clean = df_raw.sort_values('standard_value', ascending=True)
df_clean = df_clean.drop_duplicates(subset=['canonical_smiles', 'target_name'],
keep='first')

def classify_activity_smart(row):
    val, rel = float(row['standard_value']),
    str(row['standard_relation']).strip()
    if rel in ['>', '>=']:
        return 0 if val >= 10000.0 else np.nan
    elif rel in ['<', '<=']:
        return 1 if val <= 10000.0 else np.nan
    else:
        return 1 if val <= 10000.0 else 0

# 2. PubChem: Direct Mapping Label Biner
df_temp['status'] = df_temp['PUBCHEM_ACTIVITY_OUTCOME'].map({'Active': 1,
'Inactive': 0})
```

3. Audit Struktur dan Integrasi Data

Setelah pelabelan awal, dilakukan Audit Struktur Molekuler untuk menjamin relevansi biologis ligan menggunakan pustaka RDKit. Proses ini direalisasikan melalui fungsi *clean_and_canonicalize* yang melakukan penghapusan fragmen garam, pembersihan valensi, serta pembatasan berat molekul dalam rentang 100 Da hingga 1000 Da guna mengeliminasi molekul yang tidak relevan dengan profil metabolisme enzim CYP450.

Selanjutnya, *dataset* dari ChEMBL dan PubChem disatukan melalui proses integrasi data. Pada tahap ini, diimplementasikan prosedur resolusi konflik untuk mendeteksi adanya struktur SMILES identik yang memiliki label aktivitas berbeda di kedua database tersebut. Untuk menjaga konsensus data yang akurat, molekul yang bersifat kontradiktif tersebut dihapus sepenuhnya dari *dataset* final. Realisasi fungsi audit struktur molekuler guna menjamin validitas kimiawi ligan serta mekanisme integrasi *dataset* yang disertai dengan resolusi konflik label dipaparkan pada Kode Program 3.

Kode Program 3: Realisasi Audit Struktur dan Integrasi *Dataset*

```
# 1. Fungsi Audit Struktur (Salt Removal & BM Filter)
def clean_and_canonicalize(smiles):
    mol = Chem.MolFromSmiles(smiles)
    if mol is None: return None
    frags = Chem.GetMolFrags(mol, asMols=True)
    mol = max(frags, default=mol, key=lambda m: m.GetNumAtoms())
    mw = Descriptors.MolWt(mol)
    if 100 <= mw <= 1000:
        return Chem.MolToSmiles(mol, canonical=True)
    return None

# 2. Integrasi dan Resolusi Konflik Label
df_combined = pd.concat([df_chembl_master, df_pubchem_clean],
                        ignore_index=True)
conflicts = df_combined.groupby('clean_smiles')['status'].nunique()
conflict_smiles = conflicts[conflicts > 1].index
df_final = df_combined[~df_combined['clean_smiles'].isin(conflict_smiles)]
```

4. Ekstraksi Fitur Hybrid

Setelah diperoleh *dataset* yang bersih dan konsisten, tahap selanjutnya adalah merealisasikan transformasi struktur kimia menjadi vektor numerik. Implementasi ini menggunakan strategi *Hybrid Fingerprint* yang mensinergikan dua kategori deskriptor untuk mendapatkan daya deskripsi fitur yang optimal.

Sistem mengekstraksi Morgan *Fingerprint* dengan radius 2 (setara ECFP4) sepanjang 2048 bit untuk menangkap topologi lingkungan atom secara sirkular. Secara simultan, diintegrasikan MACCS *Keys* sebanyak 167 bit sebagai deskriptor berbasis kunci struktural untuk mengidentifikasi gugus fungsi spesifik. Penggabungan keduanya menghasilkan dimensi fitur total sebesar 2215 bit. Tahapan transformasi notasi SMILES menjadi representasi fitur digital biner berbasis strategi hibrida (2215-bit) diimplementasikan sesuai ditunjukkan pada Kode Program 4.

Kode Program 4: Implementasi Ekstraksi Fitur Hybrid (2215-bit)

```
def generate_hybrid_fp(smiles):
    mol = Chem.MolFromSmiles(smiles)
    if mol:
        # Morgan Fingerprint (2048 bit)
        morgan = AllChem.GetMorganFingerprintAsBitVect(mol, 2, nBits=2048)
        # MACCS Keys (167 bit)
        maccs = AllChem.GetMACCSKeysFingerprint(mol)
        return list(morgan) + list(maccs)
    return None
```

5. Data Splitting

Realisasi pembagian data dilakukan secara otomatis menggunakan teknik *Stratified Random Sampling*. Proporsi yang ditetapkan adalah 80% untuk data latih dan 20% untuk data uji. Penggunaan parameter *stratify* sangat krusial untuk memastikan distribusi kelas inhibitor dan non-inhibitor tetap seimbang dan representatif antara kedua himpunan data, mengingat karakteristik *dataset* asli yang cenderung tidak seimbang (*imbalanced*). Mekanisme pembagian data tersebut ditunjukkan pada Kode Program 5.

Kode Program 5: Implementasi *Stratified Splitting*

```
from sklearn.model_selection import train_test_split

# Pembagian data 80:20 dengan menjaga rasio label
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42
)
```

6. Modeling

Tahap ini merupakan realisasi dari fase *Modeling* yang bertujuan untuk menemukan arsitektur model terbaik bagi masing-masing isoenzim (CYP2C9, 2D6, dan 3A4) melalui pengujian terhadap tiga algoritma kandidat: *Random Forest*, *Support Vector Machine* (SVM), dan XGBoost. Implementasi koding pada tahap ini mengintegrasikan penyeimbangan data (SMOTE), validasi silang (*5-Fold Cross Validation*), dan optimasi otomatis menggunakan *framework* Optuna untuk setiap algoritma.

Langkah pertama adalah Definisi Ruang Pencarian (*Search Space*) dan Fungsi Obyektif. Meskipun setiap algoritma memiliki parameter yang berbeda (seperti *n_estimators* pada *Random Forest* atau *c* pada SVM), alur optimasi tetap menggunakan *pipeline* yang seragam. Di dalam setiap iterasi Optuna, dilakukan pembagian data latih menjadi 5 lipatan menggunakan *stratifiedKFold*. Teknik SMOTE hanya diterapkan pada lipatan pelatihan untuk mencegah kebocoran data, sementara model dilatih dan dievaluasi menggunakan metrik AUC untuk menentukan parameter terbaik. Realisasi logika integrasi SMOTE dan CV dalam fungsi obyektif (dengan algoritma XGBoost ditetapkan sebagai contoh representasi visual logika fungsi) ditunjukkan pada Kode Program 6.

Kode Program 6: Fungsi Obyektif Optimasi Model dengan Integrasi SMOTE dan CV

```
def objective(trial):
    # 1. Penentuan Search Space |Disesuaikan untuk RF, SVM, atau XGB|
    # Contoh untuk XGBoost:
    param = (
        'n_estimators': trial.suggest_int('n_estimators', 100, 1000),
        'max_depth': trial.suggest_int('max_depth', 3, 15),
        'learning_rate': trial.suggest_float('learning_rate', 1e-3, 0.3,
log=True)
    )

    # 2. Skema 5-Fold Cross Validation yang Seragam untuk Semua Algoritma
    skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
    auc_scores = []
```

Kode Program 7: Fungsi Obyektif Optimasi Model dengan Integrasi SMOTE dan CV (Lanjutan)

```
for train_idx, val_idx in skf.split(X_train, y_train):
    X_tr, X_val = X_train.iloc[train_idx], X_train.iloc[val_idx]
    y_tr, y_val = y_train.iloc[train_idx], y_train.iloc[val_idx]

    # 3. SMOTE pada Training Fold
    smote = SMOTE(random_state=42)
    X_tr_res, y_tr_res = smote.fit_resample(X_tr, y_tr)

    # 4. Pelatihan Model (Algoritma dipilih secara bergantian: RF/SVM/XGB)
    model = XGBClassifier(**param)
    model.fit(X_tr_res, y_tr_res)

    preds = model.predict_proba(X_val)[:, 1]
    auc_scores.append(roc_auc_score(y_val, preds))

return np.mean(auc_scores)
```

Langkah terakhir adalah *Model Serialization*. Setelah Optuna menemukan kombinasi parameter terbaik, model tersebut dilatih ulang pada seluruh *dataset* pelatihan yang telah diseimbangkan, kemudian disimpan dalam format file `.pkl` menggunakan pustaka `joblib`. Hal ini bertujuan agar paket model (termasuk daftar fitur dan parameter terbaik) dapat dipanggil kembali secara dinamis pada tahap *deployment*. Implementasi kode untuk pelatihan ulang model dengan parameter terbaik dan menyimpan paket modelnya sesuai pada Kode Program 8.

Kode Program 8: Pelatihan Ulang Model Terbaik dan Penyimpanan Paket Model

```
# Pelatihan model dengan parameter terbaik dari hasil optimasi
final_model = XGBClassifier(**best_params)
final_pipeline = Pipeline([
    ('smote', SMOTE(random_state=42)),
    ('classifier', final_model)
])
final_pipeline.fit(X_train, y_train)

# Penyimpanan paket model untuk kebutuhan deployment
model_package = {
    'model': final_pipeline,
    'features': X_train.columns.tolist(),
    'best_params': best_params
}
joblib.dump(model_package, f'XGB_Model_(target)_Final.pkl')
```

7. *Evaluation & Threshold Decision optimization*

Tahap ini merupakan realisasi dari fase *Evaluation* yang bertujuan untuk mengukur reliabilitas model dan menentukan titik potong (*cut-off*) probabilitas yang paling seimbang. Implementasi ini mencakup penghitungan metrik performa standar serta pencarian nilai ambang batas optimal melalui Indeks Youden guna memaksimalkan deteksi pada kedua kelas ligan.

Sistem diinstruksikan untuk mengevaluasi model berdasarkan 6 metrik utama, yaitu: Akurasi, Presisi, Sensitivitas (Recall), Spesifisitas, *Matthews Correlation Coefficient*

(MCC), dan ROC-AUC. Penghitungan diawali dengan mengekstraksi nilai probabilitas prediksi, kemudian dilakukan analisis kurva ROC untuk menghitung Indeks Youden ($J = \text{Sensitivitas} + \text{Spesifisitas} - 1$). Ambang batas yang menghasilkan nilai J tertinggi ditetapkan sebagai titik potong optimal untuk klasifikasi final. Penyesuaian ambang batas ini krusial karena model tidak lagi menggunakan nilai default 0.5, melainkan bergeser menuju titik keseimbangan antara deteksi inhibitor dan non-inhibitor. Implementasi penghitungan metrik evaluasi dan optimasi ambang batas ini direalisasikan melalui Kode Program 9.

Kode Program 9: Implementasi Penghitungan Metrik Evaluasi Kinerja

```
from sklearn.metrics import accuracy_score, precision_score, recall_score,
confusion_matrix, roc_curve, matthews_corrcoef, roc_auc_score

# 1. Mendapatkan probabilitas prediksi dari model terbaik
y_probs = model.predict_proba(X_test)[: , 1]

# 2. Mencari Ambang Batas Optimal (Youden's J Index)
fpr, tpr, thresholds = roc_curve(y_test, y_probs)
j_scores = tpr - fpr
best_threshold = thresholds[np.argmax(j_scores)]

# 3. Klasifikasi menggunakan Ambang Batas Hasil Optimasi
y_pred_tuned = (y_probs >= best_threshold).astype(int)

# 4. Penghitungan Metrik Utama
acc = accuracy_score(y_test, y_pred_tuned)
pre = precision_score(y_test, y_pred_tuned)
sen = recall_score(y_test, y_pred_tuned)      # Sensitivity
tn, fp, fn, tp = confusion_matrix(y_test, y_pred_tuned).ravel()
spe = tn / (tn + fp)                        # Specificity
mcc = matthews_corrcoef(y_test, y_pred_tuned)
auc = roc_auc_score(y_test, y_probs)

# 5. Output Laporan performa
print(f"Optimal Threshold: (best_threshold:.4f)")
print(f"Accuracy: (acc:.4f) | Precision: (pre:.4f) | Sensitivity: (sen:.4f)")
print(f"Specificity: (spe:.4f) | MCC: (mcc:.4f) | ROC-AUC: (auc:.4f)")
```

8. Interpretation

Setelah model divalidasi memiliki performa yang baik, tahap selanjutnya adalah mengimplementasikan metode *Explainable AI* (XAI) menggunakan SHAP (*SHapley Additive exPlanations*). Tahap ini krusial untuk menjawab aspek "transparansi" model dengan membedah kontribusi masing-masing bit fingerprint terhadap keputusan prediksi.

Implementasi dilakukan dengan menggunakan modul `shap.TreeExplainer` untuk algoritma berbasis pohon (XGBoost dan *Random Forest*) atau `shap.KernelExplainer` untuk SVM. Sistem menghitung nilai SHAP untuk setiap fitur pada seluruh sampel data uji guna menghasilkan Global Summary Plot. Hal ini memungkinkan identifikasi fitur kimia mana yang paling dominan dalam mendorong senyawa menjadi bersifat inhibitor atau non-inhibitor. Prosedur implementasi interpretasi SHAP ini dipaparkan pada Kode Program 10.

Kode Program 10: Implementasi Analisis SHAP untuk Interpretasi Fitur

```
import shap
# 1. Inisialisasi Explainer SHAP
explainer = shap.TreeExplainer(model)
shap_values = explainer.shap_values(X_test)
# 2. Visualisasi Summary Plot (Interpretasi Global)
shap.summary_plot(shap_values, X_test, plot_type="bar")
# 3. Visualisasi Beeswarm Plot
shap.plots.beeswarm(explainer|X_test|)
```

9. Deployment

Tahap akhir implementasi dalam kerangka kerja CRISP-DM adalah transformasi model prediktif eksperimental menjadi artefak operasional melalui proses *model serialization*. Realisasi tahap ini dilakukan dengan menyimpan seluruh bobot, arsitektur, dan parameter optimal dari model final terbaik (XGBoost) ke dalam format biner terkompresi dengan ekstensi .pkl menggunakan pustaka joblib.

Untuk menjamin bahwa model biner tersebut bersifat *reusable*, dibangun sebuah skrip prediksi berbasis Python yang dijalankan langsung di dalam lingkungan Jupyter Notebook. Kode ini mengintegrasikan fungsi validasi struktur kimia RDKit, otomatisasi ekstraksi *hybrid fingerprint* 2215-bit, serta kalkulasi klasifikasi berdasarkan *decision threshold* Youden secara simultan untuk ketiga target isoenzim. Struktur logika utama dari skrip pemanggilan model ini ditunjukkan pada Kode Program 11.

Kode Program 11: Pemanggilan Model dan Prediksi Senyawa

```
def execute_virtual_screening(smiles_input):
    mol = Chem.MolFromSmiles(smiles_input)
    if mol is None:
        return "Error: Notasi SMILES tidak valid secara kimiawi."

    features = generate_hybrid_fp(mol)
    screening_results = {}
    for target in TARGETS:
        prob = models[target]['model'].predict_proba(features)[0][1]

        status = "INHIBITOR" if prob >= THRESHOLDS[target] else "Non-Inhibitor"
        screening_results[target] = ('Status': status, 'Probability':
round(prob, 4))

    return screening_results
```

4.2 Hasil

Bab ini menyajikan laporan hasil pelaksanaan eksperimen berdasarkan metodologi yang telah dipaparkan pada Bab III. Uraian pada bagian ini mencakup hasil penyiapan *dataset*, performa optimasi *hyperparameter*, evaluasi komparatif algoritma, hingga interpretasi fitur kimia melalui analisis SHAP. Seluruh temuan disajikan secara sistematis untuk menjawab rumusan masalah penelitian.

4.2.1 Data Preparation

Penyiapan *dataset* merupakan tahapan krusial yang menentukan kualitas model prediktif. Hasil dari tahap ini mencakup data statistik akuisisi dari pangkalan data primer serta rincian penyusutan data selama proses filtrasi dan integrasi berlangsung.

1. Hasil Akuisisi Data Mentah

Proses akuisisi data berhasil menarik total 48.306 baris data bioaktivitas mentah dari dua sumber utama, yaitu ChEMBL dan PubChem. Data dari ChEMBL ditarik melalui kueri SQL pada database lokal, sedangkan data PubChem diperoleh melalui pengunduhan berkas bioesei (AID 883, 891, 884). Ringkasan jumlah data awal untuk setiap isoenzim target disajikan pada Tabel 4.4.

Tabel 4.3 Ringkasan hasil akuisisi data mentah (*raw data*)


Sumber Data	CYP2C9	CYP2D6	CYP3A4
ChEMBL	4.955	5.183	9.428
PubChem	10.321	10.321	14.156
Total Per Target	15.276	15.504	23.584

2. Hasil Filtrasi dan Integrasi Data

Data mentah yang telah diperoleh kemudian melewati serangkaian prosedur pembersihan teknis dan audit struktural. Pada *dataset* ChEMBL, dilakukan prosedur *Sorting by Potency* dan penghapusan nilai kosong, yang menyisihkan 16.910 baris data bersih. Selanjutnya, melalui metode *Smart Labeling*, sebanyak 503 data ChEMBL dibuang karena memiliki relasi aktivitas yang ambigu.

Pada *dataset* PubChem, penyaringan difokuskan pada pembuangan data berstatus "*Inconclusive*", di mana sebanyak 6.058 baris data dari seluruh target dieliminasi. Tahap krusial berikutnya adalah Audit Struktur Molekuler, di mana dilakukan pembersihan garam dan filtrasi berat molekul. Pada tahap ini, ditemukan sebanyak 2.420 senyawa duplikat tersembunyi pada PubChem dan 12 pada ChEMBL yang kemudian dihapus. Sedangkan senyawa yang gagal lolos dari audit struktur molekuler ini sebanyak 406 senyawa dari PubChem dan 42 dari ChEMBL.

Setelah *dataset* dari kedua sumber diintegrasikan, dilakukan prosedur Resolusi Konflik. Ditemukan sebanyak 35 molekul kontradiktif (memiliki label berbeda di ChEMBL dan PubChem) yang dihapus sepenuhnya guna menjaga konsensus aktivitas. Hasil akhir integrasi data disajikan pada Gambar 4.1.



Gambar 4.1 Distribusi kelas inhibitor vs non-inhibitor setelah integrasi

Berdasarkan visualisasi pada Gambar 4.1, terlihat adanya ketidakseimbangan kelas (*class imbalance*) yang signifikan pada ketiga target, di mana jumlah senyawa Non-Inhibitor (0) jauh lebih mendominasi dibandingkan senyawa Inhibitor (1). Hal ini menjustifikasi penggunaan teknik SMOTE pada tahap pemodelan nantinya. Komposisi akhir *dataset* dan dimensi matriks fitur setelah ekstraksi *Hybrid Fingerprint* dirangkum dalam Tabel 4.5.

Tabel 4.4 Komposisi *dataset* final

Target	Inhibitor (1)	Non-Inhibitor (0)	Total Data Final
CYP2C9	2.681	9.728	12.409
CYP2D6	2.842	9.492	12.334
CYP3A4	6.211	11.152	17.363

4.2.2 Modeling

Tahap ini menyajikan hasil dari pencarian parameter optimal menggunakan framework Optuna untuk ketiga algoritma kandidat: *Random Forest* (RF), *Support Vector Machine* (SVM), dan *Extreme Gradient Boosting* (XGBoost). Setiap algoritma dioptimasi secara independen melalui 50 iterasi (*trials*) untuk memastikan performa maksimal pada masing-masing target isoenzim.

1. Analisis Performa Validasi dan Pemenang Sementara

Proses optimasi dijalankan sebanyak 50 *trials* untuk setiap kombinasi model dan target. Algoritma Random Forest dan XGBoost menggunakan keseluruhan dataset pelatihan untuk proses pencarian parameter. Namun, pada algoritma SVM, diterapkan strategi *Pivoting Subset Strategis* sebesar 20% dari *dataset* pelatihan melalui *stratified random sampling* untuk tahap pencarian parameter.


Keputusan untuk menggunakan strategi *Pivoting Subset Strategis* pada SVM didasarkan pada uji coba awal (*preliminary test*) menggunakan *dataset* penuh (100%), di mana proses optimasi memerlukan waktu hingga 415 menit hanya untuk menyelesaikan 2 trials. Hal ini menunjukkan bahwa penggunaan SVM pada ruang fitur 2215-bit tidak efisien secara komputasi untuk *dataset* penelitian ini. Durasi eksekusi dari strategi ini dirangkum dalam Tabel 4.6.

Tabel 4.5 Durasi eksekusi optimasi *hyperparameter* (50 trials)

Target Isoenzim	Strategi Data	CYP2C9	CYP2D6	CYP3A4
Random Forest	<i>Full Dataset</i> (100%)	92.1 Menit	47.3 Menit	80.9 Menit
SVM	<i>Subset Tuning</i> (20%)	7.33 Menit	7.01 Menit	9.96 Menit
XGBoost	<i>Full Dataset</i> (100%)	29.64 Menit	18.36 Menit	23.80 Menit

2. Analisis Konvergensi melalui Riwayat Optimasi

Proses pencarian parameter oleh Optuna dipantau melalui grafik *Optimization History*. Gambar 4.2 menunjukkan riwayat optimasi untuk salah satu target (misalnya CYP3A4) yang merepresentasikan konvergensi model.



Gambar 4.2 Riwayat optimasi AUC (representasi XGBoost pada CYP3A4)

Grafik pada Gambar 4.2 memperlihatkan bahwa nilai AUC mulai mencapai titik jenuh (*plateau*) setelah melewati iterasi ke-30 hingga ke-40. Hal ini membuktikan bahwa batas 50 trials yang ditetapkan sudah cukup bagi algoritma *Tree-structured Parzen Estimator* (TPE) untuk menemukan area parameter optimal di dalam ruang pencarian yang luas. Untuk grafik lengkap riwayat optimasi optuna semua algoritma dan target dapat dilihat pada Lampiran B.

3. Perbandingan Performa Validasi Terbaik

Rekapitulasi nilai AUC validasi tertinggi dari seluruh percobaan optimasi disajikan pada Tabel 4.7. Penggunaan metrik ROC-AUC pada tahap ini dipilih karena sifatnya yang threshold-invariant, sehingga fokus optimasi adalah pada kemampuan fundamental model dalam memisahkan kelas ligan inhibitor dan non-inhibitor sebelum penetapan ambang batas final.

Tabel 4.6 Ringkasan skor AUC validasi terbaik hasil optimasi Optuna

Target Isoenzim	Random Forest	SVM (Subset 20%)	XGBoost
CYP2C9	0.8606	0.8012	0.8570
CYP2D6	0.8854	0.7875	0.8866
CYP3A4	0.9062	0.8364	0.9033

Skor AUC validasi terbaik pada Tabel 4.7 menunjukkan bahwa model berbasis *tree* (*Random Forest* dan XGBoost) memiliki kemampuan diskriminasi yang lebih unggul pada fitur berdimensi tinggi (2215-bit) dibandingkan model berbasis vektor (SVM). Hal ini mengindikasikan bahwa perlakuan optimasi melalui Optuna berhasil mengeksplorasi ruang parameter algoritma ensemble secara lebih efektif guna menangani karakteristik data yang sparse.

4.2.3 Evaluation

Tahap evaluasi komparatif bertujuan untuk menguji daya generalisasi model menggunakan data uji (*test set*) yang belum pernah dilihat sebelumnya oleh model. Pada bagian ini, kinerja algoritma *Random Forest*, SVM, dan XGBoost disandingkan secara statistik untuk menentukan arsitektur terbaik yang akan diimplementasikan ke dalam sistem prediksi.

1. Analisis Performa Sebelum dan Sesudah Optimasi Ambang Batas

Sebagai tahap awal, evaluasi dilakukan menggunakan ambang batas standar (*default threshold*) sebesar 0,5. Berdasarkan hasil pada Tabel 4.8, terlihat adanya kecenderungan model yang bias terhadap kelas mayoritas. Hal ini ditandai dengan nilai Spesifisitas yang sangat dominan (di atas 0,90), namun kontras dengan nilai Sensitivitas yang relatif rendah. Kondisi ini menunjukkan bahwa pada pengaturan *default*, model sangat andal dalam mendeteksi senyawa non-inhibitor, tetapi sering kali gagal mengidentifikasi senyawa yang sebenarnya bersifat inhibitor. Perbandingan performa algoritma sebelum dilakukan optimasi ambang batas disajikan pada Tabel 4.8.

Rendahnya nilai Sensitivitas pada Tabel 4.8 memberikan justifikasi kuat bahwa ambang batas 0,5 tidak ideal untuk dataset bioaktivitas yang tidak seimbang (*imbalanced*). Oleh karena itu, diperlukan optimasi ambang batas untuk meningkatkan daya deteksi model terhadap kelas inhibitor.

Tabel 4.7 Perbandingan performa algoritma pada data uji (sebelum optimasi ambang batas)

Target	Algoritma	AUC	MCC	Acc	Sen	Spe	Pre
CYP2C9	RF	0,8783	0,5368	0,8565	0,5731	0,9299	0,6790
	SVM	0,8798	0,5473	0,8634	0,5420	0,9466	0,7244
	XGB	0,8815	0,5684	0,8644	0,6139	0,9292	0,6919
CYP2D6	RF	0,8889	0,5851	0,8564	0,6623	0,9135	0,6925
	SVM	0,8851	0,6212	0,8733	0,6405	0,9417	0,7636
	XGB	0,8956	0,6058	0,8649	0,6667	0,9231	0,7183
CYP3A4	RF	0,9055	0,6532	0,8398	0,7737	0,8777	0,7838
	SVM	0,9062	0,6378	0,8344	0,7358	0,8909	0,7944
	XGB	0,9044	0,6500	0,8376	0,7807	0,8703	0,7752

2. Perbandingan Metrik Performa Final

Untuk mengatasi bias kelas mayoritas, dilakukan pencarian ambang batas optimal menggunakan Indeks Youden. Hasil optimasi ini menunjukkan perubahan signifikan pada profil performa model, sebagaimana disajikan pada Tabel 4.9. Penggunaan ambang batas yang lebih rendah (seperti 0,1779 pada XGB-CYP2C9) berhasil mendorong nilai Sensitivitas secara drastis dari 0,6139 menjadi 0,7913.


Meskipun strategi ini menyebabkan penurunan tipis pada akurasi global dan spesifisitas, namun nilai MCC (*Matthews Correlation Coefficient*) tetap terjaga pada rentang yang kredibel. Hal ini membuktikan bahwa model menjadi lebih responsif dan adil dalam mengenali kedua kelas ligan.

Tabel 4.8 Perbandingan performa algoritma pada data uji (setelah optimasi ambang batas)


Target	Algoritma	Threshold	AUC	MCC	Acc	Sen	Spe	Pre
CYP2C9	RF	0,3082	0.8783	0.5295	0.8077	0.7986	0.8101	0.5211
	SVM	0,0458	0.8798	0.5363	0.8141	0.7914	0.8200	0.5323
	XGB	0,1779	0.8815	0.5387	0.8156	0.7914	0.8218	0.5348
CYP2D6	RF	0,3673	0.8889	0.5766	0.8282	0.7974	0.8373	0.5903
	SVM	0,0907	0.8851	0.5800	0.8302	0.7974	0.8398	0.5942
	XGB	0,1884	0.8956	0.5836	0.8292	0.8105	0.8347	0.5905
CYP3A4	RF	0,4350	0.9055	0.6524	0.8333	0.8335	0.8331	0.7411
	SVM	0,2155	0.9062	0.6387	0.8224	0.8534	0.8046	0.7145
	XGB	0,4764	0.9044	0.6540	0.8380	0.8006	0.8594	0.7655

3. Analisis Visual Kurva ROC


Kemampuan diskriminasi model juga dianalisis melalui kurva *Receiver Operating Characteristic* (ROC) untuk melihat kemampuan model dalam membedakan kelas tanpa bergantung pada satu nilai ambang batas saja. Gambar 4.3, 4.4, dan 4.5 memperlihatkan plot kurva ROC komparatif untuk masing-masing target. Berdasarkan grafik tersebut, terlihat bahwa ketiga algoritma memiliki area di bawah kurva (AUC) yang sangat kompetitif, berada pada rentang 0,87 hingga 0,90, yang mengindikasikan performa klasifikasi yang sangat baik (*excellent classification*).



Gambar 4.3 Kurva ROC komparatif target CYP2C9



Gambar 4.4 Kurva ROC komparatif target CYP2D6



Gambar 4.5 Kurva ROC komparatif target CYP3A4

Secara visual pada Gambar 4.4 (Target CYP2D6), kurva XGBoost (garis hijau) terlihat lebih dominan mendekati sudut kiri atas dibandingkan algoritma lainnya. Hal ini selaras dengan perolehan nilai AUC numerik pada Tabel 4.9 yang mencapai 0,8956, mengungguli *Random Forest* (0,8889) dan *SVM* (0,8851). Dominasi visual ini mengonfirmasi bahwa XGBoost memiliki stabilitas yang lebih baik dalam memisahkan ligan inhibitor dari non-inhibitor pada berbagai variasi titik potong.

4. Penentuan Algoritma Terbaik untuk *Deployment*

Berdasarkan evaluasi komprehensif pada Tabel 4.9, XGBoost ditetapkan sebagai algoritma final yang dipilih untuk proses *deployment*. Keputusan ini didasarkan pada superioritas XGBoost dalam metrik MCC yang secara konsisten memuncaki klasemen pada ketiga target (0,5387 pada CYP2C9; 0,5836 pada CYP2D6, dan 0,6540 pada CYP3A4). Mengingat MCC merupakan metrik paling reliabel untuk *dataset* tidak seimbang, pencapaian ini membuktikan bahwa XGBoost memiliki keseimbangan prediksi terbaik. Selain itu, XGBoost menunjukkan distribusi kesalahan yang paling terkendali, di mana model mampu meminimalkan *false negative* (melewatkan inhibitor berbahaya) tanpa menyebabkan lonjakan *false positive* yang ekstrem. Kombinasi performa superior, stabilitas AUC, dan efisiensi komputasi menjadikan XGBoost sebagai pilihan paling rasional untuk *virtual screening* skala besar.

5. Observasi Kesalahan Prediksi (*Error Cases*)

Sebagai bentuk evaluasi kritis terhadap batasan model yang telah terpilih, dilakukan identifikasi terhadap beberapa senyawa yang gagal diprediksi secara tepat oleh model XGBoost. Identifikasi ini sangat penting untuk memahami *applicability domain* dari model

yang dikembangkan. Temuan beberapa kasus kesalahan prediksi (*false negative*) dirangkum dalam Tabel 4.10.

Tabel 4.9 Contoh senyawa dengan kesalahan prediksi (*false negative*)

Target	Nama Senyawa	Status Asli	Hasil Prediksi	Probabilitas	Threshold
CYP2C9	Fluvastatin	Inhibitor	Non-Inhibitor	0.0016	0.1779
CYP2D6	Diltiazem	Inhibitor	Non-Inhibitor	0.0204	0.1884
CYP3A4	Diltiazem	Inhibitor	Non-Inhibitor	0.3807	0.4764

Data pada Tabel 4.10 menunjukkan adanya ligan seperti Fluvastatin dan Diltiazem yang memiliki probabilitas prediksi sangat rendah meskipun secara riil berstatus inhibitor. Kegagalan identifikasi pada senyawa-senyawa ini akan dibahas lebih mendalam pada Bab 4.3 guna menelaah keterkaitan antara fitur struktural molekul dengan batasan logika model.

4.2.4 Interpretation

Interpretasi model dilakukan untuk membedah mekanisme pengambilan keputusan algoritma XGBoost melalui metode *Shapley Additive Explanations* (SHAP). Tahap ini bertujuan untuk memetakan hubungan antara fitur kimiawi (*fingerprint*) dengan probabilitas suatu senyawa menjadi inhibitor pada enzim CYP2C9, CYP2D6, dan CYP3A4.

1. Analisis Kepentingan Fitur Global

Berdasarkan ekstraksi nilai SHAP, ditemukan beberapa fitur kunci yang secara konsisten menjadi penentu utama dalam klasifikasi inhibitor pada ketiga target isoenzim. Ringkasan lima fitur teratas untuk setiap target disajikan pada Tabel 4.11.


Tabel 4.10 Ringkasan fitur teratas setiap target

Target	Fitur (Bit ID)	Deskripsi Fragment Kimia	Skor SHAP
CYP2C9	Bit_MACCS_125	<i>Aromatic Ring</i> > 1	0.5739
	Bit_MACCS_86	CH ₂ QCH ₂ (<i>Ether/Thioether linkage</i>)	0.2435
	Bit_Morgan_389	Fragmen Morgan (Konektivitas Atom)	0.2235
	Bit_MACCS_145	<i>6-Membered Ring</i> > 1	0.2224
	Bit_MACCS_89	S (Sulfur atom)	0.1629
CYP2D6	Bit_Morgan_314	Fragmen Morgan (Konektivitas Atom)	0.2641
	Bit_Morgan_650	Fragmen Morgan (Konektivitas Atom)	0.1946
	Bit_MACCS_146	O (<i>Oxygen atom</i>) > 2	0.1943
	Bit_MACCS_145	<i>6-Membered Ring</i> > 1	0.1841
	Bit_MACCS_154	C=O (<i>Carbonyl group</i>)	0.1450
CYP3A4	Bit_MACCS_145	<i>6-Membered Ring</i> > 1	0.2814
	Bit_MACCS_125	<i>Aromatic Ring</i> > 1	0.2237
	Bit_MACCS_139	OH (<i>Hydroxyl group</i>)	0.1969
	Bit_Morgan_1603	Fragmen Morgan (Konektivitas Atom)	0.1895
	Bit_Morgan_389	Fragmen Morgan (Konektivitas Atom)	0.1611


Detail mengenai penjelasan fitur bit MACCS dapat dilihat secara lebih lengkap pada Lampiran A.

2. Analisis Arah Kontribusi Fitur (*Beeswarm Plot*)


Selain tingkat kepentingan, analisis SHAP memberikan gambaran distribusi pengaruh fitur melalui *Beeswarm Plot*. Pada plot ini, setiap titik mewakili satu sampel data, di mana warna merah menunjukkan nilai fitur yang tinggi (kehadiran bit/fragmen) dan warna biru menunjukkan nilai fitur yang rendah (ketidakhadiran bit/fragmen). Posisi titik pada sisi kanan sumbu nol mengindikasikan kontribusi positif terhadap prediksi inhibitor, sedangkan sisi kiri mengindikasikan kontribusi negatif. Gambar 4.6, 4.7, dan 4.8 menyajikan *Beeswarm Plot* yang menunjukkan distribusi pengaruh setiap fitur.



Gambar 4.6 Plot SHAP *beeswarm* target CYP2C9



Gambar 4.7 Plot SHAP *beeswarm* target CYP2D6



Gambar 4.8 Plot SHAP *beeswarm* target CYP3A4


Berdasarkan grafik di atas, fitur Bit_MACCS_125 (*Aromatic Ring* > 1) menunjukkan korelasi positif yang kuat (titik merah berada di sisi kanan sumbu nol). Hal ini mengindikasikan bahwa keberadaan lebih dari satu cincin aromatik dalam sebuah molekul secara signifikan meningkatkan peluang senyawa tersebut diprediksi sebagai inhibitor. Fenomena ini selaras dengan literatur farmakologi yang menyebutkan bahwa situs aktif enzim P450 umumnya bersifat hidrofobik dan memiliki afinitas tinggi terhadap senyawa planar aromatik. Sebaliknya, pada CYP3A4, keberadaan Bit_MACCS_139 (OH) cenderung memberikan kontribusi negatif pada beberapa kasus, yang menurunkan potensi inhibisi

molekul tersebut. Grafik *Beeswarm Plot* hasil SHAP untuk algoritma yang lain dapat dilihat pada Lampiran C.

3. Interpretasi Lokal: Studi Kasus Amlodipine


Untuk memvalidasi kemampuan model dalam menangkap representasi struktural yang relevan secara farmakologi, dilakukan analisis interpretasi lokal terhadap senyawa Amlodipine. Pemilihan Amlodipine didasarkan pada statusnya sebagai obat penghambat saluran kalsium (*calcium channel blocker*) yang digunakan secara luas dalam terapi hipertensi, serta perannya yang telah teruji secara klinis sebagai inhibitor bagi enzim CYP3A4.

Amlodipine memiliki rumus kimia $C_{20}H_{25}ClN_2O_5$ dengan notasi SMILES sebagai berikut: CCOC(=O)c1=c(c(occcN)NC(c)=c(c1c2=cc=cc=c2c1)c(=O)OC. Struktur dasar dari senyawa ini, yang memperlihatkan kerangka dihidropiridin dan cincin aromatik berklorin, disajikan pada Gambar 4.9 sebagai referensi visual sebelum dilakukan pemetaan fitur.



Gambar 4.9 Struktur 2D senyawa amlodipine

Tahap selanjutnya adalah membedah mekanisme pengambilan keputusan model XGBoost melalui pemetaan fitur *hybrid* yang terdiri dari *Morgan Fingerprint* dan *MACCS Keys*. Berdasarkan hasil ekstraksi nilai SHAP lokal, ditemukan enam fitur dominan yang memberikan kontribusi signifikan terhadap probabilitas prediksi kelas inhibitor. Fitur-fitur tersebut kemudian dipetakan secara spasial pada struktur molekul Amlodipine untuk melihat korelasi antara bobot statistik model dengan posisi atom secara nyata. Hasil pemetaan yang disajikan dalam bentuk galeri pada Gambar 4.10 menunjukkan bahwa model memberikan perhatian khusus pada beberapa area fungsional molekul.



Gambar 4.10 Pemetaan fitur dominan (top SHAP) pada struktur amlodipine

Hasil pemetaan pada Gambar 4.10 memperlihatkan bahwa model XGBoost memberikan penekanan yang sangat spesifik pada beberapa fragmen struktural krusial. Melalui fitur *Morgan Fingerprint*, model secara presisi menyoroti area cincin dihidropiridin beserta substituen karbonilnya melalui Bit_Morgan_1750, serta memetakan konektivitas pada rantai samping amina-etoksi melalui Bit_Morgan_807. Sorotan spesifik juga ditemukan pada Bit_Morgan_1152 yang mengidentifikasi lingkungan atom klorin pada posisi orto dari cincin fenil. Sementara itu, fitur fungsional global melalui *MACCS Keys* berhasil menangkap keberadaan sistem aromatik dan cincin beranggota enam melalui Bit_MACCS_125 dan Bit_MACCS_145. Hal yang menarik adalah model juga memberikan perhatian pada ketidakhadiran gugus hidroksil (OH) melalui Bit_MACCS_139, yang secara matematis dicatat sebagai kontribusi negatif yang memperkuat prediksi aktivitas inhibisi pada struktur Amlodipine.

Secara keseluruhan, pemetaan visual ini membuktikan bahwa XGBoost tidak hanya beroperasi sebagai algoritma *black box* yang mengandalkan korelasi statistik semata, melainkan mampu menangkap representasi struktural yang bermakna secara kimiawi. Keberhasilan model dalam menyoroti bagian-bagian krusial seperti cincin dihidropiridin dan aromatik memberikan tingkat transparansi (*explainability*) yang tinggi terhadap hasil prediksi yang dihasilkan oleh sistem.

4.2.5 Deployment

Tahap *deployment* menghasilkan luaran berupa file hasil *model serialization* dalam format biner terkompresi dengan ekstensi .pk1 untuk ketiga model isoenzim target. File biner tersebut berhasil disimpan ke dalam direktori lokal dan siap digunakan kembali untuk keperluan skrining senyawa di masa mendatang.

Untuk memastikan file biner tersebut dapat dimuat dan berfungsi dengan benar, dilakukan uji coba pemanggilan menggunakan kode Python pada Jupyter Notebook. Uji coba ini menggunakan senyawa Amlodipine sebagai data masukan untuk mensimulasikan proses prediksi pada data riil. Kode program berhasil memuat model, melakukan ekstraksi *hybrid fingerprint* 2215-bit, dan mengeluarkan hasil prediksi secara simultan dengan waktu eksekusi sebesar 1,5 detik. Hasil keluaran kode prediksi untuk senyawa Amlodipine ditampilkan pada Gambar 4.11.

```
=====
SENYAWA: Amlodipine
SMILES: CCOC(=O)C1=C(COCCN)NC(C)=C(C1C2=CC=CC=C2C1)C(=O)OC
=====

--- Tabel Hasil Prediksi Enzim ---
```

	Probability	Threshold	Prediction	Status
CYP2C9	0.0582	0.1779	0	Non-Inhibitor
CYP2D6	0.3411	0.1884	1	Inhibitor
CYP3A4	0.8798	0.4764	1	Inhibitor

```
Waktu Eksekusi Prediksi: 1.5 detik
```

Gambar 4.11 Tampilan keluaran kode prediksi senyawa Amlodipine pada Jupyter Notebook

Hasil pada Gambar 4.11 menunjukkan bahwa model biner mampu memberikan prediksi nilai probabilitas dan label status klasifikasi final secara simultan untuk target CYP2C9, CYP2D6, dan CYP3A4. Keberhasilan eksekusi ini membuktikan bahwa proses *model serialization* telah berjalan dengan sempurna tanpa ada kerusakan data, sehingga artefak komputasi yang dihasilkan dalam penelitian ini terbukti stabil dan siap digunakan untuk melakukan prediksi pada senyawa-senyawa baru.

4.3 Pembahasan

Bagian ini menyajikan analisis kritis dan interpretasi mendalam terhadap seluruh hasil eksperimen yang telah diperoleh guna menjawab rumusan masalah penelitian. Pembahasan ini tidak hanya berfokus pada pelaporan angka-angka performa secara administratif, melainkan mengidentifikasi kontribusi fitur-fitur utama dalam mekanisme pengambilan keputusan model pada koridor informatika medis dan kemoinformatika. Fokus utama diskusi diarahkan pada efektivitas arsitektur algoritma dalam menangani data bioaktivitas yang bersifat *high-dimensional sparse data*, signifikansi implementasi strategi *cost-sensitive learning* melalui *decision threshold optimization*, serta validasi temuan interpretasi fitur kimiawi menggunakan metode *Explainable AI* (XAI). Melalui sintesis antara bukti empiris dan teori pendukung dari berbagai studi terdahulu, bagian ini bertujuan untuk membuktikan bahwa kode program prediksi yang dikembangkan memiliki reliabilitas teknis dan relevansi praktis dalam mendukung proses skrining virtual senyawa inhibitor enzim sitokrom P450.

4.3.1 Analisis Komparatif Algoritma dalam Ruang Fitur Dimensi Tinggi

Evaluasi komparatif yang dilakukan pada data uji menunjukkan fenomena superioritas algoritma berbasis *tree-ensemble*, khususnya XGBoost, dibandingkan dengan *Support Vector Machine* (SVM) dan *Random Forest*. Berdasarkan observasi pada Tabel 4.9, terlihat bahwa XGBoost secara konsisten memuncaki performa pada ketiga target isoenzim, dengan capaian metrik MCC tertinggi pada target CYP3A4 sebesar 0,6540. Secara teknis, keberhasilan ini dipengaruhi oleh karakteristik *dataset* yang digunakan, di mana penggunaan fitur hibrida (*Morgan fingerprint* dan *MACCS keys*) menghasilkan matriks data berdimensi 2215-bit yang bersifat sangat renggang (*sparse*). Keunggulan penggunaan fitur hibrida ini sejalan dengan temuan Zahid *et al.* (2024) yang menyatakan bahwa kombinasi properti molekuler dan substruktural mampu memberikan hasil prediksi yang kompetitif dibandingkan penggunaan fitur tunggal. Dalam penelitian tersebut, fitur hibrida menghasilkan performa MCC pada rentang 0,59 hingga 0,69, yang mana hasil capaian XGBoost dalam penelitian ini berada dalam rentang validasi ilmiah tersebut, sehingga mempertegas reliabilitas model yang dikembangkan.

Kontras dengan efisiensi yang ditunjukkan oleh XGBoost, kegagalan *Support Vector Machine* (SVM) dalam mencapai performa komputasi yang ideal memberikan gambaran nyata mengenai kendala algoritma berbasis kernel pada data berdimensi tinggi. Fakta yang ditemukan pada tahap optimasi awal menunjukkan bahwa SVM memerlukan waktu hingga 415 menit hanya untuk menyelesaikan 2 trials ketika dipaksa mengolah dataset penuh. Secara teknis, fenomena ini terjadi karena kompleksitas komputasi SVM meningkat secara kuadratik terhadap jumlah sampel dan dimensi fitur ($O(N^2 \cdot D)$) atau lebih). Dalam ruang fitur 2215-bit yang bersifat *sparse*, algoritma berbasis kernel seperti SVM mengalami hambatan serius yang dikenal sebagai *curse of dimensionality*. Hal ini sejalan dengan analisis Ding *et al.* (2021) yang mencatat bahwa meskipun algoritma tertentu mampu memberikan akurasi yang kompetitif, beban komputasi yang eksponensial sering kali menjadi faktor pembatas dalam aplikasi praktis kemoinformatika.

Oleh karena itu, penggunaan strategi *Subset Tuning* sebesar 20% pada SVM menjadi langkah kompromi yang harus diambil, namun tetap tidak mampu menandingi kecepatan XGBoost yang mampu mengolah 100% data dalam waktu yang jauh lebih singkat (rata-rata 23,8 menit). Meskipun strategi *Subset Tuning* sebesar 20% pada SVM merupakan langkah kompromi komputasi, penggunaan metode *stratified random sampling* menjamin bahwa sub-dataset tersebut tetap mempertahankan densitas informasi dan distribusi kelas yang identik dengan dataset penuh. Berdasarkan uji konsistensi awal, batas keputusan (*decision boundary*) yang dibentuk oleh subset 20% tidak menunjukkan pergeseran matematis yang signifikan dibandingkan pengujian pada dataset penuh, sehingga bias akibat perbedaan volume data *tuning* telah dimitigasi. Hal ini menegaskan bahwa keunggulan XGBoost murni lahir dari efektivitas arsitektur *gradient boosting* dalam melakukan eksploitasi fitur biner secara sekuensial.

Lebih lanjut, keberhasilan optimasi *hyperparameter* menggunakan framework Optuna memberikan dimensi baru dalam stabilitas model. Sebagaimana dieksperimentkan oleh Fadzyan dan Laksana (2025), integrasi Optuna dengan algoritma berbasis *tree* mampu mengeksplorasi ruang parameter secara jauh lebih efisien dibandingkan metode pencarian manual. Penggunaan parameter `max_depth: 10` pada XGBoost dalam penelitian ini menunjukkan bahwa model memerlukan kedalaman pohon yang moderat untuk menangkap interaksi non-linear antar-fragmen kimiawi tanpa terjebak dalam masalah *overfitting*. Strategi *gradient boosting* yang bekerja secara iteratif dalam memperbaiki residu kesalahan dari iterasi sebelumnya terbukti lebih peka dalam mendeteksi pola-pola halus pada struktur molekul inhibitor dibandingkan pendekatan linear. Hal ini membuktikan bahwa arsitektur XGBoost merupakan pilihan yang paling rasional untuk menjalankan fungsi skrining virtual senyawa bioaktif dalam skala besar dengan beban komputasi yang tetap terkendali.

4.3.2 Efektivitas *Decision Threshold Optimization*

Permasalahan ketidakseimbangan kelas (*class imbalance*) merupakan tantangan fundamental dalam dataset bioaktivitas sitokrom P450, di mana jumlah senyawa Non-Inhibitor mendominasi dengan rasio yang signifikan. Hasil eksperimen pada Tabel 4.8 menunjukkan bahwa penggunaan ambang batas *default* (0,5) menghasilkan model yang bias terhadap kelas mayoritas, ditandai dengan nilai Spesifisitas yang tinggi namun Sensitivitas yang rendah. Kondisi ini sangat berisiko dalam konteks medis; sebuah model yang gagal mendeteksi inhibitor (terjadi *false negative*) dapat berakibat pada lolosnya senyawa yang berpotensi memicu interaksi obat berbahaya. Strategi penyeimbangan data menggunakan SMOTE pada penelitian ini mengikuti preseden yang ditetapkan oleh Erlin *et al.* (2022), yang membuktikan bahwa teknik penyeimbangan kelas mampu mengurangi bias mayoritas dan meningkatkan stabilitas model pada semua indikator kinerja.

Implementasi Indeks Youden untuk mencari ambang batas optimal (misal: 0,1779 pada target CYP2C9) secara teknis mengubah paradigma pengambilan keputusan model menjadi lebih responsif. Meskipun langkah ini menyebabkan penurunan tipis pada akurasi global karena meningkatnya jumlah *false positive*, namun peningkatan drastis pada metrik Sensitivitas memberikan jaminan keamanan klinis yang lebih tinggi. Sebagaimana ditekankan oleh Zahid *et al.* (2024), dalam prediksi toksisitas atau inhibisi enzim, biaya

kesalahan *false negative* jauh lebih mahal dibandingkan *false positive*. Hal ini dikarenakan pengabaian terhadap potensi inhibitor dapat menyebabkan akumulasi toksik obat dalam tubuh pasien, sedangkan kesalahan duga inhibitor (ligan biasa dianggap inhibitor) hanya akan berujung pada penelaahan struktur lebih lanjut di laboratorium tanpa membahayakan subjek manusia.

Optimasi ambang batas ini juga mencerminkan penerapan *cost-sensitive learning* yang matang. Dengan menyesuaikan ambang batas berdasarkan titik potong optimal pada kurva ROC, model tidak lagi sekadar menebak berdasarkan probabilitas statistik mentah, melainkan menyesuaikan tingkat kepercayaan (*confidence level*) terhadap kebutuhan praktis *screening* senyawa aktif. Strategi ini memastikan bahwa kode program prediksi yang dikembangkan memiliki daya deteksi yang tajam terhadap sinyal-sinyal struktural kecil yang sering kali tertutup oleh dominasi data non-aktif. Pendekatan ini memberikan validasi bahwa pengembangan model *machine learning* untuk kebutuhan medis harus memprioritaskan keselamatan pasien di atas metrik akurasi numerik yang bersifat semu.

4.3.3 Analisis Transparansi Logika Model Melalui Global SHAP

Penerapan *Explainable AI* melalui metode SHAP bertujuan untuk mengatasi keraguan terhadap sifat *black box* dari algoritma XGBoost. Pendekatan interpretasi ini mengikuti metodologi yang diterapkan oleh Ding *et al.* (2021), yang menggunakan kombinasi XGBoost dan SHAP untuk memberikan transparansi pada prediksi properti molekuler. Dalam penelitian ini, analisis fitur global secara konsisten mengidentifikasi `Bit_maccs_125` (Aromatic Ring > 1) dan `Bit_maccs_145` (6-membered ring > 1) sebagai fitur paling berpengaruh dalam mendorong prediksi kelas inhibitor. Temuan ini memberikan validasi ilmiah bahwa model tidak melakukan hafalan data, melainkan telah berhasil mengekstraksi logika kimiawi yang relevan dengan situs aktif enzim sitokrom P450 yang bersifat hidrofobik.

Keberhasilan model dalam mengenali kontribusi negatif dari fitur tertentu, seperti `Bit_maccs_139` (Gugus Hidroksil) pada target CYP3A4, merupakan pencapaian penting dalam interpretasi fitur. Secara teoritis, keberadaan gugus polar seperti hidroksil cenderung menurunkan afinitas pengikatan pada kantong hidrofobik enzim P450. Kemampuan model untuk memahami bahwa "ketiadaan" gugus polar merupakan faktor penguat untuk sifat inhibisi menunjukkan kedalaman analisis spasial yang dilakukan oleh algoritma. Konsistensi SHAP dalam membedah fitur-fitur kompleks pada data biologis juga divalidasi oleh Uddin *et al.* (2024), yang menunjukkan bahwa pemilihan fitur berbasis kontribusi Shapley mampu meningkatkan akurasi sekaligus memberikan alasan logis di balik setiap prediksi.

Selain interpretasi global, kemampuan interpretasi lokal pada studi kasus Amlodipine memberikan nilai tambah yang besar bagi praktisi klinis. Dengan memetakan bit spesifik (seperti `Bit_morgan_1750` yang menyoroti cincin dihidropiridin), sistem memberikan wawasan struktural yang dapat digunakan untuk proses optimasi molekul obat (*lead optimization*). Aspek transparansi ini menjawab kritik dari Wang *et al.* (2022) mengenai kurangnya diskusi mekanisme spesifik dan transparansi model dalam penelitian-penelitian interaksi obat terdahulu. Dengan adanya visualisasi ini, kode program tidak hanya berfungsi

sebagai alat prediksi otomatis, tetapi juga sebagai alat bantu edukasi dan penelitian yang mampu menghubungkan bobot statistik mesin dengan realitas biokimia molekul.

4.3.4 Analisis Kesalahan dan Batasan Domain Aplikasi

Peneliti yang jujur harus mampu mengidentifikasi di mana modelnya gagal memberikan prediksi yang akurat. Analisis terhadap sampel *false negative* seperti Fluvastatin dan Diltiazem memberikan wawasan krusial mengenai batasan domain aplikasi model (*applicability domain*). Fluvastatin diprediksi dengan probabilitas sangat rendah (0,0016), yang secara teknis dapat disebabkan oleh kehadiran rantai samping asam heptenoat yang sangat polar dan panjang. Fitur struktural ini kemungkinan besar merupakan pencilan (*outlier*) atau jarang ditemui dalam distribusi data ligan inhibitor pada *dataset* pelatihan, sehingga model gagal mengenali potensi inhibisinya meskipun senyawa tersebut memiliki inti aromatik.

Dimikian pula pada kasus Diltiazem, kegagalan model dalam mendeteksi inhibisinya pada target CYP2D6 dan CYP3A4 mengindikasikan adanya keterbatasan fitur *fingerprint* dalam menangkap *scaffold* kimia yang tidak umum. Diltiazem memiliki sistem cincin benzotiazepin (cincin beranggota tujuh dengan atom S dan N) yang secara topologis sangat berbeda dengan fitur dominan berupa cincin beranggota enam yang dipelajari model. Sebagaimana diingatkan oleh Wang *et al.* (2022), kompleksitas komputasi dan variasi ligan yang sangat luas memerlukan validasi eksternal yang memadai untuk memastikan model tidak terjebak dalam ruang kimia yang terlalu sempit. Analisis kesalahan ini menegaskan bahwa meskipun kode program prediksi sangat andal untuk senyawa dengan kerangka aromatik standar, pengguna tetap harus waspada ketika menguji senyawa dengan *scaffold* kimia yang eksotis.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian, implementasi, dan analisis yang telah dilakukan pada model prediktif inhibitor enzim Sitokrom P450, maka dapat ditarik kesimpulan sebagai berikut:

1. Algoritma berbasis *Tree-Ensemble*, khususnya XGBoost, terbukti lebih efektif dan efisien dalam menangani data bioaktivitas yang memiliki karakteristik high-dimensional sparse data (2215-bit hybrid fingerprint) dibandingkan dengan algoritma berbasis vektor (SVM). Hal ini ditunjukkan oleh nilai MCC XGBoost yang secara konsisten mengungguli algoritma lainnya pada ketiga target, yakni 0,5387 (CYP2C9), 0,5836 (CYP2D6), dan 0,6540 (CYP3A4). Temuan ini menegaskan bahwa mekanisme *gradient boosting* pada XGBoost mampu menangani kerenggangan data secara lebih stabil dibandingkan kernel RBF pada SVM yang mengalami kendala beban komputasi yang eksponensial.
2. Penerapan strategi optimasi melalui framework Optuna dan optimasi ambang batas (*Decision Threshold*) menggunakan Indeks Youden berhasil memitigasi risiko pengabaian keamanan metabolisme yang disebabkan oleh rendahnya sensitivitas pada ambang batas standar (0,5). Optimasi ini mampu meningkatkan metrik Sensitivitas secara signifikan, seperti pada target CYP2C9 yang meningkat dari 0,6139 menjadi 0,7914. Meskipun terjadi penurunan akurasi global yang tipis, peningkatan sensitivitas membuktikan bahwa model menjadi lebih responsif dalam mendeteksi senyawa inhibitor potensial yang kritis bagi keselamatan pasien.
3. Metode SHAP berhasil memberikan transparansi terhadap sifat *black box* model dengan mengidentifikasi fitur molekuler yang paling berkontribusi. Hasil interpretasi global secara konsisten menunjukkan bahwa Bit_MACCS_125 (*Aromatic Ring > 1*) dan Bit_MACCS_145 (*6-membered ring > 1*) merupakan pendorong utama prediksi kelas inhibitor di seluruh target. Validasi lokal pada studi kasus Amlodipine menunjukkan bahwa model mampu menangkap representasi struktural yang relevan secara farmakologi, seperti inti dihidropiridin dan substituen klorin, sehingga memberikan tingkat *explainability* yang dapat dipertanggungjawabkan secara klinis.

5.2 Saran

Mengingat keterbatasan yang ditemukan selama penelitian, terdapat beberapa saran yang dapat dilakukan untuk pengembangan penelitian selanjutnya:

1. Melakukan eksplorasi lebih lanjut menggunakan algoritma *Deep Learning* seperti *Graph Neural Networks* (GNN) guna membandingkan efektivitas representasi molekul berbasis graf dengan *hybrid fingerprint* biner dalam menangkap interaksi spasial atom yang lebih kompleks.

2. Memperluas cakupan dataset pelatihan dengan mengintegrasikan pangkalan data ADME eksternal guna meningkatkan daya generalisasi model terhadap senyawa yang memiliki perancah (*scaffold*) kimia unik atau eksotis, sehingga dapat memperluas *Applicability Domain* model dalam mendeteksi ligan dengan karakteristik fisikokimia yang beragam.

DAFTAR PUSTAKA

- Abdulla, A., Baryannis, G., & Badi, I. (2023). An integrated machine learning and MARCOS method for supplier evaluation and selection. *Decision Analytics Journal*, 9(October), 100342. <https://doi.org/10.1016/j.dajour.2023.100342>
- Akbar, Z., Rehman, S., Khan, A., Khan, A., Atif, M., & Ahmad, N. (2021). Potential drug–drug interactions in patients with cardiovascular diseases: findings from a prospective observational study. *Journal of Pharmaceutical Policy and Practice*, 14(1), 63. <https://doi.org/10.1186/s40545-021-00348-1>
- An, X., Chen, X., Yi, D., Li, H., & Guan, Y. (2022). Representation of molecules for drug response prediction. *Briefings in Bioinformatics*, 23(1), 1–11. <https://doi.org/10.1093/bib/bbab393>
- Ding, Y., Chen, M., Guo, C., Zhang, P., & Wang, J. (2021). Molecular fingerprint-based machine learning assisted QSAR model development for prediction of ionic liquid properties. *Journal of Molecular Liquids*, 326, 115212. <https://doi.org/10.1016/j.molliq.2020.115212>
- Erlin, E., Desnelita, Y., Nasution, N., Suryati, L., & Zoromi, F. (2022). Dampak SMOTE terhadap Kinerja Random Forest Classifier berdasarkan Data Tidak seimbang. *MATRIK: Jurnal Manajemen, Teknik Informatika Dan Rekayasa Komputer*, 21(3), 677–690. <https://doi.org/10.30812/matrik.v21i3.1726>
- Fadzryan, R. M., & Laksana, E. A. (2025). Optimasi Prediksi Harga Rumah dengan Random Forest dan Optuna Hyperparameter Tuning. *Jurnal Pendidikan Dan Teknologi Indonesia*, 5(6), 1663–1671. <https://doi.org/10.52436/1.jpti.846>
- Guengerich, F. P. (2022). Inhibition of Cytochrome P450 Enzymes by Drugs—Molecular Basis and Practical Applications. *Biomolecules and Therapeutics*, 30(1), 1–18. <https://doi.org/10.4062/biomolther.2021.102>
- Handayani, W. (2025). FAKTOR-FAKTOR RISIKO PENYAKIT KARDIOVASKULAR: ARTIKEL REVIEW. *Pengembangan Ilmu Dan Praktik Kesehatan*, 4(3), 139–158. <https://doi.org/10.56586/pipk.v4i3.465>
- Landrum, G. A., & Riniker, S. (2024). Combining IC50 or Ki Values from Different Sources Is a Source of Significant Noise. *Journal of Chemical Information and Modeling*, 64(5), 1560–1567. <https://doi.org/10.1021/acs.jcim.4c00049>
- Latief, M. A., Nabila, L. R., Miftakhurrahman, W., Ma'rufatullah, S., & Tantyoko, H. (2024). Handling Imbalance Data using Hybrid Sampling SMOTE-ENN in Lung Cancer Classification. *International Journal of Engineering and Computer Science Applications (IJECSA)*, 3(1), 11–18. <https://doi.org/10.30812/ijecea.v3i1.3758>
- Li, C., Li, S., Feng, Y., Gryllias, K., Gu, F., & Pecht, M. (2024). Small data challenges for intelligent prognostics and health management: a review. In *Artificial Intelligence Review* (Vol. 57, Issue 8). Springer Netherlands. <https://doi.org/10.1007/s10462-024-10820-4>
- Litsa, E. E., Das, P., & Kavraki, L. E. (2021). Machine learning models in the prediction of drug metabolism: challenges and future perspectives. *Expert Opinion on Drug Metabolism and Toxicology*, 17(11), 1245–1247. <https://doi.org/10.1080/17425255.2021.1998454>
- Montastruc, J., Lafaunie, M., de Canecaude, C., Durrieu, G., Sommet, A., Montastruc, F., & Bagheri, H. (2021). Fatal adverse drug reactions: A worldwide perspective in the World Health Organization pharmacovigilance database. *British Journal of Clinical Pharmacology*, 87(11), 4334–4340. <https://doi.org/10.1111/bcp.14851>
- Nair, P. C., McKinnon, R. A., & Miners, J. O. (2016). Cytochrome P450 structure–function:

- insights from molecular dynamics simulations. *Drug Metabolism Reviews*, 48(3), 434–452. <https://doi.org/10.1080/03602532.2016.1178771>
- Saputri, M., & Dewi, S. R. (2023). Potensi Interaksi Polifarmasi Pasien Jantung Koroner (PJK) di Rumah Sakit I.A. Moeis Samarinda. *Jurnal Sains Dan Kesehatan*, 5(2), 109–114. <https://doi.org/10.25026/jsk.v5i2.1709>
- Uddin, I., Awan, H. H., Khalid, M., Khan, S., Akbar, S., Sarker, M. R., Abdolrasol, M. G. M., & Alghamdi, T. A. H. (2024). A hybrid residue based sequential encoding mechanism with XGBoost improved ensemble model for identifying 5-hydroxymethylcytosine modifications. *Scientific Reports*, 14(1). <https://doi.org/10.1038/s41598-024-71568-z>
- Wang, N.-N., Wang, X.-G., Xiong, G.-L., Yang, Z.-Y., Lu, A.-P., Chen, X., Liu, S., Hou, T.-J., & Cao, D.-S. (2022). Machine learning to predict metabolic drug interactions related to cytochrome P450 isozymes. *Journal of Cheminformatics*, 14(1), 23. <https://doi.org/10.1186/s13321-022-00602-x>
- Wang, Z., Li, H., & Wang, Q. (2025). An Approach to Truck Driving Risk Identification: A Machine Learning Method Based on Optuna Optimization. *IEEE Access*, 13, 42723–42732. <https://doi.org/10.1109/ACCESS.2025.3547445>
- Zahid, H., Tayara, H., & Chong, K. T. (2024). Harnessing machine learning to predict cytochrome P450 inhibition through molecular properties. *Archives of Toxicology*, 98(8), 2647–2658. <https://doi.org/10.1007/s00204-024-03756-9>
- Zhao, M., Ma, J., Li, M., Zhang, Y., Jiang, B., Zhao, X., Huai, C., Shen, L., Zhang, N., He, L., & Qin, S. (2021). Cytochrome p450 enzymes and drug metabolism in humans. *International Journal of Molecular Sciences*, 22(23), 1–16. <https://doi.org/10.3390/ijms222312808>
- Zhou, Y., & Lauschke, V. M. (2022). The genetic landscape of major drug metabolizing cytochrome P450 genes—an updated analysis of population-scale sequencing data. *Pharmacogenomics Journal*, 22(5–6), 284–293. <https://doi.org/10.1038/s41397-022-00288-2>

LAMPIRAN

Lampiran A. Tabel Penjelasan MACCS Keys (Sumber: www.mayachemtools.org)

No. Key	Deskripsi Teknis	Penjelasan Kimiawi
0	Placeholder	Bit indeks 0 biasanya tidak digunakan dalam implementasi standar MACCS 166 keys.
1	ISOTOPE	Keberadaan isotop dalam molekul.
2	103 < ATOMIC NO. < 256	Atom dengan nomor atom antara 104 hingga 255.
3	GROUP IVA,VA,VIA PERIODS 4-6 (Ge...)	Atom dari golongan IVA, VA, atau VIA pada periode 4-6 (misal: Ge, As, Se).
4	ACTINIDE	Unsur deret Aktinida.
5	GROUP IIIB,IVB (Sc...)	Unsur golongan IIIB, IVB.
6	LANTHANIDE	Unsur deret Lantanida.
7	GROUP VB,VIB,VII B (V...)	Unsur golongan VB, VIB, atau VII B.
8	QAAA@1	Heteroatom (Q) yang terhubung kembali ke atom pertama dalam rantai 4 atom.
9	GROUP VIII (Fe...)	Unsur golongan VIII.
10	GROUP IIA (ALKALINE EARTH)	Logam alkali tanah (Golongan IIA).
11	4M RING	Cincin beranggota 4 atom (4-membered ring).
12	GROUP IB,II B (Cu...)	Logam golongan IB atau II B.
13	ON(C)C	Nitrogen dengan substituen Oksigen dan dua Karbon.
14	S-S	Ikatan tunggal antara dua atom Sulfur (Disulfida).
15	OC(O)O	Gugus karbonat atau ester serupa.
16	QAA@1	Heteroatom (Q) dalam cincin 3-atom spesifik.
17	CTC	Rantai Karbon-Karbon-Karbon dengan ikatan tripel.
18	GROUP IIIA (B...)	Unsur golongan IIIA.
19	7M RING	Cincin beranggota 7 atom (7-membered ring).
20	SI	Atom Silikon.
21	C=C(Q)Q	Karbon ikatan ganda yang terikat pada dua heteroatom (Q).
22	3M RING	Cincin beranggota 3 atom (3-membered ring).
23	NC(O)O	Gugus Karbamat (Nitrogen-Karbon-Oksigen).
24	N-O	Ikatan tunggal antara Nitrogen dan Oksigen.
25	NC(N)N	Gugus Guanidina atau serupa.
26	C\$=C(\$A)\$A	Karbon ikatan ganda di dalam sistem cincin.
27	I	Keberadaan atom Iodin.
28	QCH2Q	Metilen di antara dua heteroatom.
29	P	Keberadaan atom Fosfor.
30	CQ(C)(C)A	Karbon kuaterner yang terikat pada heteroatom.
31	QX	Heteroatom terikat langsung pada halogen (X).
32	CSN	Ikatan Karbon-Sulfur-Nitrogen.
33	NS	Ikatan tunggal Nitrogen-Sulfur.
34	CH2=A	Gugus vinil terminal (metilen terikat ganda).
35	GROUP IA (ALKALI METAL)	Logam alkali (Golongan IA).
36	S HETEROCYCLE	Heterosiklik yang mengandung Sulfur.
37	NC(O)N	Gugus Urea.


38	NC(C)N	Nitrogen terikat pada Karbon yang memiliki substituen Nitrogen lain.
39	OS(O)O	Gugus Sulfit atau Sulfat.
40	S-O	Ikatan tunggal Sulfur-Oksigen.
41	CTN	Karbon ikatan tripel ke Nitrogen (Nitril).
42	F	Keberadaan atom Fluor.
43	QHAQH	Heteroatom-Hidrogen-Heteroatom (ikatan hidrogen atau serupa).
44	OTHER	Atom lainnya selain yang didefinisikan secara spesifik.
45	C=CN	Gugus Enamina atau Nitrogen terikat pada Karbon tak jenuh.
46	BR	Keberadaan atom Bromin.
47	SAN	Ikatan Sulfur-Aromatik-Nitrogen.
48	OQ(O)O	Gugus fungsional Oksigen spesifik.
49	CHARGE	Molekul bermuatan (Kation atau Anion).
50	C=C(C)C	Karbon ikatan ganda tersubstitusi.
51	CSO	Ikatan Karbon-Sulfur-Oksigen.
52	NN	Ikatan Nitrogen-Nitrogen.
53	QHAAAQH	Dua heteroatom terikat Hidrogen berjarak 4 atom.
54	QHAAQH	Dua heteroatom terikat Hidrogen berjarak 3 atom.
55	OSO	Gugus Sulfon atau serupa.
56	ON(OC)	Gugus Nitro atau serupa.
57	O HETEROCYCLE	Heterosiklik yang mengandung Oksigen.
58	QSQ	Sulfur di antara dua heteroatom.
59	Snot%A%A	Sulfur terikat pada dua atom non-aromatik.
60	S=O	Gugus Sulfoksida atau Sulfon (ikatan ganda S-O).
61	AS(A)A	Sulfur dengan tiga tetangga atom.
62	A\$A!A\$A	Atom yang berada di antara dua ikatan cincin.
63	N=O	Gugus Nitroso (ikatan ganda N-O).
64	A\$A!S	Sulfur yang terikat pada atom di dalam cincin.
65	C%N	Ikatan aromatik antara Karbon dan Nitrogen.
66	CC(C)(C)A	Gugus tert-Butil atau atom pusat dengan tiga metil.
67	QS	Ikatan heteroatom-Sulfur.
68	QHQH	Dua gugus heteroatom terikat Hidrogen.
69	QQH	Dua heteroatom dan satu heteroatom terikat Hidrogen.
70	QNQ	Nitrogen di antara dua heteroatom.
71	NO	Ikatan tunggal Nitrogen-Oksigen.
72	OAAO	Dua atom Oksigen berjarak 2 atom.
73	S=A	Ikatan ganda Sulfur ke atom lain.
74	CH3ACH3	Dua gugus metil berjarak 1 atom.
75	A!N\$A	Nitrogen terikat pada atom di dalam cincin.
76	C=C(A)A	Alkena tersubstitusi.
77	NAN	Dua atom Nitrogen berjarak 1 atom.
78	C=N	Ikatan ganda Karbon-Nitrogen (Imina).
79	NAAN	Dua atom Nitrogen berjarak 2 atom.
80	NAAAN	Dua atom Nitrogen berjarak 3 atom.
81	SA(A)A	Sulfur dengan tiga tetangga atom.
82	ACH2QH	Gugus heteroatom terikat Hidrogen yang menempel pada metilen.
83	QAAAA@1	Heteroatom (Q) dalam cincin 5-atom spesifik.

84	NH2	Gugus Amina primer.
85	CN(C)C	Gugus Dimetilamina.
86	CH2QCH2	Bier atau Tioeter (Metilen-Q-Metilen).
87	X!A\$A	Halogen terikat pada atom di dalam cincin.
88	S	Keberadaan atom Sulfur.
89	OAAAO	Dua atom Oksigen berjarak 3 atom.
90	QHAACH2A	Pola QH-A-A-CH2-A.
91	QHAAACH2A	Pola QH-A-A-A-CH2-A.
92	OC(N)C	Gugus Amida atau Karbamat.
93	QCH3	Gugus Metoksi atau heteroatom terikat metil.
94	QN	Ikatan heteroatom-Nitrogen.
95	NAAO	Nitrogen dan Oksigen berjarak 2 atom.
96	SM RING	Cincin beranggota 5 (5-membered ring).
97	NAAAO	Nitrogen dan Oksigen berjarak 3 atom.
98	QAAAAA@1	Heteroatom (Q) dalam cincin 6-atom spesifik.
99	C=C	Ikatan ganda Karbon-Karbon.
100	ACH2N	Nitrogen terikat pada metilen.
101	8M RING	Cincin beranggota 8 (8-membered ring).
102	QO	Ikatan heteroatom-Oksigen.
103	CL	Keberadaan atom Klorin.
104	QHACH2A	Pola heteroatom(H)-metilen-A.
105	A\$(A)\$A	Atom pusat dengan tiga tetangga di dalam cincin.
106	QA(Q)Q	Atom pusat dengan tiga heteroatom.
107	XA(A)A	Halogen dengan tiga tetangga.
108	CH3AAACH2A	Pola Metil-A-A-A-Metilen-A.
109	ACH2O	Oksigen terikat pada metilen.
110	NCO	Gugus Isosianat.
111	NACH2A	Nitrogen terikat pada metilen.
112	AA(A)(A)A	Atom pusat dengan empat tetangga atom.
113	Onot%A%A	Oksigen terikat pada dua atom non-aromatik.
114	CH3CH2A	Gugus Etil.
115	CH3ACH2A	Gugus Propil atau serupa.
116	CH3AACH2A	Gugus Butil atau serupa.
117	NAO	Nitrogen-A-Oksigen.
118	ACH2CH2A > 1	Keberadaan lebih dari satu gugus etilen.
119	N=A	Nitrogen ikatan ganda.
120	HETEROCYCLIC ATOM > 1	Lebih dari satu heteroatom dalam sistem cincin.
121	N HETEROCYCLE	Heterosiklik yang mengandung Nitrogen.
122	AN(A)A	Nitrogen dengan tiga tetangga atom.
123	OCO	Gugus Karboksil atau Ester (Oksigen-Karbon-Oksigen).
124	QQ	Dua heteroatom yang terikat langsung.
125	AROMATIC RING > 1	Memiliki lebih dari satu cincin aromatik.
126	A!O!A	Oksigen rantai terbuka di antara dua atom.
127	A\$A!O > 1	Memiliki lebih dari satu Oksigen terikat cincin.
128	ACH2AAACH2A	Pola Metilen-A-A-A-Metilen.
129	ACH2AACH2A	Pola Metilen-A-A-Metilen.


130	QQ > 1	Memiliki lebih dari satu pasang heteroatom.
131	QH > 1	Memiliki lebih dari satu gugus heteroatom-Hidrogen.
132	OACH2A	Oksigen-A-Metilen.
133	A\$A!N	Nitrogen terikat pada atom di dalam cincin.
134	X (HALOGEN)	Keberadaan atom Halogen (F, Cl, Br, I).
135	Nnot%A%A	Nitrogen terikat pada dua atom non-aromatik.
136	O=A > 1	Memiliki lebih dari satu atom terikat ganda Oksigen.
137	HETEROCYCLE	Keberadaan sistem heterosiklik.
138	QCH2A > 1	Memiliki lebih dari satu metilen terikat heteroatom.
139	OH	Gugus Hidroksil (Alkohol atau Fenol).
140	O > 3	Memiliki lebih dari tiga atom Oksigen.
141	CH3 > 2	Memiliki lebih dari dua gugus Metil.
142	N > 1	Memiliki lebih dari satu atom Nitrogen.
143	A\$A!O	Oksigen terikat pada atom di dalam cincin.
144	Anot%A%Anot%A	Atom di batas antara aromatik dan non-aromatik.
145	6M RING > 1	Memiliki lebih dari satu cincin beranggota 6.
146	O > 2	Memiliki lebih dari dua atom Oksigen.
147	ACH2CH2A	Gugus Etilen (Metilen-Metilen).
148	AQ(A)A	Heteroatom dengan tiga tetangga atom.
149	CH3 > 1	Memiliki lebih dari satu gugus Metil.
150	A!A\$A!A	Atom di persimpangan antara rantai dan cincin.
151	NH	Gugus Amina sekunder.
152	OC(C)C	Gugus Isopropoksi atau serupa.
153	QCH2A	Metilen terikat heteroatom.
154	C=O	Gugus Karbonil (Aldehid atau Keton).
155	A!CH2!A	Metilen dalam rantai terbuka (non-cincin).
156	NA(A)A	Nitrogen dengan tiga tetangga atom.
157	C-O	Ikatan tunggal Karbon-Oksigen.
158	C-N	Ikatan tunggal Karbon-Nitrogen.
159	O > 1	Memiliki lebih dari satu atom Oksigen.
160	CH3	Gugus Metil.
161	N	Atom Nitrogen.
162	AROMATIC	Keberadaan sistem aromatik.
163	6M RING	Cincin beranggota 6 (6-membered ring).
164	O	Atom Oksigen.
165	RING	Keberadaan sistem cincin.
166	FRAGMENTS	Keberadaan fragmen molekul.

Lampiran B. Riwayat Optimasi Optuna


1. *Random Forest*



2. SVM



3. XGBoost



Lampiran C. Grafik *Beeswarm Plot* Hasil SHAP

