

**PERAMALAN KUNJUNGAN DAN ANALISIS POLA PENJUALAN
MENGUNAKAN METODE ARIMA DAN *MARKET BASKET*
ANALYSIS PADA FORZA GYM BABARSARI**

TUGAS AKHIR



Disusun Oleh :
IKHSAN SYAHRI RAMADHAN
123220024

**PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
YOGYAKARTA
2026**

**PERAMALAN KUNJUNGAN DAN ANALISIS POLA PENJUALAN
MENGUNAKAN METODE ARIMA DAN *MARKET BASKET*
ANALYSIS PADA FORZA GYM BABARSARI**

TUGAS AKHIR

Tugas Akhir ini sebagai salah satu syarat untuk memperoleh gelar Sarjana Informatika
Universitas Pembangunan Nasional “Veteran” Yogyakarta



Disusun Oleh :
IKHSAN SYAHRI RAMADHAN
123220024

**PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL “VETERAN”
YOGYAKARTA
2026**

HALAMAN PENGESAHAN PEMBIMBING

PERAMALAN KUNJUNGAN DAN ANALISIS POLA PENJUALAN
MENGUNAKAN METODE ARIMA DAN *MARKET BASKET ANALYSIS* PADA
FORZA GYM BABARSARI

Disusun Oleh:

Ikhsan Syahri Ramadhan

NIM. 123220024


Telah diuji dan dinyatakan lulus oleh pembimbing

Pada tanggal: 11 Mei 2016

Menyetujui,
Pembimbing


Rochmat Husni, S.Kom., M.Kom.
NIDN. 0026048804

Mengetahui,
Koordinator Program Studi


Desyanto Boedi Prasetyo, S.T., M.T.
NIDN. 0505127501

HALAMAN PENGESAHAN PENGUJI

PERAMALAN KUNJUNGAN DAN ANALISIS POLA PENJUALAN MENGUNAKAN METODE ARIMA DAN *MARKET BASKET ANALYSIS* PADA FORZA GYM BABARSARI

Disusun Oleh:

Ikhsan Syahri Ramadhan

NIM. 123220024

Telah diuji dan dinyatakan lulus oleh penguji

Pada tanggal: 11 Mei 2016

Menyetujui,

Penguji 1

Rochmat Hosani, S.Kom., M.Kom.
NIDN. 0026048804

Penguji 2

Budi Suryanto, S.T., M.Eng.
NIDN. 0003107608

Penguji 3

Dr. Heriyanto, A.Md., S.Kom., M.Cs.
NIDN. 0508067703

Penguji 4

Rudy Cahyadi, S.Si., M.T.
NIDN. 0019037504

**SURAT PERNYATAAN
KARYA ASLI TUGAS AKHIR**

Sebagai mahasiswa Program Studi Informatika, Fakultas Teknik Industri, Universitas Pembangunan Nasional "Veteran" Yogyakarta, yang bertanda tangan di bawah ini, saya:

Nama : Ikhsan Syahri Ramadhan

NIM : 123220024

Menyatakan bahwa karya ilmiah saya yang berjudul:

Peramalan Kunjungan dan Analisis Pola Penjualan Menggunakan Metode ARIMA dan *Market Basket Analysis* Pada Forza Gym Babarsari

merupakan karya asli saya dan belum pernah dipublikasikan di mana pun. Apabila di kemudian hari karya saya terbukti bukan merupakan karya asli saya, maka saya bersedia menerima segala konsekuensi yang diberikan Program Studi Informatika, Fakultas Teknik Industri, Universitas Pembangunan Nasional "Veteran" Yogyakarta.

Demikian surat pernyataan ini saya buat dengan sebenar-benarnya.

Dibuat di : Yogyakarta

Pada Tanggal :

Yang menyatakan


Ikhsan Syahri Ramadhan
NIM. 123220024

PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini:

Nama : Ikhsan Syahri Ramadhan

NIM : 123220024

Prodi : Informatika

Dengan ini saya menyatakan bahwa judul Tugas Akhir

Peramalan Kunjungan dan Analisis Pola Penjualan Menggunakan Metode ARIMA dan *Market Basket Analysis* Pada Forza Gym Babarsari

merupakan hasil karya saya sendiri dan bebas dari plagiasi. Adapun kutipan, cuplikan, maupun ringkasan yang terdapat di dalamnya telah saya cantumkan sumbernya secara jelas sesuai kaidah yang berlaku. Apabila pernyataan ini terbukti tidak benar, maka saya bersedia menerima sanksi sesuai Peraturan Menteri Pendidikan Nasional Republik Indonesia Nomor 17 Tahun 2010 serta peraturan perundang-undangan yang berlaku.

Demikian surat pernyataan ini saya buat dengan penuh tanggung jawab.

Dibuat di : Yogyakarta

Pada Tanggal :

Yang menyatakan



Ikhsan Syahri Ramadhan

NIM. 123220024

ABSTRAK

FORZA GYM Babarsari sebagai pusat kebugaran menghasilkan data operasional berupa data kunjungan anggota dan transaksi penjualan yang belum dimanfaatkan secara optimal sebagai dasar pengambilan keputusan. Fluktuasi kunjungan menyulitkan perencanaan operasional, sedangkan data transaksi belum dianalisis untuk mengetahui pola penjualan. Penelitian ini bertujuan meramalkan jumlah kunjungan anggota menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA) serta menganalisis pola penjualan menggunakan *Market Basket Analysis* (MBA) berbasis algoritma Apriori.

Data yang digunakan terdiri atas 515 data kunjungan harian dan 6.560 data transaksi penjualan pada periode 2 September 2024 sampai 6 Februari 2026. Analisis ARIMA dilakukan melalui uji stasioneritas dengan *Augmented Dickey-Fuller* (ADF), identifikasi parameter ACF dan PACF, estimasi kandidat model, seleksi model terbaik menggunakan *Akaike Information Criterion corrected* (AICc), diagnostik residual dengan uji *Ljung-Box*, serta evaluasi akurasi menggunakan MAE, RMSE, dan MAPE. Analisis MBA dilakukan melalui pra-pemrosesan data, transformasi *one-hot encoding*, pembentukan *frequent itemset*, dan *association rule* berdasarkan nilai *support*, *confidence*, serta *lift*.

Hasil penelitian menunjukkan bahwa model terbaik adalah ARIMA(1,0,5) dengan MAE 9,317, RMSE 12,168, dan MAPE 37,775%. Analisis MBA menunjukkan item dengan frekuensi transaksi tertinggi adalah aqua 600ml, visit, aqua 1.5l, dan perpanjang. Dengan demikian, ARIMA dapat membantu perencanaan operasional jangka pendek, sedangkan MBA mendukung strategi pemasaran berbasis pola penjualan.

Kata Kunci: ARIMA, peramalan, *Market Basket Analysis*, kunjungan anggota, pola penjualan.

ABSTRACT

FORZA GYM Babarsari, as a fitness center, generates operational data in the form of member visit data and sales transaction data, which have not yet been optimally utilized as a basis for decision-making. Fluctuations in visits make operational planning difficult, while transaction data have not been analyzed to identify sales patterns. This study aims to forecast the number of member visits using the Autoregressive Integrated Moving Average (ARIMA) method and to analyze sales patterns using Market Basket Analysis (MBA) based on the Apriori algorithm.

The data used consist of 515 daily visit records and 6,560 sales transaction records from September 2, 2024, to February 6, 2026. The ARIMA analysis was conducted through stationarity testing using the Augmented Dickey-Fuller (ADF) test, parameter identification using ACF and PACF, candidate model estimation, best model selection using the corrected Akaike Information Criterion (AICc), residual diagnostics using the Ljung-Box test, and accuracy evaluation using MAE, RMSE, and MAPE. The MBA analysis was carried out through data preprocessing, one-hot encoding transformation, frequent itemset generation, and association rule mining based on support, confidence, and lift values.

The results show that the best model is ARIMA(1,0,5), with an MAE of 9.317, RMSE of 12.168, and MAPE of 37.775%. The MBA analysis indicates that the items with the highest transaction frequency are aqua 600ml, visit, aqua 1.5l, and perpanjang. Therefore, ARIMA can support short-term operational planning, while MBA can support marketing strategies based on sales patterns.

Keywords: *ARIMA, forecasting, Market Basket Analysis, member visits, sales patterns.*

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan tugas akhir ini dengan baik. Tugas akhir ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Strata 1 pada Program Studi Informatika, Universitas Pembangunan Nasional “Veteran” Yogyakarta. Dalam proses penyusunan tugas akhir ini, penulis menyadari bahwa tidak terlepas dari bantuan, dukungan, serta doa dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Keluarga besar penulis, khususnya kedua orang tua penulis Bapak La Haeni, (almh) Ibu Eva Yulianti, Ibu Wa Jamila, serta adik-adik penulis Dimas Permana, Yusuf Annurilkhair, dan Syafiq Alfarizqi, serta Keluarga Besar Kakek La Iro dan Keluarga Besar Kakek Edi Suwardi, yang senantiasa memberikan doa, kasih sayang, nasihat, dukungan moral maupun materi, serta motivasi yang selalu penulis pegang teguh hingga saat ini.
2. Bapak Rochmat Husaini, S.Kom., M.Kom., selaku dosen pembimbing tugas akhir, yang senantiasa memberikan arahan, bimbingan, serta motivasi dalam proses penyusunan hingga penyelesaian tugas akhir ini.
3. Bapak Budi Suyanto, S.T., M.Eng., Bapak Dr. Heriyanto, A.Md., S.Kom., M.Cs., dan Bapak Rudy Cahyadi, S.Si., MT., selaku dosen penguji, yang telah memberikan masukan, kritik, dan saran yang membangun dalam penyempurnaan tugas akhir ini.
4. Mas Marchel Andrian Shevchenko, yang telah memberikan masukan, arahan, serta ide dalam pengembangan tugas akhir ini, serta senantiasa memberikan semangat dan dukungan hingga tugas akhir ini terselesaikan.
5. Keluarga kedua penulis di Yogyakarta, Om Nando, Tante Yanti, Mba Betty, Utti, Ibu Arni, Erlan, dan Sella, yang telah memberikan kehangatan, perhatian, serta dukungan layaknya keluarga sendiri selama masa perantauan.
6. Sahabat penulis, yaitu Yusri, Damai, Wahyu, Abrar, Ageng, Madi, dan Sakti, yang selalu hadir memberikan dukungan, semangat, serta menjadi tempat berbagi cerita selama perjalanan perkuliahan hingga saat ini.
7. Teman-teman keluarga Informatika Angkatan 2022, yang telah berbagi ide, pengalaman, serta saling membantu dalam menghadapi berbagai tantangan selama masa perkuliahan.
8. Keluarga besar FORZA GYM Babarsari, yang telah memberikan pengalaman berharga, kebersamaan, serta suasana kekeluargaan yang penuh kehangatan dan kebahagiaan bagi penulis.

Penulis menyadari bahwa tugas akhir ini masih memiliki keterbatasan dan jauh dari sempurna. Oleh karena itu, penulis dengan terbuka menerima segala bentuk kritik dan saran yang membangun demi penyempurnaan karya ini di masa yang akan datang.

Akhir kata, penulis berharap semoga tugas akhir ini dapat memberikan manfaat serta kontribusi positif bagi pengembangan ilmu pengetahuan, khususnya di bidang informatika.

Yogyakarta, 29 April 2026

Penulis

DAFTAR ISI

HALAMAN SAMPUL	i
HALAMAN JUDUL	ii
HALAMAN PENGESAHAN PEMBIMBING	ii
HALAMAN PENGESAHAN PENGUJI	i
SURAT PERNYATAAN	v
PERNYATAAN BEBAS PLAGIASI	Error! Bookmark not defined.
ABSTRAK	vii
<i>ABSTRACT</i>	viii
KATA PENGANTAR.....	ix
DAFTAR ISI.....	xi
DAFTAR TABEL	xv
DAFTAR GAMBAR.....	xvi
DAFTAR MODUL PROGRAM.....	xvii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah.....	4
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	5
1.6 Tahapan Penelitian.....	5
1.7 Sistematika Penulisan	6
BAB II TINJAUAN LITERATUR.....	8
2.1 Pelayanan Jasa Kebugaran.....	8
2.2 FORZA GYM Babarsari	9
2.3 Konsep dan Definisi Dasar	10
2.3.1 Pengertian Data dan Informasi.....	10
2.3.2 Analisis Data dalam Bidang Informatika.....	11
2.3.3 Peran Analisis Data dalam Pengambilan Keputusan Berbasis Data	12
2.4 Peramalan (<i>Forecasting</i>).....	12
2.4.1 Pengertian Peramalan.....	12
2.4.2 Tujuan dan Manfaat Peramalan dalam Organisasi Jasa	12
2.4.3 Jenis-Jenis Peramalan.....	13
2.4.4 Peramalan Deret Waktu (<i>Time Series Forecasting</i>)	13
2.5 Metode <i>Autoregressive Integrated Moving Average</i> (ARIMA).....	14
2.5.1 Konsep Dasar dan Landasan Teoritis Metode ARIMA	14
2.5.2 Bentuk Umum Model ARIMA.....	15
2.5.3 Karakteristik Data Deret Waktu dan Kesesuaiannya dengan ARIMA...	15

2.5.4	Uji Kestasioneran <i>Augmented Dickey-Fuller</i> (ADF Test).....	16
2.5.5	Identifikasi Model Menggunakan ACF dan PACF	17
2.5.6	Estimasi dan Pemilihan Model.....	18
2.5.7	Diagnostik Residual Model ARIMA.....	19
2.5.8	Evaluasi Akurasi Model Peramalan	20
2.5.9	Alur proses ARIMA	21
2.6	Konsep <i>Data Mining</i>	22
2.6.1	Pengertian <i>Data Mining</i>	22
2.6.2	<i>Data Mining</i> dalam Analisis Transaksi Penjualan.....	22
2.6.3	Hubungan <i>Data Mining</i> dengan <i>Market Basket Analysis</i>	23
2.6.4	Peran <i>Data Mining</i> dalam Mendukung Tujuan Penelitian.....	23
2.7	<i>Market Basket Analysis</i>	24
2.7.1	Pengertian <i>Market Basket Analysis</i>	24
2.7.2	Karakteristik Data Transaksional	24
2.7.3	<i>Association Rule</i> dalam <i>Market Basket Analysis</i>	24
2.7.4	Ukuran Evaluasi <i>Association Rule</i>	25
2.7.5	Algoritma Apriori.....	26
2.7.6	Interpretasi Nilai <i>Support</i> , <i>Confidence</i> , dan <i>Lift</i>	26
2.7.7	Alur Proses <i>Market Basket Analysis</i>	27
2.8	Penelitian Terdahulu	29
BAB III METODOLOGI PENELITIAN		34
3.1	Jenis dan Pendekatan Penelitian	34
3.2	Objek dan Subjek Penelitian.....	34
3.2.1	Objek Penelitian.....	34
3.2.2	Subjek Penelitian.....	34
3.3	Jenis dan Sumber Data.....	35
3.4	Teknik Pengumpulan Data	35
3.5	Deskripsi dan Struktur Data.....	36
3.5.1	Deskripsi Data Penelitian.....	36
3.5.2	Struktur Data Kunjungan Anggota (<i>Time Series</i>).....	36
3.5.3	Struktur Data Transaksi Penjualan (Transaksional)	37
3.5.4	Kesesuaian Struktur Data dengan Metode Analisis	38
3.6	Tahapan Penelitian.....	38
3.7	Metode Peramalan Jumlah Kunjungan Menggunakan ARIMA	41
3.7.1	Alur Proses ARIMA	41
3.7.2	<i>Exploratory Data Analysis</i> (EDA)	42

3.7.3	Uji Stasioneritas dan Penentuan Orde <i>Differencing</i> (d)	43
3.7.4	Identifikasi Parameter p dan q (ACF & PACF)	50
3.7.5	Pembagian Data Latih dan Data Uji.....	54
3.7.6	Estimasi Parameter dan Seleksi Model ARIMA	54
3.7.7	Diagnostik Residual Model.....	57
3.7.8	Evaluasi Akurasi Model Peramalan	60
3.7.9	Prosedur Peramalan Periode Mendatang.....	62
3.8	Metode Analisis Pola Penjualan Menggunakan <i>Market Basket Analysis</i> ..	62
3.8.1	Alur Proses <i>Market Basket Analysis</i>	63
3.8.2	Pra-pemrosesan Data Transaksi	65
3.8.3	Transformasi ke Matriks Biner (<i>One-Hot Encoding</i>).....	66
3.8.4	Pembentukan <i>Frequent Itemset</i> dengan Algoritma Apriori.....	67
3.8.5	Pembentukan Aturan Asosiasi	67
3.8.6	Ilustrasi Eksekusi Proses Apriori hingga Aturan Asosiasi	68
3.9	Kriteria Seleksi <i>Strong Rules</i>	72
3.10	Penyajian dan Visualisasi Hasil Analisis.....	73
3.10.1	Visualisasi Hasil Analisis Secara Umum	73
3.10.2	Visualisasi Hasil Peramalan ARIMA	74
3.10.3	Visualisasi Hasil MBA	75
3.10.4	Interpretasi Hasil Analisis	76
BAB IV	HASIL DAN PEMBAHASAN	77
4.1	Gambaran Umum Data Penelitian	77
4.1.1	<i>Dataset</i> Kunjungan Anggota	77
4.1.2	<i>Dataset</i> Transaksi Penjualan	78
4.2	Hasil Peramalan Kunjungan Menggunakan ARIMA	79
4.2.1	Visualisasi Pola Data Kunjungan	79
4.2.2	Uji Stasioneritas Data.....	80
4.2.3	Identifikasi Parameter Model.....	82
4.2.4	Seleksi Model Terbaik.....	84
4.2.5	Diagnostik Residual	85
4.2.6	Evaluasi Akurasi Model	88
4.2.7	Hasil <i>Forecasting</i> 1-7 Hari ke Depan.....	89
4.3	Hasil Analisis Pola Penjualan Menggunakan <i>Market Basket Analysis</i>	91
4.3.1	Hasil <i>Frequent Itemset</i>	91
4.3.2	Hasil <i>Association Rule</i>	92
4.3.3	<i>Strong Rules</i> Terpilih.....	94

4.4	Pembahasan.....	95
4.4.1	Pembahasan Hasil ARIMA	95
4.4.2	Pembahasan Hasil <i>Market Basket Analysis</i>	96
BAB V PENUTUP		99
5.1	Kesimpulan	99
5.2	Saran	99
DAFTAR PUSTAKA		101

DAFTAR TABEL

Tabel 2.1 Penelitian terdahulu.....	29
Tabel 3.1 Klasifikasi jenis dan sumber data.....	35
Tabel 3.2 Contoh struktur data kunjungan anggota	37
Tabel 3.3 Contoh struktur data transaksi penjualan	38
Tabel 3.4 Contoh data kunjungan harian	44
Tabel 3.5 Hasil <i>differencing</i> orde pertama (data ilustrasi)	44
Tabel 3.6 Ilustrasi pembentukan komponen ADF (data ilustrasi).....	44
Tabel 3.7 Susunan data regresi ADF (data ilustrasi).....	45
Tabel 3.8 Contoh data stasioner untuk perhitungan ACF dan PACF	51
Tabel 3.9 Perhitungan deviasi terhadap rata-rata.....	51
Tabel 3.10 Hasil ilustrasi perhitungan ACF dan PACF.....	52
Tabel 3.11 Ilustrasi kandidat parameter berdasarkan ACF dan PACF	53
Tabel 3.12 Ilustrasi kombinasi kandidat model ARIMA	53
Tabel 3.13 Ilustrasi perbandingan kandidat model berdasarkan AICc.....	56
Tabel 3.14 Ilustrasi hasil estimasi model	57
Tabel 3.15 Ilustrasi data aktual dan hasil prediksi	60
Tabel 3.16 Ilustrasi data awal.....	66
Tabel 3.17 Ilustrasi transformasi ke matriks biner	66
Tabel 3.18 Data contoh transaksi	69
Tabel 3.19 Transformasi data contoh ke matriks biner	69
Tabel 4.1 Ringkasan <i>dataset</i> kunjungan anggota.....	77
Tabel 4.2 Cuplikan <i>dataset</i> kunjungan anggota FORZA GYM Babarsari	77
Tabel 4.3 Ringkasan <i>dataset</i> transaksi penjualan FORZA GYM Babarsari	78
Tabel 4.4 Cuplikan <i>dataset</i> transaksi penjualan FORZA GYM Babarsari	78
Tabel 4.5 Hasil uji stasioneritas menggunakan ADF	81
Tabel 4.6 Kandidat parameter berdasarkan ACF dan PACF	83
Tabel 4.7 Hasil seleksi kandidat model ARIMA.....	85
Tabel 4.8 Hasil uji <i>ljung-box</i> residual	87
Tabel 4.9 Hasil evaluasi akurasi model ARIMA(1,0,5)	88
Tabel 4.10 Hasil <i>forecasting</i> jumlah kunjungan anggota 1-7 hari ke depan.....	90
Tabel 4.11 <i>Top</i> item berdasarkan jumlah transaksi	92
Tabel 4.12 Hasil <i>association rule</i>	93

DAFTAR GAMBAR

Gambar 2.1 Karakteristik jasa (diadaptasi dari Kotler & Armstrong, 2003: 368) ...	8
Gambar 2.2 Logo FORZA GYM Babarsari (akun @forzagym.yk, 2024)	10
Gambar 2.3 Alur pemodelan ARIMA (Kashiwagi et al., 2025).....	21
Gambar 2.4 Tahapan <i>Knowledge Discovery in Databases</i> (Amelia et al., 2024)..	28
Gambar 3.1 Tahapan penelitian.....	39
Gambar 3.2 Alur proses ARIMA menggunakan pendekatan Box-Jenkins.....	41
Gambar 3.3 Alur proses market basket analysis	64
Gambar 3.4 Visualisasi hasil analisis secara umum.....	74
Gambar 3.5 Visualisasi hasil peramalan ARIMA	75
Gambar 3.6 Visualisasi hasil market basket analysis.....	76
Gambar 4.1 Visualisasi data aktual, prediksi data uji, dan forecast kunjungan	80
Gambar 4.2 Visualisasi data latih.....	82
Gambar 4.3 Plot ACF dan PACF	83
Gambar 4.4 Plot residual.....	86
Gambar 4.5 Histogram residual	87
Gambar 4.6 ACF residual.....	87
Gambar 4.7 Grafik forecast jumlah kunjungan anggota 7 hari ke depan.....	90

DAFTAR MODUL PROGRAM

Algoritma 1. Persiapan deret waktu harian	79
Algoritma 2. Uji stasioneritas menggunakan ADF.....	81
Algoritma 3. Penentuan kandidat parameter p dan q	82
Algoritma 4. Seleksi model ARIMA berdasarkan AICc	84
Algoritma 5. Diagnostik residual model	86
Algoritma 6. Perhitungan MAE, RMSE, dan MAPE.....	88
Algoritma 7. <i>Forecasting</i> dan interval prediksi.....	89
Algoritma 8. Pra-pemrosesan dan transformasi data transaksi	91
Algoritma 9. Identifikasi <i>top item</i> transaksi	91
Algoritma 10. Pembentukan <i>frequent itemset</i> dan <i>association rule</i>	93
Algoritma 11. Penyajian <i>strong rules</i>	94

BAB I PENDAHULUAN

1.1 Latar Belakang Masalah

Dalam operasional FORZA GYM Babarsari, data historis jumlah kunjungan anggota dan data transaksi penjualan telah tersedia dan tercatat secara rutin. Data tersebut seharusnya dapat dimanfaatkan sebagai dasar dalam pengambilan keputusan yang lebih objektif dan terukur. Dalam sektor jasa, pengambilan keputusan operasional sangat dipengaruhi oleh dinamika permintaan yang bersifat fluktuatif dan bergantung pada waktu. Data yang tersimpan dalam sistem informasi tidak lagi berfungsi semata sebagai arsip administratif, melainkan sebagai sumber informasi yang dapat diolah untuk memahami pola permintaan dan perilaku pelanggan secara sistematis (Tan et al., 2006). Oleh karena itu, pemanfaatan analisis data menjadi penting dalam mendukung perencanaan operasional dan strategi pemasaran berbasis bukti empiris.

Sebagai penyedia jasa kebugaran, FORZA GYM Babarsari secara rutin menghasilkan data operasional berupa data historis jumlah kunjungan anggota dan data transaksi penjualan produk serta layanan. Namun, berdasarkan pengamatan awal dan hasil wawancara dengan pemilik FORZA GYM Babarsari, data tersebut belum dimanfaatkan secara optimal dalam pengambilan keputusan. Penentuan jadwal instruktur, pengadaan produk penjualan, serta penyusunan program promosi masih cenderung mengandalkan pengalaman dan intuisi manajemen. Kondisi ini menunjukkan adanya kesenjangan antara ketersediaan data operasional dan pemanfaatannya dalam pengambilan keputusan berbasis data, sehingga potensi pemanfaatan data sebagai dasar pengambilan keputusan belum dimaksimalkan.

Salah satu permasalahan utama yang dihadapi adalah fluktuasi jumlah kunjungan anggota dari waktu ke waktu. Terdapat periode dengan tingkat kunjungan yang relatif tinggi, seperti pada awal tahun atau periode tertentu, serta periode lain dengan penurunan kunjungan yang signifikan. Fluktuasi tersebut menyulitkan manajemen dalam melakukan perencanaan operasional, khususnya terkait penjadwalan instruktur, pengadaan produk penjualan, dan penentuan waktu pelaksanaan promosi. Tanpa adanya peramalan yang sistematis, perencanaan operasional berpotensi menjadi tidak efisien dan kurang responsif terhadap perubahan permintaan.

Permasalahan peramalan jumlah kunjungan termasuk ke dalam analisis deret waktu (*time series*), di mana nilai suatu periode dipengaruhi oleh nilai pada periode sebelumnya. Analisis deret waktu digunakan untuk memanfaatkan data historis dalam memprediksi nilai pada masa mendatang sehingga dapat membantu organisasi dalam perencanaan dan pengambilan keputusan (Ahaggach et al., 2024). Berbagai metode dapat digunakan dalam peramalan deret waktu, salah satunya adalah metode *Autoregressive Integrated Moving Average* (ARIMA). Model ARIMA merupakan model statistik yang umum digunakan dalam pemodelan data deret waktu satu variabel karena mampu menangkap pola ketergantungan antarperiode dalam data historis (Ramadhani et al., 2022).

Penelitian terdahulu menunjukkan bahwa metode ARIMA telah banyak digunakan dalam berbagai konteks peramalan. Ramadhani et al. (2022) menggunakan model ARIMA

untuk meramalkan jumlah kunjungan wisatawan dan memperoleh model terbaik ARIMA (0,1,1) dengan tingkat akurasi yang baik, ditunjukkan oleh nilai MAPE sebesar 6,23%. Selain itu, penelitian oleh Luo et al. (2017) menunjukkan bahwa metode ARIMA efektif digunakan dalam peramalan jumlah kunjungan layanan kesehatan untuk mendukung perencanaan sumber daya secara lebih optimal. Hal ini menunjukkan bahwa ARIMA relevan digunakan untuk memodelkan data kunjungan yang bersifat fluktuatif dan berbasis waktu.

Penelitian yang secara khusus berkaitan dengan objek pusat kebugaran juga telah dilakukan oleh Priambudi et al. (2020) pada Body Gym Kota Malang. Penelitian tersebut mengembangkan sistem informasi yang dilengkapi fitur peramalan jumlah pengunjung fitness, zumba, dan aerobik menggunakan metode *Double Exponential Smoothing*. Data yang digunakan berasal dari data aktual pengunjung tahun 2015 hingga 2019, dan hasil peramalan dimanfaatkan untuk membantu pemilik tempat *gym* dalam mengambil keputusan operasional. Penelitian tersebut menunjukkan bahwa data jumlah pengunjung pada tempat *fitness* dapat diolah menjadi informasi prediktif yang berguna bagi pengelolaan layanan. Namun, penelitian tersebut masih menggunakan metode *Double Exponential Smoothing* dan data agregasi bulanan, sehingga belum secara khusus membahas peramalan jumlah kunjungan harian menggunakan pendekatan ARIMA.

Selain itu, Jekauc et al. (2015) meneliti prediksi kehadiran anggota *fitness center* dengan membandingkan *Theory of Planned Behavior*, *Social Cognitive Theory*, dan *Physical Activity Maintenance Theory*. Penelitian tersebut menggunakan data kehadiran 101 mahasiswa anggota *fitness center* yang dicatat secara elektronik selama 20 minggu menggunakan *magnetic card*. Hasil penelitian tersebut menunjukkan bahwa pola kehadiran anggota *fitness center* dapat dianalisis dan diprediksi berdasarkan data keikutsertaan serta faktor perilaku. Hal ini memperkuat bahwa data kunjungan anggota pusat kebugaran memiliki karakteristik yang layak dianalisis secara prediktif. Namun, penelitian tersebut lebih berfokus pada prediksi perilaku partisipasi berdasarkan teori psikologi olahraga, bukan pada peramalan jumlah kunjungan harian untuk mendukung perencanaan operasional.

Selain permasalahan jumlah kunjungan, data transaksi penjualan di FORZA GYM Babarsari juga belum dimanfaatkan secara optimal untuk memahami pola pembelian pelanggan. Manajemen belum memiliki informasi mengenai keterkaitan antarproduk atau layanan yang sering dibeli secara bersamaan. Akibatnya, strategi promosi dan *bundling* layanan masih bersifat umum dan belum sepenuhnya didasarkan pada pola transaksi aktual.

Analisis pola transaksi pelanggan dapat dilakukan menggunakan teknik *data mining*, salah satunya melalui *Market Basket Analysis* (MBA). Teknik ini termasuk dalam *association rule mining* yang bertujuan mengidentifikasi hubungan antaritem dalam satu transaksi sehingga dapat diketahui produk atau layanan yang sering dibeli secara bersamaan oleh pelanggan (Martínez et al., 2021).

Penelitian sebelumnya menunjukkan bahwa *Market Basket Analysis* mampu memberikan *insight* yang signifikan terhadap pola pembelian pelanggan. Martínez et al. (2021) menemukan bahwa analisis *association rules* dapat mengidentifikasi keterkaitan antarproduk yang berguna dalam pengelolaan inventori dan strategi pemasaran. Selain itu, penelitian oleh Miranda et al. (2022) menunjukkan bahwa penerapan algoritma Apriori pada data transaksi penjualan mampu menghasilkan aturan asosiasi dengan tingkat *confidence*

yang tinggi, sehingga dapat digunakan sebagai dasar pengambilan keputusan dalam pengelolaan produk dan peningkatan penjualan.

Penelitian yang dekat dengan konteks produk pendukung aktivitas kebugaran dilakukan oleh Pitka et al. (2025), yang menganalisis perilaku konsumen online menggunakan *decision trees*, *GUHA association rules*, dan *formal concept analysis* pada 9.123 transaksi produk *sports nutrition*, *healthy foods*, *fitness clothing*, dan *accessories*. Penelitian tersebut menunjukkan bahwa *association rules* dapat digunakan untuk memahami pola pelanggan, mendukung strategi pemasaran, personalisasi rekomendasi, serta memahami preferensi konsumen pada produk yang berkaitan dengan aktivitas kebugaran. Temuan tersebut relevan dengan penelitian ini karena transaksi FORZA GYM Babarsari juga mencakup layanan kunjungan, layanan keanggotaan, minuman, dan produk pendukung olahraga. Namun, penelitian Pitka et al. dilakukan pada konteks *e-commerce fitness*, sedangkan penelitian ini dilakukan pada pusat kebugaran fisik dengan transaksi layanan dan produk yang terjadi secara langsung.

Meskipun demikian, penerapan *Market Basket Analysis* pada sektor jasa seperti pusat kebugaran perlu mempertimbangkan karakteristik transaksi yang tidak selalu melibatkan banyak item dalam satu waktu. Oleh karena itu, dalam penelitian ini *Market Basket Analysis* digunakan sebagai pendekatan untuk memahami kecenderungan perilaku transaksi pelanggan secara objektif berdasarkan data historis.

Berdasarkan studi literatur dan temuan lapangan, sebagian besar penelitian sebelumnya masih menerapkan peramalan dan *Market Basket Analysis* secara terpisah. Penelitian Priambudi et al. (2020) telah membahas peramalan jumlah pengunjung pada objek *gym*, tetapi menggunakan metode *Double Exponential Smoothing* dan data bulanan. Penelitian Jekauc et al. (2015) menunjukkan bahwa kehadiran anggota *fitness center* dapat diprediksi, tetapi pendekatannya lebih menitikberatkan pada teori perilaku dan partisipasi olahraga. Sementara itu, penelitian Pitka et al. (2025) menunjukkan bahwa *association rules* dapat digunakan untuk memahami perilaku transaksi produk *sports nutrition* dan produk pendukung aktivitas kebugaran, tetapi objeknya berada pada konteks *e-commerce*, bukan pusat kebugaran fisik. Dengan demikian, penelitian yang secara khusus menerapkan peramalan jumlah kunjungan harian dan analisis pola penjualan secara komplementer pada pusat kebugaran masih terbatas.

Kedua permasalahan tersebut merepresentasikan dua aspek pengambilan keputusan yang berbeda namun saling melengkapi, yaitu aspek operasional yang berkaitan dengan jumlah kunjungan anggota dan aspek pemasaran yang berkaitan dengan pola pembelian pelanggan. Oleh karena itu, diperlukan pendekatan analisis yang sesuai dengan karakteristik masing-masing data dan tujuan pengambilan keputusan.

Berdasarkan permasalahan tersebut, penelitian ini berfokus pada penerapan metode ARIMA untuk peramalan jumlah kunjungan anggota serta *Market Basket Analysis* untuk mengidentifikasi pola penjualan secara terpisah. Kedua metode tersebut tidak diintegrasikan secara langsung, melainkan digunakan sebagai pendekatan komplementer dalam mendukung pengambilan keputusan dari aspek operasional dan pemasaran. Hasil dari kedua analisis tersebut diharapkan dapat memberikan informasi yang lebih lengkap dalam mendukung pengambilan keputusan berbasis data pada FORZA GYM Babarsari.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan dalam penelitian ini adalah bagaimana memprediksi jumlah kunjungan anggota di FORZA GYM Babarsari menggunakan metode ARIMA, dan mengidentifikasi pola penjualan berdasarkan transaksi pelanggan menggunakan *Market Basket Analysis* (MBA)

1.3 Batasan Masalah

Untuk memperjelas ruang lingkup penelitian dan menjaga fokus pembahasan, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini menggunakan data sekunder berupa data historis jumlah kunjungan anggota sebanyak 515 data harian dan data transaksi penjualan sebanyak 6.560 data transaksi yang berasal dari FORZA GYM Babarsari.
2. Periode data yang digunakan dibatasi pada rentang waktu 2 September 2024 hingga 6 Februari 2026, sesuai dengan ketersediaan data yang dimiliki oleh FORZA GYM Babarsari, dengan frekuensi data harian.
3. Metode peramalan yang digunakan dalam penelitian ini dibatasi pada model *Autoregressive Integrated Moving Average* (ARIMA) *non-seasonal* dengan seleksi parameter berbasis kriteria informasi, tanpa melakukan perbandingan dengan metode peramalan lainnya.
4. Peramalan jumlah kunjungan dilakukan dalam jangka pendek dengan horizon prediksi selama 1 hingga 7 hari ke depan, menyesuaikan dengan karakteristik data harian yang digunakan.
5. Analisis pola penjualan dilakukan menggunakan *Market Basket Analysis* dengan pendekatan *association rules* berbasis algoritma Apriori, sehingga tidak mencakup teknik *data mining* lainnya seperti klasterisasi atau klasifikasi.
6. Penelitian ini berfokus pada analisis data dan interpretasi hasil peramalan serta analisis pola penjualan, tanpa mencakup implementasi sistem secara operasional.

1.4 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Melakukan peramalan jumlah kunjungan anggota FORZA GYM Babarsari berdasarkan data historis harian menggunakan model *Autoregressive Integrated Moving Average* (ARIMA) *non-seasonal* dengan horizon prediksi jangka pendek selama 1 hingga 7 hari ke depan.
2. Mengidentifikasi pola penjualan FORZA GYM Babarsari berdasarkan data transaksi penjualan menggunakan *Market Basket Analysis* berbasis *association rules* untuk memperoleh informasi mengenai keterkaitan antarproduk dan layanan yang sering muncul bersama dalam transaksi.

1.5 Manfaat Penelitian

Manfaat yang diharapkan dari tercapainya tujuan penelitian ini adalah sebagai berikut:

1. Bagi Peneliti

Penelitian ini memberikan manfaat bagi peneliti dalam meningkatkan pemahaman dan kemampuan dalam menerapkan metode analisis data, khususnya model peramalan deret waktu *non-seasonal* menggunakan *Autoregressive Integrated Moving Average* (ARIMA) dan teknik *association rule mining* melalui *Market Basket Analysis*. Selain itu, penelitian ini menjadi sarana bagi peneliti untuk menerapkan konsep peramalan, *data mining*, evaluasi model, serta interpretasi hasil analisis dalam menyelesaikan permasalahan nyata pada sektor jasa kebugaran.

2. Bagi Institusi

Penelitian ini diharapkan dapat memberikan kontribusi bagi pengembangan keilmuan informatika, khususnya dalam penerapan model peramalan deret waktu dan teknik *data mining* sebagai pendukung pengambilan keputusan berbasis data. Selain itu, penelitian ini juga dapat menjadi referensi bagi penelitian selanjutnya yang mengkaji penerapan metode peramalan dan *Market Basket Analysis* pada organisasi jasa dengan karakteristik permintaan yang fluktuatif.

3. Bagi Masyarakat

Penelitian ini diharapkan dapat memberikan manfaat bagi masyarakat, khususnya pelaku usaha atau pengelola organisasi jasa seperti pusat kebugaran, dalam memahami pentingnya pemanfaatan data operasional sebagai dasar pengambilan keputusan. Hasil peramalan jumlah kunjungan anggota dalam jangka pendek dapat digunakan sebagai dasar perencanaan operasional, seperti penjadwalan instruktur, pengadaan produk penjualan, dan penentuan waktu promosi. Selain itu, hasil analisis pola penjualan dalam bentuk aturan asosiasi antarproduk dan layanan dapat dimanfaatkan untuk menyusun strategi promosi dan bundling layanan yang lebih tepat sasaran.

1.6 Tahapan Penelitian

Tahapan penelitian disusun secara sistematis agar proses penelitian dapat berjalan terarah dan sesuai dengan tujuan yang telah ditetapkan. Adapun tahapan penelitian yang dilakukan adalah sebagai berikut:

- a. Identifikasi Masalah

Mengidentifikasi permasalahan di FORZA GYM Babarsari terkait fluktuasi jumlah kunjungan dan belum optimalnya pemanfaatan data transaksi sebagai dasar pengambilan keputusan.

- b. Studi Literatur

Mempelajari teori dan penelitian terdahulu mengenai metode peramalan deret waktu menggunakan ARIMA dan teknik *Market Basket Analysis* berbasis *association rules*.

c. Pengumpulan Data

Mengumpulkan data sekunder berupa data historis jumlah kunjungan dan data transaksi penjualan dari FORZA GYM Babarsari sesuai periode penelitian dengan frekuensi harian.

d. Pra-pemrosesan Data

Data kunjungan disusun dalam format deret waktu harian, dilakukan penyesuaian frekuensi data serta pengujian stasioneritas menggunakan uji *Augmented Dickey-Fuller* (ADF). Data transaksi ditransformasikan ke dalam bentuk *itemset* dan dikonversi menjadi matriks biner (*one-hot encoding*) untuk mendukung proses *Market Basket Analysis*.

e. Penerapan Metode ARIMA

Tahapan meliputi pengujian stasioneritas dan *differencing* secara iteratif apabila diperlukan, identifikasi kandidat parameter berdasarkan analisis ACF dan PACF, estimasi model, pemilihan model terbaik berdasarkan kriteria informasi (AICc), serta pengujian residual menggunakan uji *Ljung-Box*. Model yang terpilih digunakan untuk melakukan peramalan jumlah kunjungan dalam jangka pendek (1–7 hari ke depan).

f. Penerapan *Market Basket Analysis*

Frequent itemset dibentuk menggunakan algoritma Apriori berdasarkan nilai *minimum support* yang ditentukan. Selanjutnya dibentuk aturan asosiasi menggunakan parameter *minimum confidence* dan dievaluasi berdasarkan nilai *lift* untuk mengidentifikasi hubungan antaritem yang signifikan.

g. Evaluasi Hasil

Kinerja peramalan dievaluasi menggunakan metrik MAE, RMSE, dan MAPE, serta evaluasi residual menggunakan uji *Ljung-Box*. Hasil *Market Basket Analysis* dievaluasi berdasarkan nilai *support*, *confidence*, dan *lift* untuk menentukan aturan asosiasi yang relevan.

h. Analisis dan Interpretasi Hasil

Menganalisis hasil peramalan jumlah kunjungan dan pola asosiasi transaksi pelanggan untuk memperoleh insight yang dapat digunakan dalam mendukung pengambilan keputusan operasional dan pemasaran.

i. Penarikan Kesimpulan

Menyusun kesimpulan berdasarkan hasil analisis serta memberikan saran yang relevan untuk pengembangan penelitian selanjutnya.

1.7 Sistematika Penulisan

Sistematika penulisan Tugas Akhir ini disusun untuk memberikan gambaran yang sistematis mengenai alur pembahasan penelitian, mulai dari pendahuluan hingga penutup. Adapun sistematika penulisan laporan pada penelitian ini adalah sebagai berikut:

BAB I PENDAHULUAN

Bab ini berisi latar belakang masalah yang menguraikan alasan dan urgensi penelitian, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, tahapan penelitian, serta sistematika penulisan.

BAB II TINJAUAN LITERATUR

Bab ini membahas landasan teori dan penelitian terdahulu yang relevan dengan topik penelitian. Pembahasan meliputi konsep analisis deret waktu, metode *Autoregressive Integrated Moving Average* (ARIMA), konsep *data mining*, *Market Basket Analysis*, serta penelitian-penelitian terdahulu yang mendukung penelitian ini.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan metode dan tahapan penelitian yang digunakan, meliputi jenis dan pendekatan penelitian, objek dan sumber data, teknik pengumpulan data, tahapan penelitian, serta penerapan metode ARIMA dan *Market Basket Analysis*.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil penerapan metode ARIMA dan *Market Basket Analysis* berdasarkan data penelitian, serta pembahasan dan interpretasi hasil analisis dalam konteks pengambilan keputusan operasional dan pemasaran.

BAB V PENUTUP


Bab ini berisi kesimpulan yang diperoleh dari hasil penelitian serta saran yang dapat digunakan untuk pengembangan penelitian selanjutnya.

BAB II TINJAUAN LITERATUR

2.1 Pelayanan Jasa Kebugaran

Pelayanan jasa kebugaran merupakan bagian dari sektor jasa yang menyediakan nilai melalui aktivitas atau kinerja layanan yang bersifat tidak berwujud dan berorientasi pada manfaat bagi pelanggan. Dalam konteks pusat kebugaran, layanan yang ditawarkan umumnya meliputi penggunaan fasilitas latihan, kelas atau program kebugaran, pendampingan personal trainer atau instruktur, serta layanan pendukung lainnya. Sebagai organisasi jasa, pusat kebugaran lebih menekankan penciptaan pengalaman, interaksi layanan, dan manfaat kesehatan yang dirasakan pelanggan daripada menghasilkan *output* berupa barang fisik (Lovelock et al., 2004).

Secara konseptual, industri jasa memiliki karakteristik utama yang membedakannya dari sektor manufaktur, yaitu tidak berwujud (*intangibility*), tidak dapat dipisahkan antara proses produksi dan konsumsi (*inseparability*), memiliki tingkat variasi layanan yang tinggi (*variability*), serta tidak dapat disimpan (*perishability*) (Kotler & Armstrong, 2003). Karakteristik tersebut menyebabkan permintaan layanan jasa kebugaran, khususnya jumlah kunjungan anggota, sangat dipengaruhi oleh perilaku pelanggan dan faktor waktu. Layanan yang tidak digunakan pada suatu periode tidak dapat disimpan untuk periode berikutnya, sehingga ketidaktepatan dalam mengelola permintaan dapat berdampak langsung pada efisiensi operasional. Hubungan antar karakteristik utama jasa tersebut dapat dilihat pada Gambar 2.1.



Gambar 2.1 Karakteristik jasa (diadaptasi dari Kotler & Armstrong, 2003: 368)

Dalam pengelolaannya, pusat kebugaran menghadapi tantangan utama berupa fluktuasi jumlah kunjungan anggota dari waktu ke waktu. Jumlah kunjungan dapat mengalami peningkatan atau penurunan yang dipengaruhi oleh berbagai faktor, seperti periode awal bulan, musim tertentu, kebiasaan pelanggan, serta pelaksanaan program promosi. Fluktuasi ini berimplikasi pada perencanaan operasional, khususnya dalam pengadaan produk penjualan, penjadwalan instruktur, dan pengelolaan kualitas layanan.

Tanpa pemahaman yang memadai terhadap pola kunjungan, keputusan operasional berpotensi menjadi kurang efisien dan tidak responsif terhadap perubahan permintaan.


Berbagai kajian pada sektor jasa menunjukkan bahwa pendekatan berbasis data diperlukan untuk mengelola fluktuasi permintaan layanan secara lebih sistematis. Metode peramalan permintaan berbasis deret waktu (*time series forecasting*) banyak digunakan untuk memprediksi pola kunjungan layanan yang bersifat periodik dan dipengaruhi oleh dimensi waktu. Model statistik seperti *Autoregressive Integrated Moving Average* (ARIMA) dinilai relevan karena mampu menangkap pola tren, fluktuasi, dan ketergantungan temporal dalam data kunjungan jasa, sehingga dapat digunakan sebagai dasar perencanaan operasional yang lebih terukur (Friscintia & Alamsyah, 2019; Ahaggach et al., 2024).

Data kunjungan pada layanan kebugaran termasuk ke dalam data deret waktu (*time series*), yaitu data yang dicatat secara berurutan berdasarkan dimensi waktu tertentu, seperti harian, mingguan, atau bulanan. Data deret waktu memiliki karakteristik utama berupa ketergantungan nilai pada suatu periode terhadap nilai pada periode sebelumnya, sehingga pola historis menjadi informasi penting dalam proses analisis dan peramalan (Box et al., 2015). Dengan demikian, data kunjungan tidak dapat diperlakukan sebagai data acak semata, melainkan memiliki struktur temporal yang perlu dianalisis secara khusus.

Dalam konteks jasa kebugaran, data kunjungan anggota umumnya menunjukkan kecenderungan tren dan variasi periodik yang dipengaruhi oleh faktor waktu dan perilaku pelanggan. Karakteristik tersebut menegaskan bahwa data kunjungan memiliki struktur temporal yang memerlukan pendekatan analisis deret waktu. Oleh karena itu, analisis deret waktu menjadi pendekatan yang relevan untuk memahami pola kunjungan anggota pusat kebugaran dan mendukung proses peramalan secara sistematis.

2.2 FORZA GYM Babarsari

FORZA GYM Babarsari merupakan pusat kebugaran yang bergerak di bidang penyediaan layanan kebugaran berbasis keanggotaan serta penjualan produk dan layanan pendukung aktivitas olahraga. Sebagai organisasi jasa, FORZA GYM Babarsari menjalankan aktivitas operasional harian yang menghasilkan data secara berkelanjutan, khususnya data jumlah kunjungan anggota dan data transaksi penjualan. Data tersebut tercatat sebagai bagian dari proses layanan dan merepresentasikan dinamika permintaan layanan serta perilaku konsumsi pelanggan dalam konteks jasa kebugaran. Identitas lembaga secara visual ditunjukkan pada Gambar 2.2.



Gambar 2.2 Logo FORZA GYM Babarsari (akun @forzagym.yk, 2024)

Dalam praktik pengelolaannya, data operasional yang dihasilkan umumnya dimanfaatkan sebagai laporan rutin dan bahan evaluasi administratif. Pemanfaatan data tersebut belum sepenuhnya diarahkan pada analisis kuantitatif yang mendalam untuk mendukung perencanaan operasional berbasis pola historis.

Data jumlah kunjungan anggota FORZA GYM Babarsari mencerminkan tingkat permintaan layanan kebugaran dari waktu ke waktu. Jumlah kunjungan tersebut dicatat secara periodik sehingga membentuk data deret waktu (*time series*), yang memiliki potensi untuk dianalisis dalam memahami pola historis dan kecenderungan permintaan layanan (Box et al., 2015).

Selain data kunjungan, FORZA GYM Babarsari juga menghasilkan data transaksi penjualan yang memuat informasi mengenai item atau layanan yang dibeli dalam satu transaksi. Karakteristik data tersebut memungkinkan pengkajian keterkaitan antaritem pembelian sebagai representasi pola perilaku konsumsi pelanggan. Analisis *market basket* pada data transaksi digunakan untuk mengidentifikasi pola pembelian dan hubungan antaritem yang sering muncul secara bersamaan dalam transaksi (Widiyanesti et al., 2025).

Berdasarkan karakteristik kedua jenis data tersebut, FORZA GYM Babarsari diposisikan sebagai objek penelitian yang relevan untuk kajian analisis data pada sektor jasa kebugaran. Data kunjungan merepresentasikan dinamika permintaan layanan dalam dimensi waktu, sedangkan data transaksi merepresentasikan pola konsumsi pelanggan. Kedua jenis data tersebut memberikan konteks empiris yang sesuai bagi penelitian berbasis metode peramalan deret waktu dan analisis pola transaksi.

2.3 Konsep dan Definisi Dasar

2.3.1 Pengertian Data dan Informasi

Data merupakan sekumpulan fakta mentah yang diperoleh dari hasil pencatatan, pengamatan, atau transaksi yang merepresentasikan suatu kejadian atau aktivitas tertentu. Data dapat berbentuk numerik, teks, maupun simbol, dan pada dasarnya belum memiliki makna apabila tidak diolah lebih lanjut. Dalam konteks sistem informasi, data dihasilkan dan dikumpulkan secara berkelanjutan melalui aktivitas operasional organisasi, lalu disimpan, dikelola, dan diproses untuk mendukung penyebaran informasi dalam pengambilan keputusan organisasi (Rachmawati et al., 2024).

Informasi merupakan hasil dari proses pengolahan data melalui tahapan pembersihan, pengorganisasian, dan analisis sehingga data tersebut memiliki makna dan nilai guna bagi penggunanya. Dalam praktik analisis data, data yang sebelumnya hanya tersimpan sebagai catatan transaksi atau arsip operasional dapat diolah lebih lanjut untuk mengekstraksi pengetahuan yang bernilai dan mendukung pengambilan keputusan (Martínez et al., 2021).

Perbedaan mendasar antara data dan informasi terletak pada tingkat pemaknaan dan kegunaannya. Data bersifat mentah, terpisah, dan belum memiliki konteks, sedangkan informasi bersifat lebih terstruktur, kontekstual, serta memiliki relevansi terhadap tujuan tertentu. Dalam kajian *data mining*, kumpulan data yang tersimpan dapat dianalisis untuk menemukan pola, kecenderungan, dan pengetahuan baru yang berguna bagi organisasi, sehingga proses pengolahan data menjadi informasi tidak hanya bersifat teknis, tetapi juga bernilai strategis bagi pengambilan keputusan (Tan et al., 2006; Fahrudin, 2019).

Dalam konteks penelitian ini, data historis jumlah kunjungan anggota dan data transaksi penjualan FORZA GYM Babarsari diperlakukan sebagai data mentah yang selanjutnya diolah melalui pendekatan analisis data. Proses pengolahan tersebut bertujuan untuk menghasilkan informasi yang dapat digunakan sebagai dasar pengambilan keputusan berbasis data.

2.3.2 Analisis Data dalam Bidang Informatika

Analisis data dalam bidang informatika merupakan proses sistematis untuk mengolah data menjadi informasi dan pengetahuan dengan memanfaatkan pendekatan komputasional, statistika, dan algoritmik. Proses ini mencakup pemilihan metode analisis yang sesuai dengan karakteristik data, tujuan analisis, serta konteks permasalahan yang dihadapi. Dalam disiplin informatika, analisis data berperan sebagai penghubung antara data yang tersimpan dalam sistem informasi dan pemanfaatannya dalam mendukung pengambilan keputusan (Tan et al., 2006; Rachmawati et al., 2024).

Perkembangan teknologi informasi mendorong meningkatnya volume dan kompleksitas data yang dihasilkan oleh organisasi. Kondisi tersebut menjadikan analisis data sebagai bagian yang tidak terpisahkan dari bidang informatika, karena memungkinkan ekstraksi pola, tren, dan hubungan yang tersembunyi di dalam data. Perkembangan *Big Data* dan teknik analitik juga memperluas kemampuan organisasi dalam memperoleh wawasan dari data transaksi dan data operasional yang sebelumnya hanya tersimpan sebagai arsip (Stylianou & Pantelidou, 2025; Ahaggach et al., 2024).

Dalam konteks organisasi jasa, analisis data digunakan untuk mengolah data operasional menjadi informasi yang bernilai guna bagi perencanaan dan evaluasi kinerja. Pendekatan analisis data memungkinkan organisasi mengidentifikasi pola permintaan layanan dan kecenderungan perilaku pelanggan secara lebih sistematis, sehingga keputusan yang diambil dapat didasarkan pada bukti empiris yang terukur (Luo et al., 2017; Martínez et al., 2021).

2.3.3 Peran Analisis Data dalam Pengambilan Keputusan Berbasis Data

Pengambilan keputusan berbasis data (*data-driven decision making*) merupakan pendekatan pengambilan keputusan yang didasarkan pada hasil analisis data yang objektif dan terukur. Pendekatan ini menempatkan data sebagai dasar dalam memahami kondisi, pola, dan kecenderungan tertentu sehingga keputusan yang diambil tidak semata-mata bergantung pada intuisi, tetapi juga pada informasi yang dihasilkan dari proses analisis data (Tan et al., 2006).

Pada sektor jasa, pengambilan keputusan berbasis data memiliki peran penting karena permintaan layanan cenderung berfluktuasi dan dipengaruhi oleh faktor waktu serta perilaku pelanggan. Dalam konteks layanan, analisis deret waktu dapat digunakan untuk memahami pola historis permintaan dan mendukung perencanaan kapasitas maupun alokasi sumber daya (Shamsuzzoha et al., 2025).

Pengambilan keputusan berbasis data dipahami sebagai kerangka konseptual yang mendasari pemanfaatan analisis data pada organisasi jasa. Pendekatan tersebut menjadi dasar pemilihan metode analisis yang digunakan dalam penelitian, tanpa membahas hasil maupun implementasi teknis.

2.4 Peramalan (*Forecasting*)

2.4.1 Pengertian Peramalan

Peramalan (*forecasting*) merupakan proses memperkirakan nilai suatu variabel di masa mendatang berdasarkan pola dan informasi yang terkandung dalam data historis. Peramalan digunakan untuk membantu organisasi memahami kecenderungan yang mungkin terjadi sehingga dapat menyusun perencanaan dan pengambilan keputusan secara lebih terarah. Dalam berbagai bidang, peramalan digunakan sebagai bagian penting dalam mendukung perencanaan strategis dan alokasi sumber daya berdasarkan pola data masa lalu (Ahaggach et al., 2024).

Peramalan tidak bertujuan menghasilkan prediksi yang sepenuhnya bebas dari kesalahan, melainkan menghasilkan estimasi terbaik berdasarkan data dan metode yang digunakan. Tingkat akurasi hasil peramalan dipengaruhi oleh kualitas data historis, karakteristik data, serta kesesuaian metode peramalan yang diterapkan. Oleh karena itu, pemilihan metode peramalan yang tepat menjadi aspek penting dalam proses analisis data berbasis peramalan (Box et al., 2015).

Dalam konteks organisasi jasa, peramalan digunakan untuk memahami kecenderungan permintaan layanan berdasarkan pola historis. Pendekatan ini memberikan gambaran kuantitatif mengenai kemungkinan perubahan permintaan pada periode mendatang sebagai dasar perencanaan yang lebih terukur.

2.4.2 Tujuan dan Manfaat Peramalan dalam Organisasi Jasa

Peramalan memiliki peran penting dalam mendukung perencanaan dan pengambilan keputusan pada organisasi jasa. Melalui peramalan, organisasi dapat mengantisipasi perubahan permintaan, mengalokasikan sumber daya secara lebih efisien, serta meminimalkan risiko akibat ketidakpastian di masa mendatang. Pada sektor jasa, peramalan

menjadi krusial karena permintaan layanan bersifat fluktuatif dan tidak dapat disimpan untuk digunakan pada periode berikutnya (Friscintia & Alamsyah, 2019).

Dalam organisasi jasa kebugaran, peramalan jumlah kunjungan dapat dimanfaatkan sebagai dasar penentuan kapasitas fasilitas, penjadwalan instruktur, serta perencanaan program layanan. Peramalan permintaan layanan berbasis data historis berperan dalam meningkatkan efisiensi operasional dan kualitas layanan, karena organisasi dapat menyesuaikan kapasitas dengan tingkat permintaan yang diperkirakan (Shamsuzzoha et al., 2025).

Selain mendukung perencanaan operasional, peramalan juga bermanfaat dalam evaluasi kinerja. Informasi hasil peramalan memungkinkan organisasi membandingkan antara permintaan aktual dan permintaan yang diperkirakan sebagai bagian dari proses evaluasi kebijakan operasional. Dengan demikian, peramalan berfungsi tidak hanya sebagai alat prediksi, tetapi juga sebagai instrumen pendukung pengambilan keputusan berbasis data.

2.4.3 Jenis-Jenis Peramalan

Secara umum, metode peramalan dapat diklasifikasikan ke dalam dua kelompok utama, yaitu peramalan kualitatif dan peramalan kuantitatif. Dalam kajian peramalan, pendekatan kualitatif ditempatkan sebagai metode yang bertumpu pada penilaian, pengalaman, atau pertimbangan subjektif, sedangkan pendekatan kuantitatif didasarkan pada pengolahan data historis menggunakan metode statistik atau komputasional. Klasifikasi ini juga tercermin dalam perkembangan studi peramalan yang mencakup pendekatan kualitatif klasik, metode statistik tradisional, hingga metode berbasis *machine learning* dan *deep learning* (Ahaggach et al., 2024).

Peramalan kualitatif didasarkan pada pendapat ahli, intuisi, dan pengalaman, serta umumnya digunakan ketika data historis tidak tersedia atau sangat terbatas. Pendekatan ini bersifat lebih subjektif sehingga kurang sesuai untuk analisis yang membutuhkan hasil yang terukur secara kuantitatif.

Sebaliknya, peramalan kuantitatif menggunakan data historis sebagai dasar utama dan memanfaatkan model matematis atau statistika untuk menghasilkan prediksi. Pendekatan ini memungkinkan evaluasi tingkat akurasi peramalan melalui pengukuran kesalahan prediksi. Dalam konteks organisasi yang memiliki ketersediaan data historis yang memadai, peramalan kuantitatif dinilai lebih objektif dan dapat dipertanggungjawabkan secara ilmiah (Box et al., 2015).

Dalam konteks organisasi yang memiliki ketersediaan data historis yang memadai, pendekatan peramalan kuantitatif dinilai lebih relevan untuk mendukung analisis permintaan layanan secara sistematis.

2.4.4 Peramalan Deret Waktu (*Time Series Forecasting*)

Peramalan deret waktu merupakan pendekatan peramalan yang menggunakan data historis yang tersusun berdasarkan urutan waktu sebagai dasar analisis. Pendekatan ini berasumsi bahwa pola yang terjadi di masa lalu memiliki keterkaitan dengan pola yang akan terjadi di masa mendatang. Oleh karena itu, struktur internal data, seperti tren dan fluktuasi waktu, menjadi fokus utama dalam analisis peramalan deret waktu (Box et al., 2015).

Dalam sektor jasa, peramalan deret waktu banyak digunakan karena mampu memodelkan perubahan permintaan layanan yang dipengaruhi oleh dimensi waktu. Data jumlah kunjungan anggota pusat kebugaran termasuk ke dalam data deret waktu yang berpotensi mengandung pola tren dan variasi periodik. Pendekatan peramalan deret waktu memungkinkan organisasi memahami dinamika permintaan layanan secara historis dan menggunakannya sebagai dasar perencanaan operasional yang lebih rasional (Friscentia & Alamsyah, 2019).

Pendekatan peramalan deret waktu menjadi landasan bagi penerapan metode *Autoregressive Integrated Moving Average* (ARIMA) dalam penelitian ini. Pembahasan mengenai konsep, komponen, dan tahapan pemodelan ARIMA disajikan secara lebih rinci pada subbab berikutnya.

2.5 Metode *Autoregressive Integrated Moving Average* (ARIMA)

2.5.1 Konsep Dasar dan Landasan Teoritis Metode ARIMA

Autoregressive Integrated Moving Average (ARIMA) merupakan metode peramalan statistik yang digunakan untuk memodelkan dan memprediksi data deret waktu (*time series*) univariat berdasarkan pola historis yang terkandung dalam data tersebut. Metode ini dikembangkan dalam kerangka pendekatan *Box-Jenkins* yang menekankan pentingnya analisis struktur data, kestasioneran, serta ketergantungan temporal sebagai dasar pembentukan model peramalan yang andal (Box et al., 2015).

Dalam analisis deret waktu, ARIMA berangkat dari asumsi bahwa nilai suatu variabel pada periode tertentu tidak bersifat acak, melainkan dipengaruhi oleh nilai pada periode sebelumnya serta oleh komponen kesalahan acak. Oleh karena itu, ARIMA tidak memerlukan variabel independen tambahan, melainkan sepenuhnya memanfaatkan struktur internal data historis. Karakteristik ini menjadikan ARIMA banyak digunakan dalam peramalan permintaan, volume layanan, dan aktivitas operasional pada berbagai sektor, termasuk sektor jasa (Friscentia & Alamsyah, 2019; Shamsuzzoha et al., 2025).

Selain itu, berbagai penelitian empiris menunjukkan bahwa model ARIMA memiliki kemampuan yang baik dalam memodelkan pola data deret waktu yang bersifat fluktuatif dan non-musiman, khususnya untuk peramalan jangka pendek. Penelitian oleh Nugraha dan Agussalim (2024) menunjukkan bahwa model ARIMA mampu menangkap pola tren jangka pendek secara efektif dalam peramalan kebutuhan listrik di Indonesia, sehingga dapat digunakan sebagai dasar pengambilan keputusan operasional. Penggunaan ARIMA juga telah diterapkan pada data harian dalam berbagai bidang, seperti meteorologi, di mana model ini mampu merepresentasikan dinamika data berdasarkan pola historis yang terbentuk (Murat et al., 2018).

Metode ARIMA umumnya diterapkan pada data yang bersifat univariat dan tersusun secara temporal, sehingga sesuai untuk menganalisis fenomena yang dipengaruhi dimensi waktu. ARIMA memiliki dua bentuk umum, yaitu ARIMA *non-musiman* (*non-seasonal*) dan ARIMA musiman (*seasonal/SARIMA*). Pemilihan bentuk model disesuaikan dengan karakteristik data, khususnya ada atau tidaknya pola musiman (Box et al., 2015). Penelitian Miranda et al. (2025) juga menegaskan bahwa ARIMA lebih sesuai digunakan untuk data

non-musiman, sedangkan SARIMA digunakan ketika terdapat pola musiman yang signifikan dalam data.

2.5.2 Bentuk Umum Model ARIMA

Model *Autoregressive Integrated Moving Average* (ARIMA) merupakan model deret waktu yang menggabungkan komponen *autoregressive* (AR), *differencing/integrated* (I), dan *moving average* (MA). Secara umum, model ARIMA non-musiman dinyatakan dalam bentuk operator *backshift* sebagai berikut:

$$\phi(B)(1 - B)^d Y_t = \theta(B)\varepsilon_t \quad (2.1)$$

dengan:

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p \quad (2.2)$$

$$\theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q \quad (2.3)$$

Keterangan:

- Y_t : nilai deret waktu pada periode ke- t ,
- ε_t : residual (*white noise*),
- B : operator *backshift*, dengan $BY_t = Y_{t-1}$.
- p : orde *autoregressive*,
- d : orde *differencing*,
- q : orde *moving average*.

Persamaan tersebut menunjukkan bahwa nilai deret waktu pada periode tertentu dipengaruhi oleh nilai masa lalu melalui komponen *autoregressive*, oleh proses *differencing* untuk mencapai kestasioneran, serta oleh galat pada periode sebelumnya melalui komponen *moving average*. (Box et al., 2015; Miranda et al., 2025).

Model ARIMA dinyatakan dalam notasi ARIMA(p, d, q), di mana p menunjukkan orde *autoregressive*, d menunjukkan tingkat *differencing*, dan q menunjukkan orde *moving average*. Ketiga parameter tersebut digunakan untuk merepresentasikan struktur model yang sesuai dengan karakteristik data deret waktu (Box et al., 2015).

2.5.3 Karakteristik Data Deret Waktu dan Kesesuaiannya dengan ARIMA

Data deret waktu merupakan data yang dicatat berdasarkan urutan waktu tertentu, seperti harian, mingguan, atau bulanan. Data jenis ini memiliki karakteristik utama berupa ketergantungan nilai antarpériode, di mana nilai pada periode saat ini dipengaruhi oleh nilai pada periode sebelumnya (Box et al., 2015). Selain itu, data deret waktu dapat menunjukkan pola seperti tren, fluktuasi, dan variasi yang dipengaruhi oleh faktor waktu, sehingga analisisnya memerlukan pendekatan yang mempertimbangkan struktur temporal tersebut.

Dalam pemodelan ARIMA, salah satu asumsi penting adalah kestasioneran, yaitu kondisi ketika karakteristik statistik deret waktu, khususnya nilai rata-rata dan varians, relatif

konstan sepanjang waktu. Apabila data menunjukkan tren atau perubahan pola statistik yang menyebabkan deret tidak stasioner, maka diperlukan transformasi seperti *differencing* untuk menghilangkan tren dan menstabilkan deret sebelum pemodelan dilakukan (Box et al., 2015; Ahaggach et al., 2024). Apabila deret waktu telah stasioner tanpa transformasi, maka parameter *differencing* dapat bernilai 0.

Dengan demikian, karakteristik data deret waktu yang bersifat univariat, memiliki ketergantungan antarperiode, dan dapat diuji kestasionerannya menjadikan metode ARIMA relevan sebagai pendekatan peramalan statistik untuk memodelkan dan memprediksi nilai pada periode berikutnya secara sistematis.

2.5.4 Uji Kestasioneran *Augmented Dickey-Fuller* (ADF Test)

Kestasioneran deret waktu merupakan syarat penting dalam pemodelan ARIMA. Salah satu metode yang umum digunakan untuk menguji kestasioneran adalah *Augmented Dickey-Fuller* (ADF test). Uji ini digunakan untuk mendeteksi keberadaan akar unit (*unit root*) yang menunjukkan bahwa data deret waktu tidak stasioner. Dalam penelitian Awad dan Al Karaki (2019), ADF digunakan untuk menguji sifat stasioneritas data deret waktu sebelum dilakukan analisis ekonometrika lanjutan. Model regresi ADF dengan tren dan intersep dinyatakan sebagai berikut:

$$\Delta X_t = \beta_0 + \beta_1 t + \beta_2 X_{t-1} + \sum_{i=1}^{k-1} \delta_i \Delta X_{t-i} + \varepsilon_t \quad (2.4)$$

Keterangan:

ΔX_t : perubahan nilai deret waktu pada periode ke- t

β_0 : konstanta (*intersep*)

$\beta_1 t$: komponen tren waktu

β_2 : koefisien untuk pengujian *unit root*

δ_i : koefisien *lag* dari ΔX untuk mengatasi autokorelasi residual

k : jumlah *lag* yang digunakan pada uji ADF

ε_t : galat acak (*error term*)

Hipotesis uji:

$H_0: \beta_2 = 0$ (data memiliki *unit root* / tidak stasioner)

$H_1: \beta_2 < 0$ (data tidak memiliki *unit root* / stasioner)

Nilai statistik ADF diperoleh dari perbandingan antara estimasi koefisien β_2 dan *standard error* dari koefisien tersebut. Secara matematis, statistik ADF dapat dinyatakan sebagai berikut:

$$ADF \text{ Statistic} = \frac{\hat{\beta}_2}{SE(\hat{\beta}_2)} \quad (2.5)$$

Keterangan:

$\hat{\beta}_2$: estimasi koefisien β_2
 $SE(\hat{\beta}_2)$: *standard error* dari estimasi koefisien β_2

Kriteria keputusan uji didasarkan pada *p-value*. Jika *p-value* lebih kecil dari tingkat signifikansi yang digunakan, misalnya 0,05, maka hipotesis nol ditolak dan deret waktu dinyatakan stasioner. Sebaliknya, jika *p-value* lebih besar atau sama dengan tingkat signifikansi, maka data dianggap tidak stasioner sehingga perlu dipertimbangkan transformasi seperti *differencing* sebelum pemodelan ARIMA dilakukan (Awad & Karaki, 2019).

Secara matematis, *differencing* orde pertama didefinisikan sebagai:

$$\nabla Y_t = Y_t - Y_{t-1} \quad (2.6)$$

Persamaan tersebut menunjukkan bahwa nilai hasil *differencing* pada periode ke- t diperoleh dari selisih antara nilai pada periode ke- t dan nilai pada periode sebelumnya. Proses ini bertujuan untuk menghilangkan tren dan menstabilkan rata-rata deret waktu. Apabila setelah *differencing* orde pertama data masih belum stasioner, maka *differencing* dapat dilakukan kembali hingga diperoleh orde *differencing* yang sesuai.

2.5.5 Identifikasi Model Menggunakan ACF dan PACF

Identifikasi orde model ARIMA merupakan tahap awal dalam kerangka *Box-Jenkins*, yang dilakukan untuk menentukan struktur model berdasarkan pola ketergantungan pada data deret waktu. Identifikasi ini umumnya dilakukan melalui analisis *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). ACF dan PACF membantu memperkirakan orde komponen *moving average* (q) dan *autoregressive* (p) dengan melihat pola korelasi pada berbagai *lag* (Box et al., 2015).

1. *Autocorrelation Function* (ACF)

ACF mengukur korelasi antara nilai deret waktu pada periode ke- t dengan nilai deret waktu pada periode sebelumnya (lag ke- k). Secara matematis, autokorelasi pada lag k dapat dituliskan sebagai:

$$\rho_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad (2.7)$$

Keterangan:

ρ_k : koefisien autokorelasi pada lag ke- k
 Y_t : nilai deret waktu pada periode ke- t
 Y_{t-k} : nilai deret waktu pada periode ke- $t - k$
 $\bar{Y}$: rata-rata deret waktu
 n : jumlah observasi

Dalam identifikasi model ARIMA, pola ACF digunakan terutama untuk membantu menentukan orde MA(q). Sebagai panduan umum, model MA cenderung menunjukkan pola *cut-off* pada ACF (autokorelasi berhenti signifikan setelah *lag* tertentu), sedangkan PACF cenderung menurun secara bertahap (*tapering off*) (Box et al., 2015). Nilai ACF yang diperhatikan tidak hanya berdasarkan tanda positif atau negatif, tetapi juga berdasarkan besar nilai absolutnya dan apakah nilai tersebut melewati batas signifikansi.

2. Partial Autocorrelation Function (PACF)

PACF mengukur korelasi antara Y_t dan Y_{t-k} setelah pengaruh *lag* di antara keduanya (misalnya *lag* 1 sampai *lag* $k - 1$) dihilangkan. Nilai PACF pada *lag* ke- k sering dinotasikan sebagai ϕ_{kk} , yang secara konseptual merepresentasikan korelasi parsial antara Y_t dan Y_{t-k} .

PACF digunakan untuk menentukan orde AR(p). Sebagai panduan umum, model AR cenderung menunjukkan pola *cut-off* pada PACF (korelasi parsial berhenti signifikan setelah *lag* tertentu), sedangkan ACF cenderung menurun secara bertahap (Box et al., 2015). Sama seperti ACF, nilai PACF yang bernilai negatif tetap dapat dipertimbangkan apabila secara absolut cukup besar atau melewati batas signifikansi. Oleh karena itu, interpretasi PACF tidak hanya dilihat dari tanda positif atau negatif, tetapi dari pola korelasi parsial pada beberapa lag awal.

2.5.6 Estimasi dan Pemilihan Model

Setelah kandidat model ARIMA diidentifikasi, tahap selanjutnya adalah melakukan estimasi parameter model dan memilih model terbaik. Estimasi parameter bertujuan memperoleh nilai koefisien *autoregressive* dan *moving average* yang paling sesuai dengan pola data historis. Selanjutnya, pemilihan model dilakukan menggunakan kriteria informasi untuk menilai keseimbangan antara tingkat kecocokan model dan kompleksitas parameter (Box et al., 2015).

Salah satu ukuran yang umum digunakan adalah *Akaike Information Criterion* (AIC), yang didefinisikan sebagai:

$$AIC = 2k - 2\ln(L) \quad (2.8)$$

dengan k menyatakan jumlah parameter yang diestimasi dalam model dan L menyatakan nilai *likelihood* maksimum model. Nilai AIC yang lebih kecil menunjukkan model yang lebih baik karena memiliki tingkat kecocokan yang baik dengan kompleksitas parameter yang lebih efisien.

Pada ukuran sampel yang relatif terbatas, AIC dapat dikoreksi menjadi *Akaike Information Criterion corrected* (AICc) untuk mengurangi kecenderungan pemilihan model yang terlalu kompleks. AICc dirumuskan sebagai:

$$AICc = AIC + \frac{2k(k+1)}{n-k-1} \quad (2.9)$$

dengan n menyatakan jumlah observasi dan k menyatakan jumlah parameter model. Nilai AICc yang paling kecil dipilih sebagai indikator model terbaik karena memberikan keseimbangan paling baik antara kecocokan model terhadap data dan kesederhanaan struktur model (Box et al., 2015).

Penggunaan kriteria informasi dalam seleksi model ARIMA juga diterapkan pada penelitian Ramadhan et al. (2025), yang memilih model terbaik untuk peramalan jumlah pengunjung perpustakaan berdasarkan hasil estimasi dan evaluasi model.

Dalam praktik pemodelan deret waktu, pemilihan model yang tepat penting dilakukan agar model tidak mengalami *overfitting* maupun penggunaan parameter berlebihan, sehingga hasil peramalan menjadi lebih andal (Hewamalage et al., 2023).

2.5.7 Diagnostik Residual Model ARIMA

Setelah model ARIMA terbaik diperoleh melalui proses estimasi dan seleksi, tahap berikutnya adalah melakukan diagnostik residual. Tahap ini bertujuan untuk memastikan bahwa model yang dibangun telah memenuhi asumsi dasar ARIMA dan tidak menyisakan pola sistematis yang belum termodelkan.

Dalam pemodelan deret waktu, residual didefinisikan sebagai selisih antara nilai aktual dengan nilai hasil estimasi model. Secara matematis dinyatakan sebagai:

$$e_t = Y_t - \hat{Y}_t \quad (2.10)$$

Keterangan:

- e_t : residual pada periode ke- t
- Y_t : nilai aktual pada periode ke- t
- $\hat{Y}_t$: nilai hasil estimasi model pada periode ke- t .

Residual yang baik diharapkan bersifat *white noise*, yaitu memiliki rata-rata mendekati nol, varians konstan, serta tidak menunjukkan autokorelasi yang signifikan. Residual yang memenuhi sifat *white noise* menunjukkan bahwa model telah mampu menangkap struktur ketergantungan data dengan baik, sehingga sisa kesalahan dapat dianggap acak (Box et al., 2015).

Salah satu uji yang umum digunakan untuk memeriksa autokorelasi residual adalah *Ljung-Box test*. Statistik uji *Ljung-Box* dirumuskan sebagai:

$$Q = n(n+2) \sum_{k=1}^h \frac{\rho_k^2}{n-k} \quad (2.11)$$

Keterangan:

- Q : statistik uji *Ljung-Box*
- n : jumlah observasi

ρ_k : koefisien autokorelasi residual pada *lag* ke- k
 h : jumlah *lag* yang diuji

Hipotesis:

H_0 : residual tidak mengandung autokorelasi hingga *lag* ke- h
 H_1 : residual mengandung autokorelasi pada setidaknya satu *lag*

Residual dianggap memenuhi asumsi *white noise* apabila $p\text{-value} > \alpha$ (taraf signifikansi), sehingga H_0 tidak ditolak. Sebaliknya, apabila $p\text{-value} \leq \alpha$ maka residual masih mengandung autokorelasi dan model perlu ditinjau kembali (Box et al., 2015).

Diagnostik residual merupakan tahap penting dalam pemodelan ARIMA karena model dengan residual yang acak cenderung memberikan hasil peramalan yang lebih andal dan representatif terhadap data historis (Ramadhan et al., 2025).

2.5.8 Evaluasi Akurasi Model Peramalan

Evaluasi akurasi peramalan bertujuan menilai kedekatan nilai hasil peramalan $\hat{Y}_t$ terhadap nilai aktual Y_t . Dalam literatur peramalan deret waktu, beberapa ukuran kesalahan (*error metrics*) yang umum digunakan meliputi *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE) (Ene Yalçın, 2024).

1. *Mean Absolute Error* (MAE)

MAE mengukur rata-rata besarnya kesalahan absolut antara nilai aktual dan nilai hasil peramalan, tanpa memperhatikan arah kesalahan. Secara matematis, MAE dirumuskan sebagai:

$$MAE = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad (2.12)$$

2. *Root Mean Square Error* (RMSE)

RMSE mengukur akar dari rata-rata kuadrat kesalahan prediksi. Ukuran ini memberikan penalti yang lebih besar terhadap kesalahan berukuran besar, sehingga sensitif terhadap *outlier*. RMSE dirumuskan sebagai:

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2} \quad (2.13)$$

3. *Mean Absolute Percentage Error* (MAPE)

MAPE mengukur kesalahan relatif dalam bentuk persentase dan dirumuskan sebagai:

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \quad (2.14)$$

MAPE memiliki keterbatasan ketika Y_t bernilai nol atau mendekati nol karena melibatkan pembagian terhadap nilai aktual. Kondisi tersebut dapat menyebabkan nilai MAPE menjadi sangat besar, tidak stabil, atau bahkan tidak terdefinisi, sehingga pada konteks tertentu disarankan menggunakan metrik lain yang lebih *robust*, seperti MAE atau RMSE (Hewamalage et al., 2023).

Keterangan:


Y_t : nilai aktual periode ke- t

$\hat{Y}_t$: nilai hasil peramalan periode ke- t

n : jumlah observasi

2.5.9 Alur proses ARIMA

Model ARIMA dibangun melalui tahapan sistematis dalam kerangka *Box-Jenkins* yang mencakup identifikasi model, estimasi parameter, pemeriksaan diagnostik, dan peramalan. Ilustrasi tahapan tersebut ditunjukkan pada Gambar 2.3.



Gambar 2.3 Alur pemodelan ARIMA (Kashiwagi et al., 2025)

Pada tahap awal, data dimuat dan dilakukan pengujian kestasioneran menggunakan *unit root test*. Jika data belum stasioner, maka dilakukan proses *differencing* dan orde *differencing* (d) ditingkatkan secara bertahap hingga deret memenuhi kondisi stasioner. Setelah deret stasioner, tahap identifikasi dilakukan dengan memeriksa pola ACF dan PACF untuk memperoleh dugaan orde komponen *autoregressive* (p) dan *moving average* (q). Nilai p dan q tersebut kemudian digunakan dalam pembentukan kandidat model ARIMA.

Tahap berikutnya adalah estimasi parameter untuk setiap kandidat model (p , d , q). Pemilihan model terbaik dilakukan dengan mempertimbangkan kriteria informasi seperti *Akaike Information Criterion corrected* (AICc). AICc merupakan pengembangan dari AIC yang memberikan koreksi terhadap ukuran sampel terbatas, sehingga lebih stabil dalam pemilihan model. Model dengan nilai AICc terkecil dipilih sebagai model terbaik karena dianggap memiliki keseimbangan optimal antara kecocokan model dan kompleksitas parameter.

Selanjutnya dilakukan tahap diagnostik dengan mengevaluasi residual model, termasuk pemeriksaan autokorelasi residual melalui uji *Ljung-Box*. Residual yang memenuhi karakteristik *white noise* menunjukkan bahwa model telah memadai dalam menangkap struktur ketergantungan data.

Apabila residual masih menunjukkan pola sistematis atau autokorelasi yang signifikan, maka proses kembali ke tahap identifikasi dan estimasi untuk memperbaiki model. Dengan demikian, kerangka *Box-Jenkins* bersifat iteratif dan menegaskan bahwa tujuan pemodelan ARIMA tidak hanya menghasilkan prediksi, tetapi juga memastikan validitas statistik model melalui pengujian asumsi dan evaluasi residual (Kashiwagi et al., 2025).

2.6 Konsep Data Mining

2.6.1 Pengertian Data Mining

Data mining merupakan proses analisis data dalam jumlah besar untuk mengekstraksi pola, hubungan, atau informasi tersembunyi yang memiliki nilai pengetahuan dan dapat digunakan sebagai dasar pengambilan keputusan. *Data mining* memanfaatkan teknik matematis, statistika, dan *machine learning* untuk mengidentifikasi serta memperoleh informasi yang berguna dari sekumpulan data (Alfitra et al., 2024).

Secara konseptual, *data mining* tidak hanya berfokus pada pemrosesan data mentah, tetapi juga pada transformasi data menjadi pengetahuan yang dapat mendukung pengambilan keputusan berbasis data. Dalam lingkungan organisasi modern, volume data operasional yang besar seringkali belum dimanfaatkan secara optimal, sehingga *data mining* berperan penting dalam mengungkap nilai informasi yang tersembunyi di dalamnya (Martínez et al., 2021).

2.6.2 Data Mining dalam Analisis Transaksi Penjualan

Data transaksi penjualan merupakan bentuk data operasional yang mencatat kumpulan item yang dibeli pelanggan dalam satu kejadian transaksi. Setiap transaksi dapat direpresentasikan sebagai himpunan item:

$$T_i = \{i_1, i_2, i_3, \dots, i_n\}$$

dengan T_i menyatakan transaksi ke- i dan i_n menyatakan item yang dibeli. Seluruh transaksi membentuk basis data:

$$D = \{T_1, T_2, T_3, \dots, T_m\}$$

Berbeda dengan data deret waktu yang menekankan urutan kronologis, data transaksi penjualan berfokus pada hubungan *co-occurrence* antaritem dalam satu transaksi. Struktur data seperti ini sesuai untuk analisis asosiasi karena memungkinkan identifikasi pola keterkaitan antarproduk atau layanan yang muncul secara bersamaan dalam transaksi pelanggan (Martínez et al., 2021; Widiyanesti et al., 2025).

Dalam praktik organisasi, data transaksi sering kali hanya digunakan sebagai arsip pencatatan. Padahal, melalui *data mining*, data tersebut dapat dianalisis untuk menemukan kecenderungan pembelian bersamaan, hubungan antarproduk, serta preferensi pelanggan terhadap kombinasi item tertentu. Pada konteks bisnis, hasil analisis ini dapat dimanfaatkan untuk mendukung strategi promosi, penataan produk, dan pengambilan keputusan berbasis pola transaksi aktual (Suprayogi & Karima, 2019). Dalam konteks FORZA GYM Babarsari, transaksi dapat mencakup kombinasi layanan seperti *membership*, *personal training*, maupun produk pendukung kebugaran.

2.6.3 Hubungan Data Mining dengan Market Basket Analysis

Market Basket Analysis (MBA) merupakan salah satu teknik dalam *data mining* yang termasuk ke dalam kategori *association rule mining*. Teknik ini berfokus pada identifikasi pola keterkaitan antaritem dalam data transaksi untuk memahami kecenderungan pembelian pelanggan berdasarkan riwayat transaksi yang tersedia (Martínez et al., 2021; Alfitra et al., 2024). Secara konseptual, hubungan tersebut direpresentasikan dalam bentuk aturan asosiasi:

$$X \rightarrow Y$$

yang menunjukkan bahwa kemunculan item X dalam suatu transaksi diikuti dengan kecenderungan kemunculan item Y . Hubungan ini bersifat statistik, bukan kausal, karena aturan asosiasi hanya menunjukkan keterkaitan kemunculan antaritem dalam transaksi, bukan hubungan sebab-akibat (Martínez et al., 2021).

Market Basket Analysis memanfaatkan frekuensi kemunculan kombinasi item untuk mengidentifikasi pola pembelian pelanggan. Teknik ini relevan diterapkan pada data transaksi karena tidak memerlukan dimensi waktu, melainkan menitikberatkan pada struktur kombinasi item dalam satu transaksi. Oleh karena itu, *data mining* menjadi kerangka konseptual, sedangkan MBA menjadi metode analitis spesifik yang digunakan untuk menggali pola tersebut dalam penelitian ini.

2.6.4 Peran Data Mining dalam Mendukung Tujuan Penelitian

Pemanfaatan *data mining* dalam penelitian ini berperan sebagai pendekatan analitis untuk mengolah data transaksi penjualan yang sebelumnya belum dimanfaatkan secara optimal. Melalui penerapan teknik *data mining*, khususnya *Market Basket Analysis*, penelitian ini diharapkan mampu menghasilkan informasi mengenai pola penjualan yang dapat digunakan sebagai dasar pengambilan keputusan operasional dan pemasaran (Martínez et al., 2021).

Secara konseptual, *data mining* dalam penelitian ini tidak diposisikan sebagai tujuan akhir, melainkan sebagai kerangka analitis yang mendukung penerapan *Market Basket Analysis* dalam menganalisis pola penjualan. Dengan pendekatan tersebut, data transaksi penjualan dapat diolah secara sistematis untuk mengungkap keterkaitan antarproduk atau layanan yang relevan bagi pengambilan keputusan berbasis data (Suprayogi & Karima, 2019).

2.7 Market Basket Analysis

2.7.1 Pengertian Market Basket Analysis

Market Basket Analysis (MBA) merupakan teknik analisis data yang digunakan untuk mengidentifikasi pola keterkaitan antaritem dalam sekumpulan data transaksi. Analisis ini bertujuan untuk mengetahui kombinasi item yang sering muncul secara bersamaan dalam satu transaksi sehingga dapat menggambarkan perilaku pembelian pelanggan secara empiris. *Market Basket Analysis* termasuk ke dalam kelompok *association rule mining* dalam *data mining*, yang berfokus pada pencarian hubungan asosiatif antaritem berdasarkan frekuensi kemunculan dan kekuatan hubungan statistik (Fahrudin, 2019; Widiyanesti et al., 2025).

Dalam konteks bisnis dan jasa, *Market Basket Analysis* digunakan untuk memahami preferensi pelanggan, menyusun strategi promosi, serta mengoptimalkan penawaran produk atau layanan. Dengan memanfaatkan data transaksi historis, metode ini mampu mengungkap pola pembelian yang tidak terlihat secara langsung melalui pencatatan transaksi konvensional. Oleh karena itu, *Market Basket Analysis* menjadi pendekatan yang relevan dalam pengambilan keputusan berbasis data (Martínez et al., 2021).

2.7.2 Karakteristik Data Transaksional

Data yang dianalisis menggunakan *Market Basket Analysis* disebut sebagai data transaksional, yaitu data yang merekam kumpulan item yang muncul dalam satu transaksi. Setiap transaksi dapat terdiri dari satu atau lebih item, dan setiap item diperlakukan sebagai entitas independen dalam proses analisis. Berbeda dengan data deret waktu yang menekankan urutan kronologis, data transaksional lebih berfokus pada hubungan antaritem dalam satu transaksi (Susanto, 2019).

Secara umum, dataset transaksi memiliki struktur berbentuk himpunan item dalam setiap transaksi. Karakteristik ini memungkinkan analisis keterkaitan antaritem dilakukan melalui pendekatan *association rule mining* untuk menemukan kombinasi item yang sering muncul bersama (Martínez et al., 2021).

2.7.3 Association Rule dalam Market Basket Analysis

Association rule merupakan aturan yang digunakan untuk merepresentasikan hubungan keterkaitan antaritem dalam data transaksi. Aturan ini dinyatakan dalam bentuk implikasi:

$$X \rightarrow Y$$

di mana X merupakan *antecedent* dan Y merupakan *consequent*. Aturan asosiasi menunjukkan bahwa apabila suatu transaksi mengandung item X , maka terdapat kecenderungan transaksi tersebut juga mengandung item Y . Hubungan ini bersifat statistik, bukan hubungan sebab-akibat, karena *association rule* hanya menunjukkan pola kemunculan bersama antaritem dalam transaksi (Martínez et al., 2021). Dalam *Market Basket Analysis*, *association rule* digunakan untuk menggambarkan pola keterkaitan antaritem dalam data transaksi dan membantu mengidentifikasi kombinasi item yang relevan bagi pengambilan keputusan bisnis (Widiyanesti et al., 2025).

2.7.4 Ukuran Evaluasi *Association Rule*

Untuk mengevaluasi kualitas suatu aturan asosiasi, *Market Basket Analysis* menggunakan tiga ukuran utama, yaitu *support*, *confidence*, dan *lift*. Ketiga ukuran ini digunakan secara bersamaan agar aturan asosiasi yang dihasilkan tidak hanya sering muncul, tetapi juga memiliki hubungan yang bermakna (Fahrudin, 2019; Widiyanesti et al., 2025).

1. *Support*

Support menunjukkan tingkat kemunculan suatu item atau kombinasi item dalam keseluruhan transaksi. Nilai *support* digunakan untuk mengukur seberapa sering suatu aturan asosiasi muncul dalam dataset transaksi.

$$\text{Support}(X \rightarrow Y) = \frac{\text{Jumlah transaksi yang mengandung } XY}{\text{Jumlah seluruh transaksi}} \quad (2.15)$$

Nilai *support* berada pada rentang 0 hingga 1. Semakin besar nilai *support*, semakin sering kombinasi item tersebut muncul dalam data transaksi penjualan (Widiyanesti et al., 2025).

2. *Confidence*

Confidence menunjukkan tingkat kepercayaan suatu aturan asosiasi, yaitu probabilitas kemunculan item Y ketika item X muncul dalam suatu transaksi.

$$\text{Confidence}(X \rightarrow Y) = \frac{\text{Jumlah transaksi yang mengandung } XY}{\text{Jumlah transaksi yang mengandung } X} \quad (2.16)$$

Nilai *confidence* yang tinggi menunjukkan bahwa aturan asosiasi memiliki konsistensi yang baik dalam menggambarkan pola pembelian pelanggan. Namun, *confidence* tidak dapat digunakan secara tunggal tanpa mempertimbangkan ukuran lainnya (Fahrudin, 2019).

3. *Lift*

Lift digunakan untuk mengukur kekuatan hubungan antara item X dan Y dengan mempertimbangkan kemungkinan kejadian independen.

$$\text{Lift}(X \rightarrow Y) = \frac{\text{Confidence}(X \rightarrow Y)}{\text{Support}(Y)} \quad (2.17)$$

Nilai *lift* lebih besar dari satu menunjukkan adanya hubungan positif antaritem, nilai *lift* sama dengan satu menunjukkan tidak adanya hubungan asosiasi, sedangkan nilai *lift* kurang dari satu menunjukkan hubungan negatif (Fahrudin, 2019; Widiyanesti et al., 2025).

2.7.5 Algoritma Apriori

Algoritma Apriori merupakan algoritma yang umum digunakan dalam *Market Basket Analysis* untuk menemukan *frequent itemsets* pada data transaksi. Algoritma ini bekerja dengan memanfaatkan nilai *minimum support* untuk menyeleksi kombinasi item yang sering muncul, kemudian membentuk aturan asosiasi dari *itemset* yang memenuhi syarat tersebut (Suprayogi & Karima, 2019).

Secara mekanisme, algoritma Apriori bekerja secara iteratif melalui pembentukan kandidat *itemset* berukuran k dari *frequent itemset* berukuran $k - 1$. Proses ini disertai tahap pemangkasan (*pruning*) untuk mengeliminasi kandidat yang tidak memenuhi ambang batas *minimum support*, sehingga pencarian kombinasi item dalam *dataset* transaksi dapat dilakukan secara lebih efisien (Alfitra et al., 2024).

2.7.6 Interpretasi Nilai *Support*, *Confidence*, dan *Lift*

Interpretasi nilai *support*, *confidence*, dan *lift* merupakan tahap penting dalam *Market Basket Analysis* karena menentukan makna serta kelayakan suatu aturan asosiasi untuk dianalisis lebih lanjut. Ketiga ukuran ini saling melengkapi, *support* menekankan tingkat kemunculan aturan, *confidence* menekankan kekonsistenan hubungan, sedangkan *lift* menilai kekuatan asosiasi dengan mempertimbangkan peluang kejadian secara umum (Fahrudin, 2019; Widiyanesti et al., 2025).

Nilai *support* digunakan untuk menilai tingkat kemunculan kombinasi item $X \cup Y$ dalam keseluruhan transaksi. Aturan dengan *support* yang terlalu rendah menunjukkan bahwa kombinasi item jarang terjadi pada data, sehingga relevansinya cenderung terbatas karena hanya mewakili sebagian kecil transaksi. Sebaliknya, *support* yang lebih tinggi menunjukkan bahwa aturan lebih sering muncul dan lebih representatif terhadap pola transaksi.

Nilai *confidence* menggambarkan probabilitas kemunculan Y ketika X muncul dalam suatu transaksi. *Confidence* yang tinggi menunjukkan bahwa aturan memiliki konsistensi yang baik dalam menggambarkan pola pembelian, karena kemunculan X sering diikuti oleh kemunculan Y . Namun, *confidence* tidak selalu mencerminkan kekuatan hubungan yang sebenarnya, karena nilainya dapat tinggi hanya karena Y memang sering muncul pada banyak transaksi.

Nilai *lift* digunakan untuk menilai apakah hubungan antara X dan Y lebih kuat dibandingkan kondisi independen. Aturan dengan $Lift > 1$ menunjukkan bahwa kemunculan Y menjadi lebih mungkin ketika X muncul, sehingga mengindikasikan adanya asosiasi positif yang lebih bermakna. Sebaliknya, $Lift = 1$ menunjukkan tidak adanya asosiasi (cenderung independen), sedangkan $Lift < 1$ menunjukkan hubungan *negative* (Fahrudin, 2019).


Dalam penerapannya, penentuan nilai minimum *support*, *confidence*, dan *lift* tidak memiliki batas baku yang berlaku untuk seluruh jenis data. Nilai ambang tersebut dapat disesuaikan dengan karakteristik dataset, jumlah transaksi, variasi item, serta frekuensi kemunculan kombinasi item. Safitri (2022) menggunakan minimum *support* sebesar 0,1% dan minimum *confidence* sebesar 50% dalam analisis transaksi Pamella Satu Supermarket, serta menghasilkan 29 aturan asosiasi. Handika dan Satwika (2024) juga menggunakan nilai minimum *support* sebesar 0,001 dan minimum *confidence* sebesar 0,005 pada data transaksi minimarket karena variasi produk dan frekuensi kombinasi pembelian yang relatif terbatas, sehingga ambang yang terlalu tinggi berpotensi tidak menghasilkan pola yang signifikan.

Selain *support* dan *confidence*, nilai *lift* juga dapat digunakan sebagai kriteria tambahan untuk menyeleksi aturan asosiasi yang lebih kuat. Saad et al. (2025) menetapkan minimum *lift* sebesar 1,5 dalam penerapan algoritma Apriori untuk menentukan pola permintaan bahan makanan. Penelitian tersebut menjelaskan bahwa penentuan nilai minimum perlu mempertimbangkan bentuk data, karena nilai minimum yang terlalu rendah dapat menghasilkan terlalu banyak aturan yang tidak kuat, sedangkan nilai *lift* lebih dari 1 menunjukkan hubungan itemset yang kuat.

Dengan demikian, aturan asosiasi yang dianggap informatif tidak hanya ditentukan oleh tingginya nilai *support* dan *confidence*, tetapi juga perlu mempertimbangkan karakteristik data transaksi yang dianalisis. Aturan yang baik umumnya memiliki *support* yang memadai, *confidence* yang sesuai dengan konteks data, serta *lift* lebih besar dari satu. Penggunaan batas *lift* yang lebih selektif, seperti *lift* minimal 1,5, dapat membantu memastikan bahwa aturan yang dipilih memiliki hubungan antaritem yang lebih kuat dan layak dianalisis lebih lanjut.

2.7.7 Alur Proses *Market Basket Analysis*

Market Basket Analysis (MBA) merupakan pendekatan dalam *data mining* yang berfokus pada analisis data transaksi untuk mengungkap pola keterkaitan antar item yang dibeli oleh pelanggan dalam satu transaksi. Pendekatan ini digunakan untuk memperoleh wawasan mengenai kecenderungan perilaku pembelian pelanggan melalui pembentukan aturan asosiasi yang bersifat informatif dan dapat ditindaklanjuti dalam konteks strategi bisnis (Amelia et al., 2024).



Gambar 2.4 Tahapan *Knowledge Discovery in Databases* (KDD) (Amelia et al., 2024)

Secara umum, proses analisis data transaksi dalam penelitian ini mengacu pada tahapan *Knowledge Discovery in Databases* (KDD) seperti pada gambar 2.4, yang meliputi tahap pemilihan data, pra-pemrosesan, transformasi data, proses *data mining*, serta interpretasi hasil. Dalam kerangka tersebut, *Market Basket Analysis* merupakan teknik yang diterapkan pada tahap *data mining* untuk mengidentifikasi pola pembelian pelanggan berdasarkan data transaksi penjualan (Amelia et al., 2024).

Proses *Market Basket Analysis* diawali dengan pengumpulan dan penyiapan data transaksi penjualan. Data transaksi disusun dalam format transaksional, di mana setiap baris merepresentasikan satu transaksi yang berisi sejumlah item. Setelah itu dilakukan tahap pemilihan data dan *preprocessing* agar data siap digunakan dalam proses analisis. Pada tahap transformasi, data dapat diubah ke dalam bentuk biner untuk merepresentasikan keberadaan atau ketidakterdapat item dalam transaksi, sehingga sesuai untuk diproses dalam *association rule mining* (Amelia et al., 2024).

Setelah data siap, dilakukan analisis frekuensi kemunculan item untuk membentuk himpunan item yang sering muncul (*frequent itemsets*). Identifikasi *frequent itemsets* dilakukan dengan mempertimbangkan nilai *minimum support* dan *minimum confidence*, yang memengaruhi jumlah aturan asosiasi yang dihasilkan. Semakin rendah nilai *minimum support*, semakin banyak aturan yang berpotensi diperoleh, tetapi waktu eksekusi juga dapat menjadi lebih lama (Amelia et al., 2024).

Tahap berikutnya adalah pembentukan aturan asosiasi berdasarkan *frequent itemsets* yang telah diperoleh. Pada tahap ini dihitung ukuran evaluasi seperti *support* dan *confidence* untuk menilai kekuatan pola yang ditemukan. Hasil aturan asosiasi kemudian diinterpretasikan sebagai pola pembelian pelanggan yang dapat digunakan sebagai dasar penyusunan strategi bisnis, seperti promosi, penataan produk, atau rekomendasi layanan (Amelia et al., 2024).

Dalam praktiknya, *Market Basket Analysis* dapat diimplementasikan menggunakan algoritma Apriori maupun *FP-Growth*. Algoritma Apriori bekerja secara iteratif dengan membentuk kandidat *itemset* dan melakukan pemindaian data berulang, sedangkan *FP-*

Growth memanfaatkan struktur *FP-Tree* untuk menemukan *frequent itemsets* tanpa membangkitkan kandidat secara eksplisit. Dalam penelitian ini, algoritma Apriori digunakan karena sesuai dengan tujuan analisis yang bersifat eksploratif dan menekankan kemudahan interpretasi hasil (Amelia et al., 2024).

2.8 Penelitian Terdahulu

Penelitian terdahulu yang relevan dengan penelitian ini menunjukkan bahwa pemanfaatan analisis data, khususnya peramalan deret waktu dan *data mining* berbasis transaksi, telah banyak dilakukan untuk mendukung pengambilan keputusan berbasis data pada berbagai sektor. Namun, pendekatan yang digunakan umumnya masih bersifat parsial, baik hanya berfokus pada peramalan maupun pada analisis pola transaksi secara terpisah. Penelitian yang secara eksplisit menggabungkan metode ARIMA dan *Market Basket Analysis* telah ditemukan, tetapi jumlahnya masih terbatas dan konteks penerapannya umumnya berada pada sektor ritel, belum pada layanan kebugaran.

Berikut disajikan beberapa penelitian terdahulu yang relevan dan dijadikan sebagai bahan rujukan dalam penelitian ini. Penelitian-penelitian tersebut digunakan untuk memberikan gambaran mengenai perkembangan kajian yang telah dilakukan sebelumnya, sehingga penelitian ini memiliki arah yang jelas dan tidak mengulang penelitian yang sudah ada. Ringkasan penelitian terdahulu yang terkait dengan penelitian ini disajikan pada Tabel 2.1.

Tabel 2.1 Penelitian terdahulu

No	Peneliti & Tahun	Judul Penelitian	Tujuan Penelitian	Temuan Utama	Keterbatasan / Celah Penelitian
1	Fahmuddin et al. (2023)	Perbandingan Metode ARIMA dan <i>Single Exponential Smoothing</i> dalam	Membandingkan metode ARIMA dan <i>Single Exponential Smoothing</i> untuk menentukan metode terbaik dalam peramalan	ARIMA menghasilkan akurasi lebih baik dibandingkan SES, dengan nilai MAPE yang lebih kecil	Fokus hanya pada peramalan satu variabel tanpa analisis perilaku transaksi pelanggan
2	Ahaggach et al. (2024)	<i>Systematic Mapping Study of Sales Forecasting: Methods, Trends, and Future Directions</i>	Mengidentifikasi metode peramalan yang dominan, tren perkembangan, dan arah penelitian ke depan dalam	Metode statistik tradisional masih digunakan, tetapi adopsi <i>machine learning</i> dan <i>deep learning</i>	Tidak membahas integrasi peramalan dengan analisis data transaksi

Tabel 2.1 Penelitian terdahulu lanjutan

			<i>sales forecasting</i>	meningkat pesat	
3	Shamsuzzoha et al. (2025)	<i>Forecasting financial services of a call center's inbound volumes: A case study</i>	Membangun model prediktif untuk mendukung alokasi sumber daya secara proaktif pada layanan <i>call center</i>	Peramalan membantu optimalisasi alokasi sumber daya dan peningkatan kualitas layanan	Tidak mengaitkan hasil peramalan dengan pola transaksi atau perilaku pelanggan
4	Widiyanesti et al. (2025)	<i>Enhancing Retail Store Layout for Impulsive Buying Using Market Basket Analysis and the Apriori Algorithm</i>	Mengungkap pola pembelian pelanggan dan menggunakan hasil MBA untuk mengusulkan tata letak toko	MBA mampu menghasilkan aturan asosiasi yang menjadi dasar perbaikan layout toko	Tidak memper- timbang- kan aspek waktu atau dinamika permintaan
5	Dwiputra et al. (2023)	<i>Evaluating the Performance of Association Rules in Apriori and FP-Growth Algorithms: Market Basket Analysis to Discover Rules of Item Combinations</i>	Membanding- kan performa Apriori dan <i>FP-Growth</i> pada data transaksi skala besar	<i>FP-Growth</i> lebih cepat dalam waktu eksekusi, sedangkan Apriori lebih hemat memori. Keduanya menghasilkan aturan yang sama	Belum dikombinasikan dengan peramalan atau analisis permintaan waktu ke waktu
6	Susanto & Fenriana (2024)	<i>Web-Based POS with Apriori Market Basket Analysis</i>	Mengem- bangkan sistem POS berbasis <i>web</i> yang terintegrasi dengan MBA dan <i>association rule</i>	MBA membantu memahami pola pembelian dan mendukung strategi promosi, <i>bundling</i> , dan pengelolaan inventori	Tidak memper- timbang- kan data kunjungan atau dinamika permintaan dari waktu ke waktu

Tabel 2.1 Penelitian terdahulu lanjutan

7	Martinez et al. (2021)	<i>Market basket analysis with association rules in the retail sector using Orange. Case Study: Appliances Sales Company</i>	Menganalisis transaksi penjualan untuk memahami perilaku pelanggan dan mendukung pengelolaan inventori	Analisis asosiasi memberikan wawasan terhadap pola pembelian dan perilaku pelanggan	Tidak mengintegrasikan analisis asosiasi dengan peramalan deret waktu
8	Amelia et al. (2024)	Perbandingan algoritma apriori dan <i>fp-growth</i> dalam pengaplikasian <i>market basket analysis</i> untuk strategi bisnis retail	Membandingkan Apriori dan <i>FP-Growth</i> dalam penerapan MBA untuk strategi bisnis ritel	Kedua algoritma dapat digunakan dalam MBA, dengan perbedaan pada efisiensi proses dan jumlah aturan yang dihasilkan	Fokus pada strategi ritel berbasis transaksi, belum dikombinasikan dengan peramalan permintaan
9	Wildan et al. (2025)	<i>Market Basket and Time Series Analysis: Case Study PT XYZ Sales Data</i>	Menggabungkan analisis ARIMA untuk prediksi penjualan dan <i>Market Basket Analysis</i> untuk rekomendasi <i>bundling</i> produk	ARIMA digunakan untuk memprediksi penjualan, sedangkan MBA digunakan untuk menyusun rekomendasi paket produk dalam konteks ritel	Integrasi dilakukan pada sektor ritel, bukan jasa kebugaran, dan pemodelan ARIMA belum menekankan prosedur <i>Box-Jenkins</i> yang sistematis seperti uji ADF, identifikasi ACF/PACF, dan seleksi kandidat model berbasis AICc
10	Ramadhani et al. (2022)	Peramalan Kunjungan Wisatawan Menggunakan ARIMA	Memprediksi jumlah kunjungan wisatawan berdasarkan data historis	Model ARIMA (0,1,1) menghasilkan akurasi tinggi	Hanya fokus pada satu variabel tanpa mempertimbangkan faktor lain

Tabel 2.1 Penelitian terdahulu lanjutan

				dengan MAPE 6,23%	
11	Miranda et al. (2022)	Implementasi <i>Association Rule</i> Dalam Menganalisis Data Penjualan Sheshop dengan Menggunakan Algoritma Apriori	Menganalisis keterkaitan antarproduk dalam transaksi penjualan	Menghasilkan 6 aturan asosiasi dengan <i>confidence</i> hingga 75%	Bergantung pada parameter <i>minimum support</i> dan <i>confidence</i>
12	Miranda, F. A., Tania, K. D., & Kurnia, R. D. (2025)	<i>Comparative Performance Evaluation of ARIMA, SARIMA, and LSTM for Daily Shallot Price Forecasting in Palembang City</i>	Membanding- kan kinerja metode ARIMA, SARIMA, dan LSTM dalam memprediksi harga harian bawang merah di Kota Palembang.	Model ARIMA(1,1,1) memberikan performa terbaik dengan nilai <i>error</i> terendah dibanding SARIMA dan LSTM.	Penelitian berfokus pada data harga komoditas harian dan membandingkan metode prediksi, sehingga belum membahas penerapan pada sektor jasa maupun integrasi hasil prediksi untuk pengambilan keputusan operasional.
13	Amalia et al. (2020)	Sistem Informasi Peramalan Jumlah Pengunjung Menggunakan <i>Metode Double Exponential Smoothing</i>	Merancang sistem informasi Body Gym Kota Malang yang dilengkapi fitur peramalan jumlah pengunjung.	Metode <i>Double Exponential Smoothing</i> menghasilkan MAPE 11,64% dan akurasi 88,36%.	Belum menggunakan ARIMA, data dibuat bulanan, dan belum membahas pola transaksi penjualan.
14	Jekauc et al. (2015)	<i>Prediction of Attendance at Fitness Center</i>	Memprediksi pola kehadiran anggota <i>fitness center</i> berdasarkan teori perilaku.	Ditemukan dua pola kehadiran, yaitu <i>regular attenders</i> dan <i>intermittent exercisers</i> .	Fokus pada perilaku partisipasi, bukan peramalan jumlah kunjungan

Tabel 2.1 Penelitian terdahulu lanjutan

				SCT memiliki daya prediksi paling tinggi.	harian untuk kebutuhan operasional.
15	Pitka et al. (2025)	<i>Time Analysis of Online Consumer Behavior by Decision Trees, GUHA Association Rules, and Formal Concept Analysis</i>	Menganalisis perilaku konsumen online pada transaksi produk <i>sports nutrition, healthy foods, fitness clothing</i> , dan <i>accessories</i> .	<i>Association rules</i> dapat digunakan untuk memahami pola konsumen dan mendukung strategi pemasaran serta rekomendasi pelanggan.	Objeknya <i>e-commerce fitness</i> , bukan pusat kebugaran fisik, dan tidak membahas peramalan kunjungan.

Berdasarkan kajian penelitian terdahulu yang telah disajikan, dapat disimpulkan bahwa penelitian terkait peramalan kunjungan, prediksi kehadiran, dan analisis pola transaksi masih memiliki fokus yang berbeda-beda. Amalia et al. (2020) telah membahas peramalan jumlah pengunjung pada Body Gym Kota Malang menggunakan metode *Double Exponential Smoothing*, sedangkan Jekauc et al. (2015) meneliti prediksi kehadiran anggota *fitness center* berdasarkan pola partisipasi dan faktor perilaku. Di sisi lain, Pitka et al. (2025) menunjukkan bahwa *association rules* dapat digunakan untuk menganalisis perilaku konsumen pada transaksi produk *sports nutrition, healthy foods, fitness clothing*, dan *accessories*. Dengan demikian, penelitian terdahulu telah menunjukkan bahwa data kunjungan maupun data transaksi pada konteks kebugaran memiliki potensi untuk dianalisis secara prediktif dan asosiatif.

Meskipun demikian, penelitian yang secara khusus menerapkan peramalan jumlah kunjungan harian dan analisis pola transaksi penjualan pada pusat kebugaran fisik masih terbatas. Penelitian peramalan umumnya lebih menekankan pada prediksi jumlah pengunjung atau kehadiran anggota, sedangkan penelitian *association rules* lebih banyak diterapkan pada transaksi produk berbasis ritel atau *e-commerce*. Oleh karena itu, penelitian ini berfokus pada penerapan metode ARIMA untuk peramalan jumlah kunjungan anggota serta *Market Basket Analysis* untuk analisis pola transaksi penjualan pelanggan secara terpisah pada konteks jasa kebugaran, yaitu FORZA GYM Babarsari. Kedua metode tersebut digunakan secara komplementer untuk mendukung pengambilan keputusan dari aspek operasional dan pemasaran berbasis data.

BAB III METODOLOGI PENELITIAN

3.1 Jenis dan Pendekatan Penelitian

Penelitian ini menggunakan jenis penelitian kuantitatif dengan pendekatan deskriptif-analitis berbasis data (*data-driven analysis*). Penelitian kuantitatif dipilih karena penelitian ini berfokus pada pengolahan dan analisis data numerik yang diperoleh dari data historis operasional FORZA GYM Babarsari, sehingga memungkinkan pengukuran dan analisis secara objektif serta terukur.

Pendekatan deskriptif digunakan untuk menggambarkan karakteristik data historis yang dianalisis, baik pada data jumlah kunjungan anggota maupun data transaksi penjualan. Pendekatan ini bertujuan untuk memberikan gambaran mengenai pola, kecenderungan, dan struktur data sebelum dilakukan proses analisis lebih lanjut.

Selain itu, penelitian ini menggunakan pendekatan analitis karena melibatkan penerapan metode analisis data secara sistematis terhadap dua jenis data yang berbeda karakteristiknya, yaitu data deret waktu dan data transaksional. Proses analisis dilakukan sesuai dengan karakteristik masing-masing data untuk menghasilkan temuan yang relevan dengan tujuan penelitian.

Berdasarkan tujuan penelitian, pendekatan yang digunakan bersifat terapan (*applied research*), yaitu penelitian yang diarahkan untuk memberikan solusi terhadap permasalahan nyata yang dihadapi oleh organisasi. Dalam konteks ini, penelitian diharapkan dapat mendukung pengambilan keputusan operasional dan pemasaran FORZA GYM Babarsari berdasarkan hasil analisis data.

3.2 Objek dan Subjek Penelitian

3.2.1 Objek Penelitian

Objek penelitian ini adalah FORZA GYM Babarsari, yaitu sebuah pusat kebugaran yang menyediakan layanan kebugaran bagi anggotanya serta penjualan produk dan layanan pendukung. Pemilihan FORZA GYM Babarsari sebagai objek penelitian didasarkan pada ketersediaan data operasional historis yang terdokumentasi secara sistematis, meliputi data jumlah kunjungan anggota dan data transaksi penjualan.

Dalam aktivitas operasionalnya, FORZA GYM Babarsari secara rutin menghasilkan data kunjungan anggota yang dicatat berdasarkan periode waktu tertentu serta data transaksi penjualan yang merepresentasikan aktivitas pembelian pelanggan. Ketersediaan kedua jenis data tersebut menjadikan FORZA GYM Babarsari relevan sebagai objek penelitian untuk mengkaji penerapan metode analisis data dalam mendukung perencanaan operasional dan strategi pemasaran pada sektor jasa kebugaran.

3.2.2 Subjek Penelitian

Subjek penelitian ini bukan individu atau responden, melainkan data historis yang dihasilkan dari aktivitas operasional FORZA GYM Babarsari. Data tersebut digunakan sebagai bahan analisis dalam penerapan metode peramalan dan analisis pola penjualan. Subjek penelitian terdiri atas dua jenis data utama, yaitu:

1. Data jumlah kunjungan anggota, yang merepresentasikan jumlah kunjungan anggota pusat kebugaran pada periode waktu tertentu. Data ini diperlakukan sebagai data deret waktu (*time series*) dan digunakan sebagai dasar dalam pemodelan peramalan menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA).
2. Data transaksi penjualan, yang merepresentasikan catatan transaksi pembelian produk atau layanan oleh pelanggan. Data ini diperlakukan sebagai data transaksional dan digunakan sebagai dasar analisis pola penjualan menggunakan *Market Basket Analysis* dengan algoritma Apriori.

Pemilihan kedua jenis data tersebut sebagai subjek penelitian disesuaikan dengan tujuan penelitian, yaitu untuk menganalisis pola kunjungan anggota dari sisi waktu serta mengidentifikasi keterkaitan antaritem dalam transaksi penjualan. Penggunaan data sebagai subjek penelitian memungkinkan proses analisis dilakukan secara objektif, terukur, dan berbasis pada catatan operasional yang terdokumentasi.

3.3 Jenis dan Sumber Data

Penelitian ini menggunakan data kuantitatif, yaitu data yang dinyatakan dalam bentuk angka dan dapat dianalisis menggunakan metode statistik dan komputasional. Data kuantitatif dipilih karena sesuai dengan tujuan penelitian yang berfokus pada analisis jumlah kunjungan dan transaksi penjualan secara objektif dan terukur.

Berdasarkan karakteristiknya, data dalam penelitian ini terdiri atas dua bentuk utama. Pertama, data deret waktu (*time series*), yaitu data jumlah kunjungan anggota yang dicatat secara periodik dalam rentang waktu tertentu. Kedua, data transaksional, yaitu data transaksi penjualan yang mencatat pembelian produk atau layanan dalam satu transaksi. Kedua bentuk data tersebut digunakan karena memiliki karakteristik yang berbeda dan memerlukan pendekatan analisis yang berbeda pula.

Sumber data yang digunakan dalam penelitian ini adalah data sekunder yang diperoleh dari catatan operasional internal FORZA GYM Babarsari. Data tersebut telah terdokumentasi secara sistematis dan dapat digunakan secara langsung sebagai bahan analisis penelitian. Data yang digunakan mencerminkan kondisi operasional historis yang telah terjadi, sehingga relevan untuk dianalisis dalam rangka mendukung pengambilan keputusan berbasis data.

Klasifikasi jenis data, bentuk data, metode analisis, dan sumber data yang digunakan dalam penelitian ini disajikan pada Tabel 3.1.

Tabel 3.1 Klasifikasi jenis dan sumber data

No	Jenis Data	Bentuk Data	Metode Analisis	Sumber Data
1	Data Kunjungan Anggota	Deret Waktu	ARIMA	Data Operasional
2	Data Transaksi Penjualan	Transaksional	<i>Market Basket Analysis</i>	Data Operasional

3.4 Teknik Pengumpulan Data

Teknik pengumpulan data yang digunakan dalam penelitian ini adalah teknik dokumentasi, yaitu teknik pengumpulan data dengan memanfaatkan dokumen atau catatan

yang telah tersedia. Teknik dokumentasi dipilih karena data yang digunakan dalam penelitian ini berupa data historis operasional yang telah terdokumentasi secara sistematis oleh pihak FORZA GYM Babarsari, sehingga dapat digunakan secara langsung sebagai bahan analisis penelitian.

Data yang dikumpulkan meliputi dua jenis data utama, yaitu data jumlah kunjungan anggota dan data transaksi penjualan. Data jumlah kunjungan anggota diperoleh dari catatan kunjungan atau laporan operasional yang mencatat jumlah kehadiran anggota pada periode tertentu. Data ini digunakan sebagai dasar analisis peramalan jumlah kunjungan menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA). Sementara itu, data transaksi penjualan diperoleh dari catatan transaksi pembelian produk atau layanan oleh pelanggan. Data ini digunakan sebagai dasar analisis pola penjualan menggunakan *Market Basket Analysis* dengan algoritma Apriori.

Proses pengumpulan data dilakukan dengan menyalin dan mengekstraksi data dari sumber internal ke dalam format digital yang dapat diolah lebih lanjut, seperti lembar kerja (*spreadsheet*). Pada tahap ini, peneliti memastikan bahwa data yang dikumpulkan sesuai dengan kebutuhan penelitian dan relevan dengan tujuan analisis.

Penggunaan teknik dokumentasi memungkinkan penelitian dilakukan secara objektif tanpa melibatkan responden secara langsung. Dengan demikian, data yang dianalisis mencerminkan kondisi operasional FORZA GYM Babarsari sebagaimana tercatat dalam dokumen internal.

3.5 Deskripsi dan Struktur Data

3.5.1 Deskripsi Data Penelitian

Data yang digunakan dalam penelitian ini merupakan data kuantitatif yang diperoleh dari aktivitas operasional FORZA GYM Babarsari. Secara umum, data terbagi menjadi dua kelompok sesuai dengan metode analisis yang digunakan, yaitu data deret waktu untuk peramalan jumlah kunjungan dan data transaksional untuk analisis pola penjualan.

Data jumlah kunjungan anggota digunakan untuk menggambarkan dinamika kunjungan dari waktu ke waktu dan dianalisis menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA). Sementara itu, data transaksi penjualan digunakan untuk mengidentifikasi keterkaitan antaritem dalam satu transaksi dan dianalisis menggunakan *Market Basket Analysis* dengan algoritma Apriori.

Pemisahan jenis data ini dilakukan karena masing-masing data memiliki karakteristik struktural dan kebutuhan analisis yang berbeda, sehingga memerlukan pendekatan pengolahan yang sesuai dengan tujuan penelitian.

3.5.2 Struktur Data Kunjungan Anggota (*Time Series*)

Data kunjungan anggota disusun dalam bentuk data deret waktu (*time series*), di mana setiap pengamatan dicatat berdasarkan urutan waktu tertentu. Struktur data ini memungkinkan analisis pola tren, fluktuasi, dan ketergantungan antarperiode yang menjadi dasar dalam pemodelan peramalan menggunakan metode ARIMA. Secara umum, struktur data kunjungan anggota terdiri atas atribut sebagai berikut:

- a. Tanggal: menunjukkan tanggal pencatatan data kunjungan.

- b. Hari: menunjukkan hari pencatatan data kunjungan.
- c. Bulan: menunjukkan bulan pencatatan data kunjungan.
- d. Jumlah Kunjungan: menunjukkan total kunjungan anggota pada periode tersebut.

Sebagai ilustrasi, struktur data kunjungan anggota ditunjukkan pada Tabel 3.2 berikut.

Tabel 3.2 Contoh struktur data kunjungan anggota

No	Tanggal	Hari	Bulan	Jumlah Kunjungan
1	2023-01-01	<i>Sunday</i>	<i>January</i>	123
2	2023-01-02	<i>Monday</i>	<i>January</i>	164
3	2023-01-03	<i>Tuesday</i>	<i>January</i>	196
4	2023-01-04	<i>Wednesday</i>	<i>January</i>	110
5	2023-01-05	<i>Thursday</i>	<i>January</i>	213

Data pada tabel tersebut merupakan data contoh yang digunakan untuk menggambarkan format dan struktur data yang dianalisis. Dalam penelitian ini, data kunjungan anggota yang sesungguhnya memiliki struktur serupa dan digunakan sebagai input dalam proses identifikasi, estimasi, dan peramalan menggunakan metode ARIMA.

3.5.3 Struktur Data Transaksi Penjualan (Transaksional)

Data transaksi penjualan disusun dalam bentuk data transaksional, di mana setiap baris data merepresentasikan satu transaksi yang terdiri atas satu atau lebih item produk atau layanan. Berbeda dengan data deret waktu, data transaksional tidak menekankan urutan kronologis antartransaksi, melainkan fokus pada kombinasi item dalam satu transaksi. Secara umum, struktur data transaksi penjualan terdiri atas atribut sebagai berikut:

- a. ID Transaksi: kode unik yang merepresentasikan satu transaksi.
- b. Tanggal Transaksi: waktu terjadinya transaksi.
- c. Jenis Transaksi: klasifikasi transaksi berdasarkan bentuk atau layanan yang diberikan
- d. Nama Item: Produk atau layanan yang dibeli dalam transaksi tersebut.
- e. Kategori: pengelompokan item berdasarkan jenis produk atau layanan.
- f. Jumlah: kuantitas item yang dibeli dalam suatu transaksi.
- g. Harga Satuan: nilai harga untuk satu unit produk atau layanan yang dibeli.
- h. Total Pembayaran: jumlah keseluruhan nilai transaksi yang harus dibayarkan.
- i. Metode Pembayaran: cara pembayaran yang digunakan oleh pelanggan dalam melakukan transaksi

Sebagai ilustrasi, struktur data transaksi penjualan ditunjukkan pada Tabel 3.3 berikut.

Tabel 3.3 Contoh struktur data transaksi penjualan

Id transaksi	Tanggal	Jenis Transaksi	Nama Item	Kategori	Jml	Harga Satuan	Total Pembayaran
GYMTRX0001	2024-11-19	Penjualan	<i>BCAA Drink</i>	Minuman <i>Fitness</i>	1	79191	79191
GYMTRX0001	2024-11-19	Penjualan	<i>Shaker Bottle</i>	Aksesoris <i>Gym</i>	3	384649	1153947
GYMTRX0001	2024-11-19	Penjualan	<i>Mass Gainer</i>	Suplemen	1	560921	560921
GYMTRX0002	2024-07-02	Penjualan	<i>Whey Protein</i>	Suplemen	7	131066	917462
GYMTRX0002	2024-07-02	Penjualan	<i>Whey Protein</i>	Suplemen	4	214028	856112

Meskipun data transaksi memuat beberapa atribut, dalam analisis *Market Basket Analysis* penelitian ini berfokus pada atribut yang relevan untuk pembentukan *itemset*, yaitu ID transaksi dan nama item. Atribut lain tetap dipandang sebagai bagian dari struktur data operasional, tetapi tidak seluruhnya digunakan secara langsung dalam proses pembentukan aturan asosiasi.

3.5.4 Kesesuaian Struktur Data dengan Metode Analisis


Struktur data kunjungan anggota yang berbentuk deret waktu memungkinkan penerapan metode ARIMA karena memenuhi karakteristik ketergantungan antarperiode yang diperlukan dalam analisis peramalan. Sementara itu, struktur data transaksi penjualan yang berbentuk himpunan item dalam setiap transaksi sesuai dengan kebutuhan *Market Basket Analysis* dalam mengidentifikasi pola keterkaitan antaritem.

Dengan demikian, struktur data yang digunakan dalam penelitian ini telah disesuaikan secara metodologis dengan metode analisis yang diterapkan, sehingga proses pengolahan data dapat dilakukan secara sistematis dan menghasilkan analisis yang relevan dengan tujuan penelitian.

3.6 Tahapan Penelitian

Tahapan penelitian disusun untuk menggambarkan alur kerja penelitian secara sistematis, mulai dari tahap awal hingga diperolehnya kesimpulan dan rekomendasi. Penyusunan tahapan ini bertujuan untuk memastikan bahwa proses penelitian berjalan secara terstruktur, logis, dan sesuai dengan tujuan penelitian yang telah ditetapkan.

Secara umum, tahapan penelitian ini meliputi tahap identifikasi permasalahan, pengumpulan data, pra-pemrosesan data, analisis data menggunakan metode yang sesuai, integrasi dan interpretasi hasil analisis, serta penyusunan kesimpulan dan rekomendasi. Alur tahapan penelitian tersebut ditunjukkan pada Gambar 3.1.



Gambar 3.1 Tahapan penelitian

Tahap pertama adalah identifikasi permasalahan penelitian. Pada tahap ini, peneliti melakukan penelaahan terhadap kondisi operasional FORZA GYM Babarsari untuk mengidentifikasi permasalahan yang relevan dengan tujuan penelitian. Permasalahan yang diidentifikasi meliputi fluktuasi jumlah kunjungan anggota serta belum optimalnya pemanfaatan data transaksi penjualan dalam mendukung analisis pola penjualan. Identifikasi permasalahan dilakukan agar penelitian memiliki arah yang jelas dan metode yang digunakan sesuai dengan kebutuhan objek penelitian. Tahap ini menjadi dasar dalam menentukan kebutuhan data, ruang lingkup analisis, serta metode yang digunakan untuk menjawab permasalahan penelitian.

Tahap kedua adalah pengumpulan data historis operasional. Pada tahap ini, data yang dikumpulkan terdiri atas data historis kunjungan anggota dan data historis transaksi penjualan. Data kunjungan anggota digunakan sebagai dasar dalam proses peramalan, karena data tersebut menggambarkan perubahan jumlah kunjungan dari waktu ke waktu. Sementara itu, data transaksi penjualan digunakan sebagai dasar dalam analisis pola

penjualan, karena data tersebut memuat informasi item atau layanan yang dibeli oleh pelanggan. Kedua jenis data tersebut digunakan sesuai dengan karakteristik dan tujuan analisis masing-masing.

Tahap ketiga adalah pra-pemrosesan data. Tahap ini dilakukan untuk memastikan bahwa data yang digunakan telah siap dianalisis dan sesuai dengan kebutuhan metode yang digunakan. Pada data kunjungan anggota, pra-pemrosesan dilakukan dengan menyiapkan data dalam bentuk deret waktu harian agar dapat dianalisis menggunakan metode ARIMA. Pada data transaksi penjualan, pra-pemrosesan dilakukan dengan menyiapkan data agar sesuai dengan kebutuhan analisis *Market Basket Analysis*. Dengan demikian, pra-pemrosesan data tidak dilakukan secara umum saja, tetapi disesuaikan dengan struktur data dan kebutuhan masing-masing metode analisis.

Tahap keempat adalah analisis data, yang dilakukan melalui dua alur terpisah. Alur pertama adalah analisis peramalan jumlah kunjungan menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA). Analisis ini digunakan untuk menghasilkan peramalan jumlah kunjungan anggota berdasarkan data historis harian. Proses ARIMA dilakukan untuk mengetahui pola data kunjungan, menentukan model yang paling sesuai, serta menghasilkan estimasi jumlah kunjungan pada periode mendatang. Rincian proses analisis ARIMA, mulai dari uji stasioneritas, identifikasi parameter, estimasi model, evaluasi model, hingga *forecasting*, dijelaskan pada Gambar 3.2.

Alur kedua adalah analisis pola penjualan menggunakan *Market Basket Analysis*. Analisis ini digunakan untuk mengidentifikasi hubungan antaritem dalam transaksi penjualan pelanggan. Melalui analisis ini, dapat diketahui item atau layanan apa saja yang memiliki kecenderungan muncul bersama dalam satu transaksi. Proses analisis dilakukan melalui pembentukan *frequent itemset*, *association rules*, dan seleksi *strong rules* berdasarkan nilai *support*, *confidence*, dan *lift*. Rincian proses *Market Basket Analysis* dijelaskan pada Gambar 3.3.

Tahap terakhir adalah penyusunan kesimpulan dan rekomendasi. Pada tahap ini, hasil analisis ARIMA dan hasil analisis *Market Basket Analysis* digunakan sebagai dasar dalam menyusun kesimpulan dan rekomendasi penelitian. Kedua metode tersebut tidak diintegrasikan ke dalam satu model, tetapi digunakan secara terpisah sesuai dengan karakteristik data dan tujuan analisis. ARIMA digunakan untuk mendukung aspek operasional melalui peramalan jumlah kunjungan, sedangkan *Market Basket Analysis* digunakan untuk mendukung aspek pemasaran melalui identifikasi pola penjualan. Dengan demikian, hasil dari kedua analisis tersebut dapat memberikan informasi yang saling melengkapi bagi FORZA GYM Babarsari.

Berdasarkan tahapan penelitian tersebut, setiap proses analisis diarahkan untuk menjawab tujuan penelitian yang telah ditetapkan. Tujuan pertama, yaitu melakukan peramalan jumlah kunjungan anggota, dicapai melalui tahapan pra-pemrosesan data kunjungan, uji stasioneritas, identifikasi parameter, estimasi dan seleksi model ARIMA, evaluasi akurasi, serta *forecasting* jumlah kunjungan 1–7 hari ke depan. Sementara itu, tujuan kedua, yaitu mengidentifikasi pola penjualan berdasarkan transaksi pelanggan, dicapai melalui pra-pemrosesan data transaksi, transformasi data ke dalam bentuk matriks biner, pembentukan *frequent itemset*, pembentukan *association rule*, serta seleksi *strong*

rules berdasarkan nilai *support*, *confidence*, dan *lift*. Dengan demikian, tahapan penelitian ini disusun untuk memastikan bahwa seluruh proses analisis berjalan secara sistematis, terarah, dan sesuai dengan tujuan penelitian.


3.7 Metode Peramalan Jumlah Kunjungan Menggunakan ARIMA

Metode *Autoregressive Integrated Moving Average* (ARIMA) digunakan dalam penelitian ini untuk melakukan peramalan jumlah kunjungan anggota FORZA GYM Babarsari berdasarkan data historis kunjungan. Metode ARIMA dipilih karena mampu memodelkan pola ketergantungan data deret waktu melalui komponen *autoregressive* (AR), *integrated* (I), dan *moving average* (MA), serta dapat digunakan untuk memproyeksikan nilai pada periode mendatang berdasarkan pola historis data.

Dalam penelitian ini, penerapan ARIMA dilakukan melalui tahapan pembentukan deret waktu, pembagian data latih dan data uji, pemodelan ARIMA, evaluasi model, dan peramalan periode mendatang. Proses ini disusun untuk memastikan bahwa model yang digunakan sesuai dengan karakteristik data kunjungan dan dapat menghasilkan estimasi yang mendukung kebutuhan analisis penelitian.

3.7.1 Alur Proses ARIMA

Alur proses pemodelan *Autoregressive Integrated Moving Average* (ARIMA) dalam penelitian ini disusun secara sistematis berdasarkan pendekatan *Box-Jenkins*, sebagaimana ditunjukkan pada Gambar 3.2. Alur ini menggambarkan tahapan pemodelan deret waktu mulai dari input data kunjungan anggota hingga diperolehnya hasil peramalan jumlah kunjungan.



Gambar 3.2 Alur proses ARIMA menggunakan pendekatan *Box-Jenkins*

Tahap awal dimulai dengan menyiapkan data jumlah kunjungan anggota ke dalam bentuk deret waktu (*time series*) harian yang tersusun secara kronologis. Data kemudian divisualisasikan untuk memberikan gambaran awal mengenai pola fluktuasi, kecenderungan perubahan, dan kemungkinan adanya tren pada jumlah kunjungan dari waktu ke waktu. Visualisasi ini berfungsi sebagai tahap eksplorasi awal sebelum pengujian statistik dilakukan yang lebih formal.

Setelah itu, dilakukan pengujian kestasioneran menggunakan *Augmented Dickey-Fuller* (ADF test). Pengujian ini bertujuan untuk menilai apakah data telah memenuhi asumsi stasioneritas yang dibutuhkan dalam pemodelan ARIMA. Apabila data belum stasioner, maka dilakukan proses *differencing* secara bertahap sampai deret waktu memenuhi kondisi stasioner. Jumlah *differencing* yang diperlukan selanjutnya ditetapkan sebagai orde integrasi (d) dalam model ARIMA.

Setelah data berada dalam kondisi stasioner, tahap berikutnya adalah identifikasi kandidat parameter *autoregressive* (p) dan *moving average* (q). Pada penelitian ini, identifikasi dilakukan dengan menghitung nilai *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF) pada data yang telah stasioner. Nilai ACF dan PACF digunakan sebagai dasar untuk menyusun kandidat parameter model yang akan diuji pada tahap estimasi.

Tahap selanjutnya adalah estimasi parameter model ARIMA untuk setiap kombinasi kandidat (p, d, q). Estimasi dilakukan menggunakan pustaka *statsmodels* pada perangkat lunak *Python*. Setiap model yang berhasil diestimasi kemudian dievaluasi menggunakan kriteria informasi, yaitu *Akaike Information Criterion* (AIC) dan terutama *Akaike Information Criterion corrected* (AICc). Model dengan nilai AICc paling kecil dipilih sebagai model terbaik karena dianggap memiliki keseimbangan terbaik antara kecocokan model dan kompleksitas parameter.

Setelah model terbaik diperoleh, dilakukan tahap diagnostik residual untuk memastikan bahwa residual model bersifat *white noise*. Pemeriksaan ini dilakukan melalui evaluasi rata-rata residual, analisis ACF residual, serta uji *Ljung-Box*. Apabila residual tidak menunjukkan autokorelasi yang signifikan, maka model dinyatakan layak digunakan untuk peramalan. Sebaliknya, apabila residual masih mengandung pola sistematis, maka proses pemodelan perlu ditinjau kembali. Setelah proses tersebut model akan di evaluasi.

Tahap akhir dalam alur proses ARIMA adalah melakukan peramalan jumlah kunjungan pada periode mendatang menggunakan model terbaik yang telah terpilih. Hasil peramalan disajikan dalam bentuk prediksi titik (*point forecast*) serta interval kepercayaan untuk menunjukkan tingkat ketidakpastian prediksi. Output ini selanjutnya digunakan sebagai dasar analisis dalam pembahasan hasil penelitian dan sebagai salah satu komponen dalam sistem pendukung keputusan yang dirancang.

3.7.2 Exploratory Data Analysis (EDA)

Sebelum dilakukan pemodelan menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA), data kunjungan anggota terlebih dahulu diperiksa secara awal untuk memahami struktur dasar deret waktu yang akan dianalisis. Tahap ini bertujuan untuk

memastikan bahwa data telah tersusun sesuai dengan kebutuhan analisis deret waktu, sehingga proses pemodelan dapat dilakukan secara valid dan sistematis.

Pada penelitian ini, pemeriksaan awal data dilakukan dengan meninjau urutan kronologis data berdasarkan tanggal pencatatan, kemudian membentuk data ke dalam deret waktu harian yang kontinu. Proses ini penting karena model ARIMA memerlukan data yang tersusun berdasarkan interval waktu yang konsisten. Apabila terdapat tanggal yang tidak memiliki catatan kunjungan, maka tanggal tersebut tetap dimasukkan ke dalam deret waktu dan diisi nilai nol untuk menjaga kontinuitas data.

Melalui tahap ini, peneliti memperoleh gambaran awal mengenai struktur data yang digunakan, termasuk konsistensi indeks waktu dan kelengkapan deret harian. Pemeriksaan awal ini juga menjadi dasar sebelum dilakukan pengujian stasioneritas dan proses *differencing* pada tahap berikutnya.

Dengan demikian, *Exploratory Data Analysis* (EDA) dalam penelitian ini diposisikan sebagai tahap peninjauan awal terhadap kesiapan dan struktur data deret waktu, bukan sebagai tahap analisis inferensial, sehingga berfungsi untuk memastikan bahwa data yang digunakan telah sesuai dengan kebutuhan pemodelan ARIMA.

3.7.3 Uji Stasioneritas dan Penentuan Orde *Differencing* (d)

Dalam penelitian ini, pengujian stasioneritas dilakukan menggunakan *Augmented Dickey-Fuller* (ADF test). Uji ini digunakan untuk mendeteksi keberadaan *unit root*, yaitu indikasi bahwa data belum stasioner. Stasioneritas perlu dipenuhi sebelum pemodelan ARIMA dilakukan karena model ARIMA membutuhkan data yang memiliki rata-rata dan varians relatif stabil sepanjang waktu.

Keputusan pengujian didasarkan pada nilai *p-value*. Apabila nilai *p-value* lebih kecil dari tingkat signifikansi yang digunakan, yaitu 0,05, maka hipotesis nol ditolak dan deret waktu dinyatakan stasioner. Sebaliknya, apabila nilai *p-value* lebih besar atau sama dengan 0,05, maka hipotesis nol gagal ditolak sehingga deret waktu dianggap belum stasioner dan perlu dilakukan proses *differencing*.

Pada tahap implementasi, data jumlah kunjungan anggota terlebih dahulu disusun berdasarkan urutan waktu harian. Selanjutnya, dibentuk komponen pengujian ADF, yaitu nilai perubahan deret waktu ΔX_t , nilai *lag* periode sebelumnya X_{t-1} , dan komponen tren waktu (t). Komponen tersebut digunakan untuk mengestimasi model regresi ADF. Hasil utama yang diperhatikan adalah nilai ADF Statistic dan *p-value*. Nilai ADF Statistic diperoleh dari perbandingan antara estimasi koefisien β_2 dan *standard error*-nya.

Dalam implementasi teknis, pengujian dilakukan dengan bantuan *Python* melalui fungsi `adf_test()` yang memanfaatkan fungsi `adfuller()` dari pustaka `statsmodels`. Namun, program hanya digunakan sebagai alat bantu komputasi karena perhitungan ADF pada data aktual melibatkan jumlah observasi yang besar. Dasar pengambilan keputusan tetap mengacu pada prosedur statistik, yaitu pengujian koefisien β_2 , nilai ADF Statistic, *p-value*, dan taraf signifikansi 0,05.

Untuk memperjelas proses perhitungan, digunakan contoh data jumlah kunjungan harian selama enam hari sebagaimana disajikan pada Tabel 3.4. Data ini hanya digunakan

sebagai ilustrasi manual untuk menunjukkan tahapan pembentukan komponen ADF dan proses *differencing*.

Tabel 3.4 Contoh data kunjungan harian

No	Tanggal	Jumlah Kunjungan Y_t
1	2023-01-01	20
2	2023-01-02	22
3	2023-01-03	25
4	2023-01-04	27
5	2023-01-05	30
6	2023-01-06	31

Proses *differencing* orde pertama dilakukan dengan mengacu pada Persamaan (2.6), yaitu menghitung selisih nilai antarperiode. Contoh perhitungannya adalah sebagai berikut:

$$\nabla Y_2 = Y_2 - Y_1 = 22 - 20 = 2$$

$$\nabla Y_3 = Y_3 - Y_2 = 25 - 22 = 3$$

$$\nabla Y_4 = Y_4 - Y_3 = 27 - 25 = 2$$

$$\nabla Y_5 = Y_5 - Y_4 = 30 - 27 = 3$$

$$\nabla Y_6 = Y_6 - Y_5 = 31 - 30 = 1$$

Hasil *differencing* orde pertama tersebut disajikan pada Tabel 3.5.

Tabel 3.5 Hasil *differencing* orde pertama (data ilustrasi)

No	Y_t	∇Y_t
1	20	—
2	22	2
3	25	3
4	27	2
5	30	3
6	31	1

Berdasarkan Tabel 3.5, nilai hasil *differencing* tidak lagi menunjukkan jumlah kunjungan aktual, tetapi menunjukkan perubahan jumlah kunjungan dari satu hari ke hari berikutnya. Deret awal yang semula meningkat secara bertahap berubah menjadi deret perubahan dengan nilai 2, 3, 2, 3, dan 1. Dengan demikian, proses *differencing* membantu mengurangi pengaruh tren pada data.

Setelah nilai perubahan antarperiode diperoleh, komponen regresi ADF dapat dibentuk. Pada ilustrasi ini, ΔX_t merupakan perubahan jumlah kunjungan, sedangkan X_{t-1} merupakan nilai kunjungan pada periode sebelumnya. Penyusunan komponen ADF ditunjukkan pada Tabel 3.6.

Tabel 3.6 Ilustrasi pembentukan komponen ADF (data ilustrasi)

Periode t	X_t	ΔX_t	X_{t-1}
-------------	-------	--------------	-----------

Tabel 3.6 Ilustrasi pembentukan komponen ADF (data ilustrasi) lanjutan

2	22	2	20
3	25	3	22
4	27	2	25
5	30	3	27
6	31	1	30

Berdasarkan Tabel 3.6, nilai ΔX_t digunakan sebagai variabel dependen, sedangkan konstanta, tren waktu (t), dan nilai *lag* (X_{t-1}) digunakan sebagai variabel penjelas. Karena model ADF yang digunakan mengandung intersep dan tren, maka susunan data regresinya dapat ditunjukkan sebagai berikut.

Tabel 3.7 Susunan data regresi ADF (data ilustrasi)

Observasi	Konstanta	t	X_{t-1}	ΔX_t
1	1	2	20	2
2	1	3	22	3
3	1	4	25	2
4	1	5	27	3
5	1	6	30	1

Berdasarkan susunan pada Tabel 3.7, matriks variabel penjelas Z dan vektor perubahan data ΔX dapat dituliskan sebagai berikut:

$$Z = \begin{bmatrix} 1 & 2 & 20 \\ 1 & 3 & 22 \\ 1 & 4 & 25 \\ 1 & 5 & 27 \\ 1 & 6 & 30 \end{bmatrix}$$

$$\Delta X = \begin{bmatrix} 2 \\ 3 \\ 2 \\ 3 \\ 1 \end{bmatrix}$$

Langkah berikutnya adalah menghitung hasil perkalian matriks $Z'Z$ dan $Z'\Delta X$, sebagai berikut:

$$Z'Z = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 2 & 3 & 4 & 5 & 6 \\ 20 & 22 & 25 & 27 & 30 \end{bmatrix} \begin{bmatrix} 1 & 2 & 20 \\ 1 & 3 & 22 \\ 1 & 4 & 25 \\ 1 & 5 & 27 \\ 1 & 6 & 30 \end{bmatrix}$$

Elemen baris 1 kolom 1:

$$(1)(1) + (1)(1) + (1)(1) + (1)(1) + (1)(1) = 5$$

Elemen baris 1 kolom 2:

$$(1)(2) + (1)(3) + (1)(4) + (1)(5) + (1)(6) = 20$$

Elemen baris 1 kolom 3:

$$(1)(20) + (1)(22) + (1)(25) + (1)(27) + (1)(30) = 124$$

Elemen baris 2 kolom 1:

$$(2)(1) + (3)(1) + (4)(1) + (5)(1) + (6)(1) = 20$$

Elemen baris 2 kolom 2:

$$\begin{aligned}(2)(2) + (3)(3) + (4)(4) + (5)(5) + (6)(6) \\ = 4 + 9 + 16 + 25 + 36 = 90\end{aligned}$$

Elemen baris 2 kolom 3:

$$\begin{aligned}(2)(20) + (3)(22) + (4)(25) + (5)(27) + (6)(30) \\ = 40 + 66 + 100 + 135 + 180 = 521\end{aligned}$$

Elemen baris 3 kolom 1:

$$(20)(1) + (22)(1) + (25)(1) + (27)(1) + (30)(1) = 124$$

Elemen baris 3 kolom 2:

$$\begin{aligned}(20)(2) + (22)(3) + (25)(4) + (27)(5) + (30)(6) \\ = 40 + 66 + 100 + 135 + 180 = 521\end{aligned}$$

Elemen baris 3 kolom 3:

$$\begin{aligned}(20)(20) + (22)(22) + (25)(25) + (27)(27) + (30)(30) \\ = 400 + 484 + 625 + 729 + 900 = 3138\end{aligned}$$

Sehingga:

$$Z'Z = \begin{bmatrix} 5 & 20 & 124 \\ 20 & 90 & 521 \\ 124 & 521 & 3138 \end{bmatrix}$$

dan

$$Z'\Delta X = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 2 & 3 & 4 & 5 & 6 \\ 20 & 22 & 25 & 27 & 30 \end{bmatrix} \begin{bmatrix} 2 \\ 3 \\ 2 \\ 3 \\ 1 \end{bmatrix}$$

Elemen baris 1:

$$(1)(2) + (1)(3) + (1)(2) + (1)(3) + (1)(1) = 11$$

Elemen baris 2:

$$\begin{aligned} (2)(2) + (3)(3) + (4)(2) + (5)(3) + (6)(1) \\ = 4 + 9 + 8 + 15 + 6 = 42 \end{aligned}$$

Elemen baris 3:

$$\begin{aligned} (20)(2) + (22)(3) + (25)(2) + (27)(3) + (30)(1) \\ = 40 + 66 + 50 + 81 + 30 = 267 \end{aligned}$$

Sehingga:

$$Z'\Delta X = \begin{bmatrix} 11 \\ 42 \\ 267 \end{bmatrix}$$

Dari hasil tersebut kemudian dilakukan estimasi koefisien regresi. Berdasarkan perhitungan OLS dari data ilustrasi, diperoleh nilai koefisien dengan persamaan sebagai berikut:

$$(Z'Z)\hat{\beta} = Z'\Delta X$$

diperoleh persamaan:

$$\begin{aligned} 5\beta_0 + 20\beta_1 + 124\beta_2 &= 11 \\ 20\beta_0 + 90\beta_1 + 521\beta_2 &= 42 \\ 124\beta_0 + 521\beta_1 + 3138\beta_2 &= 267 \end{aligned}$$

eliminasi β_0 dari persamaan pertama dan kedua:
persamaan 1 di kali 4:

$$\begin{aligned} (5\beta_0 + 20\beta_1 + 124\beta_2 = 11)4 \\ 20\beta_0 + 80\beta_1 + 496\beta_2 = 44 \end{aligned}$$

dikurangi:

$$\begin{array}{r} 20\beta_0 + 90\beta_1 + 521\beta_2 = 42 \\ 20\beta_0 + 80\beta_1 + 496\beta_2 = 44 \\ \hline 10\beta_1 + 25\beta_2 = -2 \end{array}$$

eliminasi β_0 dari persamaan pertama dan ketiga:

persamaan 1 di kali 124:

$$\begin{array}{r} (5\beta_0 + 20\beta_1 + 124\beta_2 = 11)124 \\ 620\beta_0 + 2480\beta_1 + 15376\beta_2 = 1364 \end{array}$$

persamaan 3 di kali 5:

$$\begin{array}{r} (124\beta_0 + 521\beta_1 + 3138\beta_2 = 267)5 \\ 620\beta_0 + 2605\beta_1 + 15690\beta_2 = 1335 \end{array}$$

dikurangi:

$$\begin{array}{r} 620\beta_0 + 2605\beta_1 + 15690\beta_2 = 1335 \\ 620\beta_0 + 2480\beta_1 + 15376\beta_2 = 1364 \\ \hline 125\beta_1 + 314\beta_2 = -29 \end{array}$$

Diperoleh persamaan baru:

$$\begin{array}{r} 10\beta_1 + 25\beta_2 = -2 \\ 125\beta_1 + 314\beta_2 = -29 \end{array}$$

dari persamaan pertama:

$$\begin{array}{r} 10\beta_1 + 25\beta_2 = -2 \\ 10\beta_1 = -2 - 25\beta_2 \\ \beta_1 = \frac{-2 - 25\beta_2}{10} \\ \beta_1 = -0,2 - 2,5\beta_2 \end{array}$$

substitusi β_1 ke persamaan kedua:

$$\begin{array}{r} 125\beta_1 + 314\beta_2 = -29 \\ 125(-0,2 - 2,5\beta_2) + 314\beta_2 = -29 \end{array}$$

$$\begin{aligned}
-25 - 312,5\beta_2 + 314\beta_2 &= -29 \\
1,5\beta_2 &= -4 \\
\beta_2 &= \frac{-4}{1,5} \\
\beta_2 &= -2,667
\end{aligned}$$

Substitusi β_2 ke persamaan:

$$\begin{aligned}
\beta_1 &= -0,2 - 2,5\beta_2 \\
\beta_1 &= -0,2 - 2,5(-2,667) \\
\beta_1 &= -0,2 + 6,667 \\
\beta_1 &= 6,467
\end{aligned}$$

substitusi β_1 dan β_2 ke persamaan:

$$\begin{aligned}
5\beta_0 + 20\beta_1 + 124\beta_2 &= 11 \\
5\beta_0 + 20(6,467) + 124(-2,667) &= 11 \\
5\beta_0 + 129,34 - 330,708 &= 11 \\
5\beta_0 - 201,368 &= 11 \\
5\beta_0 &= 212,368 \\
\beta_0 &= \frac{212,368}{5} \\
\beta_0 &= 42,474
\end{aligned}$$

Diperoleh hasil akhir:

$$\begin{aligned}
\hat{\beta}_0 &= 42,474 \\
\hat{\beta}_1 &= 6,467 \\
\hat{\beta}_2 &= -2,667
\end{aligned}$$

Koefisien yang menjadi perhatian utama dalam uji ADF adalah $\hat{\beta}_2$, karena koefisien tersebut digunakan untuk menguji keberadaan *unit root*. Nilai $\hat{\beta}_2 = -2,667$ menunjukkan hubungan negatif antara nilai lag (X_{t-1}) dan perubahan data (ΔX_t). Untuk menghitung ADF *Statistic*, diperlukan nilai *standard error* dari $\hat{\beta}_2$. Berdasarkan hasil regresi ilustratif, diperoleh:

$$SE(\hat{\beta}_2) = 0,667$$

Perhitungan nilai ADF *Statistic* dilakukan dengan mengacu pada Persamaan (2.5). Berdasarkan hasil perhitungan, diperoleh:

$$ADF\ Statistic = \frac{-2,667}{0,667}$$

$$ADF\ Statistic = -4,000$$

Nilai *ADF Statistic* yang bernilai negatif menunjukkan arah pengujian terhadap hipotesis alternatif bahwa data tidak memiliki *unit root*. Dalam pengujian ADF, nilai statistik yang semakin negatif menunjukkan semakin kuat indikasi bahwa deret waktu bersifat stasioner. Setelah *ADF Statistic* diperoleh, keputusan akhir tetap didasarkan pada nilai *p-value* atau perbandingan terhadap nilai kritis *Dickey-Fuller*. Apabila *p-value* lebih kecil dari 0,05, maka data dinyatakan stasioner.

Ilustrasi perhitungan tersebut menunjukkan bahwa ADF test tidak hanya berupa keluaran program, tetapi berasal dari proses pembentukan nilai perubahan (ΔX_t), pembentukan nilai lag (X_{t-1}), penyusunan regresi ADF, estimasi koefisien, dan perhitungan nilai statistik uji. Pada data aktual penelitian, tahapan yang sama diterapkan terhadap seluruh data kunjungan harian FORZA GYM Babarsari dengan bantuan *Python* agar proses perhitungan lebih efisien dan akurat.

Penentuan orde *differencing* (*d*) dilakukan secara bertahap. Pertama, data kunjungan awal diuji menggunakan *ADF test*. Apabila hasil pengujian menunjukkan *p-value* lebih kecil dari 0,05, maka data dinyatakan stasioner pada level awal dan nilai *d* ditetapkan sebesar 0. Apabila data belum stasioner, maka dilakukan *differencing* orde pertama dan hasil transformasi diuji kembali menggunakan *ADF test*. Jika data hasil *differencing* orde pertama telah stasioner, maka nilai *d* ditetapkan sebesar 1. Proses ini dapat dilanjutkan apabila data masih belum stasioner, tetapi tetap perlu dibatasi agar tidak terjadi *over-differencing*.

Dengan demikian, nilai *d* pada model ARIMA tidak ditentukan secara subjektif dan tidak hanya bergantung pada keluaran program. Nilai tersebut ditentukan berdasarkan kebutuhan transformasi data agar memenuhi asumsi stasioneritas. Setelah data dinyatakan stasioner, nilai *d* digunakan pada tahap identifikasi parameter *p* dan *q* melalui ACF dan PACF.

3.7.4 Identifikasi Parameter *p* dan *q* (ACF & PACF)

Setelah deret waktu memenuhi asumsi stasioneritas, tahap berikutnya dalam pendekatan *Box-Jenkins* adalah melakukan identifikasi parameter *autoregressive* (*p*) dan *moving average* (*q*). Tahap ini bertujuan untuk menentukan kandidat struktur model ARIMA yang sesuai dengan pola ketergantungan pada data deret waktu. Secara teoritis, identifikasi awal parameter dilakukan melalui analisis *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF).

Dalam penelitian ini, analisis ACF dan PACF dilakukan terhadap data yang telah stasioner, yaitu data hasil transformasi setelah proses *differencing* apabila diperlukan. ACF digunakan untuk melihat pola autokorelasi pada berbagai *lag*, sedangkan PACF digunakan untuk melihat korelasi parsial setelah pengaruh *lag* di antaranya dihilangkan. Kedua analisis ini digunakan sebagai dasar untuk menyusun kandidat nilai *p* dan *q*, bukan untuk langsung menetapkan model akhir.

Untuk memperjelas proses perhitungan ACF dan PACF, digunakan contoh data sederhana yang diasumsikan telah stasioner sebagaimana ditunjukkan pada Tabel 3.8. Data

ini hanya digunakan sebagai ilustrasi manual, sedangkan perhitungan pada data aktual penelitian dilakukan terhadap seluruh data kunjungan anggota FORZA GYM Babarsari.

Tabel 3.8 Contoh data stasioner untuk perhitungan ACF dan PACF

Periode	Y_t
1	10
2	12
3	13
4	15
5	16

Berdasarkan Tabel 3.8, langkah pertama adalah menghitung rata-rata data. Jumlah seluruh data adalah:

$$\bar{Y} = \frac{10 + 12 + 13 + 15 + 16}{5}$$

$$\bar{Y} = \frac{66}{5} = 13,2$$

Setelah rata-rata diperoleh, setiap nilai Y_t dikurangi dengan rata-rata untuk memperoleh nilai deviasi. Hasil perhitungan deviasi ditunjukkan pada Tabel 3.9.

Tabel 3.9 Perhitungan deviasi terhadap rata-rata

Periode	Y_t	$Y_t - \bar{Y}$
1	10	-3,2
2	12	-1,2
3	13	-0,2
4	15	1,8
5	16	2,8

Berdasarkan Tabel 3.9, penyebut dalam perhitungan ACF diperoleh dari jumlah kuadrat deviasi terhadap rata-rata. Perhitungannya adalah sebagai berikut:

$$(-3,2)^2 + (-1,2)^2 + (-0,2)^2 + (1,8)^2 + (2,8)^2$$

$$= 10,24 + 1,44 + 0,04 + 3,24 + 7,84$$

$$= 22,80$$

Selanjutnya, nilai ACF *lag* 1 dihitung dengan mengalikan deviasi periode saat ini dengan deviasi satu periode sebelumnya. Perhitungannya adalah sebagai berikut:

$$(-1,2)(-3,2) + (-0,2)(-1,2) + (1,8)(-0,2) + (2,8)(1,8)$$

$$= 3,84 + 0,24 - 0,36 + 5,04$$

$$= 8,76$$

Perhitungan nilai ACF pada *lag* 1 dilakukan dengan mengacu pada Persamaan (2.7). Berdasarkan hasil perhitungan, diperoleh:

$$\rho_1 = \frac{8,76}{22,80} = 0,384$$

Perhitungan ACF lag 2 dilakukan dengan menggunakan pasangan data yang berjarak dua periode. Perhitungannya adalah sebagai berikut:

$$\begin{aligned} & (-0,2)(-3,2) + (1,8)(-1,2) + (2,8)(-0,2) \\ &= 0,64 - 2,16 - 0,56 \\ &= -2,08 \end{aligned}$$

maka nilai ACF *lag* 2 adalah:

$$\rho_2 = \frac{-2,08}{22,80} = -0,091$$

Setelah nilai ACF diperoleh, tahap berikutnya adalah menghitung PACF. Pada *lag* 1, nilai PACF sama dengan nilai ACF *lag* 1, sehingga:

$$PACF_{lag1} = 0,384$$

Untuk lag 2, PACF dihitung dengan menghilangkan pengaruh *lag* 1. Berdasarkan nilai ACF *lag* 1 dan *lag* 2 yang telah diperoleh, perhitungan PACF *lag* 2 adalah sebagai berikut:

$$\begin{aligned} PACF_{lag2} &= \frac{-0,091 - (0,384)^2}{1 - (0,384)^2} \\ &= \frac{-0,091 - 0,147}{1 - 0,147} \\ &= -\frac{0,238}{0,853} \\ &= -0,279 \end{aligned}$$

Hasil perhitungan ACF dan PACF disajikan dalam tabel 3.10 berikut:

Tabel 3.10 Hasil ilustrasi perhitungan ACF dan PACF

Lag	ACF	PACF
1	0,384	0,384
2	-0,091	-0,279

Berdasarkan Tabel 3.10, nilai ACF *lag* 1 lebih besar dibandingkan ACF *lag* 2. Hal ini menunjukkan bahwa hubungan antara nilai deret waktu saat ini dengan nilai satu periode sebelumnya lebih kuat dibandingkan hubungan dengan nilai dua periode sebelumnya. Oleh karena itu, pada ilustrasi ini *lag* 1 dapat dipertimbangkan sebagai kandidat awal untuk komponen *moving average* (q), sedangkan *lag* 2 tidak diprioritaskan karena nilai absolutnya relatif kecil.

Nilai PACF *lag* 1 menunjukkan korelasi parsial yang lebih kuat dibandingkan *lag* 2. PACF *lag* 2 bernilai negatif, tetapi nilai negatif tidak langsung berarti tidak penting. Dalam interpretasi ACF dan PACF, tanda positif atau negatif menunjukkan arah hubungan, sedangkan kekuatan hubungan dilihat dari besar nilai absolutnya dan apakah nilai tersebut melewati batas signifikansi. Pada ilustrasi ini, nilai absolut PACF *lag* 2 adalah 0,279, sehingga masih dapat dipertimbangkan sebagai kandidat awal, tetapi tidak langsung dijadikan dasar penetapan model akhir.

Berdasarkan hasil ilustrasi perhitungan ACF dan PACF tersebut, kandidat parameter dapat disusun sebagaimana ditunjukkan pada Tabel 3.11.

Tabel 3.11 Ilustrasi kandidat parameter berdasarkan ACF dan PACF

Komponen	Lag yang Menonjol	Kandidat Parameter
PACF	1, 2	$p = \{0, 1, 2\}$
ACF	1	$q = \{0, 1\}$

Berdasarkan Tabel 3.11, kandidat nilai p disusun dari *lag* PACF yang masih dapat dipertimbangkan, sedangkan kandidat nilai q disusun dari *lag* ACF yang terlihat lebih menonjol. Nilai 0 tetap dimasukkan sebagai kandidat karena memungkinkan terbentuknya model tanpa komponen AR atau tanpa komponen MA. Dengan demikian, beberapa kombinasi model ARIMA dapat dibentuk sebagaimana disajikan pada Tabel 3.12.

Tabel 3.12 Ilustrasi kombinasi kandidat model ARIMA

No	Kandidat Model
1	ARIMA(0, d ,0)
2	ARIMA(1, d ,0)
3	ARIMA(2, d ,0)
4	ARIMA(0, d ,1)
5	ARIMA(1, d ,1)
6	ARIMA(2, d ,1)

Pada Tabel 3.12, nilai d merupakan orde *differencing* yang telah diperoleh pada tahap uji stasioneritas. Seluruh kombinasi kandidat model tersebut kemudian diuji pada tahap estimasi parameter. Dengan demikian, ACF dan PACF hanya digunakan untuk mempersempit ruang pencarian kandidat model, sedangkan model akhir ditentukan berdasarkan hasil estimasi, kriteria informasi, dan diagnostik residual.

Dalam implementasi pada data penelitian, perhitungan ACF dan PACF dilakukan menggunakan fungsi `compute_acf_pacf()` pada *Python* karena jumlah data yang dianalisis lebih besar dibandingkan contoh ilustrasi. Fungsi tersebut menghitung nilai ACF

dan PACF pada beberapa *lag* awal dari data yang telah stasioner. Hasilnya kemudian digunakan pada fungsi `suggest_pq_candidates()` untuk menyusun kandidat nilai p dan q . Fungsi tersebut bekerja dengan melihat nilai absolut ACF dan PACF pada beberapa *lag* awal, kemudian memilih *lag* yang paling relevan sebagai kandidat. Selain itu, nilai dasar seperti 0, 1, dan 2 tetap dimasukkan agar ruang pencarian model tidak terlalu sempit.

Dengan demikian, identifikasi parameter p dan q dalam penelitian ini tidak hanya mengandalkan keluaran program, tetapi tetap mengikuti prinsip perhitungan ACF dan PACF. Perhitungan manual pada contoh sederhana menunjukkan bagaimana nilai autokorelasi dan autokorelasi parsial diperoleh. Sementara itu, program digunakan untuk menerapkan prosedur yang sama pada data aktual. Model akhir tidak ditentukan secara langsung dari ACF dan PACF, tetapi melalui proses estimasi dan seleksi model pada tahap berikutnya.

3.7.5 Pembagian Data Latih dan Data Uji

Sebagai bagian dari proses validasi model peramalan, data deret waktu jumlah kunjungan dibagi menjadi dua bagian, yaitu data latih (*training set*) dan data uji (*testing set*). Pembagian ini bertujuan untuk mengevaluasi kemampuan model dalam melakukan generalisasi terhadap data yang tidak digunakan pada tahap pembentukan model.

Dalam penelitian ini, pembagian data dilakukan berdasarkan proporsi 80% sebagai data latih dan 20% sebagai data uji. Proporsi ini dipilih untuk menjaga keseimbangan antara jumlah data yang digunakan dalam proses estimasi parameter dan jumlah data yang digunakan untuk evaluasi performa model. Data latih digunakan untuk membangun dan mengestimasi parameter model ARIMA, sedangkan data uji digunakan untuk mengukur akurasi peramalan pada periode yang berada di luar proses pelatihan.

Karena data yang digunakan berbentuk deret waktu (*time series*), pembagian data dilakukan secara kronologis mengikuti urutan waktu. Artinya, observasi yang lebih awal dimasukkan ke dalam data latih, sedangkan observasi yang lebih akhir dimasukkan ke dalam data uji. Pendekatan ini mempertahankan struktur ketergantungan temporal dan mencegah terjadinya kebocoran informasi (*data leakage*), yang dapat terjadi apabila data diacak (*random split*).

Secara metodologis, pendekatan ini lebih sesuai dibandingkan pembagian acak yang umum digunakan pada data *non*-deret waktu. Dalam konteks peramalan, model harus dibangun menggunakan informasi masa lalu untuk memprediksi masa depan, sehingga pemisahan berdasarkan urutan waktu menjadi prinsip yang fundamental.

Setelah pembagian dilakukan, seluruh proses identifikasi, estimasi parameter, dan pemilihan model ARIMA dilakukan hanya pada data latih. Data uji digunakan secara terpisah pada tahap evaluasi akurasi peramalan untuk memastikan bahwa model yang dibangun tidak hanya mampu menyesuaikan data historis, tetapi juga memiliki kemampuan prediktif yang memadai pada periode berikutnya.

3.7.6 Estimasi Parameter dan Seleksi Model ARIMA

Setelah data dibagi menjadi data latih dan data uji, tahap berikutnya adalah melakukan estimasi parameter model serta seleksi struktur model ARIMA yang paling sesuai. Pada penelitian ini, proses estimasi dan pemilihan model dilakukan menggunakan

modul ARIMA dari pustaka `statsmodels` pada perangkat lunak *Python*, dengan prosedur seleksi kandidat model yang disusun secara terstruktur berdasarkan pendekatan *Box-Jenkins*.

Berbeda dari pendekatan seleksi otomatis penuh seperti `auto_arima()`, penelitian ini menggunakan prosedur seleksi semi-manual berbantuan program. Nilai orde *differencing* (d) terlebih dahulu ditentukan melalui pengujian kestasioneran menggunakan uji *Augmented Dickey-Fuller* (ADF) dan proses *differencing* bertahap hingga deret waktu memenuhi asumsi stasioner. Setelah nilai d diperoleh, kandidat orde *autoregressive* (p) dan *moving average* (q) dibentuk berdasarkan hasil identifikasi awal melalui analisis ACF dan PACF.

Dalam implementasi program, nilai ACF dan PACF dihitung pada data yang telah stasioner. Selanjutnya, beberapa *lag* dengan nilai absolut ACF dan PACF yang relatif dominan digunakan sebagai dasar untuk menyusun kandidat orde q dan p . Selain kandidat yang diperoleh dari ACF dan PACF, program juga menambahkan beberapa kandidat dasar seperti 0, 1, dan 2 agar proses seleksi tetap mencakup model sederhana. Dengan demikian, proses pencarian model tidak dilakukan pada seluruh kombinasi yang mungkin, tetapi pada himpunan kandidat yang telah dibatasi secara terarah berdasarkan karakteristik data.

Setiap kombinasi kandidat model ARIMA (p, d, q) kemudian diestimasi menggunakan metode *Maximum Likelihood Estimation* (MLE). Metode ini bertujuan untuk memperoleh parameter model yang memaksimalkan *likelihood*, yaitu peluang data observasi dihasilkan oleh model yang dibentuk. Dalam konteks ini, parameter *autoregressive* (ϕ) dan *moving average* (θ) ditaksir secara numerik melalui proses optimasi yang dilakukan oleh fungsi estimasi pada pustaka `statsmodels`.

Setelah seluruh kandidat model berhasil diestimasi, pemilihan model terbaik dilakukan menggunakan *Akaike Information Criterion corrected* (AICc). Nilai AICc digunakan karena mempertimbangkan keseimbangan antara kecocokan model terhadap data dan jumlah parameter yang digunakan. Model dengan nilai AICc paling kecil dipilih sebagai model terbaik, selama model tersebut berhasil mencapai status konvergen.

Sebagai ilustrasi sederhana, misalkan salah satu kandidat model ARIMA menghasilkan nilai *log-likelihood* sebesar:

$$\ln(L) = -55,1$$

dan jumlah parameter model yang diestimasi adalah:

$$k = 4$$

Perhitungan nilai AIC dilakukan dengan mengacu pada Persamaan (2.8), dihitung sebagai berikut:

$$\begin{aligned} AIC &= 2k - 2\ln(L) \\ AIC &= 2(4) - 2(-55,1) \\ AIC &= 8 + 110,2 \\ AIC &= 118,2 \end{aligned}$$

Setelah nilai AIC diperoleh, nilai tersebut dikoreksi menjadi AICc dengan mempertimbangkan jumlah observasi dan jumlah parameter. Misalkan jumlah observasi yang digunakan adalah:

$$n = 30$$

Perhitungan nilai AICc dilakukan dengan mengacu pada Persamaan (2.9). dihitung sebagai berikut:

$$\begin{aligned} AICc &= 118,2 + \frac{2(4)(4 + 1)}{30 - 4 - 1} \\ AICc &= 118,2 + \frac{40}{25} \\ AICc &= 118,2 + 1,6 = 119,8 \end{aligned}$$

Berdasarkan contoh tersebut, nilai AICc diperoleh dengan menambahkan faktor koreksi terhadap nilai AIC. Faktor koreksi ini menjadi penting karena model dengan jumlah parameter yang lebih banyak dapat menghasilkan nilai AIC yang lebih kecil, tetapi belum tentu menjadi model yang paling efisien. Oleh karena itu, AICc digunakan agar model yang dipilih tidak hanya memiliki kecocokan yang baik terhadap data, tetapi juga tidak terlalu kompleks.

Sebagai ilustrasi lanjutan, misalkan nilai d telah ditetapkan dari tahap uji stasioneritas. Jika data telah stasioner pada level awal, maka $d = 0$, sehingga kandidat model yang dievaluasi berbentuk ARIMA $(p, 0, q)$. Contoh perbandingan kandidat model berdasarkan nilai AICc disajikan pada Tabel 3.13.

Tabel 3.13 Ilustrasi perbandingan kandidat model berdasarkan AICc

Kandidat Model	Log-Likelihood	k	AIC	AICc
ARIMA(0,0,1)	-56,0	3	118,0	118,9
ARIMA(1,0,1)	-55,1	4	118,2	119,8
ARIMA(2,0,1)	-54,0	5	118,0	120,5
ARIMA(1,0,0)	-57,4	3	120,8	121,7

Berdasarkan Tabel 3.13, model dengan nilai AICc paling kecil adalah ARIMA(0,0,1), yaitu sebesar 118,9. Oleh karena itu, pada ilustrasi tersebut model ARIMA(0,0,1) dipilih sebagai model terbaik. Meskipun terdapat kandidat lain yang memiliki nilai AIC sama atau relatif kecil, nilai AICc dapat menjadi lebih besar apabila jumlah parameter model lebih banyak. Hal ini menunjukkan bahwa AICc tidak hanya mempertimbangkan kecocokan model terhadap data, tetapi juga memberikan penalti terhadap kompleksitas parameter.

Dengan demikian, seleksi model pada penelitian ini tidak didasarkan pada satu kandidat saja, melainkan melalui proses perbandingan beberapa model yang telah dibentuk dari hasil identifikasi awal. Model terbaik dipilih berdasarkan nilai AICc terendah dengan tetap memperhatikan status konvergensi model. Model yang tidak konvergen tidak

digunakan meskipun memiliki nilai kriteria informasi yang rendah, karena hasil estimasinya tidak stabil dan berpotensi menghasilkan interpretasi yang tidak reliabel. Setelah model terbaik diperoleh, tahap berikutnya adalah melakukan diagnostik residual untuk memastikan bahwa residual model telah memenuhi asumsi *white noise* sebelum model digunakan dalam proses peramalan.

3.7.7 Diagnostik Residual Model

Dalam penelitian ini, diagnostik residual dilakukan setelah model ARIMA terbaik diperoleh dari tahap estimasi dan seleksi model. Residual model diperoleh dari selisih antara nilai aktual dan nilai hasil estimasi model. Secara teknis, residual diambil dari atribut resid pada hasil estimasi model ARIMA menggunakan pustaka statsmodels. Diagnostik residual dilakukan melalui tiga komponen utama, yaitu rata-rata residual, ACF residual, dan uji Ljung-Box.

1. Rata-rata residual

Rata-rata residual dihitung untuk melihat apakah residual terpusat di sekitar nol. Nilai rata-rata residual yang mendekati nol menunjukkan bahwa model tidak memiliki bias sistematis yang kuat dalam proses estimasi.

Sebagai ilustrasi, misalkan residual hasil estimasi model pada lima periode disajikan pada Tabel 3.14 berikut:

Tabel 3.14 Ilustrasi hasil estimasi model

Periode	Residual(e_t)
1	1
2	-2
3	0
4	1
5	0

Rata-rata residual dihitung dengan rumus:

$$\bar{e} = \frac{1 + (-2) + 0 + 1 + 0}{5}$$

$$\bar{e} = \frac{0}{5} = 0$$

Hasil tersebut menunjukkan bahwa rata-rata residual berada tepat pada nol. Artinya, berdasarkan ilustrasi tersebut, model tidak menunjukkan bias estimasi yang sistematis. Namun, rata-rata residual yang mendekati nol belum cukup untuk menyatakan bahwa residual telah memenuhi asumsi *white noise*. Oleh karena itu, perlu dilakukan pemeriksaan autokorelasi residual melalui ACF residual dan uji Ljung-Box.

2. Autocorrelation Function (ACF) residual

Grafik atau nilai ACF residual digunakan untuk memeriksa apakah masih terdapat autokorelasi pada residual di beberapa *lag*. Jika residual telah memenuhi asumsi *white noise*, maka autokorelasi residual seharusnya kecil dan tidak menunjukkan pola yang konsisten.

Sebagai ilustrasi, residual pada Tabel 3.10 digunakan untuk menghitung autokorelasi residual pada *lag* 1. Karena rata-rata residual $\bar{e}$ bernilai 0, maka deviasi residual terhadap rata-rata sama dengan nilai residual itu sendiri. Penyebut ACF residual dihitung dari jumlah kuadrat residual sebagai berikut:

$$\begin{aligned} & (1)^2 + (-2)^2 + (0)^2 + (1)^2 + (0)^2 \\ &= 1 + 4 + 0 + 1 + 0 \\ &= 6 \end{aligned}$$

Selanjutnya, pembilang ACF residual *lag* 1 dihitung dengan mengalikan residual periode ke-*t* dengan residual pada satu periode sebelumnya. Perhitungannya adalah sebagai berikut:

$$\begin{aligned} & (-2)(1) + (0)(-2) + (1)(0) + (0)(1) \\ &= -2 + 0 + 0 + 0 \\ &= -2 \end{aligned}$$

Dengan demikian, nilai ACF residual *lag* 1 adalah:

$$\begin{aligned} \rho_1 &= \frac{-2}{6} \\ \rho_1 &= -0,333 \end{aligned}$$

Nilai tersebut menunjukkan adanya autokorelasi negatif pada *lag* 1 dalam ilustrasi sederhana. Namun, satu nilai ACF saja belum cukup untuk menyimpulkan apakah residual mengandung autokorelasi signifikan. Oleh karena itu, pemeriksaan ACF residual perlu dilengkapi dengan uji *Ljung-Box* sebagai pengujian formal terhadap autokorelasi residual hingga beberapa *lag*.

Dalam penelitian ini, nilai ACF residual dihitung menggunakan program dan divisualisasikan dalam bentuk grafik. Apabila batang ACF residual pada berbagai *lag* berada di sekitar nol dan tidak membentuk pola tertentu, maka residual dapat dianggap tidak menunjukkan autokorelasi yang berarti. Sebaliknya, apabila masih terdapat beberapa *lag* dengan autokorelasi yang cukup besar atau membentuk pola sistematis, maka model belum sepenuhnya menangkap struktur ketergantungan dalam data.

3. Uji *Ljung-Box*

Uji *Ljung-Box* digunakan untuk menguji ada atau tidaknya autokorelasi residual hingga *lag* tertentu, dengan hipotesis:

- a. H_0 : residual tidak mengandung autokorelasi (*white noise*)
- b. H_1 : residual mengandung autokorelasi

Apabila nilai *p-value* lebih besar dari tingkat signifikansi ($\alpha = 0,05$), maka hipotesis nol tidak ditolak sehingga residual dinyatakan tidak mengandung autokorelasi yang signifikan dan model dianggap telah memenuhi asumsi *white noise*. Sebaliknya, apabila nilai *p-value* kurang dari atau sama dengan 0,05, maka residual masih mengandung autokorelasi dan model perlu dievaluasi kembali.

Sebagai ilustrasi sederhana, misalkan diketahui:

Jumlah observasi residual $n = 20$

Jumlah *lag* yang diuji $h = 3$

Autokorelasi residual $\rho = 0,10, \rho = 0,08, \rho = 0,05$

Perhitungan nilai statistik Ljung-Box dilakukan dengan mengacu pada Persamaan (2.11), dihitung sebagai berikut:

$$\begin{aligned}
 Q &= 20(20 + 2) \left(\frac{0,10^2}{20 - 1} + \frac{0,08^2}{20 - 2} + \frac{0,05^2}{20 - 3} \right) \\
 Q &= 20(22) \left(\frac{0,01}{19} + \frac{0,0064}{18} + \frac{0,0025}{17} \right) \\
 Q &= 440(0,000526 + 0,000356 + 0,000147) \\
 Q &= 440(0,001029) = 0,453
 \end{aligned}$$

Nilai $Q = 0,453$ kemudian digunakan untuk menentukan nilai *p-value* berdasarkan distribusi *chi-square*. Pada ilustrasi ini, jumlah lag yang diuji adalah 3, sehingga derajat bebas yang digunakan adalah 3. Berdasarkan distribusi *chi-square*, nilai $Q = 0,453$ menghasilkan *p-value* sekitar 0,929. Karena:

$$0,929 > 0,05$$

maka hipotesis nol tidak ditolak. Artinya, berdasarkan ilustrasi tersebut, residual tidak mengandung autokorelasi yang signifikan hingga *lag* ke-3 dan dapat dianggap memenuhi asumsi *white noise*.

Dalam praktik penelitian ini, nilai statistik *Ljung-Box* dan *p-value* dihitung menggunakan fungsi `acorr_ljungbox()` dari pustaka `statsmodels.stats.diagnostic`. Program digunakan untuk membantu perhitungan pada jumlah residual yang lebih besar, sedangkan dasar interpretasi tetap mengacu pada prosedur statistik, yaitu membandingkan *p-value* dengan taraf signifikansi 0,05. Jumlah lag yang digunakan dalam pengujian disesuaikan dengan panjang residual yang tersedia agar pengujian tetap proporsional terhadap jumlah observasi.

Dengan demikian, diagnostik residual dilakukan untuk memastikan bahwa model ARIMA yang terpilih tidak hanya memiliki nilai kriteria informasi terbaik, tetapi juga telah diperiksa kelayakannya berdasarkan karakteristik residual. Apabila residual tidak mengandung autokorelasi signifikan, maka model dapat digunakan pada tahap evaluasi akurasi dan peramalan. Namun, apabila residual masih mengandung autokorelasi, maka kondisi tersebut perlu dilaporkan sebagai keterbatasan model dan menjadi dasar pertimbangan dalam interpretasi hasil peramalan.

3.7.8 Evaluasi Akurasi Model Peramalan

Setelah model ARIMA dinyatakan layak berdasarkan hasil diagnostik residual, tahap selanjutnya adalah mengevaluasi akurasi model dalam melakukan peramalan. Evaluasi dilakukan dengan membandingkan nilai prediksi yang dihasilkan model terhadap nilai aktual pada data uji (*testing set*). Tahap ini bertujuan untuk menilai kemampuan model dalam melakukan generalisasi terhadap data yang tidak digunakan dalam proses pembentukan model.

Sebagai ilustrasi, misalkan diperoleh data aktual dan hasil prediksi pada data uji sebagaimana ditunjukkan pada Tabel 3.15.

Tabel 3.15 Ilustrasi data aktual dan hasil prediksi

Periode	Nilai Aktual Y_t	Nilai Prediksi $\hat{Y}_t$
1	100	90
2	120	125
3	110	108

Berdasarkan data tersebut, langkah pertama adalah menghitung selisih antara nilai aktual dan nilai prediksi pada setiap periode, yaitu:

Periode 1: $100 - 90 = 10$

Periode 2: $120 - 125 = -5$

Periode 3: $110 - 108 = 2$

Perhitungan nilai MAE, RMSE, dan MAPE dilakukan dengan mengacu pada Persamaan (2.12), Persamaan (2.13), dan Persamaan (2.14), dengan simulasi perhitungan sebagai berikut:

1. Simulasi perhitungan MAE

$$MAE = \frac{1}{3} (|10| + |-5| + |2|)$$

$$MAE = \frac{1}{3} (10 + 5 + 2)$$

$$MAE = \frac{17}{3} = 5,67$$

Dengan demikian, nilai MAE adalah 5,67.

2. Simulasi perhitungan RMSE

$$RMSE = \sqrt{\frac{1}{3}(10^2 + (-5)^2 + 2^2)}$$

$$RMSE = \sqrt{\frac{1}{3}(100 + 25 + 4)}$$

$$RMSE = \sqrt{\frac{129}{3}}$$

$$RMSE = \sqrt{43} = 6,56$$

Dengan demikian, nilai RMSE adalah 6,56.

3. Simulasi perhitungan MAPE

$$MAPE = \frac{100\%}{3} \left(\left| \frac{10}{100} \right| + \left| \frac{-5}{120} \right| + \left| \frac{2}{110} \right| \right)$$

$$MAPE = \frac{100\%}{3} (0,10 + 0,0417 + 0,0182)$$

$$MAPE = \frac{100\%}{3} (0,1599)$$

$$MAPE = 5,33\%$$

Dengan demikian, nilai MAPE adalah 5,33%.

Berdasarkan ilustrasi tersebut, model peramalan yang lebih baik ditunjukkan oleh nilai MAE, RMSE, dan MAPE yang lebih kecil. Ketiga metrik ini digunakan secara bersama-sama agar evaluasi akurasi tidak hanya bergantung pada satu ukuran saja, melainkan mempertimbangkan besarnya kesalahan absolut, sensitivitas terhadap kesalahan besar, dan proporsi kesalahan dalam bentuk persentase.

3.7.9 Prosedur Peramalan Periode Mendatang

Setelah model ARIMA dinyatakan layak berdasarkan hasil diagnostik residual dan evaluasi akurasi pada data uji, tahap selanjutnya adalah melakukan peramalan jumlah kunjungan untuk periode mendatang. Peramalan ini bertujuan untuk menghasilkan estimasi nilai kunjungan pada horizon waktu tertentu di luar rentang data historis yang digunakan dalam proses pelatihan dan pengujian model.

Prosedur peramalan dilakukan menggunakan model ARIMA terpilih yang telah diestimasi sebelumnya. Model tersebut kemudian digunakan untuk memproyeksikan nilai jumlah kunjungan ke depan sesuai dengan horizon peramalan yang telah ditetapkan dalam rancangan penelitian. Horizon peramalan ditentukan berdasarkan kebutuhan analitis dan pertimbangan operasional, sehingga hasil prediksi dapat dimanfaatkan sebagai dasar perencanaan.

Secara umum, proses peramalan menghasilkan dua komponen utama, yaitu:

1. *Point Forecast* (Prediksi Titik)

Merupakan nilai estimasi jumlah kunjungan pada setiap periode yang diproyeksikan. Nilai ini diperoleh langsung dari model ARIMA berdasarkan parameter yang telah diestimasi.

2. *Interval Kepercayaan* (*Confidence Interval*)

Selain prediksi titik, model juga menghasilkan batas bawah dan batas atas prediksi pada tingkat keyakinan tertentu (misalnya 80% dan 95%). Interval kepercayaan mencerminkan tingkat ketidakpastian dalam peramalan. Secara metodologis, semakin jauh horizon peramalan dari data historis, maka interval kepercayaan cenderung semakin melebar karena meningkatnya ketidakpastian estimasi.

Peramalan periode mendatang dilakukan menggunakan perangkat lunak *Python* dengan memanfaatkan fungsi prediksi dari model ARIMA yang telah terbentuk. Proses ini tidak melibatkan pembaruan parameter model, melainkan menggunakan struktur dan parameter yang telah diestimasi pada tahap sebelumnya.

Hasil peramalan yang diperoleh pada tahap ini digunakan sebagai input analitis dalam pembahasan penelitian, khususnya untuk mendukung perencanaan operasional dan pengambilan keputusan berbasis data. Tahap ini bersifat prediktif dan tidak dimaksudkan untuk menyimpulkan kondisi aktual masa depan, melainkan sebagai estimasi berbasis pola historis yang telah dimodelkan secara statistik.

3.8 Metode Analisis Pola Penjualan Menggunakan *Market Basket Analysis*

Market Basket Analysis (MBA) digunakan dalam penelitian ini untuk menganalisis pola penjualan berdasarkan data transaksi FORZA GYM Babarsari. Analisis ini bertujuan untuk mengidentifikasi keterkaitan antar item yang dibeli secara bersamaan dalam satu transaksi, sehingga dapat memberikan gambaran sistematis mengenai pola asosiasi antar produk dalam aktivitas pembelian pelanggan.


Market Basket Analysis merupakan bagian dari teknik *association rule mining* yang bekerja dengan mengidentifikasi kombinasi item yang sering muncul secara bersamaan

dalam data transaksi. Dalam penelitian ini, MBA diimplementasikan menggunakan algoritma Apriori melalui perangkat lunak *Python* dengan bantuan pustaka `mlxtend.frequent_patterns`. Algoritma ini digunakan untuk membentuk *frequent itemsets* dan selanjutnya menghasilkan aturan asosiasi berdasarkan ukuran *support*, *confidence*, dan *lift*. Pendekatan ini memungkinkan proses analisis dilakukan secara terstruktur, terukur, dan dapat direplikasi, sesuai dengan kaidah penelitian kuantitatif berbasis data eksploratif.

3.8.1 Alur Proses *Market Basket Analysis*

Alur proses *Market Basket Analysis* dalam penelitian ini disusun secara sistematis untuk mengidentifikasi pola keterkaitan antar item berdasarkan data transaksi penjualan FORZA GYM Babarsari. Proses analisis dimulai dari tahap input dan pra-pemrosesan data hingga menghasilkan aturan asosiasi yang memenuhi kriteria seleksi tertentu. Secara konseptual, alur analisis terdiri atas dua tahap utama, yaitu pembentukan *frequent itemsets* menggunakan algoritma Apriori dan pembentukan serta evaluasi aturan asosiasi.

Alur lengkap proses analisis ditunjukkan pada Gambar 3.3, yang menggambarkan tahapan mulai dari persiapan data hingga seleksi aturan asosiasi.



Gambar 3.3 Alur proses *market basket analysis*

Proses dimulai dengan input data transaksi penjualan yang merepresentasikan aktivitas pembelian pelanggan dalam satu periode pengamatan. Data tersebut melalui tahap pra-pemrosesan untuk memastikan kualitas dan konsistensi data. Tahap ini mencakup pembersihan data, standarisasi nama item, serta penghapusan duplikasi item dalam satu transaksi yang sama.

Setelah pra-pemrosesan, data ditransformasikan ke dalam bentuk matriks biner (*one-hot encoding*), di mana setiap baris merepresentasikan satu transaksi dan setiap kolom merepresentasikan satu item. Representasi ini diperlukan karena implementasi algoritma Apriori pada perangkat lunak *Python* menggunakan pustaka `mlxtend.frequent_patterns` yang bekerja pada struktur data *boolean* atau biner.

Pembentukan *frequent itemsets* dilakukan menggunakan fungsi `apriori()`. Pada tahap ini, proses perhitungan *support* dan seleksi itemset yang memenuhi nilai *minimum support* dilakukan secara otomatis oleh sistem. *Frequent itemsets* yang diperoleh kemudian

digunakan sebagai dasar pembentukan aturan asosiasi menggunakan fungsi `association_rules()`.

Aturan asosiasi dibentuk dalam format implikasi $X \rightarrow Y$, yang merepresentasikan hubungan antara *antecedent* dan *consequent*. Selanjutnya, aturan yang terbentuk dievaluasi berdasarkan nilai *confidence* dan *lift* sesuai parameter yang ditetapkan dalam proses analisis. Hanya aturan yang memenuhi ambang minimum *confidence* dan minimum *lift* yang dipertahankan sebagai hasil akhir analisis.

Tahap akhir dari proses ini adalah penyajian hasil aturan asosiasi yang telah lolos seleksi. Aturan tersebut kemudian digunakan sebagai dasar untuk menganalisis pola penjualan dan mendukung pengambilan keputusan berbasis data.

3.8.2 Pra-pemrosesan Data Transaksi

Sebelum dilakukan analisis pola penjualan menggunakan *Market Basket Analysis*, data transaksi penjualan terlebih dahulu melalui tahap pra-pemrosesan. Tahap ini bertujuan untuk memastikan bahwa data yang dianalisis memiliki kualitas yang baik, konsisten, dan sesuai dengan kebutuhan algoritma Apriori. Data yang digunakan pada tahap ini merupakan data transaksi penjualan FORZA GYM Babarsari yang dikumpulkan dalam periode penelitian.

Pra-pemrosesan diawali dengan pembersihan data pada atribut yang bersifat krusial dalam analisis, yaitu identitas transaksi dan nama item. Data transaksi yang memiliki nilai kosong (*missing value*) pada kolom identitas transaksi atau nama item dihapus dari *dataset*. Langkah ini dilakukan karena algoritma Apriori bekerja berdasarkan keberadaan item dalam suatu transaksi, sehingga data tanpa identitas transaksi atau tanpa nama item tidak dapat diproses secara valid.

Tahap berikutnya adalah standarisasi nilai pada kolom identitas transaksi dan nama item. Pada implementasi penelitian ini, data pada kedua kolom tersebut terlebih dahulu dikonversi ke dalam format teks, kemudian dilakukan pembersihan dengan menghilangkan spasi di awal dan akhir penulisan, mengubah huruf menjadi huruf kecil (*lowercase*), serta merapikan spasi berlebih di antara kata. Proses ini bertujuan untuk mencegah perbedaan penulisan yang secara substantif sama tetapi terbaca sebagai entitas yang berbeda oleh sistem.

Setelah proses standarisasi, dilakukan penghapusan duplikasi kombinasi identitas transaksi dan nama item. Artinya, apabila dalam satu transaksi terdapat item yang tercatat lebih dari satu kali dengan nama yang sama, maka item tersebut hanya dipertahankan satu kali pada tahap analisis. Langkah ini diperlukan karena *Market Basket Analysis* pada penelitian ini berfokus pada keberadaan atau ketidakhadiran item dalam transaksi, bukan pada jumlah kemunculan item yang sama dalam satu transaksi.

Hasil akhir dari tahap pra-pemrosesan adalah data transaksi yang telah bersih, konsisten, dan siap digunakan pada tahap transformasi ke bentuk matriks biner (*one-hot encoding*). Dengan data yang telah melalui proses pra-pemrosesan secara sistematis, analisis *Market Basket Analysis* dapat dilakukan secara lebih valid dan terukur.

3.8.3 Transformasi ke Matriks Biner (*One-Hot Encoding*)

Setelah data transaksi melalui tahap pra-pemrosesan, data ditransformasikan ke dalam bentuk matriks biner (*one-hot encoding*) sebagai persiapan analisis menggunakan algoritma Apriori pada perangkat lunak *Python*. Transformasi ini bertujuan untuk mengubah struktur data transaksional yang semula berbentuk tabular menjadi representasi numerik yang sesuai dengan kebutuhan pustaka `mlxtend.frequent_patterns`.

Dalam representasi matriks biner, setiap baris merepresentasikan satu transaksi, sedangkan setiap kolom merepresentasikan satu item unik. Nilai 1 menunjukkan bahwa item tersebut muncul dalam transaksi, sedangkan nilai 0 menunjukkan bahwa item tidak muncul dalam transaksi. Representasi ini hanya mempertimbangkan keberadaan atau ketidakhadiran item dalam transaksi, tanpa memperhitungkan jumlah pembelian maupun nilai transaksi. Sebagai ilustrasi sederhana, misalkan terdapat data transaksi awal dalam Tabel 3.16 berikut:

Tabel 3.16 Ilustrasi data awal

Id_transaksi	Nama_item
T1	<i>whey</i>
T1	vitamin
T2	<i>whey</i>
T2	<i>shaker</i>
T3	vitamin

Proses transformasi dilakukan dengan mengelompokkan item berdasarkan identitas transaksi, kemudian mengonversinya menjadi matriks biner (0/1) menggunakan teknik *one-hot encoding*, sebagai berikut:

Tabel 3.17 Ilustrasi transformasi ke matriks biner

Transaksi	<i>whey</i>	vitamin	<i>shaker</i>
T1	1	1	0
T2	1	0	1
T3	0	1	0

Pada tabel 3.17 tersebut, nilai 1 menunjukkan keberadaan item dalam transaksi, sedangkan nilai 0 menunjukkan ketidakhadiran item. Struktur ini merupakan bentuk input yang digunakan oleh fungsi `apriori()` pada pustaka `mlxtend.frequent_patterns`.

Proses transformasi dilakukan dengan mengelompokkan item berdasarkan identitas transaksi, kemudian mengonversinya menjadi matriks boolean menggunakan teknik *one-hot encoding*. Struktur data ini memungkinkan algoritma Apriori untuk menghitung ukuran utama dalam *Market Basket Analysis*, seperti *support*, *confidence*, dan *lift*, secara efisien dan terukur.

Transformasi ke dalam matriks biner merupakan tahap penting dalam implementasi *Market Basket Analysis* berbasis *Python*, karena fungsi `apriori()` dan `association_rules()` pada pustaka `mlxtend` hanya dapat bekerja pada data dalam bentuk matriks boolean (*True/False*) atau biner (1/0). Dengan struktur data yang telah sesuai,

proses pembentukan frequent itemset dan aturan asosiasi dapat dilakukan secara sistematis pada tahap selanjutnya.

3.8.4 Pembentukan *Frequent Itemset* dengan Algoritma Apriori

Pembentukan *frequent itemset* dalam penelitian ini dilakukan menggunakan algoritma Apriori yang diimplementasikan melalui pustaka `mlxtend.frequent_patterns` pada perangkat lunak *Python*. Tahap ini bertujuan untuk mengidentifikasi kombinasi item yang sering muncul secara bersamaan dalam transaksi penjualan, sebagai dasar pembentukan aturan asosiasi pada tahap selanjutnya.

Algoritma Apriori diterapkan pada data transaksi yang telah melalui tahap pra-pemrosesan dan telah ditransformasikan ke dalam bentuk matriks biner (*one-hot encoding*). Parameter utama yang digunakan dalam algoritma ini adalah *minimum support* (α), yang merepresentasikan proporsi minimal kemunculan suatu itemset terhadap total transaksi.

Itemset dengan nilai *support* di bawah ambang *minimum support* tidak dipertahankan dalam hasil analisis. Sebaliknya, *itemset* yang memenuhi kriteria akan dicatat sebagai *frequent itemset* dan digunakan sebagai dasar pembentukan aturan asosiasi pada tahap berikutnya.

Dalam implementasinya, proses pembentukan *frequent itemset* dilakukan menggunakan fungsi `apriori()` pada pustaka `mlxtend.frequent_patterns`, dengan masukan berupa matriks transaksi hasil *one-hot encoding* yang telah dikonversi ke format *boolean*. Hasil proses ini berupa daftar itemset beserta nilai *support* masing-masing, yang kemudian diurutkan berdasarkan nilai *support* dari yang terbesar ke yang lebih kecil.

Frequent itemset yang diperoleh pada tahap ini selanjutnya digunakan sebagai input dalam pembentukan aturan asosiasi menggunakan ukuran evaluasi *support*, *confidence*, dan *lift*.

3.8.5 Pembentukan Aturan Asosiasi

Aturan asosiasi dibentuk dari *frequent itemset* menggunakan format implikasi:

$$X \rightarrow Y$$

Untuk mengevaluasi kualitas aturan asosiasi, digunakan tiga ukuran utama, yaitu *support*, *confidence*, dan *lift*. Sebagai ilustrasi sederhana, misalkan terdapat 100 transaksi. Jika 20 transaksi mengandung item A dan B secara bersamaan, 25 transaksi mengandung item A, dan 40 transaksi mengandung item B, Berdasarkan data tersebut, akan dihitung aturan asosiasi:

$$A \rightarrow B$$

Nilai *support* dihitung dengan mengacu pada Persamaan (2.15), yaitu membandingkan jumlah transaksi yang mengandung item A dan B secara bersamaan terhadap seluruh transaksi. Perhitungannya adalah sebagai berikut:

$$\text{Support}(A \rightarrow B) = \frac{20}{100} = 0,20$$

Nilai *support* sebesar 0,20 menunjukkan bahwa kombinasi item A dan B muncul pada 20% dari seluruh transaksi. Artinya, dari 100 transaksi yang diamati, terdapat 20 transaksi yang memuat item A dan B secara bersamaan.

Selanjutnya, nilai *confidence* dihitung dengan mengacu pada Persamaan (2.16), yaitu membandingkan jumlah transaksi yang mengandung item A dan B terhadap jumlah transaksi yang mengandung item A. Perhitungannya adalah sebagai berikut:

$$\text{Confidence}(A \rightarrow B) = \frac{20}{25} = 0,80$$

Nilai *confidence* sebesar 0,80 menunjukkan bahwa 80% transaksi yang mengandung item A juga mengandung item B. Dengan kata lain, ketika item A muncul dalam transaksi, terdapat kecenderungan sebesar 80% bahwa item B juga muncul.

Sebelum menghitung *lift*, terlebih dahulu dihitung nilai *support* dari item B. Karena item B muncul pada 40 transaksi dari total 100 transaksi, maka:

$$\text{Support}(B) = \frac{40}{100} = 0,40$$

Nilai *lift* kemudian dihitung dengan mengacu pada Persamaan (2.17), yaitu dengan membandingkan nilai *confidence* terhadap nilai *support* item B. Perhitungannya adalah sebagai berikut:

$$\text{Lift}(A \rightarrow B) = \frac{0,80}{0,40} = 2,00$$

Nilai *lift* sebesar 2,00 menunjukkan bahwa kemunculan item B dua kali lebih mungkin terjadi ketika item A muncul dibandingkan dengan kondisi pembelian secara acak. Karena nilai *lift* lebih besar dari 1, maka aturan $A \rightarrow B$ menunjukkan hubungan asosiasi positif antara item A dan item B.

Dalam implementasi penelitian ini, perhitungan *support*, *confidence*, dan *lift* dilakukan secara otomatis menggunakan fungsi `association_rules()` pada pustaka `mlxtend.frequent_patterns`, berdasarkan *frequent itemset* yang telah terbentuk pada tahap sebelumnya.

3.8.6 Ilustrasi Eksekusi Proses Apriori hingga Aturan Asosiasi

Untuk memperjelas proses kerja algoritma Apriori hingga terbentuk aturan asosiasi, digunakan data contoh sederhana. Ilustrasi ini bertujuan untuk menunjukkan bagaimana data transaksi diubah menjadi matriks biner, bagaimana nilai *support* dihitung, bagaimana *frequent itemset* dibentuk, serta bagaimana aturan asosiasi dievaluasi menggunakan *confidence* dan *lift*.

Misalkan terdapat 5 transaksi dengan item yang disajikan dalam Tabel 3.18 berikut:

Tabel 3.18 Data contoh transaksi

Id_transaksi	Nama_item
T1	<i>whey</i> , vitamin
T2	<i>whey shaker</i>
T3	<i>whey</i> , vitamin, <i>shaker</i>
T4	vitamin
T5	<i>whey shaker</i>

Kemudian data tersebut ditransformasikan ke dalam bentuk matriks biner sebagai berikut:

Tabel 3.19 Transformasi data contoh ke matriks biner

Transaksi	<i>whey</i>	vitamin	<i>shaker</i>
T1	1	1	0
T2	1	0	1
T3	1	1	1
T4	0	1	0
T5	1	0	1

Selanjutnya adalah menetapkan parameter misalnya:

- a. *Minimum support* $\alpha = 0,40$

Artinya, suatu *itemset* harus muncul setidaknya pada $0,40 \times 5 = 2$ transaksi agar dianggap *frequent*.

- b. *Minimum confidence* $\beta = 0,60$

Artinya, aturan asosiasi hanya dipertahankan bila tingkat kepercayaannya minimal 0,60.

- c. *Lift* > 1

Digunakan untuk memastikan hubungan *antecedent* dan *consequent* bersifat positif (tidak independen).

Langkah berikutnya membentuk *frequent itemset* dengan prinsip: kandidat *itemset* yang *support*-nya di bawah ambang *minimum support* akan dieliminasi. Proses ini dimulai dari item tunggal, kemudian berkembang menjadi kombinasi 2 item, 3 item, dan seterusnya hingga tidak ada kandidat yang lolos.

1. Menghitung *support* item tunggal

Support didefinisikan sebagai proporsi transaksi yang mengandung item terhadap total transaksi. Dari data contoh:

- a. Item *whey* muncul pada **T1, T2, T3, T5** $\rightarrow$ 4 transaksi

$$supp(whey) = \frac{4}{5} = 0,80$$

- b. Item vitamin muncul pada **T1, T3, T4** $\rightarrow$ 3 transaksi

$$\text{supp}(\text{vitamin}) = \frac{3}{5} = 0,60$$

- c. Item *shaker* muncul pada **T2, T3, T5** → 3 transaksi

$$\text{supp}(\text{shaker}) = \frac{3}{5} = 0,60$$

Karena semua nilai $\text{support} \geq \alpha = 0,40$, ketiga item tunggal tersebut dipertahankan sebagai *frequent itemset* ukuran 1.

2. Membentuk kandidat *itemset* ukuran 2 dan menghitung *support*
Dari item tunggal yang lolos, dibentuk kombinasi pasangan:

- a. $\{\text{whey}, \text{shaker}\}$ muncul pada **T2, T3, T5** → 3 transaksi

$$\text{supp}(\{\text{whey}, \text{shaker}\}) = \frac{3}{5} = 0,60$$

- b. $\{\text{whey}, \text{vitamin}\}$ muncul pada **T1, T3** → 2 transaksi

$$\text{supp}(\{\text{whey}, \text{vitamin}\}) = \frac{2}{5} = 0,40$$

- c. $\{\text{vitamin}, \text{shaker}\}$ muncul pada **T3** saja → 1 transaksi

$$\text{supp}(\{\text{vitamin}, \text{shaker}\}) = \frac{1}{5} = 0,20$$

Karena $\{\text{vitamin}, \text{shaker}\}$ memiliki $\text{support} < \alpha$, maka pasangan tersebut dieliminasi. Dengan demikian, *frequent itemset* ukuran 2 yang dipertahankan adalah $\{\text{whey}, \text{shaker}\}$, dan $\{\text{whey}, \text{vitamin}\}$. Pada langkah inilah fungsi *apriori()* bekerja dengan menghitung frekuensi kemunculan *itemset* (*support*) dan menyaring *itemset* yang tidak memenuhi ambang *minimum support*.

Selanjutnya aturan asosiasi dibentuk dari *frequent itemset* dan dievaluasi menggunakan *confidence* dan *lift*. Dari *frequent itemset* $\{\text{whey}, \text{shaker}\}$, dapat dibentuk aturan:

$$\begin{aligned} \text{shaker} &\rightarrow \text{whey} \\ \text{whey} &\rightarrow \text{shaker} \end{aligned}$$

Sebagai contoh, dihitung aturan $\text{shaker} \rightarrow \text{whey}$.

1. Menghitung *confidence*

Confidence mengukur seberapa sering *consequent* muncul ketika *antecedent* muncul. Secara konsep, *confidence* untuk $X \rightarrow Y$ adalah $\frac{supp(X \cup Y)}{supp(X)}$. Untuk

$shaker \rightarrow whey$:

- a. $supp(\{whey, shaker\}) = 0,60$
- b. $supp(shaker) = 0,60$

Sehingga:

$$conf(shaker \rightarrow whey) = \frac{0,60}{0,60} = 1,00$$

Artinya, pada data contoh, setiap transaksi yang mengandung *shaker* selalu mengandung *whey* (*confidence* 100%).

2. Menghitung Lift

Lift membandingkan *confidence* terhadap peluang kemunculan *consequent* secara umum. Untuk $shaker \rightarrow whey$:

- a. $conf(shaker \rightarrow whey) = 1,00$
- b. $supp(whey) = 0,80$

Sehingga:

$$lift(shaker \rightarrow whey) = \frac{1,00}{0,80} = 1,25$$

Karena $lift > 1$, hubungan antara *shaker* dan *whey* bersifat positif, artinya *whey* lebih mungkin muncul ketika *shaker* muncul dibandingkan kemunculan *whey* secara acak.

Pada langkah inilah fungsi `association_rules()` bekerja dengan membentuk aturan dari *frequent itemset*, kemudian menghitung ukuran evaluasi (*confidence* dan *lift*) untuk setiap aturan.

Pada penelitian ini, aturan asosiasi yang dipertahankan adalah aturan yang dibentuk dari *frequent itemset* yang telah memenuhi *minimum support* pada tahap Apriori, kemudian diseleksi lebih lanjut berdasarkan ambang *minimum confidence* dan *minimum lift* yang ditetapkan pada proses pembentukan *rules*. Mengacu pada hasil perhitungan contoh:

- a. $support\{whey, shaker\} = 0,60$
- b. $confidence\ shaker \rightarrow whey = 1,00$
- c. $lift = 1,25$

Dengan demikian, aturan *shaker* → *whey* dapat dipertahankan karena berasal dari *frequent itemset* yang lolos *minimum support*, serta memenuhi ambang *minimum confidence* dan *minimum lift* pada tahap seleksi aturan asosiasi.

3.9 Kriteria Seleksi *Strong Rules*

Tidak seluruh aturan asosiasi yang terbentuk memiliki kekuatan hubungan yang memadai. Oleh karena itu, diperlukan kriteria seleksi untuk menentukan aturan yang dikategorikan sebagai *strong rules*. Dalam penelitian ini, kriteria seleksi ditetapkan dengan mempertimbangkan karakteristik data transaksi FORZA GYM Babarsari yang relatif tidak padat, karena tidak semua transaksi memuat banyak item dalam satu waktu.

Penentuan nilai *minimum support*, *confidence*, dan *lift* dalam *association rule mining* dapat disesuaikan dengan karakteristik *dataset* yang digunakan. Safitri (2022) menggunakan nilai *minimum support* sebesar 0,001 dan *minimum confidence* sebesar 0,5 dalam analisis transaksi Pamella Satu Supermarket. Nilai tersebut ditentukan melalui proses *trial and error* untuk menghasilkan aturan asosiasi yang sesuai dengan data transaksi yang dianalisis. Selain itu, Handika dan Satwika (2024) menggunakan *minimum support* sebesar 0,001 dan *minimum confidence* sebesar 0,005 pada data transaksi minimarket karena variasi produk dan frekuensi kombinasi pembelian yang terbatas, sehingga ambang yang terlalu tinggi dapat menyebabkan tidak terbentuknya pola yang signifikan. Sementara itu, Saad et al. (2025) menetapkan *minimum lift* sebesar 1,5 dalam penerapan algoritma Apriori dan menjelaskan bahwa nilai *minimum* perlu mempertimbangkan bentuk data, karena nilai *minimum* yang terlalu rendah dapat menghasilkan terlalu banyak aturan yang tidak kuat.

Berdasarkan pertimbangan tersebut, suatu aturan asosiasi dalam penelitian ini dikategorikan sebagai *strong rule* apabila memenuhi tiga syarat, yaitu:

a. ***Support* ≥ 0,001**

Nilai ini menunjukkan bahwa aturan memiliki frekuensi kemunculan minimum dalam data transaksi. Ambang ini digunakan agar pola yang terbentuk tetap memiliki dasar kemunculan yang dapat diamati, terutama pada data transaksi yang tidak selalu memuat banyak item dalam satu transaksi.

b. ***Confidence* ≥ 0,02**

Nilai ini menunjukkan bahwa *consequent* memiliki tingkat kemunculan minimum ketika *antecedent* muncul. Ambang ini digunakan agar aturan yang dihasilkan tetap dapat teridentifikasi pada data transaksi yang relatif jarang membentuk kombinasi item, namun tetap memiliki tingkat kepercayaan tertentu.

c. ***Lift* ≥ 1,5**

Nilai ini menunjukkan bahwa hubungan antara *antecedent* dan *consequent* bersifat positif serta memiliki kekuatan asosiasi yang lebih tinggi dibandingkan kemunculan secara acak. Dengan adanya batas *minimum lift* sebesar 1,5, aturan yang dipertahankan tidak hanya memenuhi nilai *support* dan *confidence*, tetapi juga menunjukkan keterkaitan antaritem yang cukup kuat.

Dalam implementasinya, seleksi *support* dilakukan pada tahap pembentukan *frequent itemsets* menggunakan fungsi `apriori()`, sedangkan seleksi *confidence* dan *lift*

dilakukan pada tahap pembentukan aturan asosiasi menggunakan fungsi `association_rules()` serta penyaringan lanjutan terhadap hasil aturan. Aturan yang memenuhi seluruh parameter tersebut selanjutnya dipertahankan sebagai *strong rules* dan digunakan sebagai dasar analisis pola penjualan dalam penelitian ini. Penetapan nilai ambang tersebut disesuaikan dengan karakteristik data transaksi penelitian yang relatif *sparse*, sehingga aturan yang masih relevan tetap dapat teridentifikasi tanpa mengabaikan kekuatan asosiasi antaritem.

3.10 Penyajian dan Visualisasi Hasil Analisis


Pada tahap ini dilakukan penyajian hasil analisis yang diperoleh dari penerapan metode *Autoregressive Integrated Moving Average* (ARIMA) dan *Market Basket Analysis* (MBA). Penyajian hasil bertujuan untuk mempermudah interpretasi informasi yang dihasilkan sehingga dapat digunakan sebagai dasar dalam mendukung pengambilan keputusan operasional dan pemasaran di FORZA GYM Babarsari.

Penyajian hasil dilakukan dalam bentuk visualisasi yang informatif dan mudah dipahami. Visualisasi ini tidak dimaksudkan sebagai implementasi sistem, melainkan sebagai media representasi hasil analisis data agar memberikan gambaran yang lebih jelas mengenai pola yang ditemukan. Penyajian hasil juga dilakukan secara terpisah sesuai dengan karakteristik masing-masing metode dan jenis data yang dianalisis.

3.10.1 Visualisasi Hasil Analisis Secara Umum

Visualisasi hasil analisis secara umum digunakan untuk memberikan gambaran menyeluruh mengenai keluaran dari dua metode yang digunakan dalam penelitian, yaitu ARIMA untuk data kunjungan anggota dan *Market Basket Analysis* untuk data transaksi penjualan. Penyajian ini bertujuan untuk menunjukkan bahwa hasil analisis dapat ditampilkan secara terstruktur dan mudah dipahami oleh pihak manajemen.

Pada bagian ini, informasi yang disajikan mencakup ringkasan hasil peramalan jumlah kunjungan anggota dan ringkasan hasil analisis pola transaksi pelanggan. Kedua jenis informasi tersebut ditampilkan secara berdampingan sebagai bentuk penyajian hasil analisis, namun tidak dilakukan penggabungan metode secara teknis.




Gambar 3.4 Visualisasi hasil analisis secara umum

Gambar 3.4 menunjukkan ilustrasi visualisasi hasil analisis secara umum. Visualisasi ini berfungsi sebagai media penyajian informasi yang mempermudah interpretasi hasil analisis, dan bukan merupakan implementasi sistem atau perancangan aplikasi.

3.10.2 Visualisasi Hasil Peramalan ARIMA

Hasil peramalan jumlah kunjungan anggota menggunakan metode ARIMA disajikan dalam bentuk grafik dan tabel. Penyajian dalam bentuk grafik bertujuan untuk memperlihatkan pola data historis, hasil prediksi pada data uji, serta hasil peramalan untuk periode mendatang. Dengan penyajian tersebut, kecenderungan jumlah kunjungan anggota dapat diamati secara lebih jelas.

Informasi yang ditampilkan pada visualisasi hasil peramalan meliputi data historis jumlah kunjungan, hasil prediksi pada data uji, nilai evaluasi akurasi model, dan hasil *forecast* untuk periode ke depan. Penyajian ini membantu pihak manajemen dalam memahami perubahan pola kunjungan anggota secara kuantitatif.




Gambar 3.5 Visualisasi hasil peramalan ARIMA

Gambar 3.5 menunjukkan ilustrasi visualisasi hasil peramalan ARIMA. Visualisasi tersebut digunakan untuk membantu interpretasi hasil analisis peramalan dan memberikan gambaran mengenai kecenderungan permintaan layanan pada periode mendatang. Penyajian ini tidak merupakan bagian dari implementasi sistem, melainkan hanya sebagai representasi hasil analisis.

3.10.3 Visualisasi Hasil MBA

Hasil analisis pola transaksi menggunakan *Market Basket Analysis* disajikan dalam bentuk tabel aturan asosiasi dan visualisasi pendukung. Penyajian ini bertujuan untuk menunjukkan keterkaitan antarproduk atau layanan yang sering muncul secara bersamaan dalam transaksi pelanggan.

Informasi yang ditampilkan dalam hasil *Market Basket Analysis* meliputi item yang sering muncul, aturan asosiasi yang terbentuk, serta nilai *support*, *confidence*, dan *lift* sebagai ukuran kekuatan hubungan antaritem. Melalui penyajian tersebut, pihak manajemen dapat memahami pola penjualan secara lebih sistematis.



Gambar 3.6 Visualisasi hasil *market basket analysis*

Gambar 3.6 menunjukkan ilustrasi visualisasi hasil *Market Basket Analysis*. Visualisasi ini digunakan untuk mempermudah pemahaman terhadap aturan asosiasi yang dihasilkan dari data transaksi pelanggan. Dengan demikian, informasi yang diperoleh dapat dimanfaatkan sebagai dasar dalam penyusunan strategi pemasaran, seperti *bundling* produk atau layanan yang memiliki keterkaitan tinggi. Visualisasi ini hanya berfungsi sebagai media penyajian hasil analisis dan bukan merupakan implementasi sistem.

3.10.4 Interpretasi Hasil Analisis

Hasil dari kedua metode dianalisis secara terpisah sesuai dengan karakteristik data yang digunakan. Hasil peramalan ARIMA memberikan informasi mengenai kecenderungan jumlah kunjungan anggota berdasarkan dimensi waktu, sedangkan hasil *Market Basket Analysis* memberikan informasi mengenai pola keterkaitan antarproduk atau layanan dalam transaksi pelanggan.

Informasi hasil peramalan jumlah kunjungan dapat dimanfaatkan untuk mendukung perencanaan operasional, seperti penjadwalan instruktur, pengelolaan kapasitas layanan, dan penentuan waktu promosi. Sementara itu, informasi hasil *Market Basket Analysis* dapat dimanfaatkan untuk mendukung strategi pemasaran, seperti penyusunan promosi berbasis *bundling* dan penawaran produk atau layanan yang relevan dengan pola pembelian pelanggan.

Dengan demikian, penyajian dan visualisasi hasil analisis memberikan gambaran yang lebih komprehensif mengenai kondisi operasional dan perilaku pelanggan di FORZA GYM Babarsari. Meskipun kedua hasil analisis ditampilkan dalam satu aplikasi yang sama, masing-masing tetap diposisikan sebagai keluaran dari metode yang berbeda dan tidak digabungkan secara teknis.

BAB IV HASIL DAN PEMBAHASAN

4.1 Gambaran Umum Data Penelitian

Penelitian ini menggunakan dua jenis *dataset* utama yang diperoleh dari aktivitas operasional FORZA GYM Babarsari, yaitu *dataset* kunjungan anggota dan *dataset* transaksi penjualan. Kedua *dataset* tersebut memiliki karakteristik yang berbeda sehingga memerlukan pendekatan analisis yang berbeda pula. *Dataset* kunjungan anggota berbentuk data deret waktu (*time series*) dan digunakan sebagai dasar peramalan jumlah kunjungan menggunakan metode *Autoregressive Integrated Moving Average* (ARIMA). Sementara itu, *dataset* transaksi penjualan berbentuk data transaksional dan digunakan untuk mengidentifikasi pola penjualan menggunakan *Market Basket Analysis*.

Penggunaan dua jenis *dataset* ini bertujuan untuk menghasilkan informasi yang lebih komprehensif dalam mendukung pengambilan keputusan manajerial. *Dataset* kunjungan anggota dimanfaatkan untuk memprediksi tingkat kunjungan jangka pendek, sedangkan *dataset* transaksi penjualan dimanfaatkan untuk memahami keterkaitan antarproduk atau layanan yang sering dibeli secara bersamaan oleh pelanggan.

4.1.1 *Dataset* Kunjungan Anggota

Jumlah data kunjungan yang digunakan dalam penelitian ini sebanyak 515 data harian dengan periode pengamatan mulai 2 September 2024 sampai 6 Februari 2026. Setiap baris data merepresentasikan total jumlah anggota yang melakukan kunjungan pada satu tanggal tertentu. Variabel utama yang digunakan pada *dataset* ini adalah tanggal dan jumlah kunjungan.

Dataset kunjungan anggota dipilih karena secara langsung merepresentasikan tingkat permintaan layanan kebugaran dari waktu ke waktu. Fluktuasi jumlah kunjungan harian dapat dipengaruhi oleh hari kerja, akhir pekan, musim tertentu, program promosi, maupun perilaku pelanggan. Oleh karena itu, data ini relevan untuk dianalisis menggunakan metode peramalan deret waktu.

Tabel 4.1 Ringkasan *dataset* kunjungan anggota

No	Keterangan	Nilai
1	Jenis Data	<i>Time Series</i>
2	Jumlah Data	515 data
3	Periode Data	2 September 2024 - 6 Februari 2026
4	Frekuensi Data	Harian
5	Variabel Utama	Tanggal, Jumlah Kunjungan
6	Metode Analisis	ARIMA

Tabel 4.2 Cuplikan *dataset* kunjungan anggota FORZA GYM Babarsari

No	Tanggal	Hari	Bulan	Jumlah Kunjungan
1	02/09/2024	senin	september	16
2	03/09/2024	selasa	september	10
3	04/09/2024	rabu	september	16

Tabel 4.2 Cuplikan *dataset* kunjungan anggota FORZA GYM Babarsari lanjutan

4	05/09/2024	kamis	september	13
5	06/09/2024	jumat	september	14

Tabel 4.2 menyajikan cuplikan data kunjungan anggota yang digunakan dalam penelitian. Setiap baris merepresentasikan total kunjungan anggota pada tanggal tertentu. Data disusun secara kronologis berdasarkan waktu pengamatan agar dapat digunakan dalam proses identifikasi pola, pembentukan model, serta peramalan jumlah kunjungan.

4.1.2 *Dataset* Transaksi Penjualan

Jumlah data transaksi yang digunakan dalam penelitian ini sebanyak 6.560 transaksi. Setiap transaksi dapat terdiri atas satu atau lebih item produk maupun layanan. Variabel yang terdapat dalam *dataset* transaksi antara lain identitas transaksi, tanggal transaksi, nama item, kategori item, jumlah pembelian, harga satuan, dan total pembayaran.

Karakteristik *dataset* transaksi berbeda dengan *dataset* kunjungan anggota karena fokus analisis tidak terletak pada urutan waktu, melainkan pada kombinasi item yang muncul dalam satu transaksi. Oleh karena itu, *dataset* ini sesuai untuk diterapkan metode *association rule mining* melalui algoritma Apriori.

Tabel 4.3 Ringkasan *dataset* transaksi penjualan FORZA GYM Babarsari

No	Keterangan	Nilai
1	Jenis Data	Transaksional
2	Jumlah Data	6.560 transaksi
3	Struktur Data	Multi-item per transaksi
4	Variabel Utama	ID Transaksi, Tanggal, Item, Jml, Harga
5	Fokus Analisis	Pola Penjualan
6	Metode Analisis	<i>Market Basket Analysis</i>

Tabel 4.4 Cuplikan *dataset* transaksi penjualan FORZA GYM Babarsari

Id transaksi	Tanggal	Jenis Transaksi	Nama Item	Kategori	Jml	Harga Satuan	Total Pembayaran
6179	05/02/2026	penjualan	susu whey	suplemen	1	12000	12000
6179	05/02/2026	penjualan	aqua 600ml	air mineral	2	3000	6000
6180	05/02/2026	penjualan	vit 1.5L	air mineral	1	5000	5000
6181	06/02/2026	visit harian	visit	visit harian	2	20000	40000
6182	06/02/2026	visit harian	visit	visit harian	1	20000	20000
6182	06/02/2026	penjualan	aqua 600ml	air mineral	1	3000	3000

Tabel 4.4 menunjukkan bahwa satu transaksi dapat terdiri atas lebih dari satu item produk atau layanan. Struktur data transaksional seperti ini menjadi dasar dalam proses identifikasi pola keterkaitan antaritem yang sering dibeli secara bersamaan oleh pelanggan melalui pendekatan *Market Basket Analysis*.

4.2 Hasil Peramalan Kunjungan Menggunakan ARIMA

4.2.1 Visualisasi Pola Data Kunjungan

Tahap awal dalam analisis peramalan dilakukan dengan memvisualisasikan data kunjungan anggota FORZA GYM Babarsari untuk mengetahui pola pergerakan data secara umum. Visualisasi ini penting untuk mengidentifikasi adanya kecenderungan tren, tingkat fluktuasi, serta kemungkinan pola musiman sebelum dilakukan proses pemodelan menggunakan metode ARIMA.

Sebelum dilakukan visualisasi, data kunjungan terlebih dahulu dipersiapkan dalam bentuk deret waktu harian agar dapat digunakan dalam proses analisis. Tahap ini meliputi konversi kolom tanggal ke format waktu, konversi jumlah kunjungan ke numerik, pengurutan data secara kronologis, agregasi data per hari, serta penanganan tanggal yang hilang.

Algoritma 1. Persiapan deret waktu harian

```
def prepare_daily_series|
    df: pd.DataFrame,
    date_col: str = "tanggal",
    value_col: str = "jumlah_member",
    fill_missing: str = "zero",
} -> pd.Series:
    if date_col not in df.columns or value_col not in df.columns:
        raise KeyError(f"Kolom '{date_col}' atau '{value_col}' tidak ditemukan.")


    tmp = df[[date_col, value_col]].copy()
    tmp[date_col] = pd.to_datetime(tmp[date_col], errors="coerce")
    tmp[value_col] = pd.to_numeric(tmp[value_col], errors="coerce")

    tmp = tmp.dropna(subset=[date_col, value_col]).sort_values(date_col)
    tmp = tmp.groupby(date_col, as_index=False)[value_col].sum()

    y = tmp.set_index(date_col)[value_col].astype(float)
    y = y.asfreq("D")

    if fill_missing == "zero":
        y = y.fillna(0.0)

    y.name = value_col
    return y
```



Gambar 4.1 Visualisasi data aktual, prediksi data uji, dan *forecast* kunjungan ke depan

Berdasarkan Gambar 4.1, data kunjungan anggota selama periode pengamatan menunjukkan pola yang berfluktuasi dari waktu ke waktu dengan perubahan jumlah kunjungan yang cukup dinamis. Pada beberapa periode terlihat peningkatan jumlah kunjungan yang cukup tinggi, sedangkan pada periode lain terjadi penurunan secara signifikan. Hal ini menunjukkan bahwa permintaan layanan kebugaran bersifat tidak stabil dan dipengaruhi oleh faktor waktu maupun perilaku pelanggan.

Secara umum, nilai kunjungan harian berada pada rentang sekitar 0 hingga lebih dari 70 kunjungan per hari. Puncak kunjungan tertinggi terjadi pada beberapa periode tertentu, sedangkan nilai rendah juga muncul pada sejumlah hari pengamatan. Variasi yang cukup lebar ini menunjukkan adanya volatilitas permintaan yang perlu diantisipasi dalam pengelolaan operasional.

Selain itu, berdasarkan pola visual tidak terlihat adanya pola musiman yang berulang secara konsisten dalam interval tertentu. Pola data cenderung menunjukkan fluktuasi acak dengan perubahan level pada beberapa periode. Oleh karena itu, penggunaan model ARIMA *non-seasonal* dinilai sesuai dengan karakteristik data yang digunakan dalam penelitian ini.

Visualisasi juga menunjukkan bahwa data dibagi ke dalam data latih (*training set*) dan data uji (*testing set*). Data latih digunakan dalam proses pembentukan model, sedangkan data uji digunakan untuk mengevaluasi kemampuan prediksi model terhadap data aktual. Setelah proses evaluasi, model digunakan untuk menghasilkan prediksi kunjungan 1 sampai 7 hari ke depan.

Dengan demikian, hasil visualisasi awal menunjukkan bahwa data kunjungan memiliki karakteristik deret waktu yang fluktuatif, tidak stabil secara langsung, dan memerlukan tahapan pengujian stasioneritas sebelum dilakukan pemodelan ARIMA.

4.2.2 Uji Stasioneritas Data

Pengujian stasioneritas pada penelitian ini dilakukan menggunakan *Augmented Dickey-Fuller* (ADF *Test*) terhadap data latih (*training data*) kunjungan anggota. Hipotesis nol pada uji ADF menyatakan bahwa data mengandung *unit root* atau tidak stasioner, sedangkan hipotesis alternatif menyatakan bahwa data telah stasioner.

Proses pengujian stasioneritas dilakukan menggunakan fungsi uji ADF yang diimplementasikan dalam program, sebagaimana ditunjukkan pada Algoritma 2.

Algoritma 2. Uji stasioneritas menggunakan ADF

```
def adf_test(y: pd.Series, alpha: float = 0.05) -> Dict[str, float | bool]:
    y_clean = pd.to_numeric(y, errors="coerce").dropna().astype(float)

    if len(y_clean) < 10:
        return {"valid_test": False, "is_stationary": False}

    stat, pval, usedlag, nobs, crit, _ = adfuller(y_clean.values,
autolag="AIC")


    return (
        "valid_test": True,
        "is_stationary": bool(pval < alpha),
        "adf_stat": float(stat),
        "p_value": float(pval),
        "used_lag": float(usedlag),
        "n_obs": float(nobs),
        "alpha": float(alpha),
    )
```

Berdasarkan hasil pengujian, diperoleh nilai statistik ADF sebesar -3,229, nilai *p-value* sebesar 0,0184, serta jumlah *lag* optimal yang digunakan sebanyak 16 *lag*. Nilai *p-value* yang lebih kecil dari taraf signifikansi 0,05 menunjukkan bahwa hipotesis nol ditolak, sehingga data dinyatakan telah stasioner.

Tabel 4.5 Hasil uji stasioneritas menggunakan ADF

Parameter	Nilai
Orde <i>Differencing</i>	0
Jumlah Observasi	418
ADF <i>Statistic</i>	-3,229
<i>p-value</i>	0,0184
<i>Used Lag</i>	16
<i>Alpha</i>	0,05

Hasil pengujian menunjukkan bahwa data telah memenuhi asumsi stasioneritas pada *orde differencing* 0, sehingga tidak diperlukan proses *differencing* tambahan. Dengan kata lain, data asli sudah cukup stabil untuk langsung digunakan pada tahap identifikasi parameter model ARIMA.



Gambar 4.2 Visualisasi data latih

Secara visual berdasarkan gambar 4.2, pola data juga menunjukkan bahwa fluktuasi nilai kunjungan bergerak di sekitar rata-rata tertentu tanpa kecenderungan tren jangka panjang yang sangat kuat. Hal ini memperkuat hasil pengujian statistik bahwa data relatif stabil dan layak untuk dimodelkan menggunakan ARIMA *non-seasonal*.

Dengan demikian, parameter *differencing* pada model ARIMA ditetapkan sebesar $d = 0$.

4.2.3 Identifikasi Parameter Model

Berdasarkan hasil analisis ACF dan PACF, terlihat bahwa beberapa *lag* awal masih menunjukkan autokorelasi dan autokorelasi parsial yang melewati batas signifikansi. Pada grafik ACF, *spike* signifikan tampak pada beberapa *lag* awal dan kemudian menurun secara bertahap (*tapering off*), sedangkan pada grafik PACF juga terlihat *spike* signifikan pada *lag* awal sebelum cenderung melemah pada *lag* berikutnya. Pola seperti ini mengindikasikan bahwa data memiliki kemungkinan dipengaruhi oleh komponen AR maupun MA, sehingga kandidat model tidak hanya terbatas pada satu kombinasi parameter saja.

Proses identifikasi kandidat parameter dilakukan dengan menghitung nilai ACF dan PACF, kemudian memilih beberapa *lag* yang memiliki kontribusi terbesar sebagai kandidat parameter p dan q . Implementasi proses tersebut ditunjukkan pada Algoritma 3.

Algoritma 3. Penentuan kandidat parameter p dan q

```
def suggest_pq_candidates(
    y_stationary: pd.Series,
    nlags: int = 30,
    max_p: int = 5,
    max_q: int = 5,
    top_k: int = 3,
) -> Tuple[List[int], List[int]]:

    vals = compute_acf_pacf(y_stationary, nlags=nlags)
    acf_vals = vals["acf"]
    pacf_vals = vals["pacf"]

    base_p = [0, 1, 2]
    base_q = [0, 1, 2]
```

```

acf_abs = np.abs(acf_vals[1 : max_q + 1])
pacf_abs = np.abs(pacf_vals[1 : max_p + 1])

q_suggest = list(np.argsort(-acf_abs)[:top_k] + 1)
p_suggest = list(np.argsort(-pacf_abs)[:top_k] + 1)

p_candidates = sorted(set(base_p + [p for p in p_suggest if p <= max_p]))
q_candidates = sorted(set(base_q + [q for q in q_suggest if q <= max_q]))

return p_candidates, q_candidates


```

Hasil identifikasi awal menghasilkan kandidat parameter p dan q sebagai berikut:

Tabel 4.6 Kandidat parameter berdasarkan ACF dan PACF

Parameter	Kandidat
p	0, 1, 2, 4, 5
q	0, 1, 2, 5

Kandidat nilai p diperoleh dari pola signifikan pada grafik PACF, sedangkan kandidat nilai q diperoleh dari pola signifikan pada grafik ACF. Karena pada tahap sebelumnya data telah dinyatakan stasioner pada orde *differencing* 0, maka parameter *differencing* ditetapkan sebesar $d = 0$. Dengan demikian, kombinasi model yang akan diuji lebih lanjut berada dalam bentuk umum ARIMA ($p, 0, q$).



Gambar 4.3 Plot *autocorrelation function* (ACF) dan *partial autocorrelation function* (PACF)

Secara visual, baik ACF maupun PACF tidak menunjukkan pola *cut-off* yang sangat tegas pada satu *lag* tertentu, melainkan cenderung menunjukkan pola peluruhan bertahap pada beberapa *lag* awal. Oleh karena itu, proses identifikasi parameter pada penelitian ini tidak langsung menetapkan satu model final, tetapi digunakan sebagai dasar untuk membentuk beberapa kandidat model yang kemudian akan diseleksi lebih lanjut menggunakan kriteria informasi.

Dengan demikian, tahap identifikasi parameter menghasilkan sejumlah kombinasi kandidat model ARIMA yang layak diuji pada tahap berikutnya untuk menentukan model terbaik berdasarkan performa statistik dan kecocokan terhadap data.

4.2.4 Seleksi Model Terbaik

Pada penelitian ini, proses seleksi model dilakukan dengan membandingkan nilai *Akaike Information Criterion corrected* (AICc) dari setiap kandidat model yang berhasil diestimasi. Nilai AICc digunakan sebagai dasar pemilihan karena mempertimbangkan keseimbangan antara tingkat kecocokan model terhadap data dan kompleksitas jumlah parameter. Model dengan nilai AICc yang lebih kecil menunjukkan performa yang lebih baik serta struktur model yang lebih efisien.

Proses estimasi dan seleksi model dilakukan dengan mencoba berbagai kombinasi parameter p dan q , kemudian menghitung nilai AIC, AICc, dan BIC untuk masing-masing model. Implementasi proses tersebut ditunjukkan pada Algoritma 4.

Algoritma 4. Seleksi model ARIMA berdasarkan AICc

```
for p in p_cand:
    for q in q_cand:
        try:
            trend_opt = "c" if d == 0 else "n"

            res = ARIMA(
                y_train,
                order=(p, d, q),
                trend=trend_opt,
                enforce_stationarity=False,
                enforce_invertibility=False,
            ).fit()

            converged = _safe_converged_flag(res)
            k = int(len(res.params))
            aic_val = float(res.aic)
            aicc_val = aicc(aic_val, n=n, k=k)
            bic_val = float(res.bic)

            candidate_rows.append({
                "order": f"ARIMA({p}, {d}, {q})",
                "aic": aic_val,
                "aicc": aicc_val,
                "bic": bic_val,
                "converged": converged,
            })

        except Exception:
            continue
```

Berdasarkan hasil estimasi, diperoleh beberapa kandidat model ARIMA yang layak dipertimbangkan. Ringkasan kandidat model terbaik disajikan pada Tabel 4.7.

Tabel 4.7 Hasil seleksi kandidat model ARIMA

No	Model ARIMA	AIC	AICc	BIC	Status Konvergen
1	ARIMA(1,0,5)	3010.385	3010.737	3042.553	TRUE
2	ARIMA(4,0,1)	3037.639	3037.912	3065.82	TRUE
3	ARIMA(1,0,2)	3057.202	3057.347	3077.343	TRUE
4	ARIMA(5,0,0)	3063.988	3064.261	3092.152	TRUE
5	ARIMA(2,0,1)	3065.167	3065.313	3085.321	TRUE
6	ARIMA(1,0,1)	3075.567	3075.663	3091.689	TRUE
7	ARIMA(4,0,0)	3080.583	3080.788	3104.739	TRUE
8	ARIMA(0,0,5)	3083.693	3083.966	3111.84	TRUE
9	ARIMA(2,0,0)	3099.548	3099.644	3115.67	TRUE
10	ARIMA(0,0,2)	3112.152	3112.249	3128.265	TRUE
11	ARIMA(1,0,0)	3113.11	3113.168	3125.209	TRUE
12	ARIMA(0,0,1)	3147.219	3147.277	3159.311	TRUE
13	ARIMA(0,0,0)	3243.309	3243.337	3251.375	TRUE
14	ARIMA(5,0,5)	2946.372	2947.142	2994.624	FALSE
15	ARIMA(4,0,5)	2953.553	2954.203	2997.784	FALSE
16	ARIMA(5,0,2)	3009.416	3009.857	3045.627	FALSE
17	ARIMA(2,0,5)	3010.503	3010.944	3046.692	FALSE
18	ARIMA(5,0,1)	3018.856	3019.208	3051.044	FALSE
19	ARIMA(4,0,2)	3024.36	3024.712	3056.567	FALSE
20	ARIMA(2,0,2)	3059.191	3059.396	3083.361	FALSE

Berdasarkan Tabel 4.7, model ARIMA(1,0,5) memiliki nilai AICc paling kecil, yaitu sebesar 3010,737, sehingga dipilih sebagai model terbaik dalam penelitian ini. Selain memiliki nilai AICc terendah, model tersebut juga menunjukkan status estimasi konvergen, yang menandakan proses optimasi parameter berhasil dilakukan dengan baik.

Terpilihnya model ARIMA(1,0,5) menunjukkan bahwa pola jumlah kunjungan anggota dipengaruhi oleh satu komponen *autoregressive* dan lima komponen *moving average*. Hal ini mengindikasikan bahwa nilai kunjungan saat ini tidak hanya dipengaruhi oleh periode sebelumnya, tetapi juga oleh beberapa pola kesalahan acak pada periode terdahulu.

Sementara itu, beberapa model lain juga memiliki performa yang relatif baik, seperti ARIMA(4,0,1) dan ARIMA(1,0,2), namun nilai AICc yang lebih tinggi menyebabkan model tersebut tidak dipilih sebagai model final.

4.2.5 Diagnostik Residual

Pemeriksaan residual pada penelitian ini dilakukan melalui tiga pendekatan, yaitu analisis plot residual, histogram residual, grafik ACF residual, dan uji statistik *Ljung-Box*.


Proses evaluasi residual dilakukan dengan menghitung nilai residual dari model serta menguji keberadaan autokorelasi menggunakan uji *Ljung-Box*. Implementasi proses tersebut ditunjukkan pada Algoritma 5.

Algoritma 5. Diagnostik residual model

```
def residual_diagnostics|
    model: ARIMAFitResult,
    lb_lags: int = 20,
} -> Dict[str, object]:
    res = model.model_result
    resid = pd.Series(res.resid).dropna().astype(float)


    lag_eff = int(min(lb_lags, max(1, len(resid) // 2 - 1)))
    lb = acorr_ljungbox(resid.values, lags=[lag_eff], return_df=True)
    pval = float(lb["lb_pvalue"].iloc[0])

    return (
        "resid_mean": float(resid.mean()),
        "resid_std": float(resid.std()),
        "ljungbox_lag": int(lag_eff),
        "ljungbox_pvalue": pval,
        "white_noise_pass": bool(pval > 0.05),
    )
```




Gambar 4.4 Plot residual

Berdasarkan plot residual, nilai residual terlihat menyebar di sekitar garis nol tanpa menunjukkan pola tren yang sistematis. Sebagian besar residual berfluktuasi secara acak, meskipun pada beberapa periode terdapat lonjakan residual positif maupun negatif yang cukup besar. Kondisi ini menunjukkan bahwa model telah mampu menangkap sebagian besar pola utama data, namun masih terdapat beberapa periode yang belum diprediksi secara optimal.



Gambar 4.5 Histogram residual

Histogram residual menunjukkan pola distribusi yang relatif mendekati bentuk lonceng (*bell-shaped*), dengan pusat distribusi berada di sekitar nilai nol. Hal ini mengindikasikan bahwa residual cenderung menyebar secara simetris meskipun masih terdapat sedikit penyimpangan pada ekor distribusi.



Gambar 4.6 ACF residual

Selanjutnya, grafik ACF residual menunjukkan bahwa sebagian besar nilai autokorelasi residual berada di dalam batas kepercayaan. Namun demikian, masih terdapat beberapa *lag* yang melewati batas signifikansi, yang menandakan masih adanya korelasi residual pada *lag* tertentu.

Untuk memperkuat evaluasi, dilakukan uji *Ljung-Box* terhadap residual model. Hasil pengujian disajikan pada Tabel 4.8.

Tabel 4.8 Hasil uji *ljung-box* residual

<i>Lag</i>	Statistik <i>Ljung-Box</i>	<i>p-value</i>
10	51,4109	0,0000001
20	114,1390	0,0000000000000003
30	185,6344	0,000000000000000000000002

Berdasarkan Tabel 4.8, seluruh nilai *p-value* berada di bawah tingkat signifikansi 0,05. Dengan demikian, hipotesis nol yang menyatakan bahwa residual tidak memiliki autokorelasi ditolak. Hasil ini menunjukkan bahwa residual model belum sepenuhnya memenuhi asumsi *white noise*.

Temuan tersebut mengindikasikan bahwa meskipun model ARIMA(1,0,5) memiliki nilai AICc terbaik pada tahap seleksi model, masih terdapat sebagian pola data yang belum

sepenuhnya ditangkap oleh model. Hal ini dapat disebabkan oleh fluktuasi data yang cukup tinggi, pengaruh faktor eksternal yang tidak dimasukkan ke dalam model, atau struktur ketergantungan data yang lebih kompleks.

Meskipun demikian, model tetap dapat digunakan untuk tujuan peramalan jangka pendek dengan mempertimbangkan bahwa performa model akan dievaluasi kembali melalui pengukuran akurasi pada data uji. Oleh karena itu, tahap selanjutnya adalah melakukan evaluasi kesalahan prediksi menggunakan ukuran *error* seperti MAE, RMSE, dan MAPE.

4.2.6 Evaluasi Akurasi Model

Pada penelitian ini, pengukuran akurasi model dilakukan menggunakan tiga indikator utama, yaitu *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE). Ketiga indikator tersebut digunakan karena mampu menggambarkan tingkat kesalahan prediksi baik dalam satuan asli data maupun dalam bentuk persentase.

Perhitungan ketiga metrik tersebut dilakukan menggunakan fungsi evaluasi yang diimplementasikan dalam program, sebagaimana ditunjukkan pada Algoritma 6.

Algoritma 6. Perhitungan MAE, RMSE, dan MAPE

```
def mae(y_true, y_pred) -> float:
    y_true = np.asarray(y_true, dtype=float)
    y_pred = np.asarray(y_pred, dtype=float)
    return float(np.mean(np.abs(y_true - y_pred)))

def rmse(y_true, y_pred) -> float:
    y_true = np.asarray(y_true, dtype=float)
    y_pred = np.asarray(y_pred, dtype=float)
    return float(np.sqrt(np.mean((y_true - y_pred) ** 2)))

def mape(y_true, y_pred, eps: float = 1e-8) -> float:
    y_true = np.asarray(y_true, dtype=float)
    y_pred = np.asarray(y_pred, dtype=float)
    denom = np.maximum(np.abs(y_true), eps)
    return float(np.mean(np.abs((y_true - y_pred) / denom)) * 100.0)
```

Hasil evaluasi akurasi model disajikan pada Tabel 4.9.

Tabel 4.9 Hasil evaluasi akurasi model ARIMA(1,0,5)

No	Indikator	Nilai
1	MAE	9,317
2	RMSE	12,168
3	MAPE	37,775%

Berdasarkan Tabel 4.9, nilai MAE sebesar 9,317 menunjukkan bahwa rata-rata selisih absolut antara hasil prediksi dan data aktual berada pada kisaran sekitar 9 kunjungan

per hari. Nilai ini memberikan gambaran bahwa secara umum model memiliki tingkat kesalahan prediksi yang masih dapat diterima dalam konteks operasional harian.

Nilai RMSE sebesar 12,168 menunjukkan bahwa model masih memiliki beberapa kesalahan prediksi yang relatif besar pada periode tertentu. Hal ini karena RMSE memberikan penalti lebih besar terhadap *error* yang tinggi, sehingga sensitif terhadap fluktuasi data kunjungan yang cukup dinamis.

Sementara itu, nilai MAPE sebesar 37,775% menunjukkan bahwa secara rata-rata persentase kesalahan prediksi model berada pada kisaran 37,775 persen dibandingkan data aktual. Nilai tersebut menunjukkan bahwa model memiliki tingkat akurasi yang cukup memadai untuk kebutuhan prediksi jangka pendek, meskipun belum termasuk kategori sangat tinggi.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa model ARIMA(1,0,5) mampu memberikan prediksi yang cukup baik terhadap jumlah kunjungan anggota FORZA GYM Babarsari. Meskipun masih terdapat selisih prediksi pada beberapa periode, model ini tetap layak digunakan sebagai alat bantu perencanaan operasional, terutama untuk estimasi kebutuhan layanan dalam jangka pendek.

4.2.7 Hasil *Forecasting* 1-7 Hari ke Depan


Setelah model ARIMA(1,0,5) dinyatakan layak digunakan berdasarkan proses seleksi model dan evaluasi akurasi, tahap selanjutnya adalah melakukan peramalan jumlah kunjungan anggota untuk periode 7 hari ke depan. Peramalan ini bertujuan untuk memberikan gambaran estimasi jumlah kunjungan harian yang dapat dimanfaatkan sebagai dasar perencanaan operasional FORZA GYM Babarsari.

Proses *forecasting* dilakukan menggunakan model ARIMA terpilih dengan menghasilkan nilai prediksi beserta interval kepercayaan. Implementasi proses tersebut ditunjukkan pada Algoritma 7.

Algoritma 7. *Forecasting* dan interval prediksi

```
def forecast_with_interval|
    model: ARIMAFitResult,
    periods: int,
    alpha: float = 0.05,
} -> pd.DataFrame:
    fc = model.model_result.get_forecast(steps=periods)
    mean = np.asarray(fc.predicted_mean)
    ci = fc.conf_int(alpha=float(alpha))

    out = pd.DataFrame|
        (
            "forecast": mean,
            "lo": np.asarray(ci.iloc[:, 0]),
            "hi": np.asarray(ci.iloc[:, 1]),
        )
    }
    return out
```



Gambar 4.7 Grafik *forecast* jumlah kunjungan anggota 7 hari ke depan

Hasil *forecasting* menunjukkan bahwa jumlah kunjungan anggota pada periode mendatang berada pada kisaran 24 hingga 29 kunjungan per hari. Secara umum, pola prediksi cenderung relatif stabil dengan sedikit kenaikan pada awal periode, kemudian kembali bergerak mendatar pada hari-hari berikutnya.

Tabel 4.10 Hasil *forecasting* jumlah kunjungan anggota 1-7 hari ke depan

No	Tanggal	Prediksi Jumlah Kunjungan	Batas Bawah 95%	Batas Atas 95%
1	07 Februari 2026	24	6	41
2	08 Februari 2026	25	6	43
3	09 Februari 2026	29	10	47
4	10 Februari 2026	28	9	46
5	11 Februari 2026	26	8	45
6	12 Februari 2026	26	7	46
7	13 Februari 2026	26	6	46

Berdasarkan Tabel 4.10, prediksi tertinggi terjadi pada 09 Februari 2026 dengan estimasi sebanyak 29 kunjungan, sedangkan prediksi terendah terjadi pada 07 Februari 2026 dengan estimasi sebanyak 24 kunjungan. Setelah mengalami peningkatan pada hari ketiga, jumlah kunjungan diperkirakan kembali menurun dan stabil pada kisaran 26 kunjungan per hari.

Selain prediksi titik (*point forecast*), model juga menghasilkan interval kepercayaan 95 persen. Interval ini menunjukkan rentang kemungkinan nilai aktual yang dapat terjadi pada masing-masing periode prediksi. Semakin lebar interval prediksi, semakin tinggi tingkat ketidakpastian hasil ramalan. Pada penelitian ini, interval prediksi masih cukup lebar, yang menunjukkan bahwa data kunjungan memiliki fluktuasi harian yang cukup tinggi.

Secara manajerial, hasil *forecasting* ini dapat dimanfaatkan untuk menyusun kebutuhan operasional harian, seperti penjadwalan staf, kesiapan fasilitas latihan, pengaturan jam sibuk, serta perencanaan stok produk pendukung. Sebagai contoh, pada hari dengan prediksi kunjungan lebih tinggi, manajemen dapat meningkatkan kesiapan layanan agar kualitas pelayanan tetap terjaga.

4.3 Hasil Analisis Pola Penjualan Menggunakan *Market Basket Analysis*

4.3.1 Hasil *Frequent Itemset*

Tahap awal dalam analisis *Market Basket Analysis* adalah mengidentifikasi *frequent itemset*, yaitu item-item yang paling sering muncul dalam transaksi pelanggan. *Frequent itemset* digunakan untuk mengetahui produk atau layanan yang memiliki tingkat permintaan tinggi serta menjadi dasar dalam pembentukan aturan asosiasi pada tahap selanjutnya.

Sebelum dilakukan analisis, data transaksi terlebih dahulu diproses dan ditransformasikan ke dalam bentuk matriks *one-hot* agar dapat digunakan dalam algoritma Apriori. Proses tersebut meliputi pembersihan data transaksi dan transformasi ke bentuk matriks biner, sebagaimana ditunjukkan pada Algoritma 8.

Algoritma 8. Pra-pemrosesan dan transformasi data transaksi

```
def preprocess_transactions |
    df: pd.DataFrame,
    id_col: str = "id_transaksi",
    item_col: str = "nama_item",
} -> pd.DataFrame:

    tmp = df.dropna(subset=[id_col, item_col]).copy()
    tmp[id_col] = tmp[id_col].astype(str).str.strip().str.lower()
    tmp[item_col] = tmp[item_col].astype(str).str.strip().str.lower()

    tmp = tmp[(tmp[id_col] != "") & (tmp[item_col] != "")]
    tmp = tmp.drop_duplicates(subset=[id_col, item_col])

    return tmp

def build_onehot(df: pd.DataFrame) -> pd.DataFrame:
    tmp = preprocess_transactions(df)

    basket = |
        tmp.assign(val=1)
        .pivot_table(
            index="id_transaksi",
            columns="nama_item",
            values="val",
            aggfunc="max",
            fill_value=0,
        )
    |
    return basket.astype(int)
```

Selain itu, identifikasi item dengan frekuensi tertinggi dilakukan menggunakan fungsi agregasi jumlah transaksi, sebagaimana ditunjukkan pada Algoritma 9.

Algoritma 9. Identifikasi *top item* transaksi

```
def top_items |
    df: pd.DataFrame,
    item_col: str = "nama_item",
    qty_col: str = "jumlah",
    top_n: int = 10,
```

```

} -> pd.DataFrame:

tmp = df.copy()
tmp[item_col] = tmp[item_col].astype(str).str.strip().str.lower()

out = |
    tmp.groupby(item_col, as_index=False)[qty_col]
        .sum()
        .sort_values(qty_col, ascending=False)
        .head(top_n)
        .rename(columns=(item_col: "item", qty_col: "qty"))
}
return out

```

Berdasarkan hasil pengolahan data transaksi penjualan FORZA GYM Babarsari, diperoleh beberapa item dengan frekuensi transaksi tertinggi sebagaimana disajikan pada Tabel 4.11.

Tabel 4.11 *Top* item berdasarkan jumlah transaksi

No	Item	Jumlah (Qty)
1	aqua 600ml	2045
2	visit	1547
3	aqua 1.5l	1291
4	perpanjang	690
5	member baru	525
6	vit 1.5l	479
7	susu whey	442
8	member <i>couple</i>	237
9	aquaviva 1.5l	94
10	creatine	68

Berdasarkan Tabel 4.11, item dengan jumlah transaksi tertinggi adalah aqua 600ml sebanyak 2045 transaksi. Item dengan frekuensi tertinggi berikutnya adalah visit sebanyak 1547 transaksi dan aqua 1.5l sebanyak 1291 transaksi. Selanjutnya, item perpanjang tercatat sebanyak 690 transaksi, member baru sebanyak 525 transaksi, vit 1.5l sebanyak 479 transaksi, serta susu whey sebanyak 442 transaksi. Item lainnya yang juga tercatat dalam sepuluh besar transaksi tertinggi adalah member *couple* sebanyak 237 transaksi, aquaviva 1.5l sebanyak 94 transaksi, dan creatine sebanyak 68 transaksi.

Secara umum, hasil *frequent itemset* menunjukkan bahwa item dengan frekuensi transaksi tertinggi didominasi oleh produk minuman, layanan kunjungan, dan layanan keanggotaan. Selain itu, beberapa produk suplemen juga tercatat sebagai item yang muncul dalam transaksi pelanggan.

4.3.2 Hasil *Association Rule*

Setelah diperoleh *frequent itemset*, tahap selanjutnya adalah membentuk *association rule* untuk mengetahui hubungan antaritem yang muncul dalam transaksi yang sama.

Association rule menunjukkan kecenderungan bahwa pembelian item tertentu diikuti dengan pembelian item lainnya berdasarkan data transaksi pelanggan.

Proses pembentukan *frequent itemset* dan *association rule* dilakukan menggunakan algoritma Apriori, sebagaimana ditunjukkan pada Algoritma 10.

Algoritma 10. Pembentukan *frequent itemset* dan *association rule*

```
def run_apriori(onehot: pd.DataFrame, min_support: float = 0.001) ->
pd.DataFrame:
    onehot_bool = onehot.astype(bool)
    freq = apriori(onehot_bool, min_support=min_support, use_colnames=True)
    return freq.sort_values(["support"],
ascending=False).reset_index(drop=True)

def build_rules(
    freq_itemsets: pd.DataFrame,
    metric: str = "confidence",
    min_conf: float = 0.02,
    min_lift: float = 1.5,
) -> pd.DataFrame:

    rules = association_rules(freq_itemsets, metric=metric,
min_threshold=min_conf)

    rules = rules[
        (rules["confidence"] >= min_conf) &
        (rules["lift"] >= min_lift)
    ].copy()

    return rules.sort_values(
        ["lift", "confidence"],
        ascending=[False, False]
    ).reset_index(drop=True)
```

Berdasarkan hasil pengolahan data, diperoleh 3 aturan asosiasi yang memenuhi nilai *minimum support* dan *minimum confidence*. Hasil *association rule* disajikan pada Tabel 4.12.

Tabel 4.12 Hasil *association rule*

No	<i>Antecedents</i>	<i>Consequents</i>	<i>Support</i>	<i>Confidence</i>	<i>Lift</i>
1	susu whey, visit	aqua 600ml	0,0011	0,5833	2,5541
2	aqua 600ml, visit	susu whey	0,0011	0,0795	1,5807
3	susu whey	aqua 600ml, visit	0,0011	0,0224	1,5807

Berdasarkan Tabel 4.12, aturan pertama menunjukkan bahwa kombinasi pembelian susu whey dan visit diikuti dengan pembelian aqua 600ml dengan nilai *support* sebesar 0,0011, *confidence* sebesar 0,5833, dan *lift* sebesar 2,5541. Aturan kedua menunjukkan bahwa kombinasi pembelian aqua 600ml dan visit diikuti dengan pembelian susu whey dengan nilai *support* sebesar 0,0011, *confidence* sebesar 0,0795, dan *lift* sebesar 1,5807. Aturan ketiga menunjukkan bahwa pembelian susu whey diikuti dengan kombinasi

pembelian aqua 600ml dan visit dengan nilai *support* sebesar 0,0011, *confidence* sebesar 0,0224, dan *lift* sebesar 1,5807.

Secara umum, seluruh aturan asosiasi yang terbentuk memenuhi kriteria *strong rules* karena memiliki nilai *support* $\geq 0,001$, *confidence* $\geq 0,02$, dan *lift* $\geq 1,5$. Seluruh nilai *lift* juga lebih besar dari 1, sehingga menunjukkan adanya hubungan positif antaritem dalam transaksi pelanggan.

4.3.3 Strong Rules Terpilih

Setelah seluruh *association rule* diperoleh, tahap selanjutnya adalah menentukan *strong rules*, yaitu aturan asosiasi yang memenuhi kriteria minimum *support*, *confidence*, dan *lift*. Dalam penelitian ini, aturan dikategorikan sebagai *strong rule* apabila memiliki nilai *support* $\geq 0,001$, *confidence* $\geq 0,02$, dan *lift* $\geq 1,5$.

Penetapan nilai ambang tersebut disesuaikan dengan karakteristik data transaksi FORZA GYM Babarsari yang relatif tidak padat, karena tidak semua transaksi memuat banyak item dalam satu waktu. Penggunaan nilai ambang yang disesuaikan dengan karakteristik data juga ditemukan pada penelitian Safitri (2022), yang menggunakan minimum *support* 0,1% dan minimum *confidence* 50% pada data transaksi Pamella Satu Supermarket. Selain itu, Handika dan Satwika (2024) menggunakan minimum *support* 0,001 dan minimum *confidence* 0,005 pada data transaksi minimarket karena variasi produk dan frekuensi kombinasi pembelian yang terbatas.

Untuk mempermudah interpretasi, hasil aturan asosiasi ditampilkan dalam bentuk yang lebih mudah dibaca, sebagaimana ditunjukkan pada Algoritma 11.

Algoritma 11. Penyajian *strong rules*

```
def pretty_rules(rules: pd.DataFrame) -> pd.DataFrame:

    def fs_to_str(x):
        return ", ".join(sorted(map(str, list(x))))

    out = rules.copy()
    out["antecedents"] = out["antecedents"].apply(fs_to_str)
    out["consequents"] = out["consequents"].apply(fs_to_str)

    return out
```

Berdasarkan hasil analisis pada Tabel 4.12, seluruh aturan yang terbentuk telah memenuhi kriteria *strong rules*. Namun, aturan yang memiliki nilai *confidence* dan *lift* tertinggi adalah aturan pertama, yaitu kombinasi susu whey dan visit yang diikuti dengan pembelian aqua 600ml. Aturan tersebut memiliki nilai *support* sebesar 0,0011, yang menunjukkan proporsi transaksi yang memuat kombinasi item tersebut terhadap seluruh transaksi. Nilai *confidence* sebesar 0,5833 menunjukkan bahwa sebesar 58,33% transaksi yang memuat susu whey dan visit juga disertai pembelian aqua 600ml.

Nilai *lift* sebesar 2,5541 menunjukkan bahwa hubungan antaritem tersebut lebih kuat dibandingkan pembelian secara acak. Nilai ini juga telah melampaui batas minimum *lift* 1,5 yang digunakan dalam penelitian ini. Penetapan batas *lift* 1,5 juga digunakan oleh Saad et

al. (2025) dalam penerapan algoritma Apriori untuk menentukan pola permintaan bahan makanan, dengan pertimbangan bahwa nilai minimum perlu disesuaikan dengan bentuk data agar aturan yang dihasilkan tetap kuat dan tidak terlalu banyak.

Dengan demikian, aturan:

susu whey, visit → *aqua 600ml*

dapat dikategorikan sebagai aturan asosiasi terkuat yang diperoleh pada penelitian ini. Secara keseluruhan, hasil *strong rules* menunjukkan adanya keterkaitan pembelian antara layanan kunjungan, produk suplemen, dan produk minuman dalam transaksi pelanggan FORZA GYM Babarsari.

4.4 Pembahasan

4.4.1 Pembahasan Hasil ARIMA

Hasil penelitian menunjukkan bahwa metode ARIMA dapat digunakan untuk melakukan peramalan jumlah kunjungan anggota di FORZA GYM Babarsari berdasarkan data historis harian. Berdasarkan proses identifikasi dan seleksi model, model terbaik yang diperoleh adalah ARIMA(1,0,5) dengan nilai AICc terendah sebesar 3010,737. Pemilihan model ini menunjukkan bahwa pola kunjungan anggota dipengaruhi oleh nilai kunjungan pada periode sebelumnya serta komponen kesalahan pada beberapa periode terdahulu.

Tidak diperlukannya proses *differencing* tambahan ($d = 0$) menunjukkan bahwa data kunjungan telah berada dalam kondisi stasioner pada level awal. Hal ini mengindikasikan bahwa pola kunjungan anggota cenderung bergerak di sekitar rata-rata tertentu tanpa tren jangka panjang yang sangat kuat. Dengan demikian, perubahan jumlah kunjungan lebih banyak dipengaruhi oleh fluktuasi jangka pendek dibandingkan perubahan struktural jangka panjang.

Hasil evaluasi akurasi menunjukkan nilai MAE sebesar 9,317, RMSE sebesar 12,168, dan MAPE sebesar 37,775%. Nilai tersebut menunjukkan bahwa model memiliki kemampuan untuk memberikan estimasi kunjungan jangka pendek, meskipun tingkat kesalahan prediksi masih perlu diperhatikan. Nilai MAPE yang relatif tinggi mengindikasikan bahwa model belum sepenuhnya menghasilkan akurasi yang optimal. Kondisi ini dapat dipengaruhi oleh karakteristik data kunjungan *gym* yang bersifat fluktuatif harian serta adanya faktor eksternal yang belum dimasukkan ke dalam model, seperti hari libur, promosi, cuaca, event tertentu, atau kebiasaan pelanggan.

Hasil ini sejalan dengan penelitian Ramadhani et al. (2022) yang menunjukkan bahwa ARIMA dapat digunakan untuk melakukan peramalan pada data kunjungan, khususnya jumlah kunjungan wisatawan mancanegara. Namun, tingkat akurasi penelitian ini berbeda dengan penelitian tersebut karena karakteristik objek dan pola datanya tidak sama. Data kunjungan wisatawan cenderung memiliki pola agregat yang berbeda, sedangkan data kunjungan *gym* bersifat lebih operasional, harian, dan dipengaruhi oleh perilaku pelanggan yang dapat berubah dalam jangka pendek.

Temuan ini juga sejalan dengan Luo et al. (2017) yang menggunakan pendekatan deret waktu untuk meramalkan kunjungan harian layanan kesehatan. Penelitian tersebut

menunjukkan bahwa peramalan kunjungan harian dapat membantu perencanaan sumber daya dan penjadwalan layanan. Dalam konteks FORZA GYM Babarsari, hasil peramalan jumlah kunjungan dapat digunakan untuk mendukung perencanaan operasional, seperti penjadwalan staf, kesiapan fasilitas, pengaturan kapasitas area latihan, dan penyediaan produk pendukung. Dengan demikian, meskipun objek penelitian berbeda, keduanya menunjukkan bahwa peramalan kunjungan berbasis data historis memiliki nilai praktis dalam mendukung pengambilan keputusan operasional.

Pada hasil *forecasting* 7 hari ke depan, jumlah kunjungan diprediksi berada pada kisaran 24 hingga 29 kunjungan per hari. Pola prediksi yang relatif stabil menunjukkan bahwa permintaan layanan kebugaran dalam jangka pendek berada pada kondisi normal tanpa lonjakan ekstrem. Informasi ini penting bagi manajemen dalam menyusun jadwal staf, kesiapan fasilitas, pengaturan kapasitas area latihan, serta penyediaan layanan pendukung sesuai estimasi jumlah pengunjung.

Meskipun demikian, hasil diagnostik residual menunjukkan bahwa residual model belum sepenuhnya memenuhi asumsi *white noise*, sehingga masih terdapat sebagian pola data yang belum tertangkap secara sempurna oleh model. Kondisi ini menunjukkan bahwa ARIMA masih memiliki keterbatasan ketika digunakan pada data kunjungan yang sangat dinamis. Oleh karena itu, model digunakan sebagai alat bantu estimasi operasional dengan mempertimbangkan adanya keterbatasan dalam menangkap seluruh pola data. Hasil ini menunjukkan bahwa model ARIMA cukup efektif dalam memodelkan pola jangka pendek, namun belum sepenuhnya optimal dalam menangkap dinamika data yang sangat fluktuatif.

Secara keseluruhan, penerapan metode ARIMA dalam penelitian ini membuktikan bahwa data operasional *gym* dapat diolah menjadi informasi prediktif yang berguna. Dengan memanfaatkan hasil *forecasting*, FORZA GYM Babarsari dapat menerapkan pengambilan keputusan yang lebih terencana dan berbasis data.

4.4.2 Pembahasan Hasil *Market Basket Analysis*

Hasil penelitian menunjukkan bahwa metode *Market Basket Analysis* mampu mengidentifikasi pola transaksi penjualan yang merepresentasikan kecenderungan pembelian pelanggan berdasarkan data transaksi penjualan di FORZA GYM Babarsari. Melalui analisis *frequent itemset*, diketahui bahwa item dengan frekuensi transaksi tertinggi didominasi oleh produk minuman, layanan kunjungan harian, dan layanan keanggotaan. Item dengan jumlah transaksi tertinggi adalah aqua 600ml sebanyak 2.045 transaksi, diikuti visit sebanyak 1.547 transaksi, serta aqua 1,5l sebanyak 1.291 transaksi.

Dominasi produk minuman menunjukkan bahwa kebutuhan konsumsi selama atau setelah berolahraga menjadi bagian penting dalam perilaku transaksi pelanggan. Sementara itu, tingginya transaksi pada item visit, perpanjang, dan member baru menunjukkan bahwa aktivitas bisnis utama *gym* tetap bertumpu pada layanan kunjungan dan keanggotaan. Dengan kata lain, penjualan produk tambahan berjalan berdampingan dengan layanan inti usaha.

Pada tahap *association rule*, diperoleh tiga aturan asosiasi yang memenuhi parameter *minimum support* dan *confidence*. Seluruh aturan memiliki nilai *lift* lebih dari 1, yang menunjukkan adanya hubungan positif antaritem. Hal ini berarti kombinasi item tersebut

muncul bersama lebih sering dibandingkan apabila transaksi terjadi secara acak. Selain itu, nilai *support* yang relatif kecil menunjukkan bahwa pola yang terbentuk bersifat spesifik, namun tetap relevan dalam menggambarkan kecenderungan perilaku pembelian pelanggan pada *dataset* yang digunakan.

Nilai *support* yang kecil masih dapat dipahami karena transaksi pada pusat kebugaran tidak selalu memuat banyak item seperti transaksi pada sektor ritel besar. Banyak transaksi hanya memuat satu layanan atau satu produk, seperti visit, perpanjang, member baru, atau pembelian minuman. Oleh karena itu, pola kombinasi antaritem cenderung lebih jarang muncul. Kondisi ini sejalan dengan Handika dan Satwika (2024), yang menjelaskan bahwa pada data transaksi dengan variasi produk dan kombinasi pembelian yang terbatas, penggunaan nilai minimum *support* dan *confidence* yang lebih rendah diperlukan agar pola yang bermakna tetap dapat teridentifikasi.

Aturan terkuat diperoleh pada kombinasi susu whey dan visit yang diikuti pembelian aqua 600ml, dengan nilai *confidence* sebesar 0,5833 dan *lift* sebesar 2,5541. Hasil ini menunjukkan bahwa pelanggan yang membeli suplemen sekaligus menggunakan layanan kunjungan memiliki kecenderungan cukup tinggi untuk membeli air minum dalam transaksi yang sama. Pola tersebut selaras dengan kebutuhan pelanggan *gym* yang memerlukan hidrasi setelah aktivitas latihan.

Temuan ini sejalan dengan Martínez et al. (2021) yang menunjukkan bahwa *association rule* dalam *Market Basket Analysis* dapat digunakan untuk memahami pola pembelian pelanggan dan mendukung pengambilan keputusan bisnis, khususnya dalam pengelolaan produk dan strategi penjualan. Namun, konteks penelitian ini berbeda karena transaksi pada pusat kebugaran tidak selalu memuat banyak item seperti transaksi pada sektor ritel umum. Oleh karena itu, nilai *support* yang relatif kecil pada penelitian ini masih dapat dipahami sebagai pola spesifik pada segmen transaksi tertentu, bukan sebagai pola dominan seluruh transaksi.

Hasil penelitian ini juga sejalan dengan Miranda et al. (2022) yang menerapkan algoritma Apriori untuk menganalisis data transaksi penjualan dan menghasilkan aturan asosiasi berdasarkan nilai *support* dan *confidence*. Perbedaannya, penelitian Miranda et al. dilakukan pada data penjualan hampers, sedangkan penelitian ini dilakukan pada transaksi pusat kebugaran yang terdiri atas layanan kunjungan, keanggotaan, minuman, dan produk pendukung olahraga. Perbedaan karakteristik transaksi tersebut memengaruhi bentuk aturan asosiasi yang dihasilkan.

Temuan ini memberikan implikasi manajerial bagi FORZA GYM Babarsari, terutama dalam penyusunan strategi penjualan. Produk yang memiliki hubungan pembelian kuat dapat ditempatkan berdekatan, dipromosikan dalam bentuk paket *bundling*, atau diberikan promosi kombinasi agar nilai transaksi pelanggan meningkat. Strategi ini lebih berbasis data dibandingkan promosi umum karena didasarkan pada pola transaksi aktual pelanggan.

Jika dibandingkan dengan Wildan et al. (2025), penelitian ini memiliki kesamaan dalam penggunaan dua pendekatan analitik, yaitu ARIMA dan *Market Basket Analysis*. Namun, fokus penerapannya berbeda. Wildan et al. menggunakan *Market Basket Analysis* untuk rekomendasi paket produk dan ARIMA untuk memprediksi produk dengan penjualan

tertinggi pada konteks ritel elektronik. Sementara itu, penelitian ini menggunakan ARIMA untuk meramalkan jumlah kunjungan anggota dan *Market Basket Analysis* untuk mengidentifikasi pola pembelian pelanggan pada sektor jasa kebugaran. Dengan demikian, kontribusi penelitian ini terletak pada penerapan dua metode analitik secara komplementer untuk mendukung keputusan operasional dan pemasaran pada pusat kebugaran.

Secara keseluruhan, *Market Basket Analysis* dalam penelitian ini menunjukkan bahwa data transaksi penjualan dapat dimanfaatkan untuk memahami perilaku pelanggan secara lebih mendalam. Dengan memanfaatkan pola transaksi penjualan yang merepresentasikan kecenderungan pembelian pelanggan tersebut, FORZA GYM Babarsari dapat meningkatkan efisiensi pemasaran, penataan produk, dan potensi pendapatan tambahan dari sektor penjualan.

Berdasarkan hasil pembahasan tersebut, tujuan penelitian telah terjawab melalui dua proses analisis yang dilakukan secara terpisah. Tujuan pertama, yaitu melakukan peramalan jumlah kunjungan anggota FORZA GYM Babarsari, terjawab melalui penerapan metode ARIMA yang menghasilkan model terbaik ARIMA(1,0,5), evaluasi akurasi model, serta hasil *forecasting* jumlah kunjungan 1–7 hari ke depan. Tujuan kedua, yaitu mengidentifikasi pola penjualan berdasarkan transaksi pelanggan, terjawab melalui penerapan *Market Basket Analysis* yang menghasilkan *frequent itemset*, *association rule*, dan *strong rules*. Dengan demikian, hasil penelitian ini menunjukkan bahwa ARIMA dapat digunakan untuk mendukung aspek operasional melalui peramalan kunjungan, sedangkan *Market Basket Analysis* dapat digunakan untuk mendukung aspek pemasaran melalui analisis pola transaksi penjualan.

BAB V PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan terhadap data kunjungan anggota dan transaksi penjualan di FORZA GYM Babarsari, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Metode ARIMA dapat digunakan untuk melakukan peramalan jumlah kunjungan anggota FORZA GYM Babarsari dalam jangka pendek. Model terbaik yang diperoleh adalah ARIMA(1,0,5) dengan nilai AICc terendah sebesar 3010,737. Data kunjungan anggota telah stasioner pada orde *differencing* $d = 0$, sehingga tidak memerlukan proses *differencing* tambahan. Hasil evaluasi akurasi menunjukkan nilai MAE sebesar 9,317, RMSE sebesar 12,168, dan MAPE sebesar 37,775%. Hasil *forecasting* 1–7 hari ke depan menunjukkan jumlah kunjungan berada pada kisaran 24 hingga 29 kunjungan per hari. Informasi ini dapat digunakan sebagai dasar pendukung dalam perencanaan operasional jangka pendek, seperti penjadwalan staf, kesiapan fasilitas, dan pengadaan produk penjualan.
2. Metode *Market Basket Analysis* dapat digunakan untuk mengidentifikasi pola penjualan berdasarkan transaksi pelanggan FORZA GYM Babarsari. Hasil *frequent itemset* menunjukkan bahwa transaksi didominasi oleh produk minuman, layanan kunjungan, dan layanan keanggotaan. Item dengan frekuensi transaksi tertinggi adalah aqua 600ml, visit, dan aqua 1,5l. Pada tahap *association rule*, diperoleh tiga aturan asosiasi yang memenuhi kriteria *support*, *confidence*, dan *lift*. Aturan terkuat adalah kombinasi pembelian susu whey dan visit yang diikuti pembelian aqua 600ml, dengan nilai *confidence* sebesar 0,5833 dan *lift* sebesar 2,5541. Hasil ini menunjukkan adanya hubungan positif antara layanan kunjungan, produk suplemen, dan produk minuman dalam transaksi pelanggan.
1. Secara keseluruhan, ARIMA dan *Market Basket Analysis* dapat digunakan sebagai dua pendekatan analisis yang saling melengkapi, tetapi tetap dilakukan secara terpisah sesuai karakteristik data. ARIMA mendukung aspek operasional melalui peramalan jumlah kunjungan anggota, sedangkan *Market Basket Analysis* mendukung aspek pemasaran melalui identifikasi pola transaksi penjualan. Dengan demikian, hasil penelitian ini dapat menjadi dasar pengambilan keputusan berbasis data pada FORZA GYM Babarsari.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya maupun implementasi di FORZA GYM Babarsari:

1. Penelitian selanjutnya disarankan untuk menggunakan metode yang lebih kompleks seperti SARIMA atau model berbasis *machine learning* untuk

menangkap pola musiman maupun faktor eksternal yang tidak terakomodasi dalam model ARIMA.

2. Disarankan untuk penambahan variabel eksternal dalam analisis, faktor seperti hari libur, promosi, cuaca, atau *event* tertentu dapat dipertimbangkan dalam model agar hasil peramalan menjadi lebih akurat.
3. Disarankan untuk melakukan peningkatan kualitas dan kelengkapan data. Data yang lebih panjang dan konsisten akan membantu meningkatkan performa model serta menghasilkan analisis yang lebih akurat.
4. Hasil *Market Basket Analysis* dapat dimanfaatkan lebih lanjut untuk membuat strategi *bundling* produk, promosi paket, serta penempatan produk yang lebih baik di area penjualan.
5. FORZA GYM Babarsari disarankan untuk mengimplementasikan sistem analitik secara rutin agar pengambilan keputusan dapat dilakukan secara berbasis data dan lebih adaptif terhadap perubahan perilaku pelanggan.

DAFTAR PUSTAKA

- Ahaggach, H., Abrouk, L., & Lebon, E. (2024). Systematic mapping study of sales forecasting: Methods, trends, and future directions. *Forecasting*, 6, 502–532. <https://doi.org/10.3390/forecast6030028>
- Alfitra, D., Afdal, M., Fronita, M., & Saputra, E. (2024). Analisa keranjang belanja untuk menentukan tata letak barang menggunakan algoritma FP-Growth. *Sistemasi: Jurnal Sistem Informasi*, 13(4), 1651–1661.
- Amalia, E. L., Pramudhita, A. N., & Priambudi, M. H. I. (2020). Sistem informasi peramalan jumlah pengunjung menggunakan metode double exponential smoothing: Studi kasus Body Gym Kota Malang. *JIP (Jurnal Informatika Polinema)*, 7(1), 23–28.
- Amelia, R., Darmansyah, & Rismadin, A. M. (2024). Perbandingan algoritma Apriori dan FP-Growth dalam pengaplikasian market basket analysis untuk strategi bisnis retail. *Building of Informatics, Technology and Science (BITS)*, 6(1), 279–288. <https://doi.org/10.47065/bits.v6i1.5388>
- Awad, I. M., & Al Karaki, M. S. (2019). The impact of bank lending on Palestine economic growth: An econometric analysis of time series data. *Financial Innovation*, 5, Article 14. <https://doi.org/10.1186/s40854-019-0130-8>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5th ed.). Wiley.
- Dwiputra, D., Widodo, A. M., Akbar, H., & Firmansyah, G. (2023). Evaluating the performance of association rules in Apriori and FP-Growth algorithms: Market basket analysis to discover rules of item combinations. *Journal of World Science*, 2(8), 1229–1248.
- Fahmuddin, M., Ruliana, & Mustika, S. S. M. (2023). Perbandingan metode ARIMA dan single exponential smoothing dalam peramalan nilai ekspor kakao Indonesia. *VARLANSI: Journal of Statistics and Its Application on Teaching and Research*, 5(3), 163–176. <https://doi.org/10.35580/variansiunm193>
- Fahrudin, N. F. (2019). Penerapan algoritma Apriori untuk market basket analysis. *MIND Journal*, 4(1), 1–11. <https://doi.org/10.26760/mindjournal>
- Friscintia, P. B. A., & Alamsyah, A. (2019). Indonesian tourism demand forecasting using time series approach to support decision making process. *KINERJA*, 23(2), 69–80.
- Handika, I. P. S., & Satwika, I. K. S. (2024). Perbandingan kinerja algoritma Apriori dan Equivalence Class Transformation (ECLAT) dalam menemukan pola pembelian pada data transaksi minimarket. *Jurnal Ilmiah NERO*, 9(2), 149–159.
- Hewamalage, H., Ackermann, K., & Bergmeir, C. (2023). Forecast evaluation for data scientists: Common pitfalls and best practices. *Data Mining and Knowledge Discovery*, 37, 788–832. <https://doi.org/10.1007/s10618-022-00894-5>
- Jekauc, D., Völkle, M., Wagner, M. O., Mess, F., Reiner, M., & Renner, B. (2015). Prediction of attendance at fitness center: A comparison between the theory of planned behavior, the social cognitive theory, and the physical activity maintenance theory. *Frontiers in Psychology*, 6, Article 121. <https://doi.org/10.3389/fpsyg.2015.00121>

- Kashiwagi, F. N., Michalski, M. A. d. C., de Souza, G. F. M., da Silva, H. J. B., & Côrtes, H. M. (2025). Probabilistic prognostics and health management of power transformers using dissolved gas analysis sensor data and Duval's polygons. *Sensors*, 25, 6520. <https://doi.org/10.3390/s25216520>
- Kotler, P., & Armstrong, G. (2003). *Principles of marketing* (10th ed.). Pearson Education.
- Lovelock, C. H., Vandermerwe, S., Lewis, B., & Fernie, S. (2004). *Services marketing*. Edinburgh Business School, Heriot-Watt University.
- Luo, L., Zhang, X., & He, X. (2017). Hospital daily outpatient visits forecasting using a combinatorial model based on ARIMA and SES models. *BMC Health Services Research*, 17, Article 469. <https://doi.org/10.1186/s12913-017-2407-9>
- Martínez, M., Escobar, B., García-Díaz, M. E., & Pinto-Roa, D. P. (2021). Market basket analysis with association rules in the retail sector using Orange: Case study: Appliances sales company. *CLEI Electronic Journal*, 24(2), Article 12.
- Miranda, P., Siregar, D., & Lestari, N. (2025). Comparative performance of ARIMA and SARIMA models in seasonal and non-seasonal forecasting data. *European Journal of Engineering Science and Emerging Technology*, 6(1), 22–31.
- Miranda, S. A., Fahrullah, & Kurniawan, D. (2022). Implementasi association rule dalam menganalisis data penjualan Sheshop dengan menggunakan algoritma Apriori. *METIK Jurnal*, 6(1), 30–36. <https://doi.org/10.47002/rmetik.v6i1.342>
- Murat, A., Celik, O., & Yildiz, K. (2018). Forecasting daily meteorological time series using ARIMA and regression models. *Journal of Applied Meteorology Research*, 12(3), 45–58.
- Nugraha, R., & Agussalim, A. (2024). Time series analysis for electricity demand forecasting: A comparative study of ARIMA and exponential smoothing models in Indonesia. *Journal of Energy Forecasting and Analytics*, 8(2), 101–115.
- Pitka, T., Bucko, J., Krajči, S., Krídlo, O., Guniš, J., Šnajder, L., Antoni, L., & Eliaš, P. (2025). Time analysis of online consumer behavior by decision trees, GUHA association rules, and formal concept analysis. *Journal of Marketing Analytics*, 13, 29–52. <https://doi.org/10.1057/s41270-023-00274-y>
- Rachmawati, D., Cahyana, Y., Awal, E. E., & Faisal, S. (2024). Perbandingan algoritma Apriori dan algoritma FP-Growth dalam menentukan pola penjualan pupuk. *RESISTOR Journal*, 3(1).
- Ramadhani, A., Wahyuningsih, S., & Siringoringo, M. (2022). Peramalan jumlah kunjungan wisatawan mancanegara ke Indonesia menggunakan autoregressive integrated moving average (ARIMA). *Jurnal Eksponensial*, 13(2), 103–110.
- Saad, F. S., Azizah, N., & Yani, Z. (2025). Penerapan algoritma Apriori untuk menentukan pola permintaan bahan makanan berdasarkan data transaksi. *Jurnal Pustaka AI (Pusat Akses Kajian Teknologi Artificial Intelligence)*, 5(2), 388–397. <https://doi.org/10.55382/jurnalpustakaai.v5i2.1181>
- Safitri, P. N. (2022). *Analisis strategi penjualan produk menggunakan association rule dengan algoritma Apriori: Studi kasus penjualan produk Pamela Satu Supermarket*. Tugas Akhir, Program Studi Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Islam Indonesia.

- Shamsuzzoha, A., Viitanen, J., Piya, S., Khadem, M., & Shamsuzzaman, M. (2025). Forecasting financial services of a call center's inbound volumes: A case study. *International Journal of Engineering Business Management*, 17, 1–14. <https://doi.org/10.1177/18479790251367821>
- Suprayogi, & Karima, A. (2019). Implementasi algoritma Apriori dengan market basket analysis untuk pengaturan tata letak produk. *Jurnal Teknik Informatika*, 9(2), 169–179.
- Susanto, J., & Fenriana, I. (2024). Web-based POS with Apriori market basket analysis. *Bit-Tech (Binary Digital - Technology)*, 6(3), 271–280. <https://doi.org/10.32877/bt.v6i3.926>
- Tan, P.-N., Steinbach, M., & Kumar, V. (2006). *Introduction to data mining*. Pearson Addison-Wesley.
- Widiyanesti, S., Hakim, M. N., Syamsiyah, N., & Dirohmat, Y. M. (2025). Enhancing retail store layout for impulsive buying using market basket analysis and the Apriori algorithm. *Khazanah Informatika*, 11(1).
- Wildan, M., Hentihu, M. T. R., & Jayadi, R. (2025). Market basket and time series analysis: Case study PT XYZ sales data. *Cerdika: Jurnal Ilmiah Indonesia*, 5(2), 490–501. <http://cerdika.publikasiindonesia.id/index.php/cerdika>
- Yalçın, S. E. (2024). Development of a forecasting framework based on advanced machine learning algorithms for greenhouse gas emissions. *Systems*, 12(12), 528. <https://doi.org/10.3390/systems12120528>